Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

PDFMEF: για επιστημονικά έγγραφα και σημασιολογική αναζήτηση

Jian Wu[†] , Jason Killian[‡] , Huaiyu Yang[†] , Kyle Williams[†] , Sagnik Ray Choudhury[†] , Suppawong Tuarob[‡] , Cornelia Caragea[*] , C. Lee Giles[†‡]
[†]Επιστήμες και Τεχνολογία της Πληροφορίας
[‡]Computer Science and Engineering
Pennsylvania State University, University Park, PA, 16802 USA
[*]Computer Science and Engineering, University of North Texas, Denton, TX, 76203 USA

ΠΕΡΙΛΗΨΗ

Παρουσιάζουμε το PDFMEF, ένα πλαίσιο εξαγωγής γνώσης πολλαπλών οντοτήτων για επιστημονικά έγγραφα σε μορφή PDF. Υλοποιείται με ένα πλαίσιο που ενσωματώνει εργαλεία εξαγωγής ανοικτού κώδικα. Επί του παρόντος, αξιοποιεί το PDFBox και το TET για την εξαγωγή πλήρους κειμένου, το φίλτρο επιστημονικών εγγράφων που περιγράφεται στο [5] για την ταξινόμηση εγγράφων, το GROBID για την εξαγωγή κεφαλίδων, το ParsCit για την εξαγωγή παραπομπών, το PDFFig- ures για την εξαγωγή εικόνων και πινάκων και την εξαγωγή αλγορίθμων [27]. Ενώ μπορεί να εκτελεστεί ως σύνολο, το εργαλείο εξαγωγής σε κάθε ενότητα είναι ιδιαίτερα προσαρμόσιμο. Οι χρήστες μπορούν να αντικαταστήσουν τους προεπιλεγμένους εκχυλιστές με άλλα εργαλεία εξαγωγής που προτιμούν, γράφοντας ένα λεπτό περιτύλιγμα για την υλοποίηση των περιλήψεων. Το πλαίσιο έχει σχεδιαστεί για να είναι κλιμακούμενο και είναι ικανό να εκτελείται παράλληλα χρησιμοποιώντας μια τεχνική πολλαπλής επεξεργασίας στην Python. Τα πειράματα δείχνουν ότι το σύστημα με τις προεπιλεγμένες ρυθμίσεις είναι περιορισμένο στην KME και αφήνει μικρό αποτύπωμα στη μνήμη, γεγονός που το καθιστά καλύτερο να εκτελείται σε πολυπύρηνο μηχάνημα. Η καλύτερη απόδοση με τη χρήση ενός αποκλειστικού διακομιστή 16 πυρήνων απαιτεί κατά μέσο όρο 1,3 δευτερόλεπτα για την επεξεργασία ενός εγγράφου PDF. Χρησιμοποιείται για να ευρετηριάζει τις εξαγόμενες πληροφορίες και να βοηθά τους χρήστες να εντοπίζουν γρήγορα τα σχετικά αποτελέσματα σε δημοσιευμένα επιστημονικά έγγραφα και να κατασκευάζουν αποτελεσματικά μια μεγάλη βάση γνώσης προκειμένου να δημιουργηθεί μια σημασιολογική μηχανή επιστημονικής αναζήτησης. Μέρος της εκτελείται στη μηχανή αναζήτησης της ψηφιακής βιβλιοθήκης CiteSeerX.

Κατηγορίες και θεματικοί περιγραφείς

H.3.3 [**Αναζήτηση και ανάκτηση πληροφοριών**]: [H.3.7 [**Ψηφιακές Βιβλιοθήκες**]: [H.3.4 [**Συστήματα και λογισμικό**]: [Αξιολόγηση επιδόσεων (αποδοτικότητα και αποτελεσματικότητα)]

Γενικοί όροι

εξαγωγή μεταδεδομένων

1. ΕΙΣΑΓΩΓΗ

Επιτρέπεται η δημιουργία ψηφιακών ή έντυπων αντιγράφων του συνόλου ή μέρους αυτού του έργου για προσωπική ή διδακτική χρήση, χωρίς αμοιβή, υπό την προϋπόθεση ότι τα αντίγραφα δεν θα δημιουργηθούν ή διανεμηθούν με σκοπό το κέρδος ή το εμπορικό όφελος και ότι τα αντίγραφα θα φέρουν την παρούσα ειδοποίηση και την πλήρη αναφορά στην πρώτη σελίδα. Πρέπει να τηρούνται τα πνευματικά δικαιώματα για τα στοιχεία αυτού του έργου που ανήκουν σε άλλους εκτός του/των συγγραφέα/ων. Επιτρέπεται η περίληψη με αναφορά. Για την αντιγραφή με άλλο τρόπο, ή την αναδημοσίευση, την ανάρτηση σε διακομιστές ή την αναδιανομή σε καταλόγους, απαιτείται προηγούμενη ειδική άδεια ή/και αμοιβή. Ζητήστε άδειες από τη διεύθυνση Permissions@acm.org.
K-CAP 2015, 07 - 10 Οκτωβρίου 2015, Palisades, NY, ΗΠΑ
Τα πνευματικά δικαιώματα ανήκουν στον ιδιοκτήτη/συγγραφέα. Τα δικαιώματα δημοσίευσης παραχωρήθηκαν στην ACM. ACM 978-1-4503-3849-3/15/10$15.00
DOI: http://dx.doi.org/10.1145/2815833.2815834.

Οι ψηφιακές βιβλιοθήκες έχουν αλλάξει εντελώς τον τρόπο με τον οποίο οι χρήστες αναζητούν σχετικές εργασίες σε όλους σχεδόν τους τομείς της γνώσης. Το 2014 εκτιμήθηκε ότι ο συνολικός αριθμός επιστημονικών άρθρων στο διαδίκτυο στην αγγλική γλώσσα ήταν τουλάχιστον 114 εκατομμύρια [19]. Με την πρωτοφανή αύξηση της δημοσίευσης εργασιών [20], οι συγγραφείς δυσκολεύονται να διαβάσουν όλες τις σχετικές εργασίες προκειμένου να εντοπίσουν χρήσιμα αποτελέσματα. Σε ορισμένες περιπτώσεις, ένας συγγραφέας παραθέτει μια εργασία μόνο και μόνο επειδή τον ενδιαφέρει μια συγκεκριμένη *οντότητα*, όπως το συμπέρασμα, μια προσέγγιση, ένας πίνακας αποτελεσμάτων ή/και ένα σχήμα. Η ύπαρξη μιας επιστημονικής μηχανής αναζήτησης που μπορεί να αξιοποιήσει αυτές τις οντότητες θα βοηθούσε σε μια τέτοια αναζήτηση και θα μπορούσε να αποτελέσει τη βάση μιας σημασιολογικής επιστημονικής μηχανής αναζήτησης.

Γενικά, ένα επιστημονικό έγγραφο αποτελείται από αρκετές από αυτές τις οντότητες, αν όχι όλες: επικεφαλίδα, σώμα κειμένου, βιβλιογραφία, σχήματα, πίνακες, μαθηματικά και αλγόριθμους (ακόμη και χημικές φόρμες [26]). Η επικεφαλίδα περικλείει έναν τίτλο, ονόματα συγγραφέων, συνδέσεις συγγραφέων, ηλεκτρονικά μηνύματα συγγραφέων, μια περίληψη, ένα έτος δημοσίευσης, έναν τόπο διεξαγωγής (πρακτικά συνεδρίων ή περιοδικά), έναν αριθμό τόμου, σελίδες ή/και σειρές. Το σώμα κειμένου περιέχει όλο το περιγραφικό κείμενο, συμπεριλαμβανομένων των χαρακτήρων ASCII και μη ASCII. Η βιβλιογραφία είναι ένας κατάλογος δημοσιεύσεων που παρατίθενται από την τρέχουσα εργασία, ο οποίος εμφανίζεται συνήθως στο τέλος ενός επιστημονικού εγγράφου και μπορεί να ονομάζεται "βιβλιογραφία", "αναφορές" ή ακόμη και "σημειώσεις". Τα σχήματα είναι πολύ επεξηγηματικές οντότητες που χρησιμοποιούνται για την παρουσίαση αποτελεσμάτων με συγκεκριμένες τάσεις και χρησιμοποιούνται συχνότερα στις σύγχρονες εργασίες. Οι πίνακες είναι αποτελεσματικοί στην παρουσίαση δομημένων δεδομένων, όπως τα πειραματικά αποτελέσματα. Οι αλγόριθμοι, συνήθως εκφρασμένοι σε ψευδοκώδικες, είναι αποτελεσματικοί για την παρουσίαση ενός τρόπου επίλυσης ενός υπολογιστικού προβλήματος. Τα μαθηματικά εμφανίζονται ως εξισώσεις. Οι αλγόριθμοι δεν εμφανίζονται μόνο σε έγγραφα της επιστήμης των υπολογιστών, αλλά και σε άλλους επιστημονικούς τομείς, όπως η μαθηματική και η φυσική. Στόχος μας είναι να κατασκευάσουμε μια βάση γνώσης για κάθε επιστημονικό έγγραφο, η οποία στη συνέχεια μπορεί να κωδικοποιηθεί σε μια οντολογία επιστημονικών εγγράφων.

Έχει καταβληθεί μεγάλη προσπάθεια στην ανάπτυξη μεθόδων για την εξαγωγή συγκεκριμένων οντοτήτων από επιστημονικά έγγραφα. Για παράδειγμα, το Apache PDFBox έχει χρησιμοποιηθεί ευρέως για την εξαγωγή κειμένου και χαρακτηριστικών εγγράφων PDF. Παρόμοια εργαλεία είναι το Poppler [2] και το PDFLib TET [1]. Στις ψηφιακές βιβλιοθήκες που βασίζονται στην ανίχνευση, ο τίτλος και οι συγγραφείς είναι σημαντικοί για την ταξινόμηση σχεδόν διπλών εγγράφων με βάση την υπόθεση ότι κανένα ή πολύ λίγα ερευνητικά έγγραφα δεν έχουν ακριβώς τον ίδιο τίτλο και συγγραφείς. Οι υπάρχοντες αναλυτές κεφαλίδων ανοικτού κώδικα περιλαμβάνουν τους SVMHeaderParse [18] και GROBID [24]. Υπάρχουν βιβλιογραφικοί αναλυτές όπως ο ParsCit [13] (ο GROBID αναλύει και τις παραπομπές). Τα υπάρχοντα εργαλεία εξαγωγής πινάκων περιλαμβάνουν το Tabula

[3], αυτόματοι εξαγωγείς πινάκων [22] και PDFFigures [9]. Ένα εργαλείο εξαγωγής εικόνων [7] έχει αναπτυχθεί για γενικά ακαδημαϊκά έγγραφα και για λεζάντες και εικόνες σε βιοϊατρικά έγγραφα PDF [23]. Έχει αναπτυχθεί ένα εργαλείο εξαγωγής αλγορίθμων [27]. Επιπλέον, μια μηχανή αναζήτησης ψηφιακών βιβλιοθηκών με βάση την ανίχνευση πρέπει να φιλτράρει τα επιστρεφόμενα έγγραφα ταξινομώντας τα ως επιστημονικά ή μη [5].

Ενώ υπάρχουν πολλά υπάρχοντα εργαλεία για την εξαγωγή *σημασιολογικών* οντοτήτων, δεν έχει προταθεί ένα πλαίσιο που να τα ενσωματώνει όλα μαζί. Η αρχιτεκτονική διαχείρισης μη δομημένων πληροφοριών (UIMA) παρέχει ένα πλαίσιο για την ανάλυση κειμένου με βάση το κείμενο, μετατρέποντας μη δομημένα δεδομένα σε δομημένα δεδομένα [16]. Ωστόσο, επικεντρώνεται στην εξόρυξη κειμένου, όπως η ανάλυση αρχείων καταγραφής και κλινικών σημειώσεων, μέσω αυτόματων σχολιασμών. Το πλαίσιο εδώ αποσκοπεί στην αποτελεσματική ανά- σχηματισμό εξόρυξης πολλαπλών οντοτήτων με τη χρήση υπάρχοντος λογισμικού ανοικτού κώδικα, συμπεριλαμβανομένου, μεταξύ άλλων, απλού κειμένου, επικεφαλίδων, ci- tations, σχημάτων, πινάκων και αλγορίθμων. Αυτό το πλαίσιο έχει σχεδιαστεί ώστε να είναι αρθρωτό και επεκτάσιμο. Διαθέτει ενσωματωμένο wrap- pers για μια επιλογή εργαλείων εξαγωγής, όπως το PDFBox, αλλά άλλα μπορούν εύκολα να αντικατασταθούν, όπως ένα άλλο text extrac- tor, π.χ. το PDFLib TET, γράφοντας ένα απλό wrapper για την υλοποίηση της διεπαφής. Ο παραλληλισμός είναι επίσης παραμετροποιήσιμος καθορίζοντας τον αριθμό των ταυτόχρονων διεργασιών, επιτρέποντας στον κώδικα να επεξεργάζεται ένα μεγάλο σώμα επιστημονικών εγγράφων σε μια μηχανή πολλαπλών πυρήνων.

Η παρούσα εργασία είναι οργανωμένη με την ενότητα 2 να περιγράφει ένα τυπικό σύστημα εξαγωγής μεταδεδομένων του CiteSeerX, το οποίο απεικονίζει τις προκλήσεις και το σχεδιασμό του νέου πλαισίου εξαγωγής, συμπεριλαμβανομένων όλων των ενοτήτων και του τρόπου επιλογής και υλοποίησης ενός εργαλείου εξαγωγής. Στην Ενότητα 3, συζητάμε τις υλοποιήσεις του σχεδιασμού. Στην Ενότητα 4, εκτελούμε αυτό το πλαίσιο σε ένα τυχαίο δείγμα δεδομένων και παρουσιάζουμε την απόδοσή του. Η ενότητα 5 περιγράφει εφαρμογές που θα μπορούσαν ενδεχομένως να χρησιμοποιήσουν το πλαίσιο. Η ενότητα 6 συνοψίζει και συζητά μελλοντικές εργασίες.

2. ΣΧΕΔΙΑΣΜΟΣ

2.1 Τρέχων σχεδιασμός

Το σύστημα εξαγωγής μεταδεδομένων του CiteSeerX περιλαμβάνει τις ακόλουθες ενότητες: εξαγωγή κειμένου, φίλτρο ακαδημαϊκών εγγράφων, εξαγωγή παραπομπών και εξαγωγή επικεφαλίδων.Οι τέσσερις ενότητες είναι συγκεντρωμένες σε ένα σενάριο Perl, με ένα Java wrap- per. Το περιτύλιγμα ενεργεί σαν ένας αποστολέας εργασιών. Μόλις ξεκινήσει, δημιουργεί έναν φάκελο εργασίας και εκκινεί πολλαπλά νήματα, καθένα από τα οποία εργάζεται σε μια εργασία δέσμης, ανακτώντας έναν κατάλογο μη εξαχθέντων εγγράφων από τη βάση δεδομένων crawl και στη συνέχεια την επεξεργασία από το σενάριο Perl. Η μονάδα εξαγωγής κειμένου χρησιμοποιεί το PDFLib TET για την εξαγωγή απλού κειμένου- το φίλτρο ακαδημαϊκών εγγράφων υλοποιεί έναν ταξινομητή βασισμένο σε κανόνες, ο οποίος αναζητά λέξεις-κλειδιά/φράσεις, όπως "βιβλιογραφία", "αναφορές" και τις παραλλαγές τους από το πλήρες κείμενο [29]- η μονάδα εξαγωγής παραπομπών χρησιμοποιεί το *ParsCit* [13]- η μονάδα εξαγωγής κεφαλίδων χρησιμοποιεί το *SVMHeaderParse* (εφεξής SVMHP). Τόσο το ParsCit όσο και το SVMHP απαιτούν απλό κείμενο ως είσοδο. Η έξοδος του ParsCit και του SVMHP μεταγλωττίζονται περαιτέρω σε ένα ενιαίο αρχείο XML που χρησιμοποιείται για την εισαγωγή. Η εισαγωγή γεμίζει μια βάση δεδομένων παραγωγής με νέα μεταδεδομένα εγγράφων, προσθέτει έγγραφα σε ένα αποθετήριο παραγωγής και ευρετηριάζει πλήρες κείμενο. Η διαδικασία εξαγωγής έχει μια πολύ περιορισμένη λειτουργία καταγραφής. Η τρέχουσα μονάδα εξαγωγής έχει τα ακόλουθα μειονεκτήματα και περιορισμούς:

1. Το σενάριο Perl είναι δύσκολο να συντηρηθεί και έχει κακή μεταφερσιμότητα- η Python θα ήταν καλύτερη.

2. Παρόλο που το φίλτρο εγγράφων που βασίζεται σε κανόνες επιτυγχάνει γενικά υψηλή ακρίβεια 80%-90% [29], η ανάκληση είναι κάτω από 80%, υποδεικνύοντας ότι χάνει ένα σημαντικό ποσοστό επιστημονικών εγγράφων. Ένας εξελιγμένος αλγόριθμος ταξινόμησης, όπως αυτός που αναπτύχθηκε από το [5] με βάση δομικά χαρακτηριστικά και μηχανική μάθηση με επίβλεψη, θα τα κατάφερνε καλύτερα.

3. Το SVMHP έχει αξιολογηθεί έναντι άλλων εργαλείων εξαγωγής κεφαλίδων [21] και τα αποτελέσματα δείχνουν ότι το GROBID [24] υπερτερεί έναντι άλλων ανταγωνιστών. Πραγματοποιείται μια εξαρτημένη αξιολόγηση για να επαληθευτεί η υπεραπόδοση εξαγωγής του GROBID (βλ. παρακάτω).

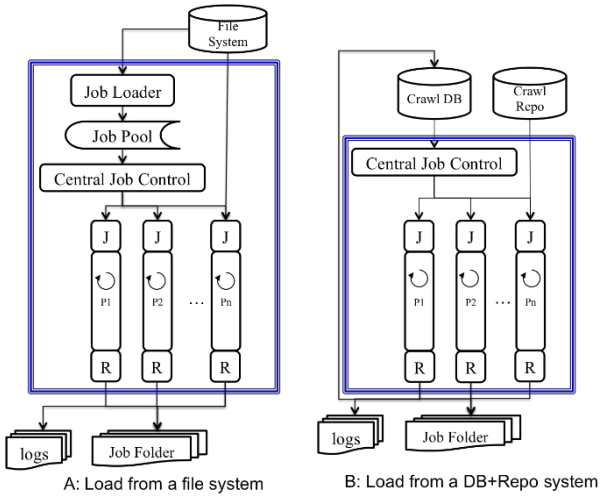
4. Η τρέχουσα εξαγωγή περιορίζεται σε περιεχόμενο κειμένου. Είναι επιθυμητή η ενσωμάτωση πολλαπλών εργαλείων εξαγωγής για σχήματα, πίνακες και αλγόριθμους.

5. Η τρέχουσα μονάδα εξαγωγής έχει περιορισμένη λειτουργία καταγραφής, καθιστώντας δύσκολη την ανίχνευση του λόγου που προκάλεσε μια αποτυχημένη εξαγωγή.

6. Ο τρέχων σχεδιασμός είναι βελτιστοποιημένος για τα TET, SVMHP και ParsCit, γεγονός που καθιστά δύσκολη τη μετάβαση σε άλλα εργαλεία εξαγωγής. Αυτός ο ad hoc σχεδιασμός περιορίζει σημαντικά τη δυνατότητα εφαρμογής του συστήματος εξαγωγής.

2.2 Νέος σχεδιασμός

Ο επανασχεδιασμός του πλαισίου εξαγωγής αντιμετωπίζει αρκετές δυσκολίες. Πρώτον, το πλαίσιο θα πρέπει να είναι εξαιρετικά φορητό και αρθρωτό, δηλαδή θα πρέπει να είναι σχετικά εύκολο να τοποθετηθεί ένα άλλο εργαλείο εξαγωγής στο πλαίσιο ή/και να συνδεθούν/αποσυνδεθούν μία ή περισσότερες ενότητες από το πλαίσιο, για παράδειγμα, να χρησιμοποιηθεί το TET για την εξαγωγή απλού κειμένου αντί του PDFBox ή να αφαιρεθεί το φίλτρο ακαδημαϊκών εγγράφων. Στις περισσότερες περιπτώσεις, αυτό απαιτεί την ανάπτυξη ενός "προσαρμογέα" ή ενός λεπτού περιτυλίγματος σε ένα συγκεκριμένο εργαλείο εξαγωγής, επειδή τα διάφορα εργαλεία είναι γραμμένα σε διαφορετικές γλώσσες προγραμματισμού, έχουν διαφορετικές απαιτήσεις εισόδου/εξόδου API, κ.λπ. Για να επιτευχθεί αυτό, το πλαίσιο θα πρέπει να ορίσει μια αφηρημένη διεπαφή για την υλοποίηση του περιτυλίγματος και η οποία να ασχολείται με την είσοδο, τα αρχεία εξόδου και την εκ νέου μετατροπή της τυπικής κατάστασης εξαγωγής. Συγκεκριμένα, το wrap- per πραγματοποιεί μια κλήση συστήματος για την εκτέλεση ενός API εφαρμογής (είτε ως γραμμή εντολών είτε ως υπηρεσία). Τα μηνύματα εξόδου και σφάλματος ανακτώνται και αναλύονται από το wrapper για τον προσδιορισμό της κατάστασης (επιτυχής ή αποτυχημένη), η οποία χρησιμοποιείται για τον έλεγχο της ροής εργασίας και την καταγραφή. Το χαρακτηριστικό pluggable απαιτεί έναν κεντρικό σχεδιασμό, έτσι ώστε μια αλλαγή μονάδας να απαιτεί ελάχιστη τροποποίηση του πηγαίου κώδικα ή των διαμορφώσεων. Δεύτερον, το de- sign θα πρέπει να λαμβάνει υπόψη τις πληροφορίες που μοιράζονται μεταξύ των ενοτήτων, ώστε να διασφαλίζεται ότι οι εξαρτήσεις δημιουργούνται πριν από τη χρήση τους και ότι το πλαίσιο δεν χάνει χρόνο για την επανάληψη κάποιου φόρτου εργασίας σε πολλαπλές ενότητες. Αυτό απαιτεί να ορίσουμε τις απαιτούμενες και τις προαιρετικές ενότητες και να τις οργανώσουμε με μια συγκεκριμένη σειρά. Για παράδειγμα, ενώ το GROBID δέχεται ένα αρχείο PDF ως είσοδο, άλλα εργαλεία εξαγωγής κεφαλίδων δέχονται ένα απλό κείμενο. Επειδή το πλήρες κείμενο αποτελεί προϋπόθεση για πολλά εργαλεία εξαγωγής, το πλαίσιο εξ ορισμού εξάγει πάντα το πλήρες κείμενο στην πρώτη θέση. Ένα άλλο παράδειγμα είναι ότι εάν το GROBID χρησιμοποιείται τόσο για την εξαγωγή κεφαλίδων όσο και για την εξαγωγή παραπομπών, χρειάζεται να εκτελεστεί μόνο μία φορά κατά την εξαγωγή κεφαλίδων και η μονάδα εξαγωγής παραπομπών μπορεί να εργαστεί απευθείας στην έξοδό του TEI. Τρίτον, η



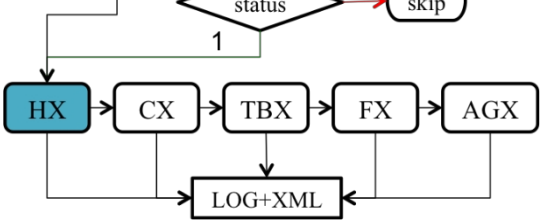
Σχήμα 1: Προτεινόμενη αρχιτεκτονική. Το "P_i" αντιπροσωπεύει τη μεμονωμένη διεργασία. Τα μπλε κουτιά περικλείουν τα πλαίσια.

πλαίσιο πρέπει να χειρίζεται κατάλληλα τις εξαιρέσεις από διαφορετικά εργαλεία εξαγωγής και τα αποτελέσματά τους. Για παράδειγμα, αν το πλήρες κείμενο περιέχει μηδενική γραμμή, αντιμετωπίζεται ως αποτυχία εξαγωγής, ακόμη και αν δημιουργείται ένα κενό αρχείο κειμένου.

Ο σχεδιασμός υψηλού επιπέδου του προτεινόμενου πλαισίου απεικονίζεται στο Σχήμα 1. Τα A και B είναι πολύ παρόμοια, εκτός από το ότι υποστηρίζουν διαφορετικούς τρόπους εισόδου. Στον τρόπο λειτουργίας A, ο *Job Loader* φορτώνει έγγραφα απευθείας από το σύστημα αρχείων, δηλαδή έναν φάκελο που περιέχει έγγραφα PDF προς εξαγωγή. Αυτός είναι ένας βολικός τρόπος για την εκτέλεση μιας εργασίας ομαδικής εξαγωγής χωρίς τη ρύθμιση της βάσης δεδομένων και του αποθετηρίου crawl. Στη συνέχεια, ο *Job Loader* δημιουργεί ένα *Job Pool*, το οποίο λειτουργεί σαν σύνολο ή λεξικό με διαδρομές εγγράφων (ή παράγωγα ισοδύναμα) ως κλειδιά. Κάθε διαδικασία έχει ένα *Job Controller* ("J") και τελειώνει με ένα *Job Cleaner* ("R"), το οποίο καθαρίζει τα προσωρινά αρχεία, ενσωματώνει τα αποτελέσματα της εξαγωγής και γράφει την κατάσταση της εξαγωγής σε αρχεία καταγραφής. Το mod- ule "J" ενεργοποιεί και απενεργοποιεί τη διαδικασία. Το *Central Job Control* λειτουργεί σαν ένας διοικητής, ο οποίος διαβάζει εξωτερικές εντολές, π.χ. μια εντολή διακοπής, από τους χρήστες ελέγχοντας περιοδικά τις ρυθμίσεις σε ένα αρχείο διαμόρφωσης. Στη συνέχεια, το σήμα διαβιβάζεται σε κάθε ελεγκτή εργασιών, ο οποίος σταματά τη λήψη νέων εγγράφων μετά την ολοκλήρωση της τρέχουσας λίστας εργασιών. Αυτή η λειτουργία *μαλακού τερματισμού* είναι ιδιαίτερα χρήσιμη όταν το πλαίσιο εκτελείται στη λειτουργία B, επειδή διατηρεί την ακεραιότητα των εργασιών εξαγωγής αποφεύγοντας την εξαγωγή μερικώς εξαχθέντων εγγράφων. Όταν το πλαίσιο τίθεται ξανά σε λειτουργία μετά από τερματισμό, δεν εκτελεί εκ νέου τα ίδια έγγραφα που είχε εκτελέσει προηγουμένως και δεν ασχολείται με έγγραφα που έχουν εξαχθεί εν μέρει χωρίς να έχει ενημερωθεί η κατάσταση στη βάση δεδομένων. Στη λειτουργία B, ο κατάλογος εγγράφων ανακτάται από τη βάση δεδομένων και ο καθαριστής εργασιών αναφέρει την κατάσταση εξαγωγής κάθε εγγράφου στη βάση δεδομένων.

Επειδή η εργασία στον τρόπο λειτουργίας B απαιτεί πρόσθετη κωδικοποίηση που εξαρτάται από συγκεκριμένα σχήματα βάσεων δεδομένων, εστιάζουμε στο σχεδιασμό και τα πειράματα στο ίδιο το πλαίσιο. Τα ερωτήματα στη βάση δεδομένων είναι συνήθως πολύ ταχύτερα από την εξαγωγή, οπότε γενικά δεν αποτελούν σημεία συμφόρησης.

Στο πλαίσιο εξαγωγής, κάθε διεργασία εκτελεί έναν αριθμό μονάδων εξαγωγής (EM). Το τρέχον προεπιλεγμένο σετ



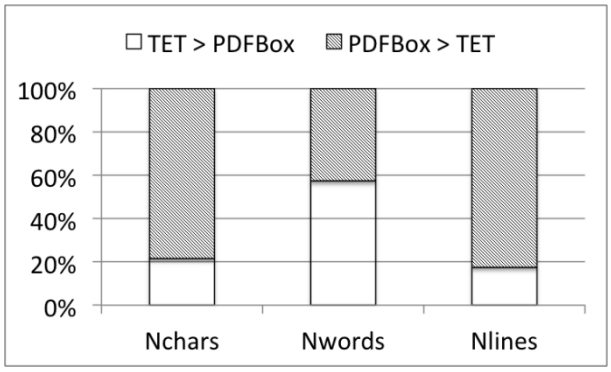
Σχήμα 2: Το διάγραμμα ροής PDFMEF.

Οι λειτουργίες περιλαμβάνουν μια μονάδα εξαγωγής κειμένου (TX), ένα φίλτρο επιστημονικών εγγράφων (SDF), μια μονάδα εξαγωγής επικεφαλίδων (HX), μια μονάδα εξαγωγής πληροφοριών (CX), μια μονάδα εξαγωγής πινάκων (TBX), μια μονάδα εξαγωγής εικόνων (FX) και μια μονάδα εξαγωγής αλγορίθμων (AGX). Εξετάζονται δύο επιλογές σχεδιασμού. Στην πρώτη επιλογή σχεδιασμού, *σε κάθε διεργασία*, τα ΕΜ διατάσσονται διαδοχικά, δηλαδή κάθε ΕΜ καλείται ένα μετά την ολοκλήρωση του προηγούμενου. Στη δεύτερη επιλογή σχεδιασμού, *εντός κάθε διεργασίας*, κάθε ΕΜ καλείται από ένα *υπονηματικό νήμα* και οι ΕΜ εκτελούνται παράλληλα. Επιλέγουμε την πρώτη. Αυτό συμβαίνει λόγω της σημαντικής χρονικής διαφοράς που κοστίζει η εκτέλεση διαφορετικών ΕΜ. Για παράδειγμα, ανάλογα με τον εκχυλιστή, η εξαγωγή παραπομπών μπορεί να είναι δέκα φορές πιο αργή από την εξαγωγή επικεφαλίδων (βλ. αποτελέσματα πειράματος παρακάτω). Εάν επιλέξουμε τη δεύτερη επιλογή σχεδιασμού, το υπονηματικό νήμα που εκτελεί την εξαγωγή επικεφαλίδων θα είναι αδρανές ενώ το υπονηματικό νήμα παραπομπών θα εργάζεται. Αντίθετα, η διαδοχική διάταξη χρησιμοποιεί τις CPU πιο αποτελεσματικά και είναι ευκολότερο να την επεκτείνουμε προσθέτοντας περισσότερους πυρήνες. Η διαδοχική διάταξη είναι επίσης ευκολότερη στην υλοποίηση, επειδή δεν χρειάζεται να αντιμετωπιστούν ζητήματα συγχρονισμού. Για παράδειγμα, καθώς η εξαγωγή πίνακα βασίζεται στο πλήρες κείμενο, πρέπει να παραμείνει σε αδράνεια μέχρι να εξαχθεί το πλήρες κείμενο. Το διάγραμμα ροής της διαδοχικής σχεδίασης απεικονίζεται στο Σχήμα 2 (ο ελεγκτής εργασιών και ο καθαριστής εργασιών δεν εμφανίζονται). Τα ΕΜ πλήρους κειμένου και επικεφαλίδας είναι υποχρεωτικά, τα άλλα ΕΜ είναι προαιρετικά. Στην επόμενη ενότητα, συζητάμε τα προεπιλεγμένα εργαλεία εξαγωγής για κάθε ΕΜ.

2.3 Εξαγωγή πλήρους κειμένου

Τα εμπορικά εργαλεία εξαγωγής κειμένου, όπως το PDFLib TET, πιστεύεται ότι έχουν καλύτερες επιδόσεις από το αντίστοιχο εργαλείο ανοικτού κώδικα, π.χ. το Apache PDFBox. Ωστόσο, και τα δύο βρίσκονται υπό ενεργή ανάπτυξη, οπότε είναι λογικό να τα αξιολογήσουμε με βάση τις τρέχουσες εκδόσεις τους.

Το δείγμα δοκιμής αποτελείται από 1000 έγγραφα PDF που επιλέχθηκαν τυχαία από τη βάση δεδομένων του CiteSeerX, οπότε το δείγμα περιέχει μη ακαδημαϊκά έγγραφα. Επειδή η δημιουργία μιας βασικής αλήθειας για την εξαγωγή κειμένου δεν είναι εφικτή



Σχήμα 3: TET vs. PDFBox για τον αριθμό των εξαγόμενων χαρακτήρων, λέξεων και γραμμών.

λόγω της εξαιρετικά περίπλοκης μορφοποίησης των αρχείων PDF και της έλλειψης τυποποιημένου σχήματος μετασχηματισμού από αρχεία PDF σε αρχεία κειμένου, πραγματοποιούμε μόνο *βασική* σύγκριση του ενός έναντι του άλλου. Για την παρούσα εργασία, συγκρίνουμε τον αριθμό των εξαγόμενων αρχείων PDF, τον αριθμό των γραμμών, των χαρακτήρων και των λέξεων για κάθε εξαγόμενο αρχείο PDF. Χρησιμοποιούμε τις πιο πρόσφατες εκδόσεις του TET (έκδοση 4.4) και του PDFBox (έκδοση 1.8.6) κατά τη στιγμή της συγγραφής. Στη συνέχεια, χρησιμοποιούμε την ενσωματωμένη στο Linux εντολή `WC` για να μετρήσουμε τις γραμμές, τους χαρακτήρες και τις λέξεις. Τα αποτελέσματα παρατίθενται σε πίνακες στον Πίνακα 1. Αυτός ο πίνακας υποδηλώνει ότι το PDFBox 1.8.6 έχει καλύτερη απόδοση όσον αφορά τον αριθμό των εξαγώγιμων αρχείων PDF, αν και υπάρχουν 40 αρχεία που κανένα από τα δύο δεν μπορεί να εξαγάγει. Στην πραγματικότητα, υπάρχει μόνο ένα αρχείο που μπορεί να εξάγεται από το TET αλλά δεν μπορεί να εξάγεται από το PDFBox, αλλά υπάρχουν 17 αρχεία κατά τα άλλα. Στο Σχήμα 3, συγκρίνουμε τον αριθμό των χαρακτήρων (Nchars), των λέξεων (Nwords) και των γραμμών (Nlines) των αρχείων που μπορούν να εξαχθούν *και* από *τα δύο*. Αυτό το διάγραμμα δείχνει ότι το PDFBox εξάγει περισσότερους χαρακτήρες και γραμμές από το TET, αλλά εξάγει λιγότερες λέξεις για τα περισσότερα έγγραφα. Λαμβάνοντας υπόψη τα τρέχοντα αποτελέσματα, είναι δύσκολο να συμπεράνουμε αν το TET ή το PDFBox μπορεί να νικήσει απόλυτα το άλλο. Εφαρμόζουμε και τα δύο στο πλαίσιο εργασίας. Επειδή το TET είναι λογισμικό επί πληρωμή και το PDFBox έχει δωρεάν άδεια χρήσης, θα πειραματιστούμε μόνο με το PDFBox.

Είτε το TET είτε το PDFBox μπορεί να εκτελεστεί με την εκκίνηση ενός
κλήση συστήματος. Ένα έγγραφο που εξάγεται επιτυχώς μεταβιβάζεται στο SDF. Διαφορετικά, απορρίπτεται και καταγράφεται.

Πίνακας 1: TET vs. PDFBox σε αρχεία που μπορούν να εξαχθούν.

		PDFBox Αποτυχία	PDFBox Επιτυχία	TET Συνολικά
TET	Επιτυχία	1	942	943
TET	Αποτυχία	40	17	57
PDFBox	Συνολικά	41	959	1000

Μια επιτυχής έξοδος εξαγωγής περιέχει τουλάχιστον μια γραμμή.

2.4 Φίλτρο ακαδημαϊκών εγγράφων

Ένας ταξινομητής βασισμένος σε κανόνες διακρίνει μεταξύ ακαδημαϊκών και μη ακαδημαϊκών εγγράφων εντοπίζοντας μοτίβα κειμένου όπως οι όροι "βιβλιογραφία" και "αναφορές" από το πλήρες κείμενο. Μια πιο εξελιγμένη προσέγγιση έχει αναπτυχθεί από το [5], η οποία βασίζεται σε ένα σύνολο δομικών χαρακτηριστικών χρησιμοποιώντας υπερ-

vised αλγόριθμοι μηχανικής μάθησης. Οι τέσσερις τύποι δομικών χαρακτηριστικών και τα παραδείγματα παρατίθενται στον πίνακα 2. Για να

Πίνακας 2: Παραδείγματα διαρθρωτικών χαρακτηριστικών. Ειδικά χαρακτηριστικά αρχείου

Μέγεθος αρχείου σε kilobytes- αριθμός σελίδας.
Ειδικά χαρακτηριστικά κειμένου
Μήκος εγγράφου σε χαρακτήρες, λέξεις και γραμμές- αναλογία μεταξύ αναφορών αναφοράς και tokens.
Ειδικά χαρακτηριστικά του τμήματος
Εμφάνιση των ονομάτων των τμημάτων, π.χ. περίληψη κ.λπ.
Χαρακτηριστικά περιεχομένου
Εμφάνιση του "αυτού του εγγράφου", του "αυτού του βιβλίου" κ.λπ.

να βελτιώσουμε την ποιότητα της ταξινόμησης, επανεκπαιδεύουμε τον ταξινομητή με ένα νέο δείγμα. Το νέο δείγμα επεκτείνει το δείγμα εκπαίδευσης που περιγράφηκε στο [5] προσθέτοντας 2.000+ χειροκίνητα επισημειωμένα έγγραφα που επιλέγονται τυχαία από το αποθετήριο περιήγησης μιας υπάρχουσας ψηφιακής βιβλιοθήκης. Συμπληρώνουμε επίσης το σύνολο του δείγματος με χειροκίνητα επιμελημένα σύνολα για διατριβές, βιογραφικά, διαφάνειες και βιβλία. Η επισήμανση πραγματοποιήθηκε από τρία άτομα σε εξάρτηση και επαληθεύτηκε από έναν εμπειρογνώμονα του τομέα. Τα αναθεωρημένα δεδομένα εκπαίδευσης αποδίδουν εξαιρετικά αποτελέσματα δοκιμών. Η ακρίβεια και η ανάκληση από 10πλές διασταυρούμενες επικυρώσεις είναι και οι δύο πάνω από 95%. Εξ όσων γνωρίζουμε, αυτή είναι η καλύτερη προσέγγιση ταξινόμησης για τον διαχωρισμό επιστημονικών εγγράφων από ένα σώμα εγγράφων PDF που έχουν ανιχνευθεί.

Για ένα δεδομένο έγγραφο, το φίλτρο λαμβάνει ως είσοδο το πλήρες κείμενο και το αρχείο PDF (το φίλτρο πρέπει να λάβει ορισμένα δομικά χαρακτηριστικά απευθείας από το αρχείο PDF) και εξάγει μια τιμή boolean.

2.5 Εξαγωγή κεφαλίδας

Στο [21], οι Lipinski et al. συγκρίνουν έναν κατάλογο εργαλείων εξαγωγής μεταδεδομένων για επιστημονικά έγγραφα PDF με βάση ένα δείγμα που επιλέχθηκε από την ψηφιακή βιβλιοθήκη του arXiv. Χρησιμοποιείται ένα σύστημα μερικής βαθμολογίας για την αξιολόγηση της απόδοσης των επιμέρους εργαλείων στα ακόλουθα πεδία μεταδεδομένων: τίτλος, συγγραφείς και περίληψη. Αξιολογούν επίσης τα επώνυμα των συγγραφέων και τις πληροφορίες για το έτος στο δεύτερο και τρίτο γύρο αξιολόγησης. Στην αξιολόγησή τους, το GROBID παρέχει τα καλύτερα αποτελέσματα, τα οποία υπερτερούν σημαντικά του SVMHP και άλλων ανταγωνιστών.

Εδώ, προσπαθούμε να επαληθεύσουμε το συμπέρασμα του [21] χρησιμοποιώντας ένα πιο ετερογενές δείγμα που επιλέχθηκε από το CiteSeerX. Στόχος είναι να διερευνήσουμε την *καλύτερη* απόδοση του GROBID έναντι του SVMHP. Το δείγμα αυτό αποτελείται από εργασίες των οποίων οι τίτλοι ή/και οι συγγραφείς εξήχθησαν λανθασμένα από το SVMHP και διορθώθηκαν από τους τελικούς χρήστες. Εξάγουμε χειροκίνητα τους τίτλους των εγγράφων και τους συγγραφείς ως βασική αλήθεια και εξάγουμε τους τίτλους και τους συγγραφείς χρησιμοποιώντας το GROBID. Στη συνέχεια, συγκρίνουμε τα μεταδεδομένα που εξάγονται αυτόματα με τη βασική αλήθεια. Επικεντρωνόμαστε στους τίτλους και τους συγγραφείς επειδή είναι τα πιο βασικά πεδία σε μια μηχανή αναζήτησης ψηφιακών βιβλιοθηκών που βασίζεται σε ερπυστρήσεις. Η αξιολόγηση πραγματοποιήθηκε από τρία άτομα ανεξάρτητα, καθένα από τα οποία συγκρίνει οπτικά τη βασική αλήθεια με τα αυτόματα εξαγόμενα μεταδεδομένα. Η μόνη κατευθυντήρια γραμμή σε αυτή τη μελέτη χρηστών είναι να είναι συνεπείς με τα δικά τους κριτήρια αξιολόγησης. Η εκ των υστέρων έρευνα δείχνει ότι οι εν λόγω χρήστες ακολουθούν γενικά δύο αρχές: (1) όλες οι λέξεις πρέπει να αναλύονται σωστά για να χαρακτηριστεί ορθή η εξαγωγή τίτλου, με εξαίρεση τα γράμματα με έμφαση ή τις ligatures- (2) όλοι οι συγγραφείς πρέπει να αναλύονται σωστά

ορθά για να χαρακτηριστεί ως σωστή εξαγωγή του συγγραφέα, με εξαίρεση τα γράμματα με έμφαση ή τις λιγγραφίες. Οι τελικές κρίσεις αναφέρονται βάσει της πλειοψηφίας για κάθε πεδίο. Στον πίνακα 3 παρουσιάζονται τα αποτελέσματα της αξιολόγησης. Τα αποτελέσματα είναι γενικά συμβατά με εκείνα του [21]. Δεδομένης της ετερογενούς ιδιότητας του δείγματός μας, είναι σαφές ότι το GROBID υπερτερεί σημαντικά του SVMHP τόσο όσον αφορά τους τίτλους όσο και τους συγγραφείς κατά τουλάχιστον 30% στο καλύτερο σενάριο.

Επειδή το δείγμα είναι προκατειλημμένο έναντι του SVMHP, τα αποτελέσματα στον πίνακα 3 αντιπροσωπεύουν την *καλύτερη* απόδοση του GROBID έναντι του SVMHP. Εμπειρικά, στις περισσότερες περιπτώσεις, το GROBID επιτυγχάνει συγκριτικά καλή ποιότητα όταν το SVMHP εξάγει καλά. Η συνολική απόδοση έναντι του SVMHP μας παρακινεί έντονα να χρησιμοποιήσουμε το GROBID για την εξαγωγή επικεφαλίδων ακαδημαϊκών εγγράφων.

Η εξαγωγή επικεφαλίδων εκτελείται μόνο σε ερευνητικά έγγραφα, οπότε το αντίστοιχο ΕΜ τοποθετείται μετά το SDF. Το GROBID μπορεί να εκτελεστεί είτε αυτόνομα είτε ως υπηρεσία. Το τελευταίο είναι πιο αποτελεσματικό επειδή φορτώνει τα απαιτούμενα αρχεία βιβλιοθήκης μόνο μία φορά. Το ΕΜ χειρίζεται κατάλληλα τα σφάλματα που εξάγονται από το GROBID, όπως π.χ. ότι η υπηρεσία δεν ανταποκρίνεται. Εκτελεί πρώτα το GROBID για να δημιουργήσει το αρχείο TEI [12] και στη συνέχεια εξάγει πεδία που αντιστοιχούν σε ένα προκαθορισμένο και προσαρμόσιμο σχήμα μεταδεδομένων σε ένα αρχείο XML.

Πίνακας 3: GROBID έναντι SVMHP.

Εξαγωγή τίτλου				
		GROBID Λανθασμένο	GROBID Σωστό	SVMHP Συνολικά %
SVMHP	Σωστό	5	43	65.7%
SVMHP	Λανθασμένο	24	1	34.3%
GROBID	Συνολικά%	8.2%	91.8%	100%
Εξαγωγή συγγραφέα				
		GROBID Λανθασμένο	GROBID Σωστό	SVMHP Συνολικά %
SVMHP	Σωστό	4	38	57.5%
SVMHP	Λανθασμένο	3	28	42.5%
GROBID	Συνολικά %	9.6%	90.4%	100%

2.6 Εξαγωγή παραπομπών

Το ParsCit είναι ένα εργαλείο εξαγωγής παραπομπών που αναπτύχθηκε από τον [13]. Δεδομένου ότι το GROBID αναλύει τις παραπομπές, πραγματοποιούμε μια *βασική* σύγκριση μεταξύ τους, εξετάζοντας τον αριθμό των στοιχείων αναφοράς που μπορούν να εξάγουν και την ποιότητα των τίτλων, των συγγραφέων και των ετών που εξάγονται. Αυτά τα τρία πεδία εμφανίζονται σχεδόν σε όλα τα στοιχεία αναφοράς, ανεξαρτήτως των εγγράφων συνεδρίων, των άρθρων περιοδικών ή των βιβλίων. Υπάρχουν λίγες εξαιρέσεις, όπως η αναφορά σε έναν ιστότοπο, όπου το πεδίο συγγραφείς είναι κενό, ή η αναφορά σε μια επερχόμενη δημοσίευση, όπου λείπουν οι πληροφορίες για το έτος.

Υπάρχουν υπάρχοντα σύνολα δεδομένων που χρησιμοποιούνται για τη συγκριτική αξιολόγηση της εξαγωγής πληροφοριών, όπως το σύνολο δεδομένων Cora [25] και το σύνολο δεδομένων Cite- SeerX που χρησιμοποιείται στο [13]. Ωστόσο, συνήθως δεν παρέχουν πρωτότυπα αρχεία PDF, τα οποία αποτελούν την είσοδο του GROBID. Ως εκ τούτου, δημιουργούμε μόνοι μας τη θεμελιώδη αλήθεια εξάγοντας χειροκίνητα αναφορές από έναν κατάλογο επιλεγμένων εργασιών.

Στο πρώτο πείραμα, επιλέγουμε τυχαία 100 επιστημονικά έγγραφα από το CiteSeerX και συγκρίνουμε τον αριθμό των στοιχείων αναφοράς που αναλύονται με τη βοήθεια της τομάτας με τους πραγματικούς αριθμούς. Τα αποτελέσματα της σύγκρισης παρατίθενται στον πίνακα 4. Τα αποτελέσματα δείχνουν ότι ενώ τόσο το ParsCit όσο και το GROBID έχουν παρόμοια

αριθμούς υπο-αναλυμένων εγγράφων, το GROBID τείνει να υπερ-αναλύει τις παραπομπές.

Πίνακας 4: ParsCit έναντι GROBID για τον αριθμό των αναλυμένων στοιχείων.

Αναλυτής	Υπο-αναλύει το	Match	Over-parse
ParsCit	28	44	28
GROBID	29	26	45

Εδώ, η "υπο-ανάλυση" είναι ο αριθμός των pa- pers για τα οποία τα στοιχεία που αναλύονται αυτόματα είναι μικρότερα από πραγματικούς αριθμούς. Οι έννοιες των "number-match" και "over-parse" είναι τότε αυτονόητες.

Για μια ολοκληρωμένη σύγκριση της ποιότητας εξαγωγής παραπομπών απαιτείται μεγάλος αριθμός παραπομπών που έχουν εξαχθεί χειροκίνητα από εργασίες και ένας ακριβής αλγόριθμος αυτόματης αντιστοίχισης τίτλων και συγγραφέων. Ένα άλλο ζήτημα είναι η ευθυγράμμιση των στοιχείων αναφοράς στα αυτόματα αναλυμένα στοιχεία με τα χειροκίνητα εξαγόμενα αποτελέσματα. Αυτά ξεφεύγουν από το πεδίο εφαρμογής του παρόντος εγγράφου. Εδώ, επικεντρωνόμαστε σε 12 έγγραφα που καλύπτουν τυπικά στυλ παραπομπών.

Για τις περισσότερες εργασίες σε συνέδρια και περιοδικά για τις οποίες το απλό κείμενο έχει εξαχθεί καλά, οι διαφορές μεταξύ GROBID και ParsCit είναι μικρές. Ωστόσο, υπάρχουν μερικές περιπτώσεις που μπορούν να κάνουν τα αποτελέσματα της ανάλυσης τους να διαφέρουν. Πρώτον, φαίνεται ότι το GROBID δεν λειτουργεί καλά με στοιχεία αναφοράς που αρχίζουν με ακρωνύμια, π.χ. [KH12]. Κατά την ανάλυση αυτών των αναφορών, τείνει να συνδυάζει δύο διαδοχικούς τίτλους για να σχηματίσει έναν λανθασμένο τίτλο. Από την άλλη πλευρά, εάν μια εργασία περιέχει παράρτημα μετά το τμήμα αναφοράς, το ParsCit αντιμετωπίζει το παράρτημα ως μέρος της τελευταίας συμβολοσειράς αναφοράς. Και οι δύο κάνουν λάθος λήψεις όταν υπάρχουν χαρακτήρες ελέγχου που παρεμβάλλονται μεταξύ του περιεχομένου του κειμένου. Βασικά, τόσο το GROBID όσο και το ParsCit εφαρμόζουν τυχαίο πεδίο υπό όρους, γεγονός που εξηγεί ότι στις περισσότερες περιπτώσεις λειτουργούν σχεδόν εξίσου καλά. Οι διαφορές οφείλονται πιθανότατα στα δείγματα εκπαίδευσης.

Ένα από τα πλεονεκτήματα του ParsCit είναι ότι εξάγει το πλαίσιο αναφοράς, το οποίο είναι αποσπάσματα κειμένου γύρω από τη θέση στην οποία αναφέρεται μια αναφορά. Το GROBID δεν εξάγει άμεσα το πλαίσιο αναφοράς, αλλά το αρχείο TEI εξόδου περιέχει ετικέτες στο σώμα του κειμένου που αντιστοιχούν σε ετικέτες των στοιχείων αναφοράς. Έτσι, εξακολουθεί να είναι δυνατή η εξαγωγή του πλαισίου αναφοράς με επιπλέον κωδικοποίηση. Για το παρόν έργο, χρησιμοποιούμε το ParsCit ως το προεπιλεγμένο εργαλείο εξαγωγής παραπομπών.

2.7 Πίνακας και Εικόνα Εξαγωγή

Μία από τις βελτιώσεις του νέου πλαισίου σε σύγκριση με το τρέχον είναι η ενσωμάτωση των EM πίνακα, σχήματος και αλγορίθμου. Υπάρχουν μερικά υπάρχοντα εργαλεία ανοικτού κώδικα για την εξαγωγή πινάκων και σχημάτων, όπως ο αλγόριθμος εξαγωγής πινάκων που προτάθηκε από το [22] και ο αλγόριθμος εξαγωγής σχημάτων που προτάθηκε από το [8]. Πρόσφατα, το [9] ανέπτυξε ένα πακέτο που ονομάζεται PDFFigures, το οποίο μπορεί να εξάγει σχήματα και πίνακες με μία εντολή. Μια ανεξάρτητη αξιολόγηση δείχνει ότι χρειάζεται 0,1-0,2 δευτερόλεπτα για κάθε σελίδα και μπορεί να επιτύχει ένα F1-measure της τάξης του 90%. Ως εκ τούτου, είναι αναμφισβήτητα ένα από τα καλύτερα εργαλεία εξαγωγής εικόνων/πινάκων ανοιχτού κώδικα. Εκτός αυτού, ενσωματώνει την εξαγωγή εικόνων και πινάκων, οπότε δεν χρειάζεται να υλοποιήσουμε μεμονωμένα EM.

Το PDFFigures εκτελείται καλώντας ένα μεταγλωττισμένο δυαδικό αρχείο με καταλόγους εξόδου για τα στοιχεία και τα αρχεία JSON. Ορίσαμε ένα χρονικό όριο των 20 δευτερολέπτων σε περίπτωση που το πρόγραμμα κολλήσει όταν είναι προ-

cessing ένα ασυνήθιστο αρχείο. Τα αρχεία JSON εξόδου συνενώνονται σε ένα ενιαίο αρχείο JSON από το περιτύλιγμα. Τα εξαγόμενα σχήματα και οι πίνακες αποθηκεύονται ως αρχεία PNG στο φάκελο εξόδου της εργασίας.

2.8 Εξαγωγή αλγορίθμου

Η εξόρυξη αλγορίθμων εξάγει αυτόματα ψευδοκώδικες και πλαίσιο αναφοράς από έγγραφα και παράγει σύνοψη για κάθε ψευδοκώδικα. Υπάρχει μια χούφτα λογισμικού ανοικτού κώδικα αφιερωμένο στην εξαγωγή αλγορίθμων. Το πιο πρόσφατο και επιτυχημένο αναπτύχθηκε από τους [4] και [27] (εφεξής *AlgEx*).

Το βασικό πρόγραμμα είναι γραμμένο σε Perl με ένα περιτύλιγμα Java. Λαμβάνει ένα αρχείο κειμένου και τον κατάλογο εξόδου ως παραμέτρους εισόδου και γράφει ένα αρχείο XML στον παρεχόμενο κατάλογο. Ορίσαμε ένα χρονικό όριο 20 δευτερολέπτων.

3. ΕΞΑΓΩΓΗ

Ένας από τους στόχους αυτού του πλαισίου είναι να αφαιρέσει τη λογική του συντονισμού και της εκτέλεσης της διαδικασίας εξαγωγής και να αφήσει τον χρήστη να επικεντρωθεί στον ορισμό της πραγματικής λογικής για την εξαγωγή μεταδεδομένων.

Το πλαίσιο υλοποιήθηκε σε Python. Η Python έχει αποδειχθεί ότι είναι πιο εύχρηστη από την Perl [28] και χρησιμοποιείται ευρέως σε ακαδημαϊκούς κύκλους. Μία από τις προκλήσεις της Python είναι το Global Interpreter Lock (GIL), που υπάρχει στην βασική υλοποίηση της Python, δηλαδή στην cPython. Το GIL εμποδίζει τον διερμηνέα της Python να εκτελεί περισσότερα από ένα νήματα ταυτόχρονα. Ως αποτέλεσμα, το GIL ουσιαστικά εμποδίζει τις εργασίες με περιορισμένη CPU να μπορούν να αποκομίσουν οφέλη απόδοσης μέσω της πολυνηματικότητας. Ωστόσο, η πολυεπεξεργασία δεν πάσχει από τους περιορισμούς της GIL, επειδή επιτρέπει την ύπαρξη πολλαπλών περιπτώσεων διερμηνέων Python. Ως εκ τούτου, η πολυεπεξεργασία χρησιμοποιείται αντί της πολυνηματικότητας προκειμένου να επιτευχθούν οι στόχοι απόδοσης για το πλαίσιο.

Ο κώδικας χωρίζεται σε τέσσερις κύριες ενότητες. Η ενότητα `core` είναι υπεύθυνη για την κύρια λειτουργικότητα του πλαισίου. Εκτελεί τη συνολική διαδικασία εξαγωγής. Περιέχει την κλάση `ExtractionRunner`, στην οποία οι χρήστες της βιβλιοθήκης λογισμικού ρυθμίζουν και εκτελούν τις εξορύξεις. Η κεντρική μονάδα διαχειρίζεται εσωτερικά όλο τον παραλληλισμό. Η ενότητα `runnables` επιτρέπει στους χρήστες να ορίζουν τα δικά τους runnables. Περιέχει τη βασική κλάση `Runnable`, η οποία κληρονομείται από τις κλάσεις `Extractor` και `Filter`. Για να ορίσει εκχυλιστές και φίλτρα, ένας χρήστης επεκτείνει είτε την κλάση `Extractor` είτε την κλάση `Filter` και υπερκαλύπτει τη μέθοδο `extract` ή `filter`, αντίστοιχα.

Η ενότητα `utils` περιέχει διάφορα χρήσιμα εργαλεία. Για παράδειγμα, η συνάρτηση που ονομάζεται `external_process` παρέχει στους χρήστες
με έναν εύκολο τρόπο για την εκκίνηση, τη διαβίβαση δεδομένων και τη λήψη του αποτελέσματος από μια εξωτερική διεργασία, καθορίζοντας ταυτόχρονα ένα χρονικό όριο για τη διεργασία. Τέλος, η ενότητα `log` περιέχει τα εργαλεία καταγραφής που χρησιμοποιεί το πλαίσιο εξαγωγής από προεπιλογή. Ο πλήρης πηγαίος κώδικας του πλαισίου εξαγωγής είναι διαθέσιμος στο διαδίκτυο στο Github .[1]

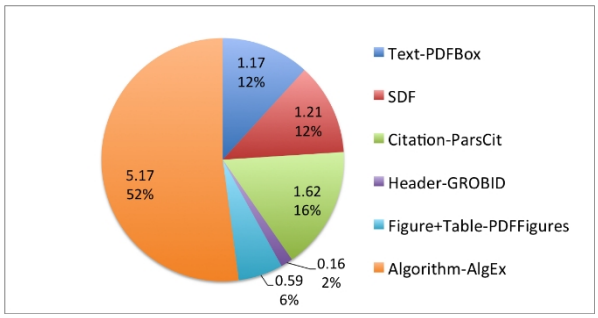
4. ΠΕΙΡΑΜΑΤΑ

Για να επικυρώσουμε το πλαίσιο, το εκτελούμε σε έναν αποκλειστικό εικονικό διακομιστή με 16 λογικούς πυρήνες Intel Xeon E5649
@ 2.53GHz. Ο διακομιστής διαθέτει 8GB RAM.

Το πρώτο πείραμα ορίζεται να εκτελέσει 1000 έγγραφα PDF που επιλέγονται τυχαία από την υπάρχουσα ψηφιακή βιβλιοθήκη με ένα

[1] `https://github.com/SeerLabs/new-csx-extractor`

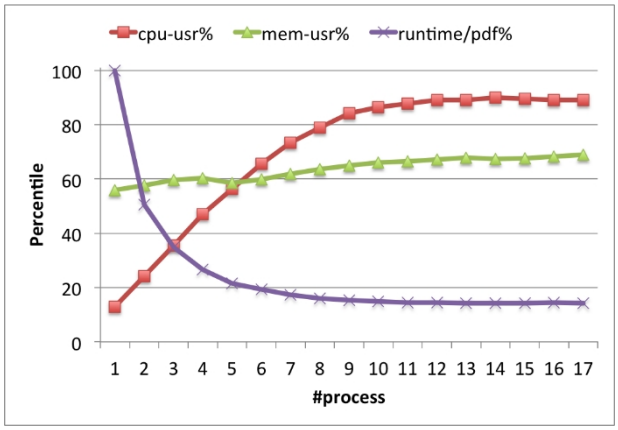
ενιαία διαδικασία. Στόχος αυτού του πειράματος είναι να διερευνηθεί η συνολική απόδοση του πλαισίου όσον αφορά τον χρόνο εκτέλεσης για κάθε ενότητα και τους πόρους του συστήματος που καταναλώνονται. Ο μέσος χρόνος εκτέλεσης για ένα έγγραφο είναι περίπου 10 δευτερόλεπτα. Το Σχήμα 4 απεικονίζει την κατανομή του μέσου χρόνου εκτέλεσης σε όλα τα ΕΜ. Μεταξύ όλων των υπομονάδων, η εξαγωγή αλγορίθμων είναι επί του παρόντος η πιο αργή, ακολουθούμενη από την εξαγωγή παραπομπών. Η εξαγωγή επικεφαλίδων είναι η ταχύτερη, καθώς διαρκεί μόλις 0,16 δευτερόλεπτα ανά έγγραφο κατά μέσο όρο. Αν δεν εκτελέσουμε την εξαγωγή αλγορίθμων, χρειάζονται κατά μέσο όρο 5 δευτερόλεπτα για την επεξεργασία ενός αρχείου PDF με τη χρήση ενός μόνο νήματος. Το πλαίσιο διαχειρίζεται όλες τις εξαιρέσεις που παράγονται από συγκεκριμένα εργαλεία εξαγωγής και εκτελείται χωρίς να κολλήσει ή να καταρρεύσει. Η μέση χρήση της CPU είναι μικρότερη από 15% με μέγιστη χρήση CPU 55% που συμβαίνει σε δύο μόνο αιχμές. Η κατανομή του χρόνου εκτέλεσης εξαρτάται από τα πραγματικά εργαλεία εξαγωγής. Οι αριθμοί που αναφέρονται εδώ δίνουν μια γραμμή-οδηγό όσον αφορά το ποια ΕΜ επιλέγονται για τις ευαίσθητες στο χρόνο εργασίες.



Σχήμα 4: Κατανομή του μέσου χρόνου εκτέλεσης (ανά έγγραφο σε δευτερόλεπτα) των ΕΜ.

Στο δεύτερο πείραμα, εκτελούμε το πλαίσιο στο ίδιο σύνολο δεδομένων μεταβάλλοντας τον αριθμό των διεργασιών (#process). Στόχος είναι να διερευνήσουμε πώς μεταβάλλονται οι πόροι του συστήματος (CPU, μνήμη) και ο μέσος χρόνος εκτέλεσης για κάθε PDF ανάλογα με το #process. Το Σχήμα 5 δείχνει ότι η χρήση της CPU αυξάνεται γραμμικά ξεκινώντας από περίπου 13% όταν η #διεργασία είναι μικρότερη από
6. Στη συνέχεια αυξάνεται ασυμπτωτικά σε περίπου 90% και παραμένει σταθερό ακόμη και όταν αυξάνεται η #διεργασία. Είναι σαφές ότι η CPU χρησιμοποιείται πλήρως με το υπόλοιπο 10% να χρησιμοποιείται από το λειτουργικό σύστημα. Η μνήμη, ωστόσο, αυξάνεται πολύ αργά ξεκινώντας από το 56% (4582MB) και χρησιμοποιείται μόνο κατά λιγότερο από 70% όταν #process= 17. Ο μέσος χρόνος εκτέλεσης ανά έγγραφο (nor- malized ως προς τον χρόνο εκτέλεσης του μεμονωμένου νήματος) μειώνεται γρήγορα με τρόπο power-law όταν το #process είναι μικρότερο από 6 και στη συνέχεια φτάνει ασυμπτωτικά σε ένα όριο γύρω στο 14,3% (1,3 sec- onds) σε σχέση με τον χρόνο εκτέλεσης του μεμονωμένου νήματος.

Η συνοχή της χρήσης της CPU και του μέσου χρόνου εκτέλεσης υποδηλώνει ότι η προεπιλεγμένη υλοποίηση του πλαισίου είναι περιορισμένη στην CPU. Η χρήση της ΚΜΕ δεν ακολουθεί μια αυστηρή σχέση γραμμής μέχρι 16 διεργασίες (ο συνολικός αριθμός πυρήνων). Πιστεύουμε ότι αυτό οφείλεται στους πόρους που χρησιμοποιούνται από συγκεκριμένα εργαλεία εξόρυξης, καθώς μπορεί να περιέχουν εσωτερικές διεργασίες που χρησιμοποιούν πολλαπλούς πυρήνες και κρυφή μνήμη, γεγονός που αυξάνει την επιβάρυνση με περισσότερες διεργασίες. Η αργή αύξηση της μνήμης δείχνει ότι το πλαίσιο αφήνει αμελητέο αποτύπωμα στη μνήμη, οπότε το μεγαλύτερο μέρος της μνήμης καταλαμβάνεται από τις ενότητες βιβλιοθήκης.



Σχήμα 5: Συνολική απόδοση με πολλαπλές διαδικασίες.

5. ΕΦΑΡΜΟΓΕΣ

Το PDFMEF μπορεί να θεωρηθεί από μόνο του ως ένα πλαίσιο σύλληψης γνώσης, καθώς είναι ικανό να ενσωματώνει εκτελέσιμα εργαλεία σύλληψης γνώσης και να οργανώνει τα αποτελέσματα. Λόγω των χρηστικών, συντηρήσιμων, αρθρωτών και κλιμακούμενων χαρακτηριστικών του, μπορεί να εφαρμοστεί σε πολλά έργα σύλληψης γνώσης.

Στην περίπτωση της μηχανής αναζήτησης της ψηφιακής βιβλιοθήκης CiteSeerX, η οποία παρέχει δωρεάν πρόσβαση σε έξι εκατομμύρια ακαδημαϊκά έγγραφα, ενώ τα μεταδεδομένα του έργου αυτού έχουν ζητηθεί συχνά και χρησιμοποιούνται ευρέως σε διάφορα έργα, η ποιότητα των μεταδεδομένων πρέπει επειγόντως να βελτιωθεί λόγω των λανθασμένα εξαγόμενων τίτλων, συγγραφέων και παραπομπών. Υπάρχει επίσης ένα κλάσμα λανθασμένα ταξινομημένων εγγράφων, δηλαδή μη ακαδημαϊκά που ταξινομούνται ως ακαδημαϊκά. Αυτή η ψηφιακή βιβλιοθήκη φιλοξενεί μια βάση δεδομένων ερπυσμού με περισσότερα από 21 εκατομμύρια αρχεία PDF. Θα μπορούσε να βελτιώσει σημαντικά την ποιότητα των μεταδεδομένων εκτελώντας το PDFMEF στο μεγάλο αποθετήριο και δημιουργώντας μια μηχανή αναζήτησης γνώσης από τις εξαγόμενες οντότητες χρησιμοποιώντας την τεχνική αυτόματης ευρετηρίασης γνώσης [14]. Μπορεί να αποτελέσει μια πολύτιμη πλατφόρμα για τους συγγραφείς ώστε να εντοπίζουν γρήγορα τα υπάρχοντα πειραματικά αποτελέσματα και τις σχετικές εργασίες.

Έχει προταθεί εδώ και καιρό ότι η επόμενη γενιά μηχανών αναζήτησης θα πρέπει να είναι σημασιολογική, π.χ. [17, 15]. Η τρέχουσα λύση της Google χρησιμοποιεί ένα γράφο γνώσης με δισεκατομμύρια οντότητες που συλλέγονται από μια μεγάλη ποικιλία πηγών. Αυτές οι οντότητες συνδέονται στη συνέχεια λογικά για να απαντήσουν στις ερωτήσεις του χρήστη. Στην πραγματικότητα, πρόσφατες εργασίες έχουν προσπαθήσει να αναπτύξουν συστήματα για την εξαγωγή απλών δηλώσεων γνώσης από απλό κείμενο [10] ή από επιστημονικά εγχειρίδια [6]. Μια μικρή τροποποίηση του PDFMEF μπορεί να εντάξει ένα τέτοιο σύστημα στο πλαίσιο και να χρησιμοποιήσει απλό κείμενο ως είσοδο για την εξαγωγή γνώσης. Ομοίως, θα ήταν χρήσιμο να δημιουργηθεί μια σημασιολογική ακαδημαϊκή μηχανή αναζήτησης με μια μεγάλη βάση γνώσης που θα συμπληρώνεται από οντότητες που εξάγονται από ακαδημαϊκά έγγραφα. Η AllenAI έχει ξεκινήσει ένα έργο με την ονομασία *Semantic Scholar* και έχει δημοσιεύσει μια σειρά εργασιών σχετικά με την εξαγωγή γνώσης, π.χ. [11].

Το πλαίσιο PDFMEF μπορεί να αποτελέσει μια κατάλληλη και αποτελεσματική λύση για τέτοια έργα για την απόκτηση μιας συλλογής μεταδεδομένων και οντοτήτων γνώσης εγγράφων.

6. ΠΕΡΊΛΗΨΗ ΚΑΙ ΜΕΛΛΟΝΤΙΚΈΣ ΕΡΓΑΣΙΕΣ

Αναπτύξαμε το PDFMEF, ένα πλαίσιο για την εξαγωγή πολλαπλών οντοτήτων γνώσης μέσα σε επιστημονικά έγγραφα. Αποτελείται από τις ακόλουθες ενότητες: έναν εξολκέα απλού κειμένου που χρησιμοποιεί το PDFBox, ένα φίλτρο επιστημονικών εγγράφων, έναν εξολκέα κεφαλίδων που χρησιμοποιεί το GROBID, έναν εξολκέα παραπομπών που χρησιμοποιεί το ParsCit, εξολκέα σχημάτων και πινάκων που χρησιμοποιούν το PDFFigures και έναν εξολκέα αλγορίθμων. Έχει σχεδιαστεί ώστε να είναι εύκολα χρησιμοποιήσιμο, συντηρήσιμο, αρθρωτό και επεκτάσιμο. Εκτός από τις ενότητες εξαγωγής πλήρους κειμένου και εξαγωγής επικεφαλίδων, όλες οι ενότητες είναι πρόσθετες, ώστε οι χρήστες να μπορούν εύκολα να αντικαταστήσουν τα προεπιλεγμένα εργαλεία εξαγωγής με τις εναλλακτικές λύσεις που προτιμούν. Το δοκιμάσαμε σε έναν αποκλειστικό διακομιστή με 16 πυρήνες @2.53GHz. Χρειάζονται κατά μέσο όρο 10 δευτερόλεπτα ανά έγγραφο για την εκτέλεση όλων των προεπιλεγμένων εργαλείων εξαγωγής με ένα μόνο νήμα και τουλάχιστον 1,3 δευτερόλεπτα για την εκκίνηση 10 διεργασιών. Το πλαίσιο αφήνει πολύ μικρό αποτύπωμα στη μνήμη. Αυτό είναι ένα πρώτο βήμα για την κατασκευή μιας βάσης γνώσης για μια επιστημονική οντολογία που χρησιμοποιεί επιστημονικά μεγάλα δεδομένα.

Η μελλοντική εργασία θα είναι η δημιουργία μιας σημασιολογικής επιστημονικής οντολογίας σε κλίμακα. Αυτό θα μπορούσε επίσης να επεκταθεί και σε άλλα έγγραφα που σχετίζονται με την επιστήμη, π.χ. βιογραφικά σημειώματα, διαφάνειες ή προγράμματα σπουδών. Η ενσωμάτωση του συστήματος στο πλαίσιο Hadoop ή Spark θα ενίσχυε σημαντικά την αποδοτικότητα του συστήματος.

7. ΕΥΧΑΡΙΣΤΙΕΣ

Ευχαριστούμε τον Zhaohui Wu για τις χρήσιμες συζητήσεις και αναγνωρίζουμε ευγνωμοσύνη για την υποστήριξη από το Εθνικό Ίδρυμα Επιστημών.

8. ΑΝΑΦΟΡΕΣ

[1] Pdflib tet. http://www.pdflib.com/products/tet/. Πρόσβαση: 2015-05-12.

[2] Poppler. http://poppler.freedesktop.org. Πρόσβαση: 2015-05-12.

[3] Tabula. http://tabula.technology. Πρόσβαση: 2015-05-13.

[4] S. Bhatia, S. Tuarob, P. Mitra και C. L. Giles. Μια μηχανή αναζήτησης αλγορίθμων για προγραμματιστές λογισμικού. Στα *πρακτικά του 3ου διεθνούς εργαστηρίου για την ανάπτυξη με βάση την αναζήτηση: Users, Infrastructure, Tools, and Evaluation*, SUITE '11, pages 13-16, New York, NY, USA, 2011. ACM.

[5] C. Caragea, J. Wu, K. Williams, S. D. Gollapalli, M. Khabsa, και C. L. Giles. Αυτόματη ταυτοποίηση ερευνητικών άρθρων από έγγραφα που ανιχνεύονται. WSDM 2014 Workshop on Web-scale Classification: 2014: Classifying Big Data from the Web: Classifying Big Data from the Web, 2014.

[6] V. K. Chaudhri, B. E. John, S. Mishra, J. Pacheco, B. Porter και A. Spaulding. Παροχή δυνατότητας σε εμπειρογνώμονες να δημιουργήσουν βάσεις γνώσεων από επιστημονικά εγχειρίδια. In *Proceedings of the 4th International Conference on Knowledge Capture*, K-CAP '07, pages 159-166, New York, NY, USA, 2007. ACM.

[7] S. Choudhury, P. Mitra, A. Kirk, S. Szep, D. Pellegrino, S. Jones και C. L. Giles. Εξαγωγή μεταδεδομένων σχήματος από ψηφιακά έγγραφα. In *12th International Conference on Document Analysis and Recognition*, ICDAR '13, pages 135-139, 2013.

[8] S. R. Choudhury, S. Tuarob, P. Mitra, L. Rokach, A. Kirk, S. Szep, D. Pellegrino, S. Jones και C. L. Giles. Μια αρχιτεκτονική μηχανής αναζήτησης σχήματος για μια ψηφιακή βιβλιοθήκη χημείας. JCDL '13, σελίδες 369-370, 2013.

[9] C. Clark και S. Divvala. Κοιτάζοντας πέρα από το κείμενο: από έγγραφα της επιστήμης των υπολογιστών. AAAI 2015 Workshop on Scholarly Big Data, 2015.

[10] P. Clark και P. Harrison. Εξαγωγή και χρήση γνώσης από κείμενο σε μεγάλη κλίμακα. Στα *πρακτικά του πέμπτου διεθνούς συνεδρίου για τη σύλληψη γνώσης*, K-CAP '09, σελίδες 153-160, Νέα Υόρκη, Νέα Υόρκη, ΗΠΑ, 2009. ACM.

[11] P. Clark, P. Harrison, N. Balasubramanian και O. Etzioni. Κατασκευή ενός κειμενικού κβ από ένα εγχειρίδιο βιολογίας. Στα *πρακτικά του κοινού εργαστηρίου για την αυτόματη κατασκευή βάσεων γνώσης και Web-scale Knowledge Extraction*, AKBC-WEKEX '12, pages 74-78, Stroudsburg, PA, USA, 2012. Association for Computational Linguistics.

[12] T. Κοινοπραξία. *TEI P5: Κατευθυντήριες γραμμές για την ηλεκτρονική κωδικοποίηση και ανταλλαγή κειμένων 2.3.0*. Κοινοπραξία TEI, 2013.

[13] I. Councill, C. L. Giles και M.-Y. Kan. Parscit: ένα πακέτο ανάλυσης συμβολοσειρών αναφοράς crf ανοικτού κώδικα. In *Proceedings of the Sixth International Conference on Language Resources and Evaluation (LREC'08)*, Marrakech, Morocco, may 2008. Ευρωπαϊκή Ένωση Γλωσσικών Πόρων (ELRA).

[14] I. G. Councill, C. L. Giles, H. Han και E. Manavoglu. Αυτόματη ευρετηρίαση αναγνωρίσεων: citeseer digital library: Expanding the semantics of contribution in the citeseer digital library. In *Proceedings of the 3rd International Conference on Knowledge Capture*, K-CAP '05, pages 19-26, New York, NY, USA, 2005. ACM.

[15] O. Etzioni. Η αναζήτηση χρειάζεται ανανέωση. *Nature*, 476(7358):25-26, 08 2011.

[16] D. FERRUCCI και A. LALLY. Uima: μια αρχιτεκτονική προσέγγιση για την επεξεργασία μη δομημένων πληροφοριών στο εταιρικό ερευνητικό περιβάλλον. *Natural Language Engineering*, 10:327-348, 9 2004.

[17] R. Guha, R. McCool και E. Miller. Σημασιολογική αναζήτηση. In *Proceedings of the 12th International Conference on World Wide Web*, WWW '03, pages 700-709, New York, NY, USA, 2003. ACM.

[18] H. Han, C. L. Giles, E. Manavoglu, H. Zha, Z. Zhang και E. A. Fox. Automatic document metadata extraction using support vector machines. In *Proceedings of the 3rd ACM/IEEE-CS Joint Conference on Digital Libraries*, JCDL '03, pages 37-48, 2003.

[19] M. Khabsa και C. L. Giles. Ο αριθμός των επιστημονικών εγγράφων στον δημόσιο ιστό. *PLoS ONE*, 9(5):e93949, Μάιος 2014.

[20] P. Larsen and M. von Ins. Ο ρυθμός αύξησης των επιστημονικών δημοσιεύσεων και η μείωση της κάλυψης που παρέχει ο δείκτης επιστημονικών αναφορών. *Scientometrics*, 84(3):575-603, 2010.

[21] M. Lipinski, K. Yao, C. Breitinger, J. Beel και B. Gipp. Αξιολόγηση προσεγγίσεων και εργαλείων εξαγωγής μεταδεδομένων επικεφαλίδων για επιστημονικά έγγραφα pdf. In *Proceedings of the 13th ACM/IEEE-CS Joint Conference on Digital Libraries*, JCDL '13, pages 385-386, New York, NY, USA, 2013. ACM.

[22] Y. Liu, P. Mitra, C. L. Giles και K. Bai. Αυτόματη εξαγωγή μεταδεδομένων πινάκων από ψηφιακά έγγραφα.

In *Proceedings of the 6th ACM/IEEE-CS Joint Conference on Digital Libraries*, JCDL '06, pages 339-340, New York, NY, USA, 2006. ACM.

[23] L. D. Lopez, J. Yu, C. N. Arighi, H. Huang, H. Shatkay και C. Wu. Ένα αυτόματο σύστημα για την εξαγωγή εικόνων και λεζάντων σε βιοϊατρικά έγγραφα pdf. *2013 IEEE International Conference on Bioinformatics and Biomedicine*, 0:578-581, 2011.

[24] P. Lopez. Grobid: Συνδυασμός αυτόματης αναγνώρισης βιβλιογραφικών δεδομένων και εξαγωγής όρων για δημοσιεύσεις υποτροφιών. In *Proceedings of the 13th European Conference on Research and Advanced Technology for Digital Libraries*, ECDL'09, pages 473-474, Berlin, Heidelberg, 2009. Springer-Verlag.

[25] K. Seymore, A. McCallum και R. Rosenfeld. Μάθηση της δομής του κρυμμένου μοντέλου markov για την εξαγωγή πληροφοριών. AAAI'99 Workshop on Machine Learning for Information Extraction, 1999.

[26] B. Sun, P. Mitra, C. Lee Giles και K. T. Mueller. Αναγνώριση, ευρετηρίαση και κατάταξη χημικών τύπων και χημικών ονομάτων σε ψηφιακά έγγραφα. *ACM Trans. Inf. Syst.*, 29(2):12:1-12:38, Απρ. 2011.

[27] S. Tuarob, S. Bhatia, P. Mitra και C. L. Giles. Αυτόματη ανίχνευση ψευδοκωδικών σε επιστημονικά έγγραφα με χρήση μηχανικής μάθησης. ICDAR, σελίδες 738-742, 2013.

[28] L. Wang και P. Pfeiffer. A qualitative analysis of the usability of perl, python, and tcl. In *Proeedings of the tenth International Python Conference*, 2002.

[29] J. Wu, K. Williams, H.-H. Chen, M. Khabsa, C. Caragea, A. Ororbia, D. Jordan και C. L. Giles. Citeseerx: Ai σε μια μηχανή αναζήτησης ψηφιακής βιβλιοθήκης. Στο *The Twenty-Sixth Annual Conference on Innovative Applications of Artificial Intelligence*, IAAI '14, 2014.