DeepL

Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

DOI 10.1007/s11192-017-2298-x

Ομαδοποίηση άρθρων με βάση τη σημασιολογική ομοιότητα

Shenghui Wang[1] - Rob Koopman[1]

Ελήφθη: Δημοσιεύθηκε στο διαδίκτυο: 27 Φεβρουαρίου 2017
© Akade´miai Kiado´, Βουδαπέστη, Ουγγαρία 2017

Περίληψη Η ομαδοποίηση εγγράφων είναι γενικά το πρώτο βήμα για τον εντοπισμό θεμάτων. Δεδομένου ότι πολλές μέθοδοι ομαδοποίησης λειτουργούν με βάση τις ομοιότητες μεταξύ εγγράφων, είναι σημαντικό να δημιουργηθούν αναπαραστάσεις αυτών των εγγράφων οι οποίες διατηρούν όσο το δυνατόν περισσότερο τη σημασιολογία τους και είναι επίσης κατάλληλες για τον αποτελεσματικό υπολογισμό της ομοιότητας. Όπως περιγράφουμε στο Koopman et al. (Proceedings of ISSI 2015 Istanbul: 15th International Society of Scientometrics and Informetrics Conference, Istanbul, Turkey, 29 June to 3 July, 2015. Bogazic¸i University Printhouse. http://www.issi2015.org/files/downloads/all-papers/1042.pdf, 2015), τα μεταδεδομένα των άρθρων του συνόλου δεδομένων *Astro* συμβάλλουν σε έναν σημασιολογικό πίνακα, ο οποίος χρησιμοποιεί έναν διανυσματικό χώρο για να αποτυπώσει τη σημασιολογία των οντοτήτων που προέρχονται από αυτά τα άρθρα και κατά συνέπεια υποστηρίζει τη διερεύνηση του πλαισίου αυτών των οντοτήτων στο *LittleAriadne*. Ωστόσο, αυτός ο σημασιολογικός πίνακας δεν επιτρέπει τον άμεσο υπολογισμό των ομοιοτήτων μεταξύ των άρθρων. Σε αυτή την εργασία θα περιγράψουμε λεπτομερώς τον τρόπο με τον οποίο κατασκευάζουμε μια σημασιολογική αναπαράσταση για ένα άρθρο από τις οντότητες που σχετίζονται με αυτό. Με βάση αυτές τις σημασιολογικές αναπαραστάσεις των άρθρων, εφαρμόζουμε δύο τυπικές μεθόδους ομαδοποίησης, τον αλγόριθμο K-Means και τον αλγόριθμο ανίχνευσης κοινοτήτων Louvain, οι οποίες οδηγούν στις δύο λύσεις ομαδοποίησης που ονομάζουμε OCLC-31 (που σημαίνει K-Means) και OCLC-Louvain (που σημαίνει Louvain). Στην παρούσα εργασία θα δώσουμε τις λεπτομέρειες υλοποίησης και μια βασική σύγκριση με άλλες λύσεις ομαδοποίησης που αναφέρονται σε αυτό το ειδικό τεύχος.

Λέξεις-κλειδιά Σημασιολογική ευρετηρίαση - Συσταδοποίηση - Οπτικοποίηση - K-Means - Ανίχνευση κοινότητας Louvain

✉ Shenghui Wang
shenghui.wang@oclc.org

Rob Koopman
rob.koopman@oclc.org

[1] OCLC Research, Schipholweg 99, Leiden, Κάτω Χώρες

Εισαγωγή

Τα θέματα, τα επιμέρους πεδία, οι ειδικότητες δημιουργούν τον πυρήνα στην αυτοοργανωμένη διαδικασία παραγωγής επιστημονικής γνώσης (Bruckner et al. 1990). Υπάρχει μεγάλη ασάφεια ως προς τον τρόπο ορισμού αυτών των μονάδων γνωστικής και κοινωνικής οργάνωσης (Sugimoto and Weingart 2015) και μια συνεχής συζήτηση σχετικά με τον τρόπο εξαγωγής τους με αυτόματο, αλγοριθμικό τρόπο (Gla¨ser et al. 2017). Παρόλα αυτά, ένας τρόπος για τον εντοπισμό *θεμάτων* είναι η ομαδοποίηση εγγράφων. Υπάρχουν διάφοροι τρόποι για να προσδιοριστεί αν δύο έγγραφα απευθύνονται σε ένα συναφές θέμα. Ορισμένα γνωστά σήματα για μια θεματική συνάφεια περιλαμβάνουν τις παραπομπές (αν ένα έγγραφο παραπέμπει σε ένα άλλο) (Garfield 1983), τις συν-παραπομπές (αν δύο έγγραφα παραπέμπονται από ένα τρίτο έγγραφο) (Small 1973), τη βιβλιογραφική σύζευξη (αν δύο έγγραφα μοιράζονται μια αναφορά στη βιβλιογραφία τους) (Gla¨nzel and Czerwon 1996) και τις συν-λέξεις (αν δύο έγγραφα μοιράζονται ορισμένες λέξεις) (Leydesdorff 1989). Κάθε ένα από αυτά τα σήματα ή ίχνη μπορεί να χρησιμοποιηθεί για την κατασκευή ενός διαφορετικού πίνακα συγγένειας ή ομοιότητας μεταξύ εγγράφων, βάσει του οποίου μπορούν να εντοπιστούν συστάδες εγγράφων ή θέματα.

Στη βιβλιομετρική βιβλιογραφία έχουν συζητηθεί άφθονα τα πλεονεκτήματα και τα μειονεκτήματα των διαφόρων μεθόδων. Σε γενικές γραμμές, γίνεται διάκριση μεταξύ των μετρικών που βασίζονται σε παραπομπές και των μετρικών που βασίζονται σε κείμενο (Boyack et al. 2013). Παρόλο που οι λέξεις αναμένεται να είναι λιγότερο κωδικοποιημένες από τις παρατιθέμενες αναφορές, συμμεριζόμαστε την πεποίθηση ότι οι λέξεις, ιδίως αυτές στους τίτλους και τις περιλήψεις, μεταφέρουν ένα ορισμένο ποσό του γνωστικού ισχυρισμού που διατυπώνεται από μια εργασία (Leydesdorff and Hellsten 2006). Ως εκ τούτου, σύμφωνα με το πρόγραμμα της γνωστικής επιστημομετρίας (Rip and Courtial 1984) και τις πιο πρόσφατες βιβλιομετρικές μελέτες με βάση το πλήρες κείμενο (Boyack et al. 2013), δηλώνουμε ότι αν δύο έγγραφα μοιράζονται αρκετές λεξικές πληροφορίες, θεωρείται ότι σχετίζονται.

Για τις προσεγγίσεις ομαδοποίησης που περιγράφονται λεπτομερώς σε αυτό το έγγραφο, βασιζόμαστε σε μια νέα σημασιολογική απεικόνιση των άρθρων για να προσδιορίσουμε τις ομοιότητές τους. Τόσο η υποκείμενη μέθοδος όσο και μια διαδραστική διεπαφή αναζήτησης που βασίζεται σε αυτήν έχουν ονομαστεί *Ariadne* (Koopman et al. 2015, 2015). Η προσέγγισή μας έχει μεγάλη ομοιότητα με τις μεθόδους που χρησιμοποιούνται στην ανάκτηση πληροφοριών, καθότι λειτουργεί σε ένα χώρο λέξεων. Σε διαφορά όμως από τις μεθόδους που βασίζονται στον λεκτικό χώρο των εγγράφων του Salton, χρησιμοποιούμε πληροφορίες από όλα τα στοιχεία ενός εγγράφου (στην περίπτωσή μας, ενός άρθρου) και δημιουργούμε έναν λεκτικό χώρο για όλα αυτά τα στοιχεία ή τις οντότητες. Το κίνητρο γι' αυτό βασίζεται στην υπόθεση ότι η χρήση πληροφοριών από πολλά διαφορετικά στοιχεία ενός άρθρου παρέχει μια πιο ακριβή σημασιολογική αναπαράσταση αυτού του άρθρου. Κατά συνέπεια, υποθέτουμε ότι αυτό βελτιώνει επίσης τη βάση στην οποία καθορίζεται η ομοιότητα/σχέση μεταξύ των άρθρων. Όταν χρησιμοποιούμε οντότητες όπως συγγραφείς, περιοδικά, θεματικές επικεφαλίδες ή αναφορές, αναζητούμε ταυτόχρονα τη σημασιολογική ομοιότητα/σχέση με βάση τις προοπτικές μιας κοινωνικής (συγγραφείς), επικοινωνιακής (περιοδικά ως τόπος δημοσίευσης) ή ανταλλαγής γνώσεων (αναφορές) οργάνωσης της παραγωγής επιστημονικής γνώσης.

Επομένως, τα ερευνητικά μας ερωτήματα είναι: (α) αν θα μπορούσαμε να ανακατασκευάσουμε μια έγκυρη σημασιολογική αναπαράσταση για τα άρθρα από όλες τις οντότητες με τις οποίες συνδέονται και (β) αν θα μπορούσαμε να εντοπίσουμε ομάδες

άρθρων με τη χρήση τυποποιημένων μεθόδων που βασίζονται σε μια τέτοια σημασιολογική αναπαράσταση.

Σε αυτό το έγγραφο, περιγράφουμε πρώτα πώς να αναπαραστήσουμε τη σημασιολογία των άρθρων με βάση τις οντότητες που εμπλέκονται σε αυτά τα άρθρα. Στη συνέχεια, παρουσιάζουμε εν συντομία δύο τυπικές μεθόδους ομαδοποίησης, τον αλγόριθμο K-Means και τον αλγόριθμο ανίχνευσης κοινοτήτων Louvain, πριν αναφέρουμε τις λεπτομέρειες υλοποίησης. Στο τέλος, συγκρίνουμε τις δύο λύσεις μας με τις άλλες λύσεις ομαδοποίησης που αναφέρονται σε αυτό το ειδικό τεύχος και ολοκληρώνουμε την εργασία.

Από τη σημασιολογία των οντοτήτων στη σημασιολογία των άρθρων

Για την προσέγγισή μας, υιοθετούμε την έννοια της *Στατιστικής Σημασιολογίας* (Furnas et al. 1983- Weaver 1955) που βασίζεται στην υπόθεση "μια λέξη χαρακτηρίζεται από την παρέα που κρατάει" (Firth 1957) ή στη Γλωσσολογία την *υπόθεση της κατανομής* (Harris 1954- Sahlgren 2008): λέξεις που εμφανίζονται σε παρόμοια περιβάλλοντα τείνουν να έχουν παρόμοιες σημασίες. Στο *Ariadne*, επεκτείνουμε τις λέξεις σε οντότητες (όπως συγγραφείς, περιοδικά, θέματα, παραπομπές), έτσι ώστε κάθε οντότητα να ευρετηριάζεται από ένα διάνυσμα σε έναν σημασιολογικό χώρο που αντανακλά το λεξιλογικό της πλαίσιο, δηλαδή τις συν-εμφανίσεις της με ορισμένους όρους (συμπεριλαμβανομένων των θεματικών όρων που εξάγονται από τον τίτλο και την περίληψη συν τα θέματα που ορίζει ο χρήστης) (Koopman et al. 2017).

Ο προκύπτων πίνακας συνεμφάνισης οντοτήτων-όρων μπορεί να γίνει εξαιρετικά μεγάλος και αραιός, γεγονός που καθιστά οποιονδήποτε υπολογισμό πάνω σε αυτόν πολύ ακριβό και μη πρακτικό. Χάρη στην τυχαία προβολή (Achlioptas 2003- Johnson and Lindenstrauss 1984), μπορούμε να μειώσουμε δραματικά τη διαστατικότητα αυτού του σημασιολογικού χώρου, αποκτώντας έναν πολύ μικρότερο και διαχειρίσιμο *σημασιολογικό πίνακα,* διατηρώντας όμως τη σημασιολογία των οντοτήτων όσο το δυνατόν περισσότερο. Με όλες τις οντότητες να αναπαρίστανται ως διανύσματα στον ίδιο σημασιολογικό χώρο, είναι δυνατόν να υπολογιστεί η απόσταση ή η συγγένεια μεταξύ οποιουδήποτε ζεύγους οντοτήτων, ανεξαρτήτως των τύπων τους. Αυτή η ελευθερία είναι ένα μοναδικό χαρακτηριστικό της *Ariadne*. Παρέχει μια άποψη πλαισίου για μια οντότητα ή ένα ερώτημα ως αρχή ενός διερευνητικού ταξιδιού. Για μια πιο λεπτομερή περιγραφή ανατρέξτε σε άλλες εργασίες (Koopman et al. 2015, 2017).

Στον σημασιολογικό πίνακα κάθε άρθρο συμβάλλει στη σημασιολογία των επιμέρους οντοτήτων. Όταν εκτελείται σε ένα μεγάλο σώμα κειμένων, τα στατιστικά στοιχεία είναι αξιόπιστα για τον υπολογισμό της ομοιότητας μεταξύ οντοτήτων, Ωστόσο, από αυτόν τον σημασιολογικό πίνακα δεν μπορούμε να υπολογίσουμε άμεσα τις ομοιότητες μεταξύ των άρθρων.

Για να μπορέσουμε να ομαδοποιήσουμε τα άρθρα, και συνεπώς να είμαστε συγκρίσιμοι με τις άλλες μεθόδους, κατασκευάζουμε πρώτα μια ολοκληρωμένη αναπαράσταση ενός άρθρου από τις οντότητες που σχετίζονται με αυτό. Για να το κάνουμε αυτό, για κάθε άρθρο, αναζητούμε όλες τις οντότητες που σχετίζονται με αυτό το άρθρο στο Semantic Matrix. Κατά συνέπεια, λαμβάνουμε ένα σύνολο διανυσμάτων $V = \{v_1, \ldots, v_n\}$ για κάθε άρθρο, όπου n είναι ο αριθμός των οντοτήτων που σχετίζονται με αυτήν και v_i είναι το διάνυσμα για την οντότητα e_i . Οι οντότητες αυτές μπορεί να είναι οι συγγραφείς, τα θέματα, το περιοδικό, οι παραπομπές, οι θεματικοί όροι (που εξάγονται από τον τίτλο και την περίληψή του) κ.λπ. Κάθε άρθρο αντιπροσωπεύεται από ένα μοναδικό σύνολο διανυσμάτων. Το μέγεθος του συνόλου n μπορεί να ποικίλλει, αλλά κάθε ένα από τα διανύσματα μέσα σε ένα σύνολο έχει το ίδιο μήκος, στην περίπτωσή μας 600 (βλ. Koopman et al. (2017) για περισσότερες λεπτομέρειες).

Για κάθε άρθρο κατασκευάζουμε τώρα ένα νέο διάνυσμα v' , το σταθμισμένο κεντροειδές των διανυσμάτων που το αποτελούν:

$$v' = \frac{\sum_{i=1}^{n} w_i \cdot v_i}{\sum_{i=1}^{n} w_i}, \quad (1)$$

όπου $w_i = log(N/f)_i^3$, N είναι ο συνολικός αριθμός των άρθρων και f_i είναι ο αριθμός των άρθρων που περιέχουν την οντότητα e_i . Με αυτή τη συγκεκριμένη στάθμιση οι συχνές οντότητες τιμωρούνται έντονα ώστε να έχουν μικρή συμβολή στην προκύπτουσα

αναπαράσταση του άρθρου. Στο τέλος, κάθε άρθρο αναπαρίσταται από ένα διάνυσμα 600 διαστάσεων.

Επιλογή χαρακτηριστικών Επεκτείνουμε τα αποτελέσματα που δημοσιεύσαμε στο Koopman et al. (2015), τοποθετώντας τις παραπομπές ως πρόσθετες οντότητες στον Σημασιολογικό Πίνακα (βλ. Koopman et al. (2017) για περισσότερες λεπτομέρειες). Προκειμένου να δούμε ποιον ρόλο παίζει η πληροφορία των παραπομπών όσον αφορά την ταξινόμηση, θα πειραματιστούμε συμπεριλαμβάνοντας ή αποκλείοντας τα διανύσματα παραπομπών κατά τον υπολογισμό των σημασιολογικών διανυσμάτων για τα άρθρα (Εξ. 1). Έτσι, για κάθε άρθρο, δημιουργούμε 3 διανύσματα, το ένα είναι ένας σταθμισμένος μέσος όρος όλων των άλλων εκτός από τις παραπομπές (δηλ. θεματικών όρων, θεμάτων, συγγραφέων και

journals, το ίδιο και στο Koopman et al. (2015)), ένα είναι ένας σταθμισμένος μέσος όρος μόνο των οντοτήτων αναφοράς και ένα είναι ένας σταθμισμένος μέσος όρος όλων των τύπων οντοτήτων. Στην ενότητα Sect. 3.1, θα αναφέρουμε τα αποτελέσματα της σύγκρισης.

Τυπικοί αλγόριθμοι συστάδων

Αφού δημιουργηθούν τα διανύσματα άρθρων, το επόμενο βήμα είναι ο εντοπισμός συστάδων άρθρων. Μπορούν να εφαρμοστούν διάφορες μέθοδοι ομαδοποίησης. Πειραματιζόμαστε κυρίως με την μέθοδο K-Means επειδή είναι μια απλή και εξαιρετικά κλιμακούμενη μέθοδος ομαδοποίησης που λειτουργεί απευθείας στις διανυσματικές αναπαραστάσεις των άρθρων. Στόχος μας είναι να ελέγξουμε αν τέτοιες σημασιολογικές αναπαραστάσεις αποδίδουν λογικές συστάδες.

Οι μέθοδοι ομαδοποίησης με βάση το δίκτυο χρησιμοποιούνται ευρέως στην κοινότητα της επιστήμης της επιστήμης. Ως εκ τούτου, προσπαθούμε επίσης να επιλύσουμε το πρόβλημα της ομαδοποίησης από τη σκοπιά του δικτύου. Ως περαιτέρω διαδικασία τέτοιων σημασιολογικών αναπαραστάσεων, μετατρέπουμε τις ομοιότητες που υπολογίζονται με βάση τέτοιες διανυσματικές αναπαραστάσεις σε ένα δίκτυο ομοιότητας άρθρων από το οποίο θα μπορούσαν να εντοπιστούν κοινότητες (συστάδες). Επιλέγουμε να εφαρμόσουμε τη μέθοδο ανίχνευσης κοινοτήτων του Louvain (Blondel et al. 2008), καθώς χρησιμοποιείται ευρέως στην επιστημονικομετρική κοινότητα, αλλά εφαρμόζεται κυρίως σε μοντέλα δεδομένων που βασίζονται σε παραπομπές. Μας ενδιαφέρει να ελέγξουμε αν η μέθοδος Louvain θα μπορούσε επίσης να βρει κοινότητες με βάση τις σημασιολογικές ομοιότητες των άρθρων, αντί των αναφορών μεταξύ τους.

Περιγράφουμε τώρα εν συντομία αυτούς τους δύο τυπικούς αλγορίθμους και τις λεπτομέρειες εφαρμογής στο δικό μας σύνολο δεδομένων.

Ομαδοποίηση με χρήση K-means

Ο αλγόριθμος K-Means είναι ένας από τους απλούστερους αλγορίθμους μάθησης χωρίς επίβλεψη που επιλύει το καλά καθορισμένο πρόβλημα ομαδοποίησης (MacKay 2003, Witten et al. 2011). Κλιμακώνεται καλά σε μεγάλο αριθμό δειγμάτων και έχει χρησιμοποιηθεί σε μεγάλο εύρος εφαρμογών σε πολλούς διαφορετικούς τομείς, συμπεριλαμβανομένης της επιστήμης της επιστήμης (Boyack et al. 2005).

Δεδομένου ενός συνόλου σημείων δεδομένων ή παρατηρήσεων (x_1 , x_2 , …, x_n), όπου κάθε σημείο δεδομένων χαρακτηρίζεται από ένα d-διάστατο πραγματικό διάνυσμα, η ομαδοποίηση k-μέσων αποσκοπεί στην κατάτμηση του n
τα σημεία δεδομένων σε $k(\leq n)$ σύνολα ή συστάδες $S = \{S_1 , S_2 , \ldots, S_k \}$ έτσι ώστε να ελαχιστοποιείται το άθροισμα τετραγώνων εντός της συστάδας (WCSS). Με άλλα λόγια, ο στόχος του αλγορίθμου K-Means είναι η εύρεση

$$\underset{S}{\operatorname{argmin}} \sum_{i=1}^{k} \sum_{x \in S_i} \| x - \mu_i \|^2 \qquad (2)$$

όπου μ_i είναι το κεντροειδές (μέσος όρος) των σημείων στο S_i.

Αυτός ο αλγόριθμος απαιτεί να καθοριστεί εκ των προτέρων ο αριθμός των συστάδων.

Ξεκινά με ένα
αρχικό σύνολο k κεντροειδών $m_1^{(1)}$, …, $m_k^{(1)}$ και προχωρά εναλλάξ σε δύο βήματα
(MacKay 2003):

Βήμα ανάθεσης: Αναθέστε κάθε σημείο δεδομένων στη συστάδα της οποίας ο μέσος όρος αποδίδει το μικρότερο WCCS [1]

$$S^{(t)}_i = \{x_p : \|x_p - m^{(t)}_i\|^2 \leq \|x_p - m^{(t)}_j\|^2 \ \forall j, 1 \leq j \leq k\}, \quad (3)$$

όπου κάθε x_p ανατίθεται σε ακριβώς ένα $S^{(t)}$, ακόμη και αν θα μπορούσε να ανατεθεί σε δύο ή περισσότερα από αυτά.

Βήμα ενημέρωσης: Υπολογίστε τους νέους μέσους όρους ως τα κεντροειδή των σημείων δεδομένων στις νέεςσυστάδες.

$$m^{(t+1)}_i = \frac{1}{|S^{(t)}_i|} \sum_{x_j \in S^{(t)}_i} x_j \quad (4)$$

Ο αλγόριθμος συγκλίνει όταν οι αναθέσεις δεν αλλάζουν πλέον, γεγονός που οδηγεί σε ένα (τοπικό) βέλτιστο, ενώ το παγκόσμιο βέλτιστο δεν είναι εγγυημένο.

Ο αλγόριθμος Mini Batch K-Means (Sculley 2010) είναι μια παραλλαγή του αλγορίθμου K-Means που χρησιμοποιεί μίνι παρτίδες για να μειώσει τον υπολογιστικό χρόνο, ενώ εξακολουθεί να προσπαθεί να βελτιστοποιήσει την ίδια αντικειμενική συνάρτηση. Ο αλγόριθμος λαμβάνει μικρές παρτίδες (τυχαία επιλεγμένες) του συνόλου δεδομένων για κάθε επανάληψη. Στη συνέχεια αναθέτει μια συστάδα σε κάθε σημείο δεδομένων της παρτίδας, ανάλογα με τις προηγούμενες θέσεις των κεντροειδών των συστάδων. Ενημερώνει τις θέσεις των κέντρων των συστάδων με βάση τα νέα σημεία της παρτίδας. Η ενημέρωση είναι μια ενημέρωση με κάθοδο κλίσης, η οποία είναι σημαντικά ταχύτερη από μια κανονική ενημέρωση Batch K-Means.

Η χρήση μίνι-πακέτων μειώνει δραστικά τον υπολογισμό που απαιτείται για τη σύγκλιση σε μια τοπική λύση, αλλά η ποιότητα των αποτελεσμάτων μειώνεται. Στην πράξη αυτή η διαφορά στην ποιότητα μπορεί να είναι αρκετά μικρή (Be´jar 2013). Ως εκ τούτου, επιλέγουμε να χρησιμοποιήσουμε μια εφαρμογή Mini-Batch K-Means που παρέχεται από μια βιβλιοθήκη μηχανικής μάθησης ανοικτού κώδικα για την ομαδοποίηση των άρθρων στο *Astro* Dataset, όπου κάθε άρθρο είναι ένα σημείο δεδομένων στον 600 διαστάσεων σημασιολογικό χώρο , όπως περιγράφεται στην Ενότητα 2.

Ομαδοποίηση με τη μέθοδο Louvain για την ανίχνευση κοινοτήτων

Θεωρούμε κάθε άρθρο ως έναν κόμβο σε ένα δίκτυο και υπάρχει σύνδεση μεταξύ δύο άρθρων όταν αυτά είναι πολύ παρόμοια. Πρακτικά στην περίπτωσή μας, συνδέουμε κάθε άρθρο με τα 40 πιο παρόμοια/σχετιζόμενα άρθρα με βάση τις ομοιότητες συνημίτονου που υπολογίζονται από τη διανυσματική αναπαράστασή τους. Αυτό έχει ως αποτέλεσμα ένα δίκτυο ομοιότητας άρθρων όπου μπορούν να εντοπιστούν συστάδες ή κοινότητες. Ο στόχος είναι να κατατμηθεί το δίκτυο σε κοινότητες πυκνά συνδεδεμένων κόμβων, χωρίς ή με αραιές συνδέσεις μεταξύ των κόμβων που ανήκουν σε διαφορετικές κοινότητες.

Η μέθοδος Louvain (Blondel et al. 2008) είναι μια απλή, αποτελεσματική και αποδεκτή μέθοδος για τον εντοπισμό κοινοτήτων σε μεγάλα δίκτυα. Χρησιμοποιείται ευρέως σε πολλές εφαρμογές σε διάφορους τομείς, συμπεριλαμβανομένης της επιστημονικής μέτρησης (Zhang et al. 2010, Gla¨nzel and Thijs 2017, Zhang et al. 2010). Το εφαρμόζουμε για να δούμε πόσο καλά αποδίδει σε ένα δίκτυο ομοιότητας και όχι σε ένα δίκτυο με βάση τις αναφορές, όπως αυτό που ανέφερε η ομάδα ECOOM σε αυτό το ειδικό τεύχος.

Η ίδια η μέθοδος είναι μια άπληστη μέθοδος βελτιστοποίησης που προσπαθεί να βελτιστοποιήσει την "αρθρωτότητα" ενός τμήματος του δικτύου. Η αρθρωτότητα είναι μια τιμή κλίμακας μεταξύ -1 και 1 που μετρά την πυκνότητα των ακμών εντός των

κοινοτήτων σε σύγκριση με τις ακμές εκτός των κοινοτήτων . Ορίζεται ως Newman (2006):

[1] Δεδομένου ότι το άθροισμα των τετραγώνων είναι το τετράγωνο της ευκλείδειας απόστασης, αυτό είναι διαισθητικά ο "πλησιέστερος" μέσος όρος.

$$Q = \frac{1}{2|E|}\sum_{ij}\left[A_{ij} - \frac{k_i k_j}{2|E|}\right]\delta(c_i, c_j) \qquad (5)$$

όπου $|E|$ είναι ο συνολικός αριθμός ακμών στο δίκτυο, k_i είναι ο βαθμός του κόμβου i, A_{ij} είναι ένα στοιχείο του πίνακα γειτνίασης (π.χ. το βάρος της ακμής μεταξύ i και j), και c_i είναι η κοινότητα στην οποία έχει ανατεθεί ο κόμβος i, και η συνάρτηση d είναι 1 εάν $c_i = c_j$ και 0 διαφορετικά. Η βελτιστοποίηση πραγματοποιείται σε δύο βήματα επαναληπτικά. Στην πρώτη φάση, η μέθοδος αναζητά "μικρές" κοινότητες βελτιστοποιώντας την αρθρωτότητα τοπικά. Κάθε κόμβος ανατίθεται αρχικά σε μια διαφορετική κοινότητα, δηλαδή υπάρχουν τόσες κοινότητες όσοι και οι κόμβοι. Στη συνέχεια, για κάθε κόμβο i υπολογίζεται το κέρδος της αρθρωτότητας μετακινώντας *τον i* από τη δική του κοινότητα στην κοινότητα κάθε γείτονα j του i. Αφού υπολογιστεί αυτή η τιμή για όλες τις κοινότητες με τις οποίες συνδέεται *ο i*, ο i τοποθετείται στην κοινότητα που είχε ως αποτέλεσμα τη μεγαλύτερη αύξηση της αρθρωτότητας. Εάν δεν είναι δυνατόν να προκύψει θετικό κέρδος, *το i* παραμένει στην αρχική του κοινότητα. Αυτή η διαδικασία εφαρμόζεται επανειλημμένα και διαδοχικά σε όλους τους κόμβους μέχρι να μην υπάρχει μπορεί να υπάρξει βελτίωση της αρθρωτότητας και τότε η πρώτη φάση έχει ολοκληρωθεί.

Στη δεύτερη φάση, συγκεντρώνει τους κόμβους που ανήκουν στην ίδια κοινότητα και δημιουργεί ένα νέο δίκτυο του οποίου οι κόμβοι είναι οι κοινότητες της προηγούμενης φάσης. Στη συνέχεια, η πρώτη φάση μπορεί να εφαρμοστεί εκ νέου σε αυτό το νέο δίκτυο. Με αυτόν τον τρόπο, βελτιστοποιεί επαναληπτικά τις τοπικές κοινότητες έως ότου επιτευχθεί ένα μέγιστο της συνολικής αρθρωτότητας.

Σε σύγκριση με τη μέθοδο K-Means, το πλεονέκτημα της χρήσης της μεθόδου Louvain είναι ότι ο αριθμός των διαμερισμάτων ή συστάδων καθορίζεται από τα ίδια τα δεδομένα. Παρόμοια με τη μέθοδο K-Means, η μέθοδος Louvain είναι επίσης μια προσεγγιστική μέθοδος που δεν εγγυάται πραγματικά ένα παγκόσμιο μέγιστο της αρθρωτότητας. Είναι όμως εξαιρετικά κλιμακούμενη και συχνά παράγει καλή προσέγγιση των βέλτιστων κοινοτήτων.

Πειράματα

Εφαρμόσαμε τις δύο προαναφερθείσες μεθόδους ομαδοποίησης στο σύνολο δεδομένων *Astro, το* οποίο περιέχει 111.616 άρθρα αστρονομίας και αστροφυσικής από το 2003 έως το 2010 (βλ. - Gla¨ser et al. (2017) για πλήρη περιγραφή του συνόλου δεδομένων).

Πειράματα με K-means

Προσδιορισμός του K με βάση μια ψευδο-αλήθεια εδάφους

Η αξιολόγηση των αποτελεσμάτων της ομαδοποίησης ή των εντοπισμένων κοινοτήτων είναι ένα πολύπλοκο πρόβλημα. Τα αποτελέσματα θα μπορούσαν να παρουσιαστούν σε εμπειρογνώμονες οι οποίοι αποφασίζουν αν κάθε συστάδα ή κοινότητα είναι έγκυρη ή όχι. Εναλλακτικά, θα μπορούσε να χρησιμοποιηθεί μια βασική αλήθεια, δηλαδή μια κατανομή συστάδων ή κοινοτήτων αναφοράς, για να μετρηθεί πόσο καλά η λύση ομαδοποίησης ταιριάζει με την βασική αλήθεια. Δυστυχώς, οποιοσδήποτε από τους δύο τρόπους είναι εξαιρετικά επίπονος, αν όχι αδύνατος στην περίπτωσή μας.

Αυτό δημιουργεί ένα πρακτικό πρόβλημα κατά την εφαρμογή των K-Means. Μια θεμελιώδης αλήθεια, ή προηγούμενη γνώση των δεδομένων, θα βοηθούσε στον προσδιορισμό μιας από τις πιο σημαντικές παραμέτρους για τον K-Means, την επιλογή

του *k*. Η έλλειψη θεμελιώδους αλήθειας μας αναγκάζει να προσδιορίσουμε *το k* με ρεαλιστικό τρόπο. Η μέση σιλουέτα των δεδομένων (Rousseeuw 1987) είναι ένα μέτρο που θα μπορούσε να χρησιμοποιηθεί για τον προσδιορισμό *του k*. Η σιλουέτα μετρά πόσο στενά ένα σημείο δεδομένων ταιριάζει με άλλα σημεία δεδομένων εντός της συστάδας του και πόσο χαλαρά ταιριάζει με σημεία δεδομένων της γειτονικής συστάδας, δηλαδή της συστάδας της οποίας η μέση απόσταση από το σημείο δεδομένων είναι η μικρότερη. Η σιλουέτα κυμαίνεται από -1 που υποδηλώνει μια λανθασμένη αντιστοίχιση έως 1, μια κατάλληλη αντιστοίχιση, ενώ

βαθμολογίες γύρω από το μηδέν που υποδηλώνουν συστάδες που επικαλύπτονται. Υπολογίσαμε τη μέση σιλουέτα ενός δείγματος 20.000 σημείων δεδομένων με *k* από 10 έως 100. Όπως φαίνεται στο Σχήμα 1, αν και η μέση βαθμολογία σιλουέτας ανεβαίνει αργά, εξακολουθεί να είναι γύρω στο μηδέν. Αυτό σημαίνει ότι οποιοσδήποτε αριθμός συστάδων από αυτό το σύνολο δεδομένων επικαλύπτεται σε μεγάλο βαθμό και ένα σαφές όριο μεταξύ των συστάδων δεν φαίνεται να είναι δυνατό. Αυτό μπορεί να αντικατοπτρίζει τις εγγενώς αλληλένδετες επιστημονικές επικοινωνίες μεταξύ διαφορετικών θεμάτων. Ένας άλλος πιθανός λόγος είναι ότι αυτά τα άρθρα μπορεί να εστιάζουν σε διαφορετικά θέματα του αστροφυσικού τομέα, αλλά μπορεί να εξακολουθούν να χρησιμοποιούν το αλληλεπικαλυπτόμενο λεξιλόγιο, γεγονός που καθιστά δύσκολη την ανίχνευση μιας σαφούς διάκρισης με βάση τις λεξιλογικές πληροφορίες. Δεδομένου ότι υπάρχουν ήδη μερικές λύσεις ομαδοποίησης στο ίδιο σύνολο δεδομένων από διαφορετικές ερευνητικές ομάδες, θα μπορούσαμε να δημιουργήσουμε μια *ψευδο-αλήθεια εδάφους* με βάση τη συναίνεση των διαθέσιμων λύσεων ομαδοποίησης. Συγκεντρώσαμε τέσσερις λύσεις ομαδοποίησης, και συγκεκριμένα τις CWTS- C5, UMSI0, ECOOM-BC13 και STS-RG. Σε όλες αυτές τις τέσσερις λύσεις, υπάρχουν 93.986.261 ζεύγη άρθρων, που αφορούν 96.072 άρθρα (86% του συνόλου των δεδομένων), τα οποία βρίσκονται πάντα στις ίδιες συστάδες. Χρησιμοποιούμε αυτά τα κοινά ζεύγη ως ψευδο-αλήθεια εδάφους. Δεν είναι σε καμία περίπτωση η πραγματική θεμελιώδης αλήθεια, αλλά μια συναίνεση που θα μπορούσαμε να χρησιμοποιήσουμε για να συντονίσουμε το *k* μας ώστε να κάνουμε ένα καλύτερο μαντέψτε.

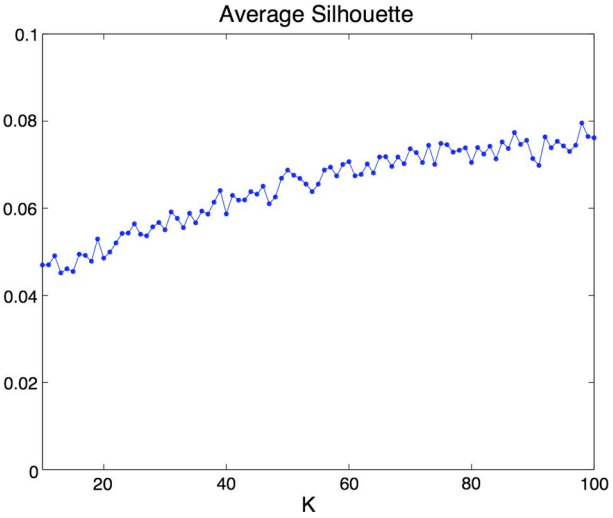
Όπως φαίνεται στον πίνακα 1, οι συστάδες CWTS-C5 παρέχουν τον μικρότερο αριθμό ζευγών άρθρων, ενώ έχουν το μεγαλύτερο ποσοστό που μοιράζονται με τις άλλες τρεις λύσεις. Ενώ οι συστάδες STS- RG είναι ακριβώς το αντίθετο: παράγουν περισσότερα από 940 K ζεύγη άρθρων, αλλά μόνο το 10% των οποίων μοιράζονται με άλλους. Αυτό οφείλεται κυρίως στις 3 μεγαλύτερες συστάδες της, οι οποίες περιέχουν ήδη το 61% του συνόλου των δεδομένων. Παράγουν μεγάλο αριθμό ζευγών άρθρων εντός της συστάδας. Επειδή όμως τα άρθρα αυτά βρίσκονται στις ίδιες συστάδες, ο συνολικός αριθμός των κοινών ζευγών δεν μειώνεται πολύ με τη συμπερίληψη των συστάδων STS-RG. Σημειώστε ότι οι συστάδες STS-RG παράγονται με μια μάλλον διαφορετική μέθοδο από αυτές που χρησιμοποιούνται από τις άλλες τρεις (Velden et al. 2017). Χωρίς τις συστάδες STS-RG, εμπλέκονται 140 εκατ. κοινά ζεύγη και 100 K άρθρα. Ωστόσο, καθώς διαπιστώνουμε ότι η συμπερίληψή τους δεν έχει μεγάλη επίδραση στην επιλογή του *k*, αποφασίσαμε να συμπεριλάβουμε τις συστάδες STS-RG για να δημιουργήσουμε την ψευδο-ομάδα-αλήθεια.

Αυτή η απλή σύγκριση που παρουσιάζεται στον Πίνακα 1 υποδηλώνει επίσης ότι μπορεί να υπάρχει ένα βασικό σύνολο άρθρων των οποίων οι ομαδοποιήσεις είναι μάλλον σταθερές ανεξάρτητα από τη μέθοδο ομαδοποίησης που χρησιμοποιείται. Επομένως, υποστηρίζουμε ότι αυτό το σύνολο 93 εκατομμυρίων *κοινών ζευγών* που αφορούν 96 K άρθρα θα μπορούσε να χρησιμοποιηθεί για την αξιολόγηση νέων λύσεων ομαδοποίησης, όπως τα δικά μας αποτελέσματα του Louvain.

Με αυτή την ψευδο-αλήθεια βάσης, αναζητούμε ένα βέλτιστο *k*. Από τη μία πλευρά, αυτές οι *k* συστάδες συμφωνούν περισσότερο με τις άλλες τέσσερις λύσεις, δηλαδή αναπαράγουν τα περισσότερα κοινά ζεύγη. Από την άλλη πλευρά, οι μεγάλες συστάδες τιμωρούνται εάν τοποθετούν άσχετα άρθρα στις ίδιες συστάδες. Τυπικά μετράμε την ακρίβεια (*p*) και την ανάκληση (*r)* ως εξής:

$$p = \frac{\#\text{ ζεύγη κοινών } \textit{σωματιδίων}}{\#\text{total produced pairs}}, \; r = \frac{\#\text{ ζεύγη κοινών σωματιδίων}}{\#\text{total shared pairs}} \tag{6}$$

όπου *#total* shared pairs είναι ο συνολικός αριθμός των ζευγών άρθρων στην ψευδο-αλήθεια, δηλαδή 93 εκατομμύρια, *#total* produced pairs είναι ο συνολικός αριθμός των ζευγών άρθρων εντός των συστάδων που παράγονται από τις *k* συστάδες, και *#article* pairs in common είναι ο αριθμός των ζευγών άρθρων που παράγονται από τις *k* συστάδες και μοιράζονται επίσης από τις άλλες τέσσερις λύσεις. Ένα υψηλό *p* σημαίνει ότι ένα μεγάλο ποσοστό των παραγόμενων ζευγών άρθρων συμφωνείται από τις άλλες τέσσερις λύσεις, ενώ ένα υψηλό *r* δείχνει ότι ένα μεγάλο ποσοστό των κοινών ζευγών στην ψευδο-αλήθεια παράγεται από τις *k* συστάδες. Μπορεί να επιτευχθεί ανάκληση 100% τοποθετώντας όλα τα άρθρα σε μια συστάδα, αλλά αυτό θα έδινε πολύ χαμηλή ακρίβεια, καθώς η πλειοψηφία των ζευγών άρθρων εντός της συστάδας δεν συμφωνείται από τις άλλες τέσσερις λύσεις. Πολλές μικρές συστάδες θα μπορούσαν να βελτιώσουν την ακρίβεια, καθώς περιέχουν μόνο τα άρθρα που θεωρούνται ότι βρίσκονται στην



Σχήμα 1 Μέση σιλουέτα για 20.000 τυχαία επιλεγμένα δείγματα, με *k* από 10 έως 100

Πίνακας 1 Στατιστικά στοιχεία των τεσσάρων λύσεων ομαδοποίησης για την ψευδο-αλήθεια του εδάφους

	#Cluster	#Συνολικά ζεύγη	Από τα οποία μοιράζονται με τους άλλους (%)
CWTS-C5	22	337,151,232	28
UMSI0	22	453,492,311	21
ECOOM-BC13	13	498,846,580	18
STS-RG	556	940,553,592	10

ίδια συστάδα από τις άλλες τέσσερις λύσεις, ωστόσο, πολλά δυνητικά συναφή άρθρα κατανέμονται σε διαφορετικές συστάδες, γεγονός που βλάπτει την ανάκληση.

Για να εξισορροπήσουμε μεταξύ *p* και *r*, υπολογίζουμε το μέτρο F1[2] όπως χρησιμοποιείται ευρέως στην κοινότητα της Ανάκτησης Πληροφοριών:

$$\mathrm{F1} = 2 \times \frac{p \times r}{p + r} \tag{7}$$

Επιπλέον, υπό την ίδια κατάσταση όσον αφορά την F1, στοχεύουμε σε ένα λογικά υψηλότερο επίπεδο αφαίρεσης, δηλαδή όσο μεγαλύτερες συστάδες τόσο το καλύτερο, υπό την προϋπόθεση ότι περιλαμβάνεται ένας λογικός αριθμός άσχετων άρθρων. Ως εκ τούτου, επιβραβεύουμε μεγαλύτερες συστάδες προσθέτοντας στον υπολογισμό μια παράμετρο του μέσου μεγέθους των συστάδων. Επομένως, η τελική μας βαθμολογία για ένα σύνολο συστάδων υπολογίζεται ως εξής:

$$\mathrm{adjustedF1} = F \times \log(avgSize) \tag{8}$$

Επομένως, επιλέγουμε το καλύτερο *k* που δίνει την υψηλότερη *προσαρμοσμένη* βαθμολογίαF1. Όπως αναφέρθηκε προηγουμένως, θα χρησιμοποιήσουμε αργότερα τη βαθμολογία *adjustedF1* για την αξιολόγηση των αποτελεσμάτων ομαδοποίησης από τη μέθοδο Louvain.

[2] https://en.wikipedia.org/wiki/F1_score.

Αποτελέσματα ομαδοποίησης K-means

Όπως αναφέρθηκε στην Ενότητα 2, κατασκευάζουμε για κάθε άρθρο τρεις διανυσματικές αναπαραστάσεις: μία με μέσο όρο τα σημασιολογικά διανύσματα όλων των οντοτήτων, μία με όλες τις οντότητες εκτός από τις παραπομπές και μία μόνο με τις οντότητες των παραπομπών. Τώρα αναζητούμε το καλύτερο k για αυτές τις τρεις αναπαραστάσεις των άρθρων.

Ο αλγόριθμος K-Means είναι ευαίσθητος στο βήμα αρχικοποίησης, δηλαδή στο πού τοποθετούνται αρχικά τα k κεντροειδή. Ως εκ τούτου, για k από 10 έως 60, εκτελέσαμε 10 φορές τον αλγόριθμο Mini Batch K-Means που παρέχεται στη βιβλιοθήκη scikit-learn python[3] και επιλέξαμε την καλύτερη λύση που έχει το ελάχιστο WCSS. Στη συνέχεια χρησιμοποιήσαμε το μέτρο *adjustedF1* για να αξιολογήσουμε τις λύσεις μας σε σχέση με την ψευδο-αλήθεια του εδάφους. Οι βαθμολογίες *adjustedF1* απεικονίζονται συναρτήσει *του k* στο Σχήμα 2.

Αν χρησιμοποιηθούν όλες οι οντότητες, η βαθμολογία ανεβαίνει μέχρι το k να είναι περίπου 30 και στη συνέχεια μειώνεται, με το $k = 31$ να δίνει την υψηλότερη βαθμολογία. Ως εκ τούτου, επιλέξαμε $k = 31$ ως το καλύτερο k αν χρησιμοποιούνται όλες οι οντότητες για τη σημασιολογική αναπαράσταση του άρθρου. Ομοίως, βρήκαμε το καλύτερο $k = 28$ αν χρησιμοποιούνται μόνο παραπομπές και $k = 24$ αν δεν χρησιμοποιούνται παραπομπές. Ωστόσο, η Εικ. 2β παρουσιάζει, εάν δεν χρησιμοποιούνται παραπομπές, υπάρχουν πολύ μεγαλύτερες διακυμάνσεις, όταν θα μπορούσε να παρατηρηθεί μια παρόμοια καμπύλη ανόδου και καθόδου. Ενώ αν χρησιμοποιούνται μόνο παραπομπές, μια τέτοια καμπύλη δεν παρατηρείται σχεδόν καθόλου.

Ο πίνακας 2 παρουσιάζει τις λεπτομερείς βαθμολογίες ποιότητας αυτών των τριών λύσεων ομαδοποίησης με βάση την ψευδο-αλήθεια εδάφους. Η τελευταία στήλη δίνει τις μέσες βαθμολογίες Adjusted Mutual Information (AMI) Vinh et al. (2010) μεταξύ αυτής της λύσης και των άλλων τεσσάρων λύσεων, δηλαδή των CWTS-C5, UMSI0, ECOOM-BC13 και STS-RG. Βλέπουμε ότι εάν χρησιμοποιούνται μόνο παραπομπές, οι προκύπτουσες συστάδες συμφωνούν περισσότερο με τις άλλες λύσεις ομαδοποίησης από ό,τι εκείνες εάν δεν χρησιμοποιούνται παραπομπές, των οποίων η *προσαρμοσμένη* βαθμολογίαF1 είναι επίσης η χαμηλότερη. Αυτό δεν αποτελεί έκπληξη, καθώς οι άλλες λύσεις ομαδοποίησης βασίζονται σε μεγάλο βαθμό στις πληροφορίες των παραπομπών. Έτσι, ακόμη και αν οι τρόποι χρήσης των παραπομπών είναι διαφορετικοί, οι πληροφορίες των παραπομπών εξακολουθούν να επιφέρουν αρκετή συμφωνία μεταξύ τους. Η χρήση όλων των οντοτήτων για την αναπαράσταση άρθρων έχει το υψηλότερο *προσαρμοσμένο* σκορF1 και συμφωνεί περισσότερο με τις άλλες.

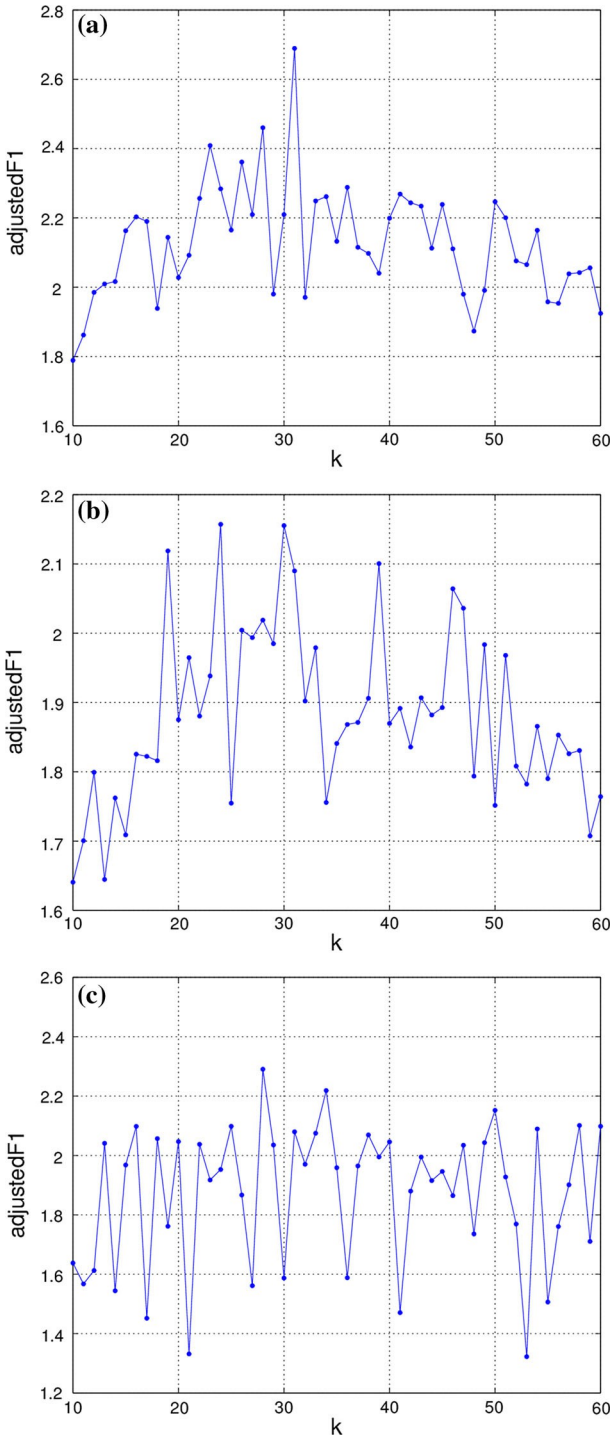
Στον πίνακα 3 δίνονται οι βαθμολογίες AMI μεταξύ αυτών των τριών λύσεων και των συστάδων που βασίζονται στη μέθοδο Louvain. Και πάλι οι συστάδες που βασίζονται μόνο σε παραπομπές συμφωνούν με τα αποτελέσματα της Louvain σχεδόν στον ίδιο βαθμό με εκείνες που χρησιμοποιούν όλες τις οντότητες. Σύμφωνα με αυτά τα μέτρα, αποφασίσαμε να χρησιμοποιήσουμε όλες τις οντότητες ως τελική επιλογή χαρακτηριστικών και να κρατήσουμε αυτές τις 31 συστάδες ως τα τελικά αποτελέσματα K-Means, με την ονομασία OCLC-31. Η κατανομή του μεγέθους αυτών των 31 συστάδων παρουσιάζεται στο Σχήμα 3α: .

Ανίχνευση της κοινότητας με τη μέθοδο Louvain

Διαφορετικά από την τυπική εφαρμογή της μεθόδου Louvain, της οποίας η είσοδος είναι ένα δίκτυο βασισμένο σε παραπομπές, εμείς εφαρμόζουμε τη μέθοδο Louvain σε ένα δίκτυο σημασιολογικής ομοιότητας όπου κάθε κόμβος είναι ένα άρθρο και υπάρχει μια

ακμή μεταξύ δύο άρθρων αν είναι πολύ παρόμοια/σχετικά. Με βάση τα πειράματα με το K-Means, χρησιμοποιούμε και πάλι όλες τις οντότητες για τον υπολογισμό της σημασιολογικής αναπαράστασης των άρθρων. Για κάθε άρθρο, υπολογίσαμε τα 40 πιο όμοια άρθρα των οποίων οι τιμές ομοιότητας είναι υψηλότερες από ένα ορισμένο κατώφλι (στην προκειμένη περίπτωση 0,6) και θεωρούμε ότι αυτό το άρθρο και τα 40 πιο κοντινά ομόλογά του είναι συνδεδεμένα. Μόλις κάθε άρθρο συνδεθεί με τους ομότιμους του, σχηματίζεται ένα δίκτυο ομοιότητας και στη συνέχεια γίνεται μάλλον απλή η εφαρμογή της μεθόδου Louvain για τον εντοπισμό κοινοτήτων ή συστάδων σε αυτό το δίκτυο .

[3] http://scikit-learn.org/.



Σχήμα 2 Αναζήτηση του καλύτερου *k* με βάση το *adjustedF1*, χρησιμοποιώντας διαφορετικά σύνολα οντοτήτων α όλες οι οντότητες, β χωρίς παραπομπές, γ μόνο παραπομπές

Πίνακας 2 Σύγκριση ποιότητας μεταξύ διαφορετικών επιλογών χαρακτηριστικών

	#Clusters	*r*	*p*	f1	ΠροσαρμοσμένοF1	Μέσος όρος AMI σε άλλους
Δεν υπάρχουν παραπομπές	24	0.53	0.17	0.26	2.16	0.44
Μόνο παραπομπές	28	0.58	0.18	0.28	2.29	0.47
Όλες οι οντότητες	31	0.56	0.23	0.33	2.69	0.47
OCLC_Louvain	32	0.61	0.21	0.31	2.57	0.49

Πίνακας 3 Προσαρμοσμένη αμοιβαία πληροφορία μεταξύ των λύσεων

	Δεν υπάρχουν παραπομπές	Μόνο παραπομπές	Όλες οι οντότητες	Louvain
Δεν υπάρχουν παραπομπές	1.00	0.59	0.63	0.56
Μόνο παραπομπές		1.00	0.69	0.65
Όλες οι οντότητες			1.00	0.67
OCLC_Louvain				1.00

Χρησιμοποιούμε τη βιβλιοθήκη networkx της python[4] και την ενότητα ανίχνευσης κοινοτήτων της, η οποία υλοποιεί την ανίχνευση κοινοτήτων χρησιμοποιώντας τη μέθοδο Louvain.[5] Αυτό έχει ως αποτέλεσμα 32 καλύτερες κατατμήσεις (clusters), οι οποίες χαρακτηρίζονται ως OCLC-Louvain, με τη μεγαλύτερη κατάτμηση να περιέχει 9646 άρθρα, τη μικρότερη 86 άρθρα και κατά μέσο όρο 3488 άρθρα, βλέπε Σχήμα 3β. Η ποιότητά του σε σχέση με την ψευδο-αλήθεια του εδάφους δίνεται στον πίνακα 2.

Οι συστάδες Louvain έχουν παρόμοιες επιδόσεις με τις συστάδες K-Means και συμφωνούν περισσότερο με τις άλλες λύσεις ομαδοποίησης. Ωστόσο, το μειονέκτημα της χρήσης της μεθόδου Louvain είναι ότι δεν είναι επεκτάσιμη για ένα μεγαλύτερο σύνολο δεδομένων, καθώς το δίκτυο ομοιότητας είναι ακριβό για να δημιουργηθεί με τη χρήση μιας μετρικής απόστασης, ακόμη και αν ο ίδιος ο αλγόριθμος Louvain είναι σχετικά επεκτάσιμος.

Έλεγχος συναίνεσης

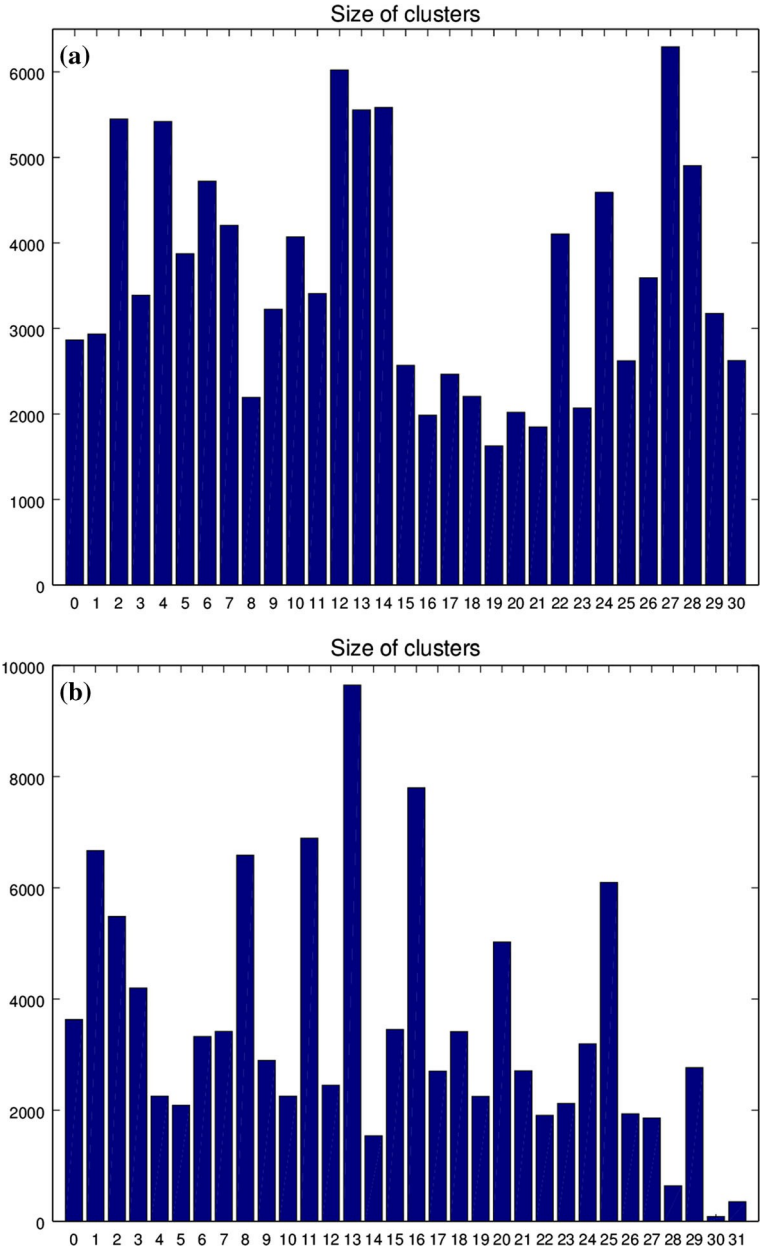
Τώρα μπορούμε να χρησιμοποιήσουμε τυπικά μέτρα συναίνεσης, όπως η προσαρμοσμένη αμοιβαία πληροφορία (Adjusted Mutual Information - AMI) (Vinh et al. 2010), για να ελέγξουμε πόσο συμφωνούν μεταξύ τους οι δύο λύσεις ομαδοποίησης. Ο πίνακας 4 δίνει τη βαθμολογία συναίνεσης μεταξύ αυτών των δύο λύσεων και των άλλων πέντε λύσεων που αναφέρονται σε αυτό το ειδικό τεύχος.[6] Η τελευταία σειρά δίνει το μέσο AMI μεταξύ μιας λύσης ομαδοποίησης και όλων των άλλων λύσεων.

Αυτοί οι αριθμοί υποδηλώνουν ότι το μοντέλο δεδομένων έχει μεγαλύτερη επίδραση στη λύση από ό,τι ο αλγόριθμος που επιλέγεται, επειδή οι OCLC-31 και OCLC-Louvain έχουν τη δεύτερη υψηλότερη τιμή όσον αφορά τη συμφωνία μεταξύ τους (η υψηλότερη συμφωνία είναι μεταξύ των CWTS-C5 και UMSI0, οι οποίες επίσης χρησιμοποιούν το ίδιο μοντέλο δεδομένων). Σύγκριση με STS-RG και ECOOM

[4] https://networkx.github.io/.

[5] http://perso.crans.org/aynaud/communities/.

[6] Τα CWTS-C5 και UMSI0 είναι οι λύσεις ομαδοποίησης που προκύπτουν από δύο διαφορετικές μεθόδους, την Infomap και τον αλγόριθμο έξυπνης τοπικής μετακίνησης (SLMA) αντίστοιχα, οι οποίες εφαρμόζονται στο δίκτυο άμεσων παραπομπών των άρθρων. Οι δύο λύσεις ομαδοποίησης ECOOM παράγονται από την εφαρμογή της μεθόδου Louvain για την εύρεση κοινοτήτων μεταξύ των βιβλιογραφικά συζευγμένων άρθρων, όπου η ECOOM-NLP11 ενσωματώνει επίσης τις πληροφορίες για τις λέξεις-κλειδιά. Οι συστάδες STS-RG δημιουργούνται με την πρώτη προβολή του μικρού συνόλου δεδομένων *Astro* στην πλήρη βάση δεδομένων Scopus και



Σχ. 3 Η κατανομή μεγέθους των δύο λύσεων ομαδοποίησης α OCLC-31, β OCLC-Louvain

λύσεις, οι δύο λύσεις μας συμφωνούν περισσότερο με το CWTS-C5 και το UMSI0, γεγονός που δείχνει ότι

Υποσημείωση 6 συνεχίζεται
συλλέγοντας τις ομαδοποιήσεις τους μετά την ομαδοποίηση των πλήρων άρθρων του Scopus με τη χρήση SLMA στο δίκτυο άμεσων αναφορών. Λεπτομερέστερη περιγραφή μπορεί να βρεθεί στο Velden et al.

(2017).

Πίνακας 4 Έλεγχος συναίνεσης με χρήση προσαρμοσμένης αμοιβαίας πληροφορίας (AMI)

	sr	c	u	eb	en	εντάξει	ol
STS-RG (sr)	1.0	0.44	0.46	0.43	0.34	0.41	0.42
CWTS-C5 (γ)		1.0	0.77	0.47	0.39	0.56	0.61
UMSI0 (u)			1.0	0.47	0.38	0.51	0.55
ECOOM-BC13 (eb)				1.0	0.46	0.46	0.46
ECOOM-NLP11 (el)					1.0	0.41	0.39
OCLC-31 (εντάξει)						1.0	0.67
OCLC-Louvain (ol)							1.0
Μέσος όρος AMI	0.42	0.54	0.52	0.46	0.40	0.50	0.52

ακόμη και με διαφορετικό μοντέλο δεδομένων, τα αποτελέσματα εξακολουθούν να είναι σε μεγάλο βαθμό συγκρίσιμα. Λεπτομερέστερη σύγκριση μπορείτε να βρείτε στο Velden et al. (2017).

Συμπέρασμα

Στην παρούσα εργασία, εφαρμόσαμε δύο μεθόδους συσταδοποίησης για τον εντοπισμό συστάδων στο σύνολο δεδομένων Astro. Διαφορετικά από τις άλλες μεθόδους που παρουσιάζονται σε αυτό το ειδικό τεύχος, κατασκευάσαμε σημασιολογική απεικόνιση για τα άρθρα και προσπαθήσαμε να εντοπίσουμε συστάδες άρθρων με βάση τη σημασιολογική τους ομοιότητα. Δώσαμε τεχνικές λεπτομέρειες και την πορεία λήψης αποφάσεων προς τις δύο λύσεις ομαδοποίησης, μία βασισμένη στη μέθοδο K-Means και μία βασισμένη στη μέθοδο ανίχνευσης κοινοτήτων Louvain. Η σημασιολογική αναπαράσταση των άρθρων βασίζεται σε έναν σημασιολογικό πίνακα στον οποίο συνεισφέρουν τα άρθρα αυτά. Κάθε οντότητα (θεματικοί όροι, θέμα, συγγραφέας, περιοδικό, παραπομπή) αντιπροσωπεύεται από το λεξιλογικό της περιβάλλον που εξάγεται και μειώνεται σε μεγάλο βαθμό από το σώμα κειμένων. Ενσωματώσαμε τα σημασιολογικά διανύσματα όλων των οντοτήτων που εμπλέκονται σε ένα άρθρο ως αναπαράσταση αυτού του άρθρου. Τα πειράματά μας δείχνουν ότι αυτή η ενσωμάτωση της σημασιολογίας των επιμέρους οντοτήτων αντικατοπτρίζει τη σημασιολογία των άρθρων και τα αποτελέσματα της ομαδοποίησης είναι ανταγωνιστικά με άλλες λύσεις ομαδοποίησης που βασίζονται κυρίως σε πληροφορίες παραπομπών.

Θα θέλαμε να τονίσουμε ότι οι δύο μέθοδοι ομαδοποίησης που χρησιμοποιήθηκαν στην παρούσα εργασία είναι μόνο δύο επιλογές που δοκιμάσαμε σε μια τέτοια σημασιολογική αναπαράσταση. Η μέθοδος K-Means είναι εξαιρετικά κλιμακούμενη και παράγει αποτελέσματα με υψηλή συμφωνία με άλλες λύσεις. Ένα πλεονέκτημα είναι ότι είναι εφαρμόσιμη όταν λείπουν δεδομένα παραπομπών. Θα μπορούσε να αποτελέσει ένα πρώτο βήμα ομαδοποίησης για τον διαχωρισμό των άρθρων με βάση τις λεξιλογικές πληροφορίες τους, πριν από την εμβάθυνση σε σχετικά υποσύνολα με πιο λεπτές και πολύπλοκες μεθόδους ομαδοποίησης.

Ευχαριστίες Μέρος αυτής της εργασίας χρηματοδοτήθηκε από τη δράση COST TD1210 Knowescape. Θα θέλαμε να ευχαριστήσουμε τον Jochen Gla¨ser και την Andrea Scharnhorst για εκτενή σχόλια σε προηγούμενες εκδόσεις του κειμένου. Θα θέλαμε επίσης να ευχαριστήσουμε τον εσωτερικό κριτή Michael Heinz καθώς και τους ανώνυμους εξωτερικούς κριτές για τα πολύτιμα σχόλια και τις υποδείξεις τους.

Αναφορές

Achlioptas, D. (2003). Φιλικές προς τη βάση δεδομένων τυχαίες προβολές: Johnson-Lindenstrauss με δυαδικά νομίσματα.
Journal of Computer and System Sciences, *66*(4), 671-687. doi:10.1016/S0022-0000(03)00025-4.

Be´jar, J. (2013). K-means vs mini batch k-means: Μια σύγκριση. Tech. rep., Universitat Polite`cnica de Catalunya. http://upcommons.upc.edu/bitstream/handle/2117/23414/R13-8.pdf.

Blondel, V. D., Guillaume, J. L., Lambiotte, R., & Lefebvre, E. (2008). Γρήγορο ξεδίπλωμα κοινοτήτων σε μεγάλα δίκτυα. *Journal of Statistical Mechanics: Theory and Experiment*, *10*, P10008. (12pp).

Boyack, K. W., Klavans, R., & Bo¨rner, K. (2005). Χαρτογράφηση της ραχοκοκαλιάς της επιστήμης. *Scientometrics*, *64*(3), 351-374.

Boyack, K. W., Small, H., & Klavans, R. (2013). Βελτίωση της ακρίβειας της ομαδοποίησης συν-παραπομπών με χρήση πλήρους κειμένου . *Journal of the American Society for Information Science and Technology*, *64*(9), 1759-1767. doi:10.1002/asi.22896.

Bruckner, E., Ebeling, W., & Scharnhorst, A. (1990). Η εφαρμογή των μοντέλων εξέλιξης στην επιστήμη. *Scientometrics*, *18*(1-2), 21-41. doi:10.1007/BF02019160.

Firth, J.R. (1957). Μια σύνοψη της γλωσσολογικής θεωρίας 1930-1955. *Studies in Linguistic Analysis* pp. 1-32.

Furnas, G. W., Landauer, T. K., Gomez, L. M., & Dumais, S. T. (1983). Στατιστική σημασιολογία: Ανάλυση της δυνητικής απόδοσης των συστημάτων πληροφοριών με λέξεις-κλειδιά. *Bell System Technical Journal*, *62*(6), 17531806. doi:10.1002/j.1538-7305.1983.tb03513.x.

Garfield, E. (1983). *Η θεωρία και η εφαρμογή της στην επιστήμη, την τεχνολογία και τις ανθρωπιστικές επιστήμες*.
Φιλαδέλφεια: ISI Press.

Gla¨nzel, W., & Czerwon, H. J. (1996). Μια νέα μεθοδολογική προσέγγιση της βιβλιογραφικής σύζευξης και η εφαρμογή της σε εθνικό, περιφερειακό και θεσμικό επίπεδο. *Scientometrics*, *37*, 195-221.

Gla¨nzel, W., & Thijs, B. (2017). Χρήση υβριδικών μεθόδων και "βασικών εγγράφων" για την αναπαράσταση συστάδων και θεμάτων. the astronomy dataset. *Scientometrics*. doi:10.1007/s11192-017-2301-6.

Gla¨ser, J., Gla¨nzel, W., & Scharnhorst, A. (2017). Ίδια δεδομένα: διαφορετικά αποτελέσματα; Προς μια συγκριτική προσέγγιση για τον εντοπισμό θεματικών δομών στην επιστήμη. *Scientometrics*. doi:10.1007/s11192- 017-2296-z.

Harris, Z. (1954). Δομή κατανομής. *Word*, *10*(23), 146162.

Johnson, W., & Lindenstrauss, J. (1984). Επεκτάσεις απεικονίσεων Lipschitz σε χώρο Hilbert. *Contemporary Mathematics*, *26*, 189-206.

Koopman, R., Wang, S., & Scharnhorst, A. (2015) .Contextualization of topics-browsing through terms, authors, journals and cluster allocations. In: Salah, A.A., Tonta, Y., Salah, A.A.A., Sugimoto, C.R., Al, U., (Eds.), *Proceedings of ISSI 2015 Istanbul: 15th International Society of Scientometrics and Informetrics Conference, Istanbul, Turkey*, 29 June to 3 July, 2015. Bogazic¸i University Printhouse. http://www.issi2015.org/files/downloads/all-papers/1042.pdf.

Koopman, R., Wang, S., & Scharnhorst, A. (2017). Περιεχομενοποίηση των θεμάτων-περιήγηση στο σύμπαν των βιβλιογραφικών πληροφοριών. Στο J. Gla¨ser, A. Scharnhorst, & W. Gla¨nzel (Eds.), *Same data- different results? Towards a comparative approach to the identification of thematic structures in science*, Special Issue of Scientometrics.

Koopman, R., Wang, S., Scharnhorst, A., & Englebienne, G. (2015). Το νήμα της Αριάδνης: Interactive navi- gation in a world of networked information. In: Begole, B., Kim, J., Inkpen, K., Woo, W., (Eds.), *Proceedings of the 33rd Annual ACM Conference Extended Abstracts on Human Factors in Com- puting Systems, Seoul, CHI 2015 Extended Abstracts, Republic of Korea*, April 18-23, 2015, σελ. 1833-1838. ACM doi:10.1145/2702613.2732781.

Leydesdorff, L. (1989). Λέξεις και συν-λέξεις ως δείκτες διανοητικής οργάνωσης. *Research Policy*, *18*(4), 209-223. doi:10.1016/0048-7333(89)90016-4.

Leydesdorff, L., & Hellsten, I. (2006). Μέτρηση της σημασίας των λέξεων σε περιβάλλοντα: frankenfoods" και "βλαστοκύτταρα". *Scientometrics*, *67*(2), 231-258.

MacKay, D. (2003). Θεωρία πληροφορίας, συμπερασματολογία και αλγόριθμοι μάθησης, κεφ. Κεφάλαιο 20. Ένα παράδειγμα εργασίας εξαγωγής συμπερασμάτων: 284292. Cambridge University Press.

Newman, M. E. (2006). Αρθρωτότητα και δομή της κοινότητας στα δίκτυα. *Proc Natl Acad Sci USA*, *103*(23), 8577-8582. doi:10.1073/pnas.0601602103. http://www.ncbi.nlm.nih.gov/sites/entrez?cmd=retrieve&db=pubmed&list_uids=16723398&dopt=AbstractPlus.

Rip, A., & Courtial, J. P. (1984). Συν-λεκτικοί χάρτες της βιοτεχνολογίας: Ένα παράδειγμα γνωστικής επιστημομετρίας.
Scientometrics, *6*(6), 381-400.

Rousseeuw, P. (1987). Σιλουέτες: Μια γραφική βοήθεια για την ερμηνεία και την επικύρωση της ανάλυσης συστάδων. *Journal of Computational and Applied Mathematics*, *20*(1), 53-65. doi:10.1016/0377-0427(87)90125- 7.

Sahlgren, M. (2008). Η υπόθεση της διανομής. *Rivista di Linguistica*, *20*(1), 3353.

Sculley, D. (2016). Συσταδοποίηση k-means σε κλίμακα ιστού. In: *Proceedings of the 19th International*

Conference on World Wide Web, p. 11771178. Raleigh, NC, HIIA.

Small, H. (1973). Συν-παραπομπή στην επιστημονική βιβλιογραφία: Ένα νέο μέτρο της σχέσης μεταξύ δύο εγγράφων. *Journal of the American Society for Information Science*, *24*, 265-269.

Sugimoto, C. R., & Weingart, S. (2015). Το καλειδοσκόπιο της επιστημονικότητας. *Journal of Documentation*, *71*(4), 775-794. doi:10.1108/JD-06-2014-0082. http://www.scopus.com/inward/record.url?eid=2-s2.0- 84933503812&partnerID=tZOtx3y1.

Velden, T., Boyack, K., van Eck, N., Gla¨nzel, W., Gla¨ser, J., Havemann, F., Heinz, M., Koopman, R., Scharnhorst, A., Thijs, B., & Wang, S. (2017). Σύγκριση προσεγγίσεων εξαγωγής θεμάτων και των αποτελεσμάτων τους. Στο J. Gla¨ser, A. Scharnhorst, & W. Gla¨nzel (Eds.), *Same data-different results? Towards a comparative approach to the identification of thematic structures in science*, Special Issue of Scientometrics.

Vinh, N. X., Epps, J., & Bailey, J. (2010). Θεωρητικά μέτρα πληροφορίας για τη σύγκριση συστάδων: Παραλλαγές, ιδιότητες, κανονικοποίηση και διόρθωση για την τύχη. *Journal of Machine Learning Research*, *11*, 28372854.

Weaver, W. (1955). Μετάφραση. In W. Locke & D. Booth (Eds.), *Machine translation of languages* (pp. 15-23). Cambridge, Μασαχουσέτη: MIT Press.

Witten, I. H., Frank, E., & Hall, M. A. (2011). *Εξόρυξη δεδομένων: niques, third edition edn. The Morgan Kaufmann series in data management systems*. Burlington: Morgan Kaufmann.

Zhang, L., Liu, X., Janssens, F., Liang, L., & Gla¨nzel, W. (2010). Ανάλυση ομαδοποίησης θεμάτων με βάση την ταξινόμηση κατηγοριών ISI . *Journal of Informetrics*, *4*(2), 185-193. doi:10.1016/j.joi.2009.11.005. http:// www.sciencedirect.com/science/article/pii/S1751157709000832.

Zhang, L., Liu, X., Janssens, F., Liang, L., & Gla¨nzel, W. (2010). Ανάλυση ομαδοποίησης θεμάτων με βάση την ταξινόμηση κατηγοριών ISI. *Journal of Informetrics4*(2), 185-193. doi:10.1016/j.joi.2009.11.005. http:// www.sciencedirect.com/science/article/pii/S1751157709000832. Το προ-συνεδριακό σεμινάριο ASIS&ISSI "metrics" και η Παγκόσμια Συμμαχία.