DeepL

Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

Συστήματα βασισμένα στη γνώση 39 (2013)
185-193

Κατάλογοι περιεχομένων διαθέσιμοι στο SciVerse ScienceDirect

Συστήματα βασισμένα στη γνώση

Αρχική σελίδα περιοδικού: www.elsevier.com/locate/knosys

Αποτελεσματική κατασκευή σημασιολογικού δικτύου με εφαρμογή στην αναζήτηση στο PubMed ☆

Jinoh Oh[a], Taehoon Kim[a], Sun Park[a], Hwanjo Yu[a], Young Ho Lee[b,*]

[a] Πανεπιστήμιο Επιστήμης και Τεχνολογίας Pohang (POSTECH), Pohang, Νότια Κορέα
[b] Τμήμα Πληροφορικής, Πανεπιστήμιο Gachon, Incheon, Νότια Κορέα

ΑΡΤΙΚΙΝΦΟ ΤΗΤΑ

Ιστορικό του άρθρου:
Ελήφθη 13 Ιανουαρίου 2012
Παραλήφθηκε σε αναθεωρημένη μορφή 23 Οκτωβρίου 2012 Αποδεκτή 26 Οκτωβρίου 2012
Διαθέσιμο στο διαδίκτυο 16 Νοεμβρίου 2012

Λέξεις-κλειδιά:
Κατασκευή σημασιολογικού δικτύου
Αφαίρεση περιττών σχέσεων PubMed
Αλγόριθμος
Μηχανή ανακύκλωσης πληροφοριών

ΑΒΣΤΡΑΚΤΙΚΌΤΗΤΑ

Η εξερεύνηση του PubMed για την εύρεση σχετικών πληροφοριών είναι δύσκολη και χρονοβόρα, επειδή το PubMed τυπικά επιστρέφει έναν μακρύ κατάλογο άρθρων ως αποτέλεσμα του ερωτήματος. Το σημασιολογικό δίκτυο βοηθά τους χρήστες να εξερευνήσουν μια μεγάλη συλλογή εγγράφων και να αποτυπώσουν βασικές έννοιες και σχέσεις μεταξύ των εννοιών. Το σημασιολογικό δίκτυο χρησιμεύει επίσης για τη διεύρυνση των γνώσεων του χρήστη και την επέκταση της λέξης-κλειδί του ερωτήματος με τον εντοπισμό και την οπτικοποίηση νέων σχετικών εννοιών ή σχέσεων που κρύβονται στα έγγραφα που ανακτώνται. Το πρόβλημα των υφιστάμενων τεχνικών σημασιολογικών δικτύων είναι ότι συνήθως παράγουν πολλές περιττές σχέσεις, γεγονός που εμποδίζει τους χρήστες να συλλάβουν γρήγορα τις υποκείμενες σχέσεις μεταξύ των εννοιών. Η παρούσα εργασία αναπτύσσει ένα επιγραμμικό σύστημα αναζήτησης PubMed, το οποίο εμφανίζει σημασιολογικά δίκτυα που δεν έχουν περιττές σχέσεις σε πραγματικό χρόνο ως αποτέλεσμα ερωτήματος. Για το σκοπό αυτό, προτείνουμε έναν αποτελεσματικό αλγόριθμο κατασκευής σημασιολογικών δικτύων, ο οποίος αποτρέπει την παραγωγή περιττών σχέσεων κατά την κατασκευή του δικτύου. Τα εκτεταμένα πειράματά μας σε πραγματικά δεδομένα PubMed δείχνουν ότι η προτεινόμενη μέθοδος (COMPACT) είναι σημαντικά ταχύτερη από τη μέθοδο που αφαιρεί τις περιττές σχέσεις εκ των υστέρων. Η μέθοδός μας υλοποιείται και ενσωματώνεται σε μια μηχανή αναζήτησης με ανατροφοδότηση συνάφειας PubMed, που ονομάζεται RefMed, "http://dm.postech.ac.kr/ refmed".

© 2012 Elsevier B.V. Όλα τα δικαιώματα διατηρούνται.

1. Εισαγωγή

Το PubMed-Medline είναι ένα αποθετήριο βιοϊατρικής και βιοεπιστημονικής βιβλιογραφίας που περιέχει 18 εκατομμύρια άρθρα και αυξάνεται συνεχώς. Αποτελεί μια από τις σημαντικότερες πηγές γνώσης για τους ιατρούς και τους ερευνητές της βιοϊατρικής. Το PubMed υποστηρίζει ακριβή αναζήτηση με χρήση χαρακτηριστικών όπως τίτλος, συγγραφέας, περίληψη, περιοδικό, όροι MeSH.[1] Ωστόσο, η εξερεύνηση του PubMed για την εύρεση σχετικών πληροφοριών είναι δύσκολη και χρονοβόρα, επειδή το PubMed επιστρέφει συνήθως έναν μακρύ κατάλογο άρθρων ως αποτέλεσμα της αναζήτησης.

Το σημασιολογικό δίκτυο είναι μια προσέγγιση που βελτιώνει την ποιότητα των αποτελεσμάτων αναζήτησης σε μεγάλα σώματα όπως το PubMed [1]. Παρουσιάζει την υποκείμενη σχέση μεταξύ των εννοιών στο σώμα, έτσι ώστε οι χρήστες να κατανοούν βαθιά τη λέξη-κλειδί και να βοηθούν στην επέκταση του ερωτήματος

☆ Η εργασία αυτή υποστηρίχθηκε εν μέρει από το πρόγραμμα Brain Korea 21 Project το 2012 και το πρόγραμμα Mid-career Researcher Program μέσω της επιχορήγησης NRF που χρηματοδοτείται από το MEST (αριθ. KRF- 2011-0016029).

* Ανταποκρινόμενος συγγραφέας. Διεύθυνση: A: Gachon Blg., Πανεπιστήμιο Gachon,
HamBakmoei Street 191, Yeon-su, Incheon, Νότια Κορέα. Τηλ: +82 32 820 4100, φαξ: +82 32 820 4100, φαξ: +82 32 820 4100:
+82 32 820 4109.
Διεύθυνση ηλεκτρονικού ταχυδρομείου: lyh@gachon.ac.kr (Y.H. Lee).

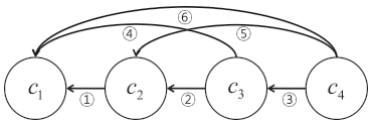
[1] http://www.ncbi.nlm.nih.gov/mesh.

λέξη-κλειδί. Οι τυπικές τεχνικές σημασιολογικών δικτύων αναλύουν τη σχέση μεταξύ εννοιών λαμβάνοντας υπόψη τη συνύπαρξη εννοιών [2-7]. Για παράδειγμα, μία από τις θεμελιώδεις σχέσεις μεταξύ των εννοιών είναι η σχέση υπερ-έννοιας-υποέννοιας. Εάν το σύνολο εγγράφων που εμφανίζει μια συγκεκριμένη έννοια *x* περιλαμβάνεται σε ένα άλλο σύνολο εγγράφων που εμφανίζει μια άλλη έννοια *y*, ονομάζουμε το *y* υπερ-έννοια του *x* και το *x* υποέννοια *του y*.

Το πρόβλημα των υφιστάμενων τεχνικών δημιουργίας σημασιολογικών δικτύων είναι ότι υπάρχουν τόσες πολλές σχέσεις υπερεννοιών-υποεννοιών και πολλές από αυτές είναι περιττές και συνεπώς δεν παρέχουν πρόσθετες πληροφορίες. Αντίθετα, δυσχεραίνουν την ανακάλυψη χρήσιμων υποκείμενων σχέσεων. Για παράδειγμα, στο Σχήμα 1, υπάρχουν έξι σχέσεις υπερ-έννοιας-υποέννοιας. Ωστόσο, μεταξύ αυτών, τρεις σχέσεις (δηλ. σχέση u, v, w) δεν παρέχουν πρόσθετη πληροφορίες στον χρήστη. Ο εντοπισμός και η αφαίρεση τέτοιων περιττών σχέσεων απαιτεί υψηλό υπολογιστικό κόστος. Για να παραδώσουμε πληροφορίες με σαφήνεια, πρέπει να αφαιρέσουμε τις περιττές σχέσεις, ωστόσο, η αφαίρεση τέτοιων περιττών σχέσεων απαιτεί υψηλή πολυπλοκότητα.

Στην παρούσα εργασία, στόχος μας είναι να προτείνουμε μια νέα μέθοδο που κατασκευάζει αποτελεσματικά σημασιολογικό δίκτυο χωρίς περιττές σχέσεις. Η βασική μας παρατήρηση είναι ότι η αποτροπή των περιττών σχέσεων κατά τη διάρκεια της κατασκευής είναι πιο αποτελεσματική από την αφαίρεση των περιττών σχέσεων μετά την κατασκευή. Με βάση την παρατήρηση αυτή, ορίζουμε πρώτα το *ελάχιστο σημασιολογικό δίκτυο* και το *συμπαγές*

0950-7051/$ - βλ. μπροστινό μέρος © 2012 Elsevier B.V. All rights reserved.
http://dx.doi.org/10.1016/j.knosys.2012.10.019



Σχήμα 1. Παράδειγμα περιττών σχέσεων. Οι κόμβοι είναι έννοιες και οι ακμές υποδεικνύουν τις σχέσεις υπερ-έννοιας-υποέννοιας.

σημασιολογικό δίκτυο και ανάπτυξη αλγορίθμου για την κατασκευή του σημασιολογικού δικτύου. Επιπλέον, εφαρμόζουμε την προτεινόμενη μέθοδο COMPACT σε μια πραγματική εφαρμογή που ονομάζεται RefMed. Το RefMed είναι ένα διαδραστικό σύστημα αναζήτησης βασισμένο σε ανατροφοδότηση για το PubMed. Προσθέτουμε νέες λειτουργίες στο RefMed και αξιολογούμε το COMPACT με βάση το ερώτημα του RefMed.

Το υπόλοιπο της παρούσας εργασίας οργανώνεται ως εξής. Η σχετική εργασία συνοψίζεται στην ενότητα 2. Στην ενότητα 4 παρουσιάζεται η προτεινόμενη μέθοδος. Στην ενότητα 5 παρουσιάζεται μια εφαρμογή που αξιοποιεί τη μέθοδο πρότασης σε εργασία ανάκτησης εγγράφων στο PubMed. Τα πειραματικά αποτελέσματα παρουσιάζονται στην ενότητα 6.

2. Σχετικές εργασίες

2.1. Διάφορες προσπάθειες για τη βελτίωση της ποιότητας της αναζήτησης στο PubMed

Για να βελτιώσουν την ποιότητα της αναζήτησης στον PubMed, οι ερευνητές έχουν μελετήσει μεθοδολογίες αναζήτησης για τον PubMed, όπως ο τρόπος χρήσης συμβατικού λεξιλογίου, όρων MeSH ή γνώσεων υποβάθρου για τη διατύπωση κατάλληλων ερωτημάτων στον PubMed [8,9]. Έχει διερευνηθεί η αναδιοργάνωση των αποτελεσμάτων αναζήτησης με τη χρήση οντολογιών ή τεχνικών ομαδοποίησης για την καλύτερη παρουσίαση των αποτελεσμάτων στους χρήστες [10]. Αυτές οι τεχνικές είναι χρήσιμες όταν οι χρήστες δεν γνωρίζουν τι θέλουν εκ των πραγμάτων ή όταν πρέπει να βρουν νέο τομέα. Οι ερευνητές της εξόρυξης κειμένου έχουν επίσης προσπαθήσει να υπολογίσουν τη συνολική σημασία των άρθρων χρησιμοποιώντας τις πληροφορίες παραπομπών και την έχουν εφαρμόσει για την κατάταξη των αποτελεσμάτων, όπως γίνεται στο Google [11,12,10,13]. Αυτές οι τεχνικές μπορούν να βελτιώσουν τη συνολική απόδοση της ανάκτησης εγγράφων και να ανιχνεύσουν άρθρα που δεν περιλαμβάνουν άμεσα τις λέξεις-κλειδιά του ερωτήματος. Οι ερευνητές έχουν επίσης εφαρμόσει τεχνικές μηχανικής μάθησης για την εύρεση σχετικών άρθρων κατατάσσοντας τα άρθρα σύμφωνα με τη μαθημένη συνάρτηση συνάφειας [14,15]. Αυτού του είδους τα αποτελέσματα βοηθούν στην κατάταξη περισσότερων σχετικών άρθρων στην κορυφή της λίστας άρθρων αποτελεσμάτων. Η ανατροφοδότηση συνάφειας, μια καθιερωμένη τεχνική στην IR για τη βελτίωση της απόδοσης ανάκτησης [16,17], έχει εφαρμοστεί στο PubMed (π.χ. MiSearch [18] και RefMed [19]). Αυτή η προσέγγιση είναι ιδιαίτερα χρήσιμη όταν ο χρήστης έχει ήδη συγκεκριμένο ενδιαφέρον, αλλά υποφέρει από τον όγκο των άρθρων αποτελεσμάτων, που συνήθως ξεπερνούν τα 10.000.

2.2. Σημασιολογικό δίκτυο

Ένα σημασιολογικό δίκτυο είναι ένας τρόπος αναπαράστασης της γνώσης ή

υποκείμενη δομή των εννοιών με τη χρήση γραφικών συμβολισμών [1,20-26]. Επιπλέον, σύμφωνα με το σημασιολογικό δίκτυο, το σημασιολογικό δίκτυο. Τα σημασιολογικά δίκτυα με ανθρώπινο σχολιασμό μπορεί να είναι ακριβή, αλλά λιγότερο ευέλικτα και αναποτελεσματικά για να συλλάβουν νέες έννοιες ή θέματα που εξελίσσονται ταχύτατα. Έτσι, οι πρόσφατες έρευνες προσαρμόζουν μια προσέγγιση δυναμικής κατασκευής σημασιολογικών δικτύων για την επίλυση αυτού του προβλήματος [25,26].

Με βάση διάφορα σημασιολογικά δίκτυα, έχουν προταθεί διάφορες προσπάθειες για τη βελτίωση της ποιότητας της αναζήτησης [23-26]. Μεταξύ αυτών, η [26] πρότεινε μια τεχνική αυτόματης δημιουργίας σημασιολογικού δικτύου. Η βασική ιδέα της εργασίας είναι η ανάλυση της δομής του σημασιολογικού δικτύου με την αναδρομική δημιουργία ερωτημάτων χρησιμοποιώντας έννοιες από ανακτημένα έγγραφα. Επιπλέον, προσαρμόζουν την εντροπία από τη θεωρία πληροφοριών και επεξεργάζονται περαιτέρω ανάλυση με βάση το περιεχόμενο και τις μεταπληροφορίες για τα αποτελέσματα αναζήτησης. Ωστόσο, δεδομένου ότι το σημασιολογικό τους δίκτυο παράγεται από την επαναλαμβανόμενη διαδικασία αναζήτησης, είτε επιβαρύνεται με μεγάλο χρονικό κόστος για να εξυπηρετηθεί σε online χρόνο είτε απαιτεί offline στάδιο επεξεργασίας, το οποίο αποδυναμώνει το πλεονέκτημα της αυτόματης δημιουργίας σημασιολογικού δικτύου- μια γρήγορη ανταπόκριση σε νεοπροστιθέμενες έννοιες.

2.3. Σημασιολογικά δίκτυα σε βιοϊατρικές βάσεις δεδομένων

Εμπνευσμένο από την επιτυχία του σημασιολογικού δικτύου στην κοινωνία της ανάκτησης πληροφοριών, μια ποικιλία βιοϊατρικών ή βιολογικών δεδομένων αποθηκεύονται ως σημασιολογικό δίκτυο. Για παράδειγμα, τα MeSHs (Medical Subject Headings), GO (Gene Ontology) [27] και UniProt (Universal Protein) [28] είναι σημασιολογικά δίκτυα για βιοϊατρικούς όρους. Αυτά τα σημασιολογικά δίκτυα πάσχουν από το ίδιο πρόβλημα των γενικών σημασιολογικών δικτύων- απαιτείται μεγάλο κόστος για τη συντήρηση και την ενημέρωση των σημασιολογικών δικτύων και είναι λιγότερο ευέλικτα σε νεοπροστιθέμενες έννοιες. Για παράδειγμα, το MeSH ενημερώνεται μία φορά το χρόνο και συνεπώς είναι πιο αργό στην υιοθέτηση νέων εννοιών. Στην παρούσα εργασία, στοχεύουμε στην ανάπτυξη ενός συστήματος που δημιουργεί δυναμικά σημασιολογικό δίκτυο από τη βάση δεδομένων PubMed.

3. Προκαταρκτικά: στοιχεία του σημασιολογικού δικτύου

Όπως αναφέρεται στο [26], υπάρχουν διάφοροι τύποι σημασιολογικών δικτύων ως εξής. Μεταξύ αυτών, εστιάσαμε στα δίκτυα ισχυρισμού, τα οποία έχουν σχεδιαστεί για να ισχυρίζονται προτάσεις. Η βασική δομή και η διαδικασία κατασκευής του σημασιολογικού δικτύου παρουσιάζονται στο [4,1]. Το σημασιολογικό δίκτυο αποτελείται από έννοιες και σχέσεις μεταξύ των εννοιών. Δύο έννοιες μπορούν να σχετίζονται μεταξύ τους ως σχετικό σύνολο ή ως υπερ-έννοια-υποέννοια στο δίκτυο.

3.1. Έννοια

Μια έννοια σημαίνει σημαντικούς όρους από μια συλλογή εγγράφων. Ένας όρος x_i γίνεται σημαντικός εάν (1) εμφανίζεται περισσότερο από ένα ορισμένο κατώφλι στα αποτελέσματα αναζήτησης και (2) το κλάσμα της πιθανότητας του όρου στα αποτελέσματα αναζήτησης επί της συνολικής συλλογής εγγράφων είναι μεγαλύτερο από ένα κατώφλι [4]. Για παράδειγμα, ένας όρος γίνεται έννοια όταν ικανοποιεί τις ακόλουθες δύο συνθήκες.

p $\frac{\#\text{ της εμφάνισης του όρου } x_i \text{ στο D}}{\text{ν συνήθως κάτι περισσότερο από τη δομή της γνώσης.}}$

παρέχου

Για παράδειγμα, το WordNet είναι ένα από τα γνωστά σημασιολογικά δίκτυα [20]. Πρόκειται για μια λεξιλογική βάση δεδομένων η οποία σχολιάζει διάφορες σχέσεις μεταξύ των αγγλικών λέξεις. Μεταξύ των διαφόρων σχέσεων, μία από τις σημαντικές σχέσεις στο WordNet είναι το *synset,* το οποίο είναι ομάδες συνωνύμων. Επίσης, παρέχει μια σύντομη περιγραφή για κάθε *synset* και διατηρεί διάφορες σημασιολογικές σχέσεις μεταξύ των *synset*. Ομοίως, προτείνονται διάφορα είδη σημασιολογικών δικτύων [21,22,26,25].

Ωστόσο, τα περισσότερα σημασιολογικά δίκτυα έχουν δύο σοβαρά προβλήματα. Αυτά τα σημασιολογικά δίκτυα σχολιάζονται και συντηρούνται χειροκίνητα από ειδικούς του τομέα. Συνεπώς, είναι δαπανηρή η σχολιασμός και η συντήρηση

$$\frac{\#\text{ των εγγράφων στο D}}{\#\text{ των εγγράφων στο T}}(x_i) > h1_c \quad (1)$$

και

$$\frac{p_D(x)_i}{p_T(x_i)} > h2_c \quad (2)$$

όπου *D* και *T* είναι τα ανακτηθέντα έγγραφα και η συνολική συλλογή εγγράφων, αντίστοιχα. Συγκεκριμένα, θέτουμε h_c 1 = 5% για το σύστημά μας. Για παράδειγμα, όταν δημιουργούμε ένα ερώτημα χρησιμοποιώντας τη λέξη-κλειδί "mrsa" στο την εφαρμογή μας, ο όρος "αντίσταση" γίνεται μία από τις έννοιες, επειδή η αντίσταση εμφανίζεται σε 10.484 άρθρα μεταξύ 13.114, επομένως p_D ('" resis- tance") > 0,05. Αντίθετα, κοινοί όροι όπως "η" δεν μπορούν να

να είναι μια έννοια παρόλο που εμφανίζεται περισσότερο από το όριο h_c 1 . Αυτό οφείλεται στο γεγονός ότι ο όρος εμφανίζεται συνήθως και σε άλλα άρθρα και συνεπώς δεν ικανοποιεί τη δεύτερη προϋπόθεση. (Στο σύστημά μας, θέτουμε h_c 2 = 5).

3.2. Σχέση υπερ-έννοιας-υποέννοιας

Η σχέση υπερ-έννοιας-υποέννοιας καθορίζεται με παρόμοιο τρόπο. Εάν το σύνολο εγγράφων του x_i περιλαμβάνεται σχεδόν σε αυτό του x_j αλλά όχι με τον άλλο τρόπο, το x_j είναι μια υπεροχή-υπό-έννοια του x_i.

$$p_D(x_j|x)_i = \frac{p_D(x_i; x_j)}{p_D(x)_i} > h_p \text{ και } p_D(x_i|x_j) < h_p \quad (3)$$

όπου

$$p_D(x_i; x_j) = \frac{\#\text{ των συν-εμφανίσεων των } x_i; x_j}{\#\text{ των εγγράφων στο D}} \quad (4)$$

Σημειώστε ότι όταν η x_j είναι μια υπερ-έννοια της x_i τότε $|x_j| > |x_i|$ όπου $|x|_i$ είναι το μέγεθος των εγγράφων που παρουσιάζουν x_i . Είναι σαφές διότι $P_D(x_i, x_j) > h_p / P_D(x_j) > h_p$ παράδειγμα, $P_D(x_i|x_j) > h_p$. Συγκεκριμένα, θέτουμε h = 0,6. Για υποέννοια του c_3 και το c_3 όταν δημιουργούμε ένα ερώτημα χρησιμοποιώντας τη λέξη-κλειδί "mrsa", ο όρος "chromo- some" γίνεται υποέννοια του "strain" επειδή το 60% των άρθρων που περιλαμβάνουν το χρωμόσωμα περιλαμβάνουν επίσης τον όρο "strain".

3.3. Σημασία των εννοιών

Ας υποθέσουμε ότι ένας όρος εμφανίζεται στο 95% των εγγράφων του αποτελέσματος. Τότε, είναι πιθανό να σχετίζεται σε μεγάλο βαθμό με τους όρους του ερωτήματος, αλλά ο όρος είναι επίσης πιθανότατα πολύ γενικός και όχι πολύ εκπληκτικός (αναμενόμενος από τον χρήστη). Η προσθήκη του όρου στο ερώτημα μπορεί να μη βοηθήσει στη μείωση των αποτελεσμάτων αναζήτησης, καθώς δεν παρέχει πρόσθετες πληροφορίες. Από την άλλη πλευρά, όταν ο όρος είναι πολύ σπάνιος στα αποτελέσματα, είναι λιγότερο πιθανό να σχετίζεται με το ερώτημα και η προσθήκη του όρου στο ερώτημα θα μπορούσε να μειώσει τα αποτελέσματα re- περισσότερο από όσο χρειάζεται. Με βάση τη διαίσθηση, χρησιμοποιούμε το en- tropy για να μετρήσουμε τη σημασία των εννοιών [29,30].

$$G(x_i) = -p_D(x_i) \log(p_D(x))_i \quad (5)$$

Αν ένας όρος εμφανίζεται πολύ συχνά ή πολύ σπάνια, τότε η εντροπία του μειώνεται. Θα αξιολογήσουμε ποιοτικά αυτό το μέτρο στην ενότητα 6.

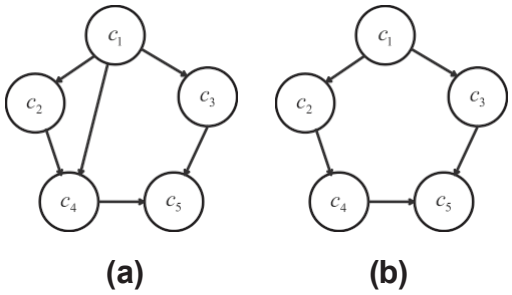
3.4. Σχετικός όρος

Η σχετική σχέση ορίζεται επίσης με βάση την αναλογία συνεμφάνισης δύο εννοιών. Ας υποθέσουμε ότι ένας όρος x_j εμφανίζεται στα περισσότερα έγγραφα που έχουν x_i και αντίστροφα. Τότε, υποδηλώνει ότι υπάρχει ισχυρή σχέση μεταξύ των όρων x_i και x_j . Αυτό ονομάζεται *σχετιζόμενη* σχέση. Για παράδειγμα, οι έννοιες x_i και x_j γίνονται *συναφείς* έννοιες μεταξύ τους εάν ικανοποιούν τις ακόλουθες συνθήκες.

$$p_D(x_i|x_j) > h_s \text{ και } p_D(x_j|x_i) > h_s \quad (6)$$

4. Ευαίσθητη κατασκευή σημασιολογικού δικτύου

Σε αυτή την ενότητα, προτείναμε μια αποτελεσματική μέθοδο κατασκευής σημασιολογικών δικτύων που ονομάζεται COMPACT. Πιο συγκεκριμένα, (1) ορίζουμε τις περιττές σχέσεις με πιο επίσημο τρόπο, (2) εισάγουμε μέθοδο μετα- επεξεργασίας για την αφαίρεση των περιττών σχέσεων, (3) εισάγουμε νέες έννοιες, το συμπαγές δίκτυο και το ελάχιστο δίκτυο,
(4) και προτείνουν μια μέθοδο η οποία αποτρέπει τις περιττές σχέσεις κατά την κατασκευή του δικτύου.



Σχήμα 2. Παράδειγμα περιττών και μη περιττών σχέσεων.

ple, θεωρήστε το Σχήμα 1 ως τις σχέσεις που προκύπτουν από τέσσερις έννοιες. Κάθε κόμβος αναπαριστά μια έννοια και κάθε κατευθυνόμενη ακμή αναπαριστά μια σχέση υπερ-έννοιας-υποέννοιας μεταξύ δύο συνδεδεμένων κόμβων. Μια κατευθυνόμενη ακμή από το c_j στο c_i σημαίνει ότι το c_i είναι υποέννοια του c_j.
Στο Σχήμα 1, το c_1 είναι μια υποέννοια του c_2 , το c_2 είναι μια

4.1. Περιττή σχέση

Η ανίχνευση των σχέσεων υπερεννοιών-υποεννοιών μεταξύ κάθε ζεύγους εννοιών συχνά οδηγεί στη δημιουργία πολλών περιττών σχέσεων που είναι περιττές και συνεπώς πρέπει να αφαιρεθούν. Για παράδειγμα...

είναι υποέννοια της γ_4 . Κατά την ανίχνευση των σχέσεων υπερ-έννοιας-υποέννοιας, η γ_1 είναι πολύ πιθανό να προσδιοριστεί ως υποέννοια της γ_3 . Όμως, αυτή η σχέση δεν παρέχει καμία πρόσθετη πληροφορία, άρα είναι περιττή, αφού η σχέση μπορεί να προκύψει από το γράφημα που έχει το c_1 ως υποέννοια του c_2 και το c_2 ως υποέννοια του c_3 . Ομοίως, οι σχέσεις μεταξύ του c_1 και του c_4 , και του c_2 και του c_4 είναι περιττές. Με βάση αυτή την παρατήρηση, ορίζουμε επίσημα την πλεονάζουσα σχέση ως εξής.

Definition 1 (*πλεονάζουσα σχέση*). Έστω c_i ? c_j δηλώνει ότι η c_i είναι υπερ-έννοια της c_j . Μια σχέση c_i ? c_j είναι περιττή αν υπάρχει άλλη διαδρομή c_i ? c_k ? --- ? c_j στο σημασιολογικό δίκτυο.

Ως άλλο παράδειγμα, αναλογιστείτε το Σχήμα 2α. Η σχέση υπερ-έννοιας-υπο-έννοιας από το c_1 στο c_4 είναι περιττή, επειδή υπάρχει ένα άλλο μονοπάτι c_1 ? c_2 ? c_4 . Σημειώστε ότι, ο ορισμός μας δεν συμπεραίνει ότι ένα μονοπάτι είναι πάντα περιττό αν υπάρχει ένα άλλο μονοπάτι. Για παράδειγμα, παρόλο που υπάρχουν δύο μονοπάτια από το c_1 στο c_5 (δηλαδή, c_1 ? c_2 ? c_4 ? c_5 και c_1 ? c_3 ? c_5), δεν υπάρχει πλέον περιττή σχέση στο Σχήμα 2β. Αυτό οφείλεται στο γεγονός ότι οποιαδήποτε πρόσθετη αφαίρεση ακμής δεν μπορεί να συναχθεί με τη χρήση άλλων διαδρομών.

4.2. Αφαίρεση περιττών σχέσεων

Οι περιττές σχέσεις καθιστούν το γράφημα πολύπλοκο χωρίς να παρέχουν πρόσθετες πληροφορίες και συνεπώς πρέπει να αφαιρεθούν. Οι πλεονάζουσες σχέσεις μπορούν να αφαιρεθούν με την εκ των υστέρων επεξεργασία μετά την κατασκευή του σημασιολογικού δικτύου ή να αποκλειστούν εκ των προτέρων κατά την κατασκευή του σημασιολογικού δικτύου. Στην κρίσιμη για το χρόνο εφαρμογή μας, είναι σημαντικό να τις αφαιρέσουμε αποτελεσματικά. Στο υποκεφάλαιο που ακολουθεί παρουσιάζονται δύο αλγόριθμοι για την αφαίρεση των περιττών σχέσεων.

4.2.1. Αφαίρεση περιττών σχέσεων ως μετα-επεξεργασία

Μπορούμε να εντοπίσουμε και να αφαιρέσουμε τις περιττές σχέσεις αφού κατασκευάσουμε πλήρως το σημασιολογικό δίκτυο με τις περιττές σχέσεις. Έστω R = {(c_i , c_j , *Type*)} το σύνολο των εξαγόμενων σχέσεων και κάθε σχέση εκφράζεται από μια τριπλέτα (c_i , c_j , *Type*) όπου c_i και c_j είναι έννοιες και "Type" είναι ο τύπος της σχέσης μεταξύ c_i και c_j . Για παράδειγμα, μια τριπλέτα (c_i , c_j , *Superconcept*) υποδηλώνει "c_i είναι μια *superconcept* του c_j ". Η μέθοδος μετα-επεξεργασίας εξάγει πρώτα *το R* από το σύνολο εγγράφων και για κάθε τριπλέτα (c_i , c_j , *Superconcept*) ∈ R, εάν υπάρχει άλλο μονοπάτι από *το* c_i στο c_j , αφαιρεί την τριπλέτα από το R. Ο αλγόριθμος μετα-επεξεργασίας περιγράφεται στον Αλγόριθμο 1.

Αλγόριθμος 1. Η μέθοδος μετα-επεξεργασίας για την αφαίρεση περιττών σχέσεων

Είσοδος: ένα σύνολο εννοιών *C*, ένα σύνολο εγγράφων *D*, τα κατώτατα όρια h.
Έξοδος: ένα σύνολο από tripets $R = \{(c_i, c_j, Type)\}$.

```
Ορισμός R :=Ø
// Ανίχνευση σχέσεων
for i = 1 … n do
    for j = 1 … n do
        εάν p(c_i | c_j) > h και p(c_j | c_i) < h τότε
            R:=R ∪ (c_i, c_j, Superconcept)
        end if
    end for
end for
// Αφαίρεση περιττών σχέσεων
για κάθε (c_i, c_j, Type) ∈ R do
    αν Type = = Superconcept και υπάρχει άλλη διαδρομή από το
c_i σε c_j
        R:=R - (c_i, c_j, Superconcept)
    end if
end for
return R
```

Σημειώστε ότι η πολυπλοκότητα του αλγορίθμου είναι τετραγωνική ως προς τον αριθμό των τριπλετών στο *R* ($O(|R|^2)$), επειδή, για κάθε τριπλέτα στο *R*, η εξέταση της πιθανότητας έμμεσων μονοπατιών απαιτεί μια επιπλέον σάρωση του *R*. Στη χειρότερη περίπτωση, ο αριθμός των τριπλετών είναι ανάλογος με τα ζεύγη των εννοιών (δηλαδή, $|R| = O(n^2)$ όπου *n* είναι ο αριθμός των εννοιών). Τότε, η πολυπλοκότητα ως προς τον αριθμό των εννοιών γίνεται $O(n^4)$. Η μέθοδος μετα-επεξεργασίας είναι πολύ ακριβή για να εκτελεστεί στις εφαρμογές μας, όπου το σημασιολογικό δίκτυο πρέπει να κατασκευάζεται σε πραγματικό χρόνο ως αποτέλεσμα ερωτήματος. Στην επόμενη ενότητα παρουσιάζουμε έναν νέο αλγόριθμο για την αποτελεσματική κατασκευή του "συμπαγούς" σημασιολογικού δικτύου, ο οποίος αποκλείει τις περιττές σχέσεις κατά την κατασκευή του σημασιολογικού δικτύου.

4.2.2. Δημιουργία συμπαγούς σημασιολογικού δικτύου

Στην παρούσα ενότητα προτείνεται ένας νέος αλγόριθμος για τη δημιουργία του *σημασιολογικού δικτύου com- pact,* ο οποίος δεν έχει περιττές σχέσεις και, συνεπώς, δεν απαιτεί την εκ των υστέρων αφαίρεση των περιττών σχέσεων. Ο αλγόριθμος εκτελείται σε δύο φάσεις - (1) δημιουργία *ελάχιστου σημασιολογικού δικτύου* και (2) επέκταση του *ελάχιστου σημασιολογικού δικτύου* στο *σημασιολογικό δίκτυο com- pact*.

4.2.2.1. Φάση 1. Δημιουργία του ελάχιστου σημασιολογικού δικτύου. Αρχικά, απο- λεπτοποιούμε δύο νέες ορολογίες - την *πλησιέστερη υπερ- έννοια* και το *ελάχιστο σημασιολογικό δίκτυο*. Ως *πλησιέστερη υπερ-έννοια* ορίζεται η υπερ-έννοια που έχει το μικρότερο μέγεθος υποστηρικτικού εγγράφου:

Definition 2 (*Πλησιέστερη υπερ-έννοια*). Έστω $C_x = \{c_1 \dots c_k\}$ ένα σύνολο υπερ-εννοιών του c_x. Μεταξύ αυτών, η μικρότερη έννοια c_i (δηλαδή $\arg\min_c i\ |c_i|$) είναι η πλησιέστερη υπερ-έννοια του c_x.

Το ακόλουθο Λήμμα δείχνει ότι η σχέση μεταξύ μιας έννοιας c_x και της πλησιέστερης υπερ-έννοιάς της *δεν* είναι πάντοτε *περιττή*.

πλησιέστερη υπερ-έννοια του γ_j. Επομένως, εάν το γ_i είναι η πλησιέστερη υπερ-έννοια του γ_j, *το* γ_i ? γ_j δεν είναι πλεονάζον. H

Ως *ελάχιστο σημασιολογικό δίκτυο* ορίζεται το σημασιολογικό δίκτυο στο οποίο οι κόμβοι έχουν μόνο τις πλησιέστερες υπερέννοιες:

Ορισμός 3 (*Ελάχιστο σημασιολογικό δίκτυο*). Έστω γράφημα $G = (C; R)$.
ένα σημασιολογικό δίκτυο όπου *C* είναι ένα σύνολο εννοιών και *R* είναι ένα σύνολο τριπλετών (*c* , *c* , *Type*). Ένα σημασιολογικό δίκτυο $G' (\subset G) = (C; R' (\subset R))$ είναι ένα
ελάχιστο σημασιολογικό δίκτυο εάν, για όλες τις σχέσεις υπερ-έννοιας-υποέννοιας $R_k = (c_i ; c_j ; Υπερ\text{-}έννοια) \in R'$, *το* c_i είναι το πλησιέστερο υπερ-
έννοια του c_j.

Λήμμα 1. *Για κάθε έννοια* c_x *σε ένα σημασιολογικό δίκτυο G, μια σχέση μεταξύ της* c_x *και της πλησιέστερης υπερέννοιας δεν είναι περιττή.*

Απόδειξη. Το αποδεικνύουμε με αντίφαση. Έστω c_i η πλησιέστερη υπερ-έννοια της c_j (δηλαδή, c_i ? c_j). Για να είναι περιττή η c_i ? c_j, πρέπει να υπάρχει μια ακολουθία $K = c_1$? --- ? c_n που συνδέει τις c_i και c_j (δηλαδή, c_i ? - *K* ? c_j). Τότε, μία από τις έννοιες c_k στο *K* είναι υπερέννοια της c_j και υποέννοια της c_i. Δηλαδή, $|c_k| > |c_j|$ και $|c_k| < |c_i|$ από τον ορισμό της σχέσης υπερέννοια-υποέννοια. Συνεπώς, η c_i δεν μπορεί να είναι η

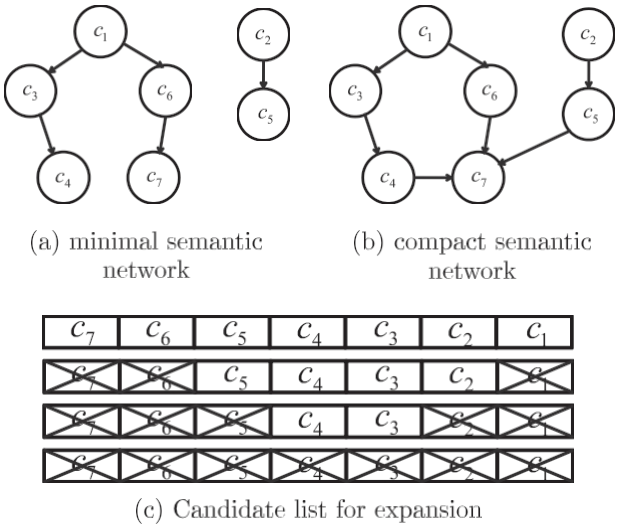
Για να κατασκευάσουμε το ελάχιστο σημασιολογικό δίκτυο, ταξινομούμε πρώτα τις έννοιες $C = \{c_1 ; \ldots ; c_n\}$ ανάλογα με το μέγεθός τους σε αύξουσα σειρά. Στη συνέχεια, για κάθε έννοια c_i , ελέγχουμε τη σχέση υπερ-έννοιας-υπο-έννοιας από c_{i+1} σε c_n και σταματάμε τον έλεγχο όταν βρούμε την πρώτη υπερ-έννοια που θα είναι η πλησιέστερη υπερ-έννοια της c_i . Ο αλγόριθμος περιγράφεται στον Αλγόριθμο 2.

4.2.2.2. Φάση 2. Επέκταση σε συμπαγές σημασιολογικό δίκτυο. Αφού κατασκευαστεί το ελάχιστο σημασιολογικό δίκτυο, το επεκτείνουμε στο συμπαγές σημασιολογικό δίκτυο δημιουργώντας πρόσθετες σχέσεις υπερ-έννοιας-υποέννοιας που δεν είναι περιττές. Αρχικά αποδεικνύουμε με το ακόλουθο Λήμμα ότι, δεδομένου ενός ελάχιστου σημασιολογικού δικτύου G, οποιαδήποτε πρόσθετη σχέση υπερ-έννοιας-υποέννοιας μεταξύ *του* c_i και του προγόνου του c_j θα είναι περιττή.

Λήμμα 2. *Έστω το γράφημα G ένα ελάχιστο σημασιολογικό δίκτυο. Για κάθε έννοια* c_i *και τους προγόνους της* c_1 , … . ,c_k *στο G, κάθε πρόσθετη σχέση υπερ-έννοιας-υποέννοιας από μία από τις* c_1 , … ,c_k *στην* c_i *θα είναι περιττές.*

Είναι προφανές ότι οποιαδήποτε πρόσθετη διαδρομή προς το c_i από τον πρόγονό του c_j (δηλ. c_j ? c_i) είναι περιττή, επειδή υπάρχει άλλη διαδρομή από το c_j στο c_i (δηλ. c_j ? -- - ? c_i) αφού το c_j είναι πρόγονος του c_i . (Σημειώστε ότι ορίσαμε τον πλεονασμό χρησιμοποιώντας την ύπαρξη εναλλακτικής διαδρομής που συνίσταται σε άλλη σχέση υπερ-έννοιας-υποέννοιας). Από το Λήμμα 2, μπορούμε να παραλείψουμε την εξέταση της σχέσης υπερ-έννοιας-υποέννοιας από το c_i στους προγόνους του. Παρουσιάζουμε τον αλγόριθμο επέκτασης με το ακόλουθο παράδειγμα.

Παράδειγμα 1. Τα Σχήματα 3α-γ δείχνουν αντίστοιχα ένα παράδειγμα ελάχιστου σημασιολογικού δικτύου, συμπαγούς σημασιολογικού δικτύου και τέσσερις λίστες εννοιών ταξινομημένες ανάλογα με το μέγεθός τους. Από το ελάχιστο σημασιολογικό δίκτυο, ας υποθέσουμε ότι εξετάζουμε την εύρεση μιας άλλης μη πλεονάζουσας υπερ-έννοιας της c_7 . Τότε, μπορούμε να αποκλείσουμε τις c_7 , c_6 , c_1 από τις



Σχήμα 3. Παράδειγμα επέκτασης σημασιολογικού δικτύου.

εξέταση για πρόσθετη κατασκευή μη πλεονάζοντος υπερ-
Σημείωση

σχέση έννοιας-υποέννοιας επειδή είναι πρόγονοι της γ_7
ή τον εαυτό του (όπως φαίνεται στη δεύτερη λίστα του Σχ. 3γ).
Μετά από αυτό, δοκιμάζουμε το
σχέση μεταξύ των c_5 και c_7 και να βρείτε νέα σχέση υπερ-υπο-
έννοιας από το c στο c . Στη συνέχεια, μπορούμε να αποκλείσουμε
το c
και
c_2 επειδή το c_2 έγινε πρόγονος του c_7 (φαίνεται στην τρίτη λίστα της Εικ. 3γ). Αν επαναλάβουμε αυτή τη διαδικασία μέχρι να ελέγξουμε όλα τα στοιχεία της λίστας, θα ανακαλύψουμε ολόκληρες επιπλέον μη πλεονάζουσες υπερ-έννοιες του c_7 . Αφού το ελέγξουμε αυτό για όλους τους κόμβους του ελάχιστου σημασιολογικού δικτύου, θα έχουμε τελικά το συμπαγές σημασιολογικό δίκτυο του Σχ. 3β.

Αλγόριθμος 2. Δημιουργία συμπαγούς σημασιολογικού δικτύου

Είσοδος: ένας ταξινομημένος κατάλογος εννοιών C, ένα σύνολο εγγράφων D, κατώφλια χρήστη h.
Έξοδος: ένα σύνολο τριπλέτας $R = \{(c_i , c_j , Type)\}$.

```
Ορισμός R :=Ø
// Δημιουργία ελάχιστου σημασιολογικού δικτύου
for i = 1 --- n - 1 do
  for j = i +1 --- n do
    if p(c_j |c_i )> h_p and p(c_i |c_j ) < h_p then
      R:=R ∪ (c_j , c_i , Superconcept);
      Exit loop,
    end if
  end for
end for
// Επέκταση σε συμπαγές σημασιολογικό δίκτυο
for i = 1 --- n - 1 do
  L[1:n] = true
  L[Ancestors of c_i ]=
  false for j = i +1 --- n
  do
    εάν L[j] == true και p(c_i |c_j ) < h_p και p(c_j |c_i )> h_p τότε
      R:=R ∪ (c_j , c_i , Superconcept),
      L[c_j και πρόγονοι του c_j ]= false
    end if
  end for
end for
επιστροφή R
```

Ο αλγόριθμος επέκτασης περιγράφεται στον αλγόριθμο 2.

ότι, p (c_j^D $|c_i^{\frac{pD(c_i;c_j)}{}}$ $_{pD(c_i}$ υπολογίζεται με τη χρήση των εξισώσεων (1) και (4).
Η χρονική πολυπλοκότητα του αλγορίθμου δημιουργίας συμπαγούς σημασιολογικού δικτύου είναι $O(n^2$ h) όπου n είναι ο αριθμός των εννοιών και h είναι το
μέγιστο μήκος διαδρομής από την πιο μεγάλη έννοια. Αυτό είναι...

γιατί, έχουμε έναν βρόχο φωλιάσματος και, για κάθε βρόχο, πρέπει να ξοδέψουμε το πολύ h βήμα για να εξαλείψουμε τους προγόνους από το σύνολο των υποψηφίων.

Αποδεικνύουμε την ορθότητα του προτεινόμενου αλγορίθμου μέσω θεωρητικών αναλύσεων.

Θεώρημα 1. *Ο αλγόριθμος 2 δεν παράγει περιττή σχέση.*

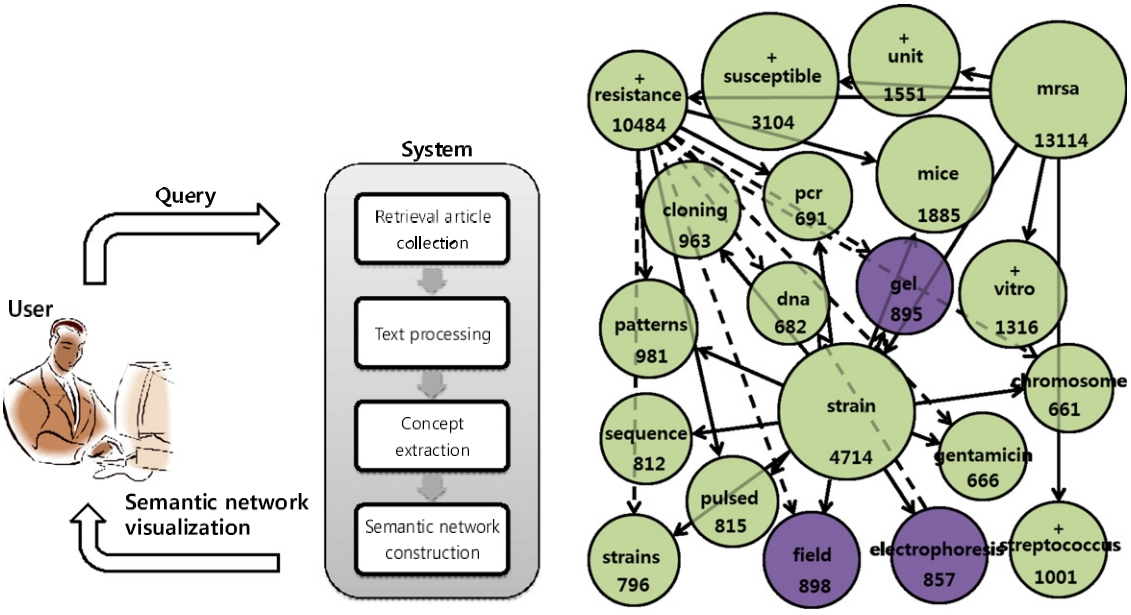
Απόδειξη. Ας υποθέσουμε ότι ο αλγόριθμος 2 παράγει μια πλεονάζουσα σχέση και έστω x_i ? x_j . Εφόσον πρόκειται για πλεονάζουσα σχέση, υπάρχει άλλο μονοπάτι από *το* x_i στο x_j (δηλ. x_i ? --- ? x_j). Ωστόσο, εφόσον υπάρχει μονοπάτι από το x_i στο x_j , *το* x_i αποκλείεται μέσω του Αλγορίθμου 2 κατά την εύρεση της υπερσχέσης του x_j . Απόδειξη με αντίφαση. H

Θεώρημα 2. *Όλες οι πιθανές μη πλεονάζουσες σχέσεις ανιχνεύονται από* Αλγόριθμος 2.

Απόδειξη. Ας υποθέσουμε ότι υπάρχει μια μη ανιχνευμένη μη πλεονάζουσα σχέση και έστω x_i ? x_j . Αφού x_i ? x_j , $|x_i| > |x_j|$. Και επίσης, αφού το x_i ? x_j δεν είναι περιττή σχέση, δεν υπάρχει άλλο μονοπάτι από το x_i στο x_j , πράγμα που σημαίνει ότι το x_i δεν θα αποκλειστεί κατά την εύρεση της υπερ- έννοιας του x_j . Επομένως, ο Αλγόριθμος 2 θα ελέγξει τη σχέση μεταξύ των x_i και x_j και θα βρει τη σχέση. Απόδειξη με αντίφαση.

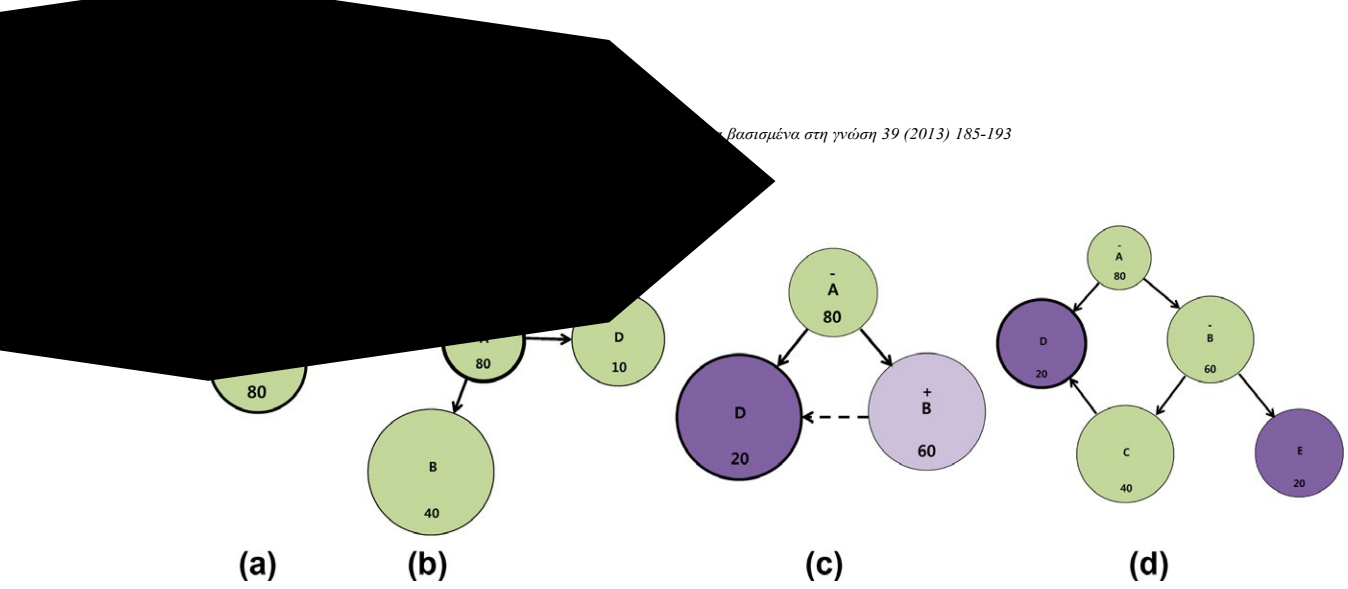
5. Εφαρμογή: RefMed

Αξιολογούμε το COMPACT (αλγόριθμος 2) έναντι του POST (αλγόριθμος 1) που αφαιρεί τον πλεονασμό μετά την κατασκευή. Για την αξιολόγηση, υλοποιήσαμε τις μεθόδους στο RefMed, ένα διαδραστικό πρόγραμμα αναζήτησης για το PubMed. Σε αυτή την ενότητα, παρουσιάζουμε εν συντομία το RefMed, καθώς και τους κανόνες οπτικοποίησης που χρησιμοποιήσαμε για την παρουσίαση του σημασιολογικού δικτύου.



(a) Framework (b) Example of semantic network for “mrsa”

Σχήμα 4. Πλαίσιο του συστήματός μας και παράδειγμα αποτελεσμάτων σημασιολογικού δικτύου με χρήση ενός ερωτήματος του PubMed "mrsa".



Σχήμα 5. Παράδειγμα επέκτασης κόμβων, *συναφών* και πολλαπλών υπερ-εννοιών.

5.1. Επισκόπηση του συστήματος RefMed

Στο Σχήμα 4α παρουσιάζεται το πλαίσιο του συστήματός μας. Εάν ο χρήστης εισάγει μια λέξη-κλειδί, το σύστημα (1) βρίσκει πρώτα ακριβώς τα έγγραφα που ταιριάζουν, όπως στην αρχική μηχανή αναζήτησης PubMed, (2) επεξεργάζεται τα έγγραφα που προκύπτουν εκ των προτέρων εκτελώντας stemming και stopwords, (3) εξάγει τις έννοιες, (4) κατασκευάζει το σημασιολογικό δίκτυο των εννοιών εξάγοντας τη σχέση μεταξύ των εννοιών και (5) τα απεικονίζει σχεδιάζοντας ένα διαδραστικό γράφημα.

Στο Σχήμα 4β παρουσιάζεται ένα παράδειγμα του σημασιολογικού δικτύου που σχεδιάστηκε στο σύστημά μας ως αποτέλεσμα του ερωτήματος "mrsa". Το σημασιολογικό δίκτυο περιέχει συνολικά 123 έννοιες, συμπεριλαμβανομένης της έννοιας του ερωτήματος, 148 σχέσεις υπερέννοιας-υποέννοιας και τρεις *συναφείς* σχέσεις. Το μέγεθος του σημασιολογικού δικτύου είναι ρυθμιζόμενο από τα κατώτατα όρια των εννοιών. Στο σχήμα, ο κόμβος ερωτήματος έχει έξι υποέννοιες και μία από τις υποέννοιες, "strain", περιέχει 13 υποέννοιες. Η έννοια "πηκτή" είναι *συναφής* έννοια με την έννοια "ηλεκτροφόρηση". Η λεπτομερής περιγραφή της δομής του σημασιολογικού δικτύου παρέχεται στην ενότητα 5.2.

5.2. Διαδραστική οπτικοποίηση

Η οπτικοποίηση του σημασιολογικού δικτύου δεν είναι εύκολη υπόθεση λόγω του μεγάλου μεγέθους και της πολύπλοκης δομής του. Το RefMed οπτικοποιεί διαδραστικά το προκύπτον σημασιολογικό δίκτυο για να επιτρέπει στους χρήστες να εξερευνήσουν διαισθητικά το σημασιολογικό δίκτυο. Το RefMed επεκτείνει πρώτα μόνο τις υποέννοιες που προέρχονται από την έννοια του ερωτήματος. Εάν ο χρήστης θέλει να εξερευνήσει βαθύτερα κάποια υπο-έννοια έννοιας, τότε επεκτείνεται ο κόμβος της έννοιας. Τα παρακάτω συνοψίζουν τους βασικούς κανόνες για την οπτικοποίηση του RefMed.

- Κάθε κόμβος αντιπροσωπεύει μια έννοια: το μέγεθος του κόμβου αντικατοπτρίζει τη σημασία της έννοιας που μετράται από την εντροπία συχνότητας που υπολογίζεται με τη χρήση της εξίσωσης (7), και ο αριθμός στον κόμβο είναι η συχνότητα της έννοιας στο σύνολο αποτελεσμάτων.

$$entropy(x_i) = {}_{-pD}(x_i)\log({}_{pD}(x))_i \qquad (7)$$

- Το '+' υποδηλώνει ότι υπάρχουν κρυφές υποέννοιες του κόμβου, οι οποίες θα επεκταθούν όταν κάνετε κλικ σε αυτόν.
- Η κατευθυνόμενη γραμμή υποδεικνύει τη σχέση υπερ-έννοιας-υποέννοιας μεταξύ των κόμβων.

Στο Σχήμα 5 παρουσιάζεται ένα απλό παράδειγμα που εξηγεί τους παραπάνω κανόνες. Το μέγεθος του συνόλου αποτελεσμάτων θεωρείται ότι είναι 100. Το Σχ. 5α δείχνει ότι η ριζική έννοια "A" εμφανίζεται σε 80 άρθρα και υπάρχουν κρυφές υποέννοιες. Όταν γίνεται κλικ στον κόμβο, εμφανίζονται οι υποέννοιες του, όπως φαίνεται στην Εικ. 5β, στην οποία η κατευθυνόμενη γραμμή μεταξύ των "A" και "B" υποδηλώνει ότι η "A" είναι υπερέννοια της "B". Σημειώστε ότι οι κόμβοι των υποεννοιών-εννοιών έχουν διαφορετικά μεγέθη ανάλογα με τις βαθμολογίες σημαντικότητάς τους.

Τα παρακάτω συνοψίζουν τους κανόνες απεικόνισης για το *σχετικό* σύνολο και την κρυφή σχέση υπερ-έννοιας.

- Οι κόμβοι συναφών εννοιών θα χρωματίζονται διαφορετικά όταν ο χρήστης τοποθετεί το σημείο του ποντικιού πάνω σε έναν από τους κόμβους.
- Εάν μία από τις *συναφείς* έννοιες έχει σκιασμένο χρώμα, υποδηλώνει ότι μια υποέννοια του κόμβου με σκιασμένο χρώμα είναι *συναφής* έννοια των άλλων χρωματιστών κόμβων.
- Η διακεκομμένη γραμμή από *το* c_i στο c_j δείχνει ότι μία από τις υποέννοιες του c_i
  έχει μια σχέση υπερ-έννοιας-υποέννοιας με το $c_{,j}$

Στο Σχ. 5γ και δ παρουσιάζεται ένα παράδειγμα που εξηγεί την οπτικοποίηση της *σχετικής* σχέσης και της κρυφής σχέσης υπερ-έννοιας. Στο Σχ. 5γ, οι κόμβοι "B" και "D" χρωματίζονται όταν ο χρήστης τοποθετεί το σημείο του ποντικιού πάνω σε έναν από τους κόμβους. Σημειώστε ότι το σκιασμένο χρώμα του κόμβου "B" υποδηλώνει ότι μια υποέννοια του "B" είναι *συγγενική* έννοια του "D". Υπάρχει επίσης μια διακεκομμένη γραμμή από τον κόμβο "B" στον κόμβο "Δ", η οποία υποδηλώνει ότι μια υποέννοια του κόμβου "B" είναι υπερέννοια του κόμβου "Δ". Ο κόμβος "B" θα αποκαλύψει τις κρυμμένες υποέννοιές του όταν τον πατήσετε, όπως φαίνεται στο Σχήμα 5δ. Στο σχήμα, βλέπουμε ότι οι κόμβοι 'D' και 'E' είναι *συναφείς* έννοιες μεταξύ τους και ο κόμβος 'C' είναι μια υπερέννοια του 'D'.

6. Πειραματικά αποτελέσματα

6.1. Εφαρμογή

Η δυναμική κατασκευή του σημασιολογικού δικτύου υλοποιείται στην PHP (v5.1.6) και στο Adobe Flash CS4. Ο αλγόριθμος υλοποιείται με τη χρήση της PHP και η οπτικοποίηση με τη χρήση του Flash. Η υλοποίηση ενσωματώνεται στο RefMed μας. Το RefMed υλοποιείται με τη χρήση της MySQL (v5.1) και της γλώσσας C. Αποθηκεύουμε το σύνολο των δεδομένων PubMed στο RefMed. Το σύστημά μας είναι προσβάσιμο στη διεύθυνση "http://dm.postech.ac.kr/refmed/". Το σύστημα επί του παρόντος

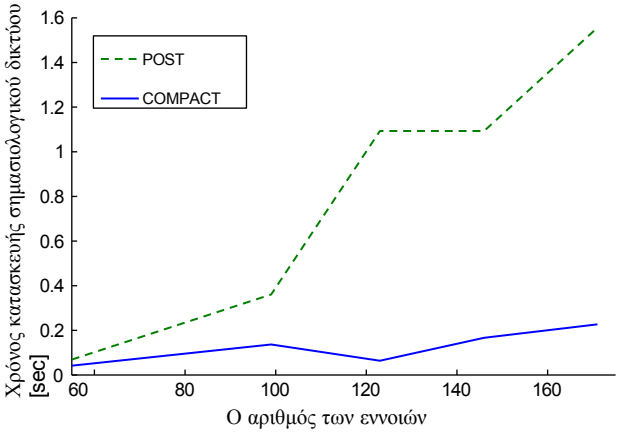
τρέχει σε έναν διακομιστή τετραπύρηνου πυρήνα 2,87 GHz με μνήμη 46 M, επομένως το δεν μπορεί να υποστηρίξει πολλές ταυτόχρονες προσβάσεις σε αυτό το σημείο. Στο σύστημά μας, η αφαίρεση του stemming και των stop words γίνεται για κάθε άρθρο και κάθε άρθρο αναπαρίσταται με τη μορφή διανύσματος tf/idf. Μόλις υποβληθεί ένα ερώτημα λέξης-κλειδί στο σύστημα, ανακτώνται τα αντίστοιχα έγγραφα και κατασκευάζεται ένα σημασιολογικό δίκτυο από τα έγγραφα.

6.2. Αξιολόγηση του χρόνου κατασκευής σημασιολογικού δικτύου

Αξιολογούμε το χρόνο κατασκευής σημασιολογικών δικτύων σε ουρές με αποτελέσματα διαφορετικού μεγέθους. Η κατασκευή ενός δικτύου περιλαμβάνει την καταμέτρηση της συν-εμφάνισης, της συχνότητας και της ανεστραμμένης συχνότητας εγγράφων για κάθε όρο από τα ανακτηθέντα έγγραφα. Δεδομένου ότι αυτό το μέρος είναι κοινό για όλες τις μεθόδους, δεν περιλαμβάνουμε το χρόνο για αυτή τη διαδικασία στη σύγκριση. Ο χρόνος εκτέλεσης της μεθόδου μετα-επεξεργασίας, POST, περιλαμβάνει το χρόνο για την κατασκευή ολόκληρου του δικτύου (τμήμα ανίχνευσης σχέσεων στον αλγόριθμο 1) και την αφαίρεση περιττών σχέσεων (τμήμα αφαίρεσης περιττών σχέσεων στον αλγόριθμο 1). Ομοίως, ο χρόνος εκτέλεσης της προτεινόμενης μεθόδου, COMPACT, περιλαμβάνει το χρόνο για την κατασκευή του ελάχιστου σημασιολογικού δικτύου και του συμπαγούς σημασιολογικού δικτύου. Στον πίνακα 1 αναφέρεται ο χρόνος κατασκευής. Η μέθοδός μας χρειάστηκε λιγότερο από 0,3 δευτερόλεπτα για όλα τα ερωτήματα. Από την άλλη πλευρά, στη χειρότερη περίπτωση, η POST χρειάστηκε περισσότερο από 1,5 s, δηλαδή επτά φορές περισσότερο χρόνο από τη μέθοδό μας.

Πίνακας 1
Χρόνος κατασκευής δικτύου.

Ερώτηση	# Of doc.	# Of concepts	POST (s)	COMPACT (s)
Mrsa	14,345	123	1.0931	0.0638
Αιμορροφιλία	20,039	55	0.0688	0.0417
Μεθυλοτρανσφεράση	28,153	99	0.3606	0.1367
Μελάνωμα	76,274	146	1.0930	0.1665
Κακοήθης	239,278	171	1.5557	0.2269
Κυτταροκίνη	469,843	51	0.1614	0.2204



Σχήμα 6. Η μεταβολή του χρόνου κατασκευής καθώς αυξάνεται ο αριθμός των εννοιών.

Στο Σχήμα 6 απεικονίζεται ο χρόνος κατασκευής σε αυξανόμενο αριθμό εννοιών. Ο χρόνος κατασκευής της POST αυξάνεται ραγδαία καθώς αυξάνεται ο αριθμός των εννοιών. Από την άλλη πλευρά, η μέθοδός μας παράγει σταθερό χρόνο κατασκευής. Αυτό το αποτέλεσμα δεν φαίνεται να έρχεται σε αντίθεση με τα αποτελέσματα της ανάλυσης της χρονικής πολυπλοκότητας, αφού οι χρονικές πολυπλοκότητες των POST και COMPACT είναι $O(n^4)$ και $O(n^2 h)$ αντίστοιχα. Ωστόσο, η χρονική πολυπλοκότητα γράφεται σε μεγάλο όριο O και μπορεί να ποικίλει ανάλογα με την τοπολογία του σημασιολογικού δικτύου. Από τη διερεύνηση των σημασιολογικών δικτύων που προέκυψαν, διαπιστώσαμε ότι τα σημασιολογικά δίκτυα από πραγματικά δεδομένα απέχουν πολύ από το να είναι πλήρη όσον αφορά τις συνδέσεις μεταξύ των κόμβων. Έτσι, ο αριθμός των σχέσεων δύσκολα γίνεται n^2 . Ως αποτέλεσμα, η χρονική διαφορά δεν είναι τόσο μεγάλη όσο περιμέναμε.

6.3. Ποιοτική αξιολόγηση σημασιολογικού δικτύου

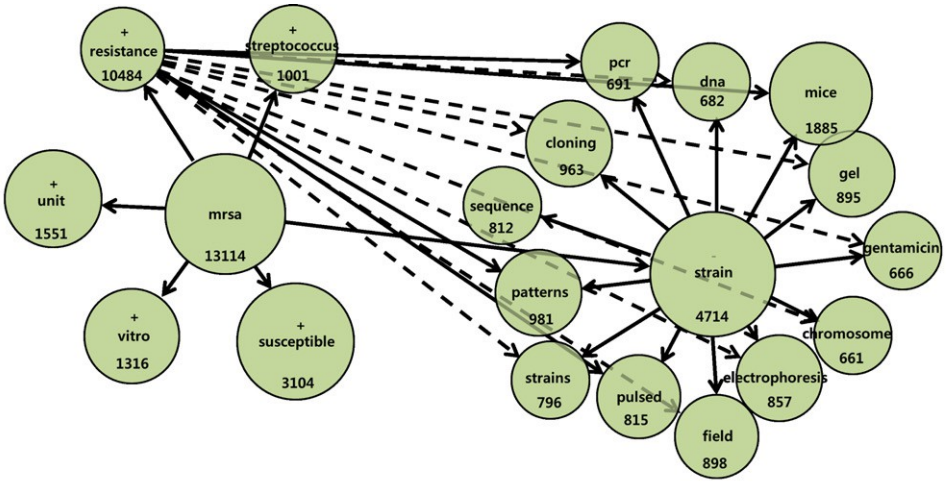
Αξιολογούμε ποιοτικά την αποτελεσματικότητα του συστήματός μας. Αξιολογούμε επίσης το σύστημά μας με ποιοτικό τρόπο. Το Σχ. 7α είναι ένα τυπικό αποτέλεσμα για τη λέξη-κλειδί "mrsa". Σε αυτό το σχήμα, κάθε κόμβος αντιπροσωπεύει την έννοια στο σημασιολογικό δίκτυο και ο αριθμός σε κάθε κόμβο υποδηλώνει την εμφάνιση της έννοιας στα αποτελέσματα αναζήτησης. Σε αυτό το παράδειγμα, το στέλεχος εμφανίζεται σε 4147 άρθρα στα αποτελέσματα αναζήτησης. Στην περίπτωση της αντίστασης, ο όρος αναζήτησης εμφανίζεται σε 10.484 άρθρα. Το μέγεθος της λέξης-κλειδί resistance είναι μικρότερο από αυτό της strain, επειδή η resistance εμφανίζεται πολύ συχνά στον κατάλογο. Επεξεργαστήκαμε την ποιοτική αξιολόγηση προσθέτοντας τους δύο όρους στο ερώτημα ανεξάρτητα και συγκρίνοντας πόσες χρήσιμες πληροφορίες παράγονται από κάθε επέκταση. Επιλέγουμε δύο νέες μη τετριμμένες έννοιες, "resistance" και "strain", που εντοπίστηκαν από το σύστημά μας.

Το Σχήμα 7β είναι ένα αποτέλεσμα της λέξης-κλειδί του ερωτήματος "mrsa resistance". Σημειώστε ότι ο όρος "αντίσταση" δεν θεωρείται καλή έννοια στο σημασιολογικό δίκτυο για το mrsa. Το σημασιολογικό δίκτυο που παράγεται από την εκτεταμένη λέξη-κλειδί "mrsa resistance" παρουσιάζει παρόμοιο αποτέλεσμα σε σύγκριση με εκείνο της αρχικής λέξης-κλειδί "mrsa". Δεν υπάρχουν πολλές νέες έννοιες που προστέθηκαν και ακόμη και το μέγεθος των εννοιών δεν έχει αλλάξει πολύ. Επιπλέον, η δομική διάταξη των εννοιών είναι επίσης παρόμοια με εκείνη της "mrsa" Μπορούμε να συμπεράνουμε ότι η λέξη-κλειδί "αντίσταση" δεν μεταφέρει καμία πρόσθετη πληροφορία, όπως περιμέναμε.

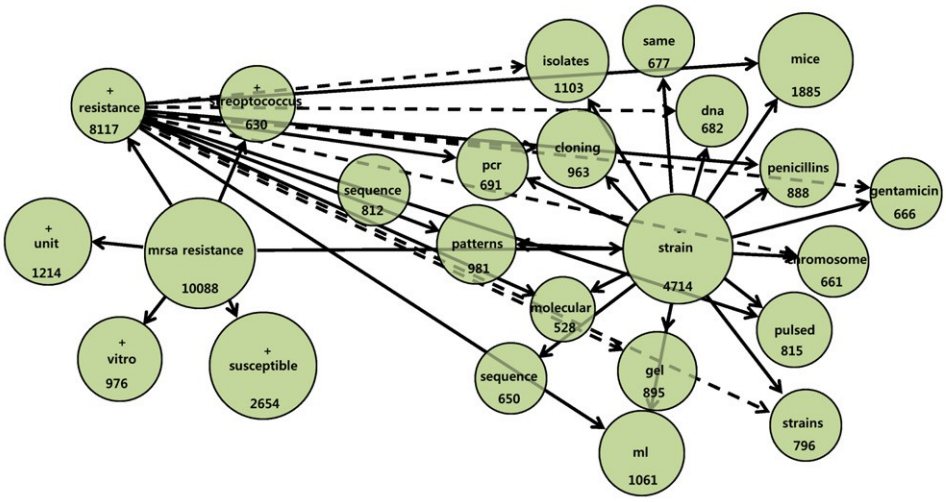
Αναλύσαμε επίσης το αποτέλεσμα της αναζήτησης χρησιμοποιώντας ξανά τη λέξη-κλειδί "mrsa strain" (Εικ. 7γ). Είναι σαφές ότι το αποτέλεσμα του σημασιολογικού δικτύου του "mrsa strain" είναι διαφορετικό από εκείνο του "mrsa". Νέες λέξεις-κλειδιά όπως "oxacillin", "vancomycin", "ciprofloxacin" εμφανίζονται στο σημασιολογικό δίκτυο. Επιπλέον, η δομική διάταξη είναι αρκετά διαφορετική από εκείνη της "mrsa". Από αυτή τη σύγκριση, μπορούμε να συμπεράνουμε ότι η καλοσύνη της έννοιας είναι καλή για την επέκταση των ερωτημάτων.

Κατά τη διάρκεια της εξερεύνησης, μάθαμε ότι το "mrsa" έχει σχέση με διάφορους όρους "resistance", "streptococcus", "susceptible", "strain", "oxacillin", "vancomycin". Στην πραγματικότητα, η λέξη-κλειδί "mrsa" σημαίνει methicilin resistance staphylococcus aureus (σταφυλόκοκκος ανθεκτικός στη μεθικιλίνη), ο οποίος είναι ένας τύπος βακτηρίου που δεν μπορεί να θανατωθεί από αντιβιοτικά. Πιο συγκεκριμένα, το "mrsa" είναι ένα είδος στελέχους (στέλεχος σημαίνει γενετικές παραλλαγές ή υποτύπους ενός μικροοργανισμού), το οποίο έχει αντοχή σε ορισμένα αντιβιοτικά β-λακτάμης, τα οποία περιλαμβάνουν, μεταξύ άλλων, αντιβιοτικά όπως η οξακιλλίνη, η βανκομυκίνη, η

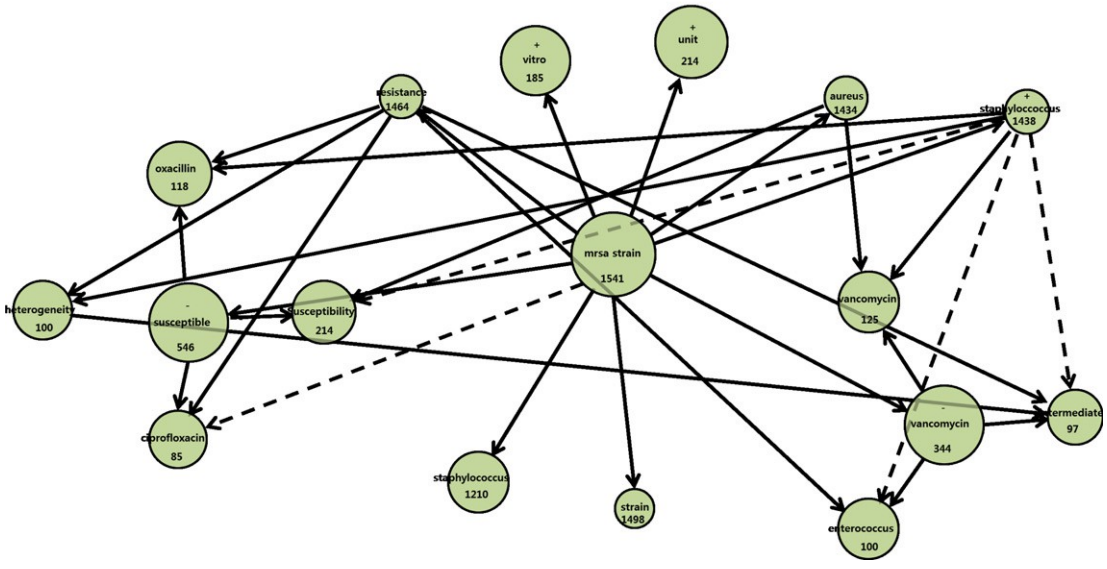
σιπροφλοξασίνη. Ο συγκεκριμένος τύπος mrsa καθορίζεται ανάλογα με τα αντιβιοτικά. Από αυτή τη διερεύνηση, μπορούμε να συμπεράνουμε ότι το σημασιολογικό δίκτυο στο σύστημά μας είναι καλό για τη σύλληψη σημαντικών όρων για τη λέξη-κλειδί του ερωτήματος.



(a) The result of the keyword 'mrsa'



(b) The result of the keyword 'mrsa resistance'



(c) The result of the keyword 'mrsa strain'

Σχήμα 7. Αποτελέσματα αναζήτησης για ποιοτική αξιολόγηση.

7. Συμπεράσματα

Στην παρούσα εργασία, προτείναμε μια αποτελεσματική μέθοδο κατασκευής σημασιολογικού δικτύου. Οι παραδοσιακές μέθοδοι σημασιολογικών δικτύων δημιουργούν πολλές σχέσεις, αλλά οι περισσότερες από αυτές δεν παρουσιάζουν χρήσιμες πληροφορίες . Συνεπώς, αυτές οι περιττές σχέσεις πρέπει να μετακινηθούν εκ νέου ώστε να παρουσιάσουν με σαφήνεια την υποκείμενη σημαντική σχέση μεταξύ των εννοιών. Ωστόσο, η αφαίρεση αυτών των περιττών σχέσεων απαιτεί πολύ χρόνο καθώς αυξάνεται ο αριθμός των εννοιών. Στην παρούσα εργασία προτείνεται μια νέα αποτελεσματική μέθοδος που κατασκευάζει σημασιολογικό δίκτυο χωρίς περιττές σχέσεις. Εφαρμόσαμε τη μέθοδο στο RefMed για να αξιολογήσουμε την αποδοτικότητά της. Ο χρόνος κατασκευής του σημασιολογικού δικτύου της μεθόδου POST αυξάνεται ραγδαία καθώς αυξάνεται ο αριθμός των εννοιών. Αντίθετα, η COMPACT παράγει σταθερό χρόνο κατασκευής και δεν αυξάνεται ραγδαία.

Αναφορές

[1] S. Szumlanski, F. Gomez, Automatically acquiring a semantic network of related concepts, in: ACM International Conference on Information and Knowledge Management, ACM, 2010, σσ. 19-28.

[2] D. Lawrie, W.B. Croft, A. Rosenberg, Finding topic words for hierarchical summarization, in: Proceedings of the 24th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval - SIGIR '01, ACM Press, New York, USA, 2001, pp. 349-357.

[3] D. Lawrie, W.W. Croft, Discovering and comparing topic hierarchies, in: Proceedings of RIAO 2000 Conference, Citeseer, 2000, σσ. 314-330.

[4] M. Sanderson, B. Croft, Deriving concept hierarchies from text, in: Proceedings of the 22nd Annual International ACM SIGIR Conference on Research and Development in Information Retrieval - SIGIR '99, ACM Press, New York, USA, 1999, pp. 206-213.

[5] R. Krishnapuram, K. Kummamuru, Automatic taxonomy generation: issues and possibilities, in: Fuzzy Sets and SystemsIFSA 2003, Springer, 2003, σ. 184.

[6] K. Kummamuru, R. Lotlikar, S. Roy, K. Singal, R. Krishnapuram, A hierarchical monothetic document clustering algorithm for summarization and browsing search results, in: Proceedings of the 13th Conference on World Wide Web - WWW '04, ACM Press, New York, USA, 2004, σ. 658.

[7] C. Carpineto, S. Osiski, G. Romano, D. Weiss, A survey of web clustering engines, ACM Computing Surveys 41 (3) (2009) 1-38.

[8] L.S. Murphy, S. Reinsch, W.I. Najm, V.M. Dickerson, M.A. Seffinger, A. Adams, S.I. Mishra, Searching biomedical databases on complementary medicine: the use of controlled vocabulary among authors, indexers and investigators, BMC Complementary and Alternative Medicine (2003).

[9] C.A. Sneiderman, D. Demner-Fushman, M. Fisaman, N.C. Ide, T.C. Rindflesch, Knowledge-based methods to help clinicians find answers in MEDLINE, Journal of American Medical Informatics Association (2007).

[10] Y. Lin, W. Li, K. Chen, Y. Liu, A document clustering and ranking system for exploring MEDLINE citations, Journal of American Medical Informatics Association (2007).

[11] E. Bernstam, J. Herskovic, Y. Aphinyanaphongs, C. Aliferis, M. Sriram, W. Hersh, Using citation data to improve retrieval from MEDLINE, Journal of the American Medical Informatics Association 13 (2006) 96.

[12] Z. Lu, W. Kim, W.J. Wilbur, Evaluating relevance ranking strategies for MEDLINE retrieval, Journal of American Medical Informatics Association (2009).

[13] M.S. Siadaty, J. Shu, W.A. Knaus, Relemed: sentence-level search engine with relevance score for the MEDLINE database of biomedical articles, BMC Bioinformatics (2007).

[14] B. Suomela, M. Andrade, Ranking the whole MEDLINE database according to a large training set using text indexing, BMC Bioinformatics (2005).

[15] G.L. Poulter, D.L. Rubin, R.B. Altman, C. Seoighe, MScanner: a classifier for retrieving Medline citations, BMC Bioinformatics (2008).

[16] G. Salton, C. Buckley, Improving retrieval performance by relevance feedback, Journal of the American Society for Information Science and Technology 41 (1990) 288-297.

[17] H. Oh, S. Myaeng, M. Lee, A practical hypertext categorization method using links and incrementally available class information, in: Proc. ACM SIGIR Int. Conf. Information Retrieval (SIGIR'00), 2000, σ. 264-271.

[18] D.J. States, A.S. Ade, Z.C. Wright, A.V. Bookvich, B.D. Athey, MiSearch adaptive PubMed search tool, Bioinformatics (2008).

[19] H. Yu, T. Kim, J. Oh, I. Ko, S. Kim, W.-S. Han, Enabling multi-level relevance feedback on PubMed by integrating rank learning into DBMS, BMC Bioinformatics 11 (Suppl. 2) (2010) S6.

[20] C. Fellbaum, WordNet: an electronic lexical database, Language, Speech, and Communication, vol. 71, MIT Press, 1998.

[21] H. Liu, P. Singh, ConceptNet a practical commonsense reasoning tool-kit, BT Technology Journal 22 (4) (2004) 211-226.

[22] F.M. Suchanek, G. Kasneci, G. Weikum, Yago: ένας πυρήνας σημασιολογικής γνώσης, in:
C.L. Williamson, M.E. Zurko, P.F. Patel-Schneider, P.J. Shenoy (Eds.), WWW, WWW '07, vol. 392, ACM Press, 2007, pp. 697-706.

[23] Z. Gong, C.W. Cheang, L.H. U, Web query expansion by WordNet, DEXA05 International Conference on Database and Expert Systems Applications (2005) 166-175.

[24] M.-h. Hsu, M.-f. Tsai, H.-h. Chen, Combining WordNet and ConceptNet for automatic query expansion: a learning approach, Work 4993 (2008) 213-224.

[25] K.W.-t. Leung, W. Ng, D.L. Lee, Personalized concept-based clustering of search engine queries, IEEE Transactions on Knowledge and Data Engineering 20 (11) (2008) 1505-1518.

[26] K.W.-T. Leung, H.Y. Fung, D.L. Lee, Constructing concept relation network and its application to personalized web search, in: Proceedings of the 14th International Conference on Extending Database Technology - EDBT/ICDT '11, 2011, σ. 413.

[27] M. Ashburner, C.A. Ball, J.A. Blake, D. Botstein, H. Butler, J.M. Cherry, A.P. Davis, K. Dolinski, S.S. Dwight, J.T. Eppig, M.A. Harris, D.P. Hill, L. Issel-Tarver, A. Kasarskis, S. Lewis, J.C. Matese, J.E. Richardson, M. Ringwald, G.M. Rubin, G. Sherlock, Gene ontology: tool for the unification of biology, Nature Genetics 25 (1) (2000) 25-29.

[28] R. Apweiler, A. Bairoch, C. Wu, W. Barker, B. Boeckmann, S. Ferro, E. Gasteiger, H. Huang, R. Lopez, M. Magrane, et al., UniProt: the universal protein knowledgebase, Nucleic acids research 32 (Suppl. 1) (2004) D115.

[29] R.M. Gray, Entropy and Information Theory (1990).

[30] K.W.-T. Leung, D.L. Lee, W.-C. Lee, Personalized web search with location preferences, in: ICDE, 2010, σ. 701-712.