Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

Ρητή σημασιολογική κατάταξη για ακαδημαϊκή αναζήτηση μέσω ενσωμάτωσης γράφου γνώσης

Chenyan Xiong*
Ινστιτούτο Γλωσσικών Τεχνολογιών Carnegie Mellon University Pittsburgh, PA, USA
cx@cs.cmu.edu

Russell Power
Allen Institute for Artificial Intelligence
Seattle, WA, ΗΠΑ
russellp@allenai.org

Jamie Callan
Ινστιτούτο Γλωσσικών Τεχνολογιών Carnegie Mellon University Pittsburgh, PA, USA
callan@cs.cmu.edu

ΠΕΡΙΛΗΨΗ

Η παρούσα εργασία παρουσιάζει την Explicit Semantic Ranking (ESR), μια νέα τεχνική κατάταξης που αξιοποιεί το γράφημα γνώσης em- bedding. Η ανάλυση του αρχείου καταγραφής ερωτημάτων από την ακαδημαϊκή μηχανή αναζήτησης, SemanticScholar.org, αποκαλύπτει ότι μια σημαντική πηγή σφαλμάτων είναι η αδυναμία της να κατανοήσει το νόημα των ερευνητικών εννοιών στα ερωτήματα. Για την αντιμετώπιση αυτής της πρόκλησης, η ESR ανα- παρουσιάζει τα ερωτήματα και τα έγγραφα στο χώρο οντοτήτων και τα κατατάσσει με βάση τις σημασιολογικές συνδέσεις τους από την ενσωμάτωση του γράφου γνώσης. Τα πειράματα αποδεικνύουν την ικανότητα του ESR να βελτιώνει το online σύστημα παραγωγής του Semantic Scholar, ιδίως σε δύσκολα ερωτήματα όπου η κατάταξη με βάση τις λέξεις αποτυγχάνει.

Λέξεις-κλειδιά

Ακαδημαϊκή αναζήτηση, κατάταξη βάσει οντοτήτων, γράφος γνώσης

1. ΕΙΣΑΓΩΓΗ

Το Semantic Scholar (S2) ξεκίνησε στα τέλη του 2015, με στόχο να βοηθήσει τους ερευνητές να βρουν εργασίες χωρίς να ψάχνουν σε άσχετες πληροφορίες. Το έργο ήταν επιτυχημένο, με πάνω από 3 εκατομμύρια επισκέψεις τον τελευταίο χρόνο. Το σημερινό σύστημα κατάταξης της παραγωγής του βασίζεται στο μοντέλο βασισμένο σε λέξεις του ElasticSearch, το οποίο αντιστοιχίζει τους όρους του ερωτήματος με διάφορα μέρη μιας εργασίας, σε συνδυασμό με χαρακτηριστικά εγγράφων, όπως ο αριθμός των παραπομπών και ο χρόνος δημοσίευσης σε ένα σύστημα μάθησης για την κατάταξη του αρχείου [15]. Σε μελέτες χρηστών που πραγματοποιήθηκαν στο Ινστιτούτο Allen, αυτό το μοντέλο κατάταξης παρέχει τουλάχιστον συγκρίσιμη ακρίβεια με άλλες ακαδημαϊκές μηχανές αναζήτησης.

Από την ανάλυση των αρχείων καταγραφής ερωτημάτων του S2 διαπιστώθηκε ότι ένα μεγάλο μέρος της διαδικτυακής κίνησης είναι ad-hoc ερωτήματα σχετικά με έννοιες της επιστήμης των υπολογιστών ή ερευνητικά θέματα. Οι ανάγκες πληροφόρησης που κρύβονται πίσω από τέτοια ερωτήματα είναι μερικές φορές δύσκολο να ικανοποιηθούν από τα μοντέλα κατάταξης που βασίζονται στη συχνότητα όρων. Για παράδειγμα, ένας χρήστης που εισάγει το ερώτημα "δυναμικός προγραμματισμός τμηματοποίησης" έχει ένα πολύπλοκο

*Μέρος αυτής της εργασίας έγινε όταν ο πρώτος συγγραφέας εργαζόταν στο Ινστιτούτο Τεχνητής Νοημοσύνης Allen.

©2017 International World Wide Web Conference Committee (IW3C2), δημοσιευμένο με άδεια Creative Commons CC BY 4.0. *WWW 2017,* 3-7 Απριλίου 2017, Περθ, Αυστραλία.
ACM 978-1-4503-4913-0/17/04.
http://dx.doi.org/10.1145/3038912.3052558

σημασιολογική πρόθεση, η οποία περιγράφεται κατά προσέγγιση ως "δείξε μου NLP pa- pers που χρησιμοποιούν αλγορίθμους δυναμικού προγραμματισμού για την επίλυση του προβλήματος τμηματοποίησης λέξεων". Η ανάλυση σφαλμάτων που κάναμε χρησιμοποιώντας τα κλικ των χρηστών διαπίστωσε ότι τα μοντέλα κατάταξης που βασίζονται σε λέξεις μερικές φορές αποτυγχάνουν να συλλάβουν το σημασιολογικό νόημα πίσω από τέτοια ερωτήματα. Αυτό αποτελεί μια σημαντική πηγή σφαλμάτων στην κατάταξη του S2.

Η παρούσα εργασία παρουσιάζει την ρητή σημασιολογική κατάταξη (Explicit Semantic Ranking - ESR),
μια νέα τεχνική κατάταξης για τη σύνδεση ερωτήματος και εγγράφων με τη χρήση σημασιολογικών πληροφοριών από ένα γράφο γνώσης. Αρχικά, κατασκευάζουμε έναν ακαδημαϊκό γράφο γνώσης χρησιμοποιώντας το σώμα κειμένων του S2 και την Freebase. Ο γράφος γνώσης περιλαμβάνει τις έννοιες, τις περιγραφές τους, τις συσχετίσεις πλαισίου, τις σχέσεις με τους συγγραφείς και τους τόπους διεξαγωγής και τις ενσωματώσεις που εκπαιδεύονται από τη δομή του γράφου. Εφαρμόζουμε αυτό το γράφημα γνώσης και τις εμφυτεύσεις στην εργασία κατάταξης. Τα ερωτήματα και τα έγγραφα αναπαρίστανται από οντότητες στο γράφο γνώσης, παρέχοντας "έξυπνη διατύπωση" για την κατάταξη. Η σημασιολογική συγγένεια μεταξύ των οντοτήτων των ερωτημάτων και των εγγράφων υπολογίζεται στο χώρο ενσωμάτωσης, ο οποίος παρέχει μια ήπια αντιστοίχιση μεταξύ σχετικών οντοτήτων. Το ESR χρησιμοποιεί ένα pooling δύο σταδίων για να γενικεύσει αυτές τις αντιστοιχίες με βάση τις οντότητες σε χαρακτηριστικά κατάταξης ερωτημάτων-εργα- λείων και χρησιμοποιεί ένα μοντέλο μάθησης για την κατάταξη για να τις συνδυάσει.

Η ρητή σημασιολογία από τον γράφο γνώσης έχει τη δυνατότητα να βελτιώσει την κατάταξη με πολλαπλούς τρόπους. Οι οντότητες και τα επιφανειακά ονόματα βοηθούν το μοντέλο κατάταξης να αναγνωρίσει ποιο μέρος ενός ερωτήματος είναι μια πληροφοριακή μονάδα και αν διαφορετικές φράσεις έχουν την ίδια σημασία, παρέχοντας ένα ισχυρό σήμα *ακριβούς αντιστοιχίας*. Οι ενσωματώσεις οντοτήτων από το γράφημα γνώσης μπορούν επίσης να αξιοποιηθούν για την παροχή ενός σήματος *ήπιας αντιστοίχισης*, επιτρέποντας την κατάταξη εγγράφων που σχετίζονται σημασιολογικά αλλά δεν ταιριάζουν με τους ακριβείς όρους του ερωτήματος. Τα πειράματά μας στο σύνολο δεδομένων αναφοράς κατάταξης του S2 αποδεικνύουν την αποτελεσματικότητα αυτής της ρητής σημασιολογίας. Το ESR βελτιώνει το ήδη αξιόπιστο online σύστημα παραγωγής του S2 κατά περισσότερο από 10%. Τα κέρδη είναι εύρωστα, με μεγαλύτερα κέρδη και μικρότερα σφάλματα, και επίσης ευνοούν τις κορυφαίες θέσεις κατάταξης. Περαιτέρω ανάλυση επιβεβαιώνει ότι τόσο η ακριβής αντιστοίχιση όσο και η μαλακή αντιστοίχιση στο χώρο των εν- ταυτοτήτων παρέχουν αποτελεσματικά και νέα σήματα κατάταξης. Αυτά τα σήματα αξιοποιούνται με επιτυχία από το πλαίσιο κατάταξης του ESR και βελτιώνουν σημαντικά τα ερωτήματα που το σύστημα κατάταξης με βάση τις λέξεις του S2 δυσκολεύεται να αντιμετωπίσει.

Στο υπόλοιπο της παρούσας εργασίας, η Ενότητα 2 αναλύει τις σχετικές εργασίες- η Ενότητα 3 αναλύει την κίνηση αναζήτησης του S2- η Ενότητα 4 αναλύει το σύστημα ρητής σημασιολογικής κατάταξης- οι Ενότητες 5 και 6 περιγράφουν την πειραματική μεθοδολογία και αξιολόγηση- τα συμπεράσματα και οι μελλοντικές εργασίες βρίσκονται στην Ενότητα 7.

2. ΣΧΕΤΙΚΗ ΕΡΓΑΣΙΑ

Η προηγούμενη έρευνα στην ακαδημαϊκή αναζήτηση επικεντρώνεται περισσότερο στην ανάλυση του ακαδημαϊκού γράφου παρά στην ad-hoc κατάταξη. Η Microsoft χρησιμοποιεί το Microsoft Academic Graph για τη δημιουργία συστημάτων ακαδημαϊκού διαλόγου και συστάσεων [20]. Άλλες έρευνες σχετικά με τους ακαδημαϊκούς γράφους περιλαμβάνουν την εξαγωγή και την αποσαφήνιση των συγγραφέων, την ενσωμάτωση διαφορετικών πηγών δημοσιεύσεων [21] και την εύρεση εμπειρογνωμόνων [2, 7, 29]. Ο ακαδημαϊκός γράφος μπορεί επίσης να χρησιμοποιηθεί για τη μοντελοποίηση της σημασίας των εργασιών [23] και για την εξαγωγή νέων οντοτήτων [1].

Το soft match είναι ένα ευρέως μελετημένο θέμα στον τομέα των πληροφοριών, κυρίως σε συστήματα αναζήτησης με βάση τις λέξεις. Τα μεταφραστικά μοντέλα αντιμετωπίζουν την κατάταξη ως μεταφράσεις μεταξύ των όρων του ερωτήματος και των όρων του εγγράφου χρησιμοποιώντας έναν πίνακα μεταφράσεων [3]. Τεχνικές μοντελοποίησης θεμάτων έχουν χρησιμοποιηθεί για να αντιστοιχίσουν πρώτα το ερώτημα και το έγγραφο σε έναν λανθάνοντα χώρο και στη συνέχεια να τα ταιριάξουν σε αυτόν [24]. Η ενσωμάτωση λέξεων και οι τεχνικές βαθιάς μάθησης έχουν μελετηθεί πρόσφατα. Μια δυνατότητα είναι να δημιουργηθούν πρώτα αναπαραστάσεις ερωτήματος και εγγράφου χρησιμοποιώντας ευρετικά την ενσωμάτωση των λέξεων τους και στη συνέχεια να γίνει αντιστοίχισή τους στον χώρο ενσωμάτωσης [22]. Το μοντέλο DSSM εκπαιδεύει απευθείας ένα μοντέλο αναπαράστασης χρησιμοποιώντας βαθιά νευρωνικά δίκτυα, το οποίο μαθαίνει κατανεμημένες αναπαραστάσεις για το ερώτημα και το έγγραφο, και τις ταιριάζει χρησιμοποιώντας τις αναπαραστάσεις που μαθαίνει [13]. Μια πιο re- cent μέθοδος, η DRMM, μοντελοποιεί τη συνάφεια ερωτήματος-έγγραφου με ένα νευρωνικό δίκτυο που βασίζεται στον πίνακα μετάφρασης σε επίπεδο λέξεων [11]. Ο πίνακας μετάφρασης υπολογίζεται με προ-εκπαιδευμένες ενσωματώσεις λέξεων. Οι βαθμολογίες μετάφρασης σε επίπεδο λέξης συνοψίζονται με bin-pooling (ιστογράμματα) και στη συνέχεια χρησιμοποιούνται από το νευρωνικό δίκτυο κατάταξης.

Η πρόσφατη ανάπτυξη των γράφων γνώσης έχει δώσει κίνητρο για πολλές νέες τεχνικές στη χρήση βάσεων γνώσης για την ανάκτηση πληροφοριών με επίκεντρο το κείμενο [9]. Ένας διαισθητικός τρόπος είναι η χρήση των κειμενικών χαρακτηριστικών των σχετικών οντοτήτων για τον εμπλουτισμό της αναπαράστασης του ερωτήματος. Για παράδειγμα, τα άρθρα της Wikipedia έχουν χρησιμοποιηθεί ως ένα καλύτερο σώμα για ψευδοανατροφοδότηση συνάφειας για τη δημιουργία καλύτερων όρων επέκτασης [28]. Οι οντότητες της Freebase που ανακτώνται από το ερώτημα [6] ή εμφανίζονται συχνά στις επισημειώσεις των κορυφαίων ανακτημένων εγγράφων [10] συνήθως σχετίζονται με τις πληροφοριακές ανάγκες του ερωτήματος- καλύτεροι όροι επέκτασης μπορούν να βρεθούν στις περιγραφές αυτών των σχετικών οντοτήτων [26]. Τα κειμενικά χαρακτηριστικά των σχετιζόμενων οντοτήτων έχουν επίσης χρησιμοποιηθεί από την επέκταση χαρακτηριστικών ερωτήματος οντοτήτων (EQFE) για την εξαγωγή πλουσιότερων χαρακτηριστικών μάθησης για την κατάταξη. Κάθε κειμενικό χαρακτηριστικό παρέχει μοναδικά χαρακτηριστικά ομοιότητας κειμένου με το έγγραφο [8].

Ένας άλλος τρόπος για να χρησιμοποιηθούν οι γράφοι γνώσης στην αναζήτηση είναι να χρησιμοποιηθούν οι οντότητες ως πηγή πρόσθετων συνδέσεων από το ερώτημα στα έγγραφα. Ο λανθάνων χώρος οντοτήτων (Latent Entity Space - LES) χρησιμοποιεί οντότητες ερωτήματος και στενά συνδεδεμένες οντότητες εγγράφων ως λανθάνων χώρο μεταξύ ερωτήματος και εγγράφων και οι περιγραφές των λανθάνων οντοτήτων χρησιμοποιούνται για τη σύνδεση ερωτήματος και εγγράφων σε ένα μοντέλο χωρίς επίβλεψη [16]. Το LES αποδίδει καλά με υψηλής ποιότητας σχολιασμούς ερωτημάτων [17]. Το EsdRank χρησιμοποιεί οντότητες από τη σύνδεση οντοτήτων και την αναζήτηση οντοτήτων για τη δημιουργία πρόσθετων συνδέσεων μεταξύ ερωτήματος και εγγράφων [25]. Οι συνδέσεις εκφράζονται με χαρακτηριστικά κειμένου μεταξύ του ερωτήματος, των οντοτήτων και των υποψήφιων εγγράφων. Ένα μοντέλο εκμάθησης λανθάνων χώρων για την κατάταξη μαθαίνει από κοινού τις συνδέσεις από το ερώτημα στις οντότητες και την κατάταξη των εγγράφων.

Μια πιο πρόσφατη τάση είναι η δημιουργία αναπαραστάσεων κειμένου βασισμένων σε οντότητες και η βελτίωση της κατάταξης βάσει λέξεων με μοντέλα ανάκτησης βάσει οντοτήτων. Το γλωσσικό μοντέλο βασισμένο σε οντότητες χρησιμοποιεί τις επιφανειακές μορφές και τα ονόματα οντοτήτων των σχολίων εγγράφων για να

οικοδόμηση ενός γλωσσικού μοντέλου προσανατολισμένου στις οντότητες [12]. Βελτιώνει πλήρως την ακρίβεια της ανάκτησης όταν συνδυάζεται με την τυπική ανάκτηση με βάση τις λέξεις. Μια παρόμοια ιδέα χρησιμοποιείται στο μοντέλο bag-of-entities, στο οποίο το ερώτημα και τα έγγραφα αναπαρίστανται από τις επισημάνσεις οντοτήτων τους [27]. Τα μοντέλα Boolean και τα μοντέλα με βάση τη συχνότητα στο χώρο των οντοτήτων μπορούν να βελτιώσουν την ακρίβεια κατάταξης της ανάκτησης με βάση τις λέξεις. Το ESR διερευνά περαιτέρω τις δυνατότητες της αναπαράστασης με βάση τις οντότητες με την ενσωμάτωση γράφων γνώσης και τις μαλακές αντιστοιχίσεις και χρησιμοποιεί το γράφο γνώσης σε έναν νέο τομέα: την ακαδημαϊκή αναζήτηση.

3. ΑΝΆΛΥΣΗ ΑΡΧΕΊΟΥ ΚΑΤΑΓΡΑΦΉΣ ΕΡΩΤΗΜΆΤΩΝ

Το τρέχον σύστημα κατάταξης του S2 βασίζεται στο μοντέλο διανυσματικού χώρου του Elastic- Search. Υπολογίζει μια βαθμολογία κατάταξης με βάση το tf.idf των όρων του ερωτήματος και τα bi-grams στον τίτλο, την περίληψη, το κείμενο και το πλαίσιο παραπομπής των pa- pers. Περιλαμβάνονται επίσης στατικά χαρακτηριστικά κατάταξης, για παράδειγμα, ο αριθμός των αναφορών, οι πρόσφατες αναφορές και ο χρόνος δημοσίευσης. Για τον χειρισμό του αιτήματος για έναν συγγραφέα ή για μια συγκεκριμένη εργασία με βάση τον τίτλο, μερικά πρόσθετα χαρακτηριστικά ταιριάζουν ρητά με τους συγγραφείς και ενισχύουν τις ακριβείς αντιστοιχίες τίτλων. Το σύστημα κατάταξης εκπαιδεύτηκε με τη χρήση της εκμάθησης κατάταξης σε ένα σύνολο εκπαίδευσης που δημιουργήθηκε στο Ινστιτούτο Allen. Πριν και μετά την κυκλοφορία, πραγματοποιήθηκαν διάφοροι γύροι μελετών χρηστών από ερευνητές του Allen Institute (κυρίως διδάκτορες της επιστήμης των υπολογιστών) και από μια τρίτη εταιρεία. Τα αποτελέσματα συμφωνούν ότι σε ερωτήματα που αφορούν την επιστήμη των υπολογιστών η S2 αποδίδει τουλάχιστον στο ίδιο επίπεδο με άλλες ακαδημαϊκές μηχανές αναζήτησης της αγοράς.

Η αυξανόμενη διαδικτυακή κίνηση στο S2 καθιστά δυνατή τη μελέτη των πληροφοριακών αναγκών στην ακαδημαϊκή αναζήτηση, η οποία είναι σημαντική για την καθοδήγηση της ανάπτυξης μοντέλων κατάταξης. Για παράδειγμα, αν οι χρήστες αναζητούν κυρίως τίτλους εργασιών, η κατάταξη θα ήταν απλή ακριβής αντιστοίχιση- αν οι χρήστες αναζητούν κυρίως ονόματα συγγραφέων, η κατάταξη θα αφορούσε κυρίως την αποσαφήνιση, τη συγκέντρωση και την αναγνώριση ονομάτων.

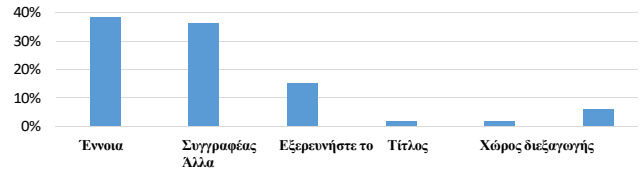
Χαρακτηρίσαμε με το χέρι τις προθέσεις των 400 συχνότερων ερωτημάτων του S2 κατά τους πρώτους έξι μήνες του 2016. Ένα ερώτημα επισημάνθηκε με βάση τα αποτελέσματα αναζήτησης και τα κλικ. Το αποτέλεσμα δείχνει ότι οι ανάγκες πληροφόρησης σχετικά με την κίνηση της κεφαλής μπορούν να κατηγοριοποιηθούν στις ακόλουθες κατηγορίες:

- Έννοια: π.χ. "βαθιά ενισχυτική μάθηση",
- Συγγραφέας: Συγγραφέας: Αναζήτηση συγκεκριμένου συγγραφέα,
- Εξερεύνηση: Διερεύνηση ενός ερευνητικού θέματος, π.χ. "εγκληματολογία και μηχανική μάθηση",
- Τίτλος: Αναζήτηση μιας εργασίας χρησιμοποιώντας τον τίτλο της,
- Τόπος διεξαγωγής:: και
- Άλλα: Ασαφής ή δεν σχετίζεται με την έρευνα.

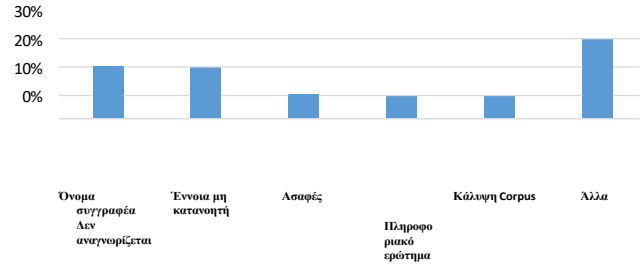
Το Σχήμα 1α δείχνει την κατανομή αυτών των προθέσεων. Περισσότερο από το ήμισυ της κίνησης του S2 σχετίζεται με ερευνητικές έννοιες: αναζήτηση μιας ακαδημαϊκής έννοιας (39%) και διερεύνηση θεμάτων εκ νέου αναζήτησης (15%). Περίπου το ένα τρίτο αφορά την αναζήτηση ενός συγγραφέα (36%). Πολύ λίγες από τις αναζητήσεις κεφαλής είναι τίτλοι εργασιών- οι περισσότερες τέτοιες αναζητήσεις βρίσκονται στη μακρά ουρά της διαδικτυακής κίνησης.

Το μεγάλο ποσοστό των ερωτημάτων που σχετίζονται με έννοιες δείχνει ότι ένα μεγάλο μέρος της ακαδημαϊκής αναζήτησης είναι ένα πρόβλημα ad-hoc αναζήτησης. Τα ερωτήματα είναι συνήθως σύντομα, κατά μέσο όρο περίπου 2-3 όροι, και οι ανάγκες τους σε πληροφορίες δεν είναι τόσο σαφείς όσο τα ερωτήματα για τον συγγραφέα, τον τόπο διεξαγωγής ή τον τίτλο της εργασίας. Πρόκειται για πολύ τυπικά ad-hoc ερωτήματα αναζήτησης, σε έναν συγκεκριμένο τομέα - την επιστήμη των υπολογιστών.

Για να κατανοήσουμε πού κάνει λάθη το S2, μελετήσαμε τις πηγές σφαλμάτων των αποτυχημένων ερωτημάτων στο αρχείο καταγραφής ερωτημάτων.



(a) Κατανομή προθέσεων ερωτήματος



(b) Κατανομή πηγής σφάλματος

Σχήμα 1: Ανάλυση του αρχείου καταγραφής ερωτημάτων στην κίνηση αναζήτησης της S2 κατά τους πρώτους έξι μήνες του 2016. Οι προθέσεις των ερωτημάτων επισημαίνονται χειροκίνητα στις 400 συχνότερες αναζητήσεις. Οι πηγές σφαλμάτων επισημαίνονται χειροκίνητα στα 200 ερωτήματα με τη χειρότερη απόδοση.

Αυτά τα ερωτήματα αποτυχίας επιλέχθηκαν με βάση το μέσο βάθος κλικ στο αρχείο καταγραφής ερωτημάτων: Όσο πιο χαμηλά είναι τα κλικ, τόσο χειρότερη είναι η απόδοση του S2. Μεταξύ των ερωτημάτων με περισσότερα από 10 κλικ, επισημάναμε χειροκίνητα τα 200 κορυφαία ερωτήματα με τις χειρότερες επιδόσεις. Η κατανομή των τύπων σφαλμάτων παρουσιάζεται στην Εικόνα 1β. Οι δύο κύριες αιτίες αποτυχίας είναι το *όνομα του συγγραφέα που δεν αναγνωρίστηκε* (22%) και η *έννοια που δεν έγινε κατανοητή* (20%).

Η στρατηγική του S2 για τις αναζητήσεις συγγραφέων είναι να εμφανίζει τη σελίδα του συγγραφέα. Όταν το όνομα του συγγραφέα δεν αναγνωρίζεται, το S2 χρησιμοποιεί την κανονική του κατάταξη με βάση την ομοιότητα κειμένου των εργασιών με το όνομα του συγγραφέα, η οποία συχνά οδηγεί σε άσχετες εργασίες.

Ένα σφάλμα *μη κατανοητής έννοιας* συμβαίνει όταν το S2 επιστρέφει έγγραφα που δεν αντιστοιχούν σωστά στις σημασιολογικές έννοιες των ερωτημάτων εννοιών. Δεδομένου ότι αυτή είναι η μεγαλύτερη πηγή σφαλμάτων στο μέρος της ad-hoc κατάταξης του S2, αναλύσαμε περαιτέρω τι κάνει αυτά τα ερωτήματα δύσκολα.

Το πρώτο μέρος της δυσκολίας είναι ο θόρυβος στο σήμα ακριβούς αντιστοίχισης. Λόγω της γλωσσικής ποικιλίας, ο όρος του ερωτήματος μπορεί να μην εμφανίζεται αρκετά συχνά στα σχετικά έγγραφα (vo- cabulary mismatch), για παράδειγμα, "softmax categorization" έναντι "softmax classification". Η τμηματοποίηση των εννοιών του ερωτήματος αποτελεί επίσης πρόβλημα. Για παράδειγμα, ολόκληρο το ερώτημα "διεπαφή φυσικής γλώσσας" θα πρέπει να θεωρηθεί ως σύνολο επειδή αποτελεί μια πληροφοριακή μονάδα, αλλά το μοντέλο κατάταξης ταιριάζει με όλες τις λέξεις και τα n-grams του ερωτήματος και το αποτέλεσμα κυριαρχείται από τη δημοφιλή φράση "φυσική γλώσσα".

Το δεύτερο μέρος είναι πιο λεπτό, καθώς αφορά το νόημα της έννοιας του ερωτήματος. Μπορεί να υπάρχουν πολλαπλές πτυχές της έννοιας του ερωτήματος και μια

4. ΡΗΤΉ ΣΗΜΑΣΙΟΛΟΓΙΚΉ ΚΑΤΆΤΑΞΗ

Αυτή η ενότητα περιγράφει αρχικά τον γράφο γνώσης που δομήσαμε και στη συνέχεια παρουσιάζει τη μέθοδο Explicit Semantic Ranking (ESR) που μοντελοποιεί τη συνάφεια ερωτημάτων και εγγράφων χρησιμοποιώντας τη σημασιολογία του γράφου γνώσης.

4.1 Γράφημα γνώσης

Προϋπόθεση των συστημάτων σημασιολογικής κατάταξης είναι ένας γράφος γνώσης που αποθηκεύει σημασιολογικές πληροφορίες. Συνήθως, είναι επίσης απαραίτητο ένα σύστημα σύνδεσης οντοτήτων που συνδέει κείμενο φυσικής γλώσσας με οντότητες στον γράφο γνώσης [8, 16, 25]. Στην παρούσα εργασία, κατασκευάζουμε έναν τυπικό γράφο γνώσης G με εννοιολογικές οντότητες (E) και ακμές (κατηγορήματα P και ουρές T)συλλέγοντας το corpus του S2 και την Freebase, και να χρησιμοποιήσουμε ένα σύστημα δημοτικότητας

εργασία που την αναφέρει συχνότερα μπορεί να μην αφορά την πιο σημαντική πτυχή. Για παράδειγμα, η "κατασκευή οντολογιών" αφορά τον τρόπο κατασκευής οντολογιών γενικά, αλλά μπορεί να μην αφορά τον τρόπο κατασκευής μιας συγκεκριμένης οντολογίας- η "τμηματοποίηση δυναμικού προγραμματισμού" αφορά την τμηματοποίηση λέξεων στην οποία ο δυναμικός προγραμματισμός είναι απαραίτητος, αλλά δεν αφορά την τμηματοποίηση εικόνων.

Συμπερασματικά, η ανάλυσή μας διαπιστώνει ότι υπάρχει ένα χάσμα μεταξύ της ομοιότητας κειμένου των εγγράφων ερωτήσεων και της σημασιολογικής τους συσχέτισης. Τα συστήματα κατάταξης που βασίζονται αποκλειστικά σε στατιστικές σε επίπεδο όρων έχουν λίγους τρόπους επίλυσης αυτής της ασυμφωνίας. Η επιθυμία μας να αντιμετωπίσουμε αυτό το κενό οδήγησε στην ανάπτυξη του ESR.

με βάση το σύστημα σύνδεσης οντοτήτων για τη σύνδεση ερωτημάτων και εγγράφων.

Οι εννοιολογικές οντότητες στο γράφημα γνώσης μπορούν να συλλεχθούν από δύο διαφορετικές πηγές: από σώματα κειμένων (Corpus) και από την Freebase. Οι οντότητες του σώματος είναι φράσεις-κλειδιά που εξάγονται αυτόματα από το σώμα κειμένων του S2. Η εξαγωγή φράσεων-κλειδιών είναι μια ευρέως μελετημένη εργασία που αποσκοπεί στην εύρεση αντιπροσωπευτικών φράσεων-κλειδιών για ένα έγγραφο, για παράδειγμα, για την προσέγγιση των χειροκίνητα εκχωρημένων λέξεων-κλειδιών ενός εγγράφου. Η παρούσα εργασία χρησιμοποιεί τις φράσεις-κλειδιά που εξάγονται από το σύστημα παραγωγής του S2, το οποίο εξάγει ουσιαστικές φράσεις από τον τίτλο, την περίληψη, την εισαγωγή, το συμπέρασμα και τα συμφραζόμενα παραπομπής ενός εγγράφου και επιλέγει τις κορυφαίες σε ένα μοντέλο κατάταξης φράσεων-κλειδιών με τυπικά χαρακτηριστικά όπως η συχνότητα και η θέση [4].

Η δεύτερη πηγή οντοτήτων είναι η Freebase. Παρά το γεγονός ότι είναι
μια γενική βάση γνώσης του τομέα, η χειροκίνητη εξέτασή μας διαπίστωσε ότι η Freebase έχει αρκετά καλή κάλυψη των οντοτήτων των εννοιών της επιστήμης των υπολογιστών στα ερωτήματα κεφαλής της S2.

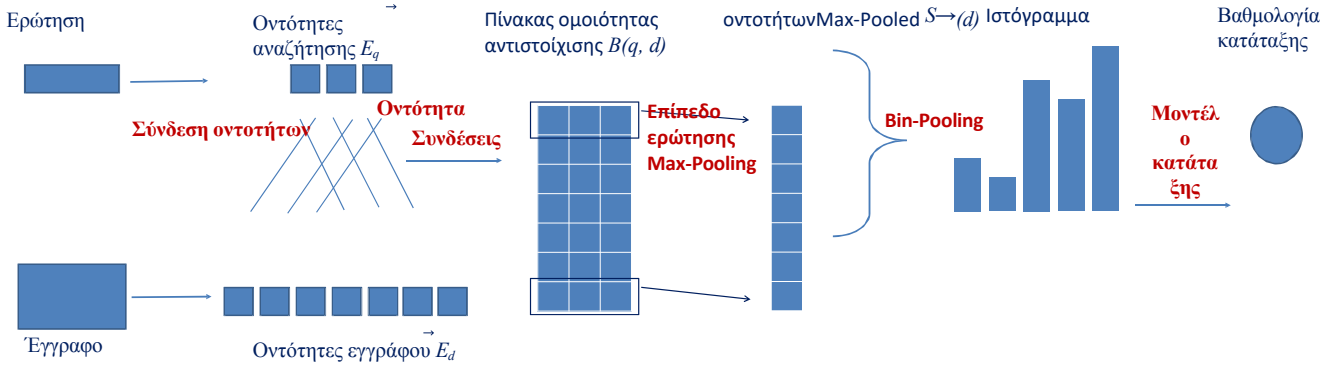
Σύνδεση οντοτήτων: που συνδέει επιφανειακές μορφές (αναφορές οντοτήτων) σε ένα ερώτημα ή έγγραφο με τις πιο συχνά συνδεδεμένες οντότητες στο σχολιασμό FACC1 της Google [10, 12, 27]. Παρόλο που το CMNS δεν παρέχει αποσαφήνιση οντοτήτων, έχει αποδειχθεί ότι είναι αποτελεσματικό για τη σύνδεση οντοτήτων ερωτημάτων [12] και η γλώσσα στα έγγραφα της επιστήμης των υπολογιστών είναι λιγότερο διφορούμενη από ό,τι σε έναν γενικότερο τομέα.

Οι ακμές στο γράφημα γνώσης περιλαμβάνουν δύο μέρη: Προεπιλογές P και ουρές T . Από την Freebase και το σώμα CMNS με σχολιασμό S2, συλλέγονται οι ακόλουθοι τέσσερις τύποι ακμών:

- Οι ακμές συγγραφέα συνδέουν μια οντότητα με έναν συγγραφέα εάν ο συγγραφέας
  έχει μια εργασία που αναφέρει την οντότητα στον τίτλο,
- Οι ακμές πλαισίου συνδέουν μια οντότητα με μια άλλη οντότητα, εάν οι δύο αυτές οντότητες συναντώνται σε ένα παράθυρο 20 λέξεων περισσότερες από 5 φορές στο σώμα κειμένων,
- Οι ακμές περιγραφής συνδέουν μια οντότητα με λέξεις στην περιγραφή της στη βάση Freebase (αν υπάρχει) και
- Οι ακμές χώρου συνδέουν μια οντότητα με έναν χώρο, εάν η οντότητα ap-
  αχλάδια στον τίτλο μιας εργασίας που δημοσιεύεται στον τόπο. Ο γράφος γνώσης G περιέχει δύο τύπους οντοτήτων:

Corpus-extracted (Corpus) και Freebase, και τέσσερις τύποι ακμών: Συγγραφέας, Πλαίσιο, Περιγραφή και Τόπος διεξαγωγής.

Οι ενθυλακώσεις των οντοτήτων μας εκπαιδεύονται με βάση τους γείτονές τους στον γράφο γνώσης. Η δομή του γράφου γύρω από μια οντότητα μεταφέρει τη σημασιολογία αυτής της οντότητας. Κατά συνέπεια, οντότητες με παρόμοιους γείτονες συνήθως σχετίζονται. Χρησιμοποιούμε ενσωματώσεις οντοτήτων για να μοντελοποιήσουμε αυτή τη σημασιολογία.



Σχήμα 2: Το πλαίσιο της ρητής σημασιολογικής κατάταξης (ESR).

Εκπαιδεύουμε ένα ξεχωριστό μοντέλο ενσωμάτωσης για κάθε ένα από τα {Author, Context, Desc, *Venue}* ακμές χρησιμοποιώντας το μοντέλο skip-gram [18]:

$$l = \sum_{e \in E, t \in T} w(e, t)\, \sigma(V(e)^T U(t)) - E_{t' \sim T}\, \sigma(-V(e)^T U(t')) .$$

Η συνάρτηση απώλειας l βελτιστοποιείται με μια τυπική μέθοδο κλίσης. V και U είναι οι πίνακες ενσωμάτωσης οντοτήτων που μαθαίνονται για οντότητες και ουρές αυτού του τύπου ακμής. Κάθε μια από τις γραμμές τους ($V(e)$ ή $U(t)$) είναι η ενσωμάτωση μιας οντότητας e ή μιας ουράς t, αντίστοιχα. σ είναι η συνάρτηση Sigmoid. T είναι η συλλογή όλων των ουρών για αυτόν τον τύπο ακμής. $E_{t' \sim T}()$ δειγματοληπτεί αρνητικές περιπτώσεις με βάση τη συχνότητα των ουρών (αρνητική δειγματοληψία). $w(e, t)$ είναι η συχνότητα σύνδεσης της οντότητας e και της ουράς t, για παράδειγμα, πόσες φορές χρησιμοποιείται μια οντότητα από έναν συγγραφέα.

4.2 Μοντέλο κατάταξης

Δεδομένου ενός ερωτήματος q και ενός συνόλου υποψήφιων εγγράφων $D = \{d_1, ..., d_n\}$, ο στόχος του ESR είναι να βρεθεί μια συνάρτηση κατάταξης $f(q, d|G)$, η οποία κατατάσσει καλύτερα το D χρησιμοποιώντας τη ρητή σημασιολογία που είναι αποθηκευμένη στο γράφημα γνώσης G. Η ρητή σημασιολογία περιλαμβάνει οντότητες ($E = \{e_1, ..., e_{|E|}\}$) και ακμές (κατηγορήματα P και ουρές T). Το υπόλοιπο της παρούσας ενότητας περιγράφει το πλαίσιο ESR, το οποίο παρουσιάζεται επίσης στο Σχήμα 2.

Αναπαραστάσεις βασισμένες σε οντότητες.

Το ESR αναπαριστά το ερώτημα και τα έγγραφα με τη βοήθεια των οντοτήτων που κατασκευάζονται με βάση τις επισημειώσεις οντοτήτων που συνδέονται με το CMNS [19, 27]. Κάθε ερώτημα ή έγγραφο αναπαρίσταται από ένα διάνυσμα ($\vec{E}_{\to q}$ ή $\vec{E}_{\to d}$). Κάθε διάσταση στο διάνυσμα αντιστοιχεί σε μια οντότητα e στον σχολιασμό του ερωτήματος ή του εγγράφου και το βάρος είναι η συχνότητα της οντότητας που σχολιάζεται σε αυτό.

Αντιστοίχιση ερωτήματος και εγγράφων στο χώρο οντοτήτων.

Αντί να περιορίζεται στα κλασικά μοντέλα ανάκτησης [19, 27], το ESR ταιριάζει τις αναπαραστάσεις οντοτήτων του ερωτήματος και των εγγράφων χρησιμοποιώντας την ενσωμάτωση του γράφου γνώσης.

Το ESR υπολογίζει πρώτα έναν πίνακα μετάφρασης αποτέλεσμα "έξυπνη διατύπωση". Βαθμολογίες μικρότερες του 1 προσδιορίζουν συναφείς οντότητες ως συνάρτηση της δομής του γράφου γνώσης και παρέχουν σήματα *ήπιας αντιστοίχισης*.

Στη συνέχεια, το ESR εκτελεί δύο βήματα συγκέντρωσης για να γενικεύσει τις ακριβείς αντιστοιχίες και τις μαλακές αντιστοιχίες στη μετάφραση οντοτήτων οντοτήτων ερωτήματος-έγγραφου. Κάθε στοιχείο του πίνακα είναι η σύνδεση δύναμη μεταξύ μιας οντότητας ερωτήματος e_i και μιας οντότητας εγγράφου e_j, που υπολογίζονται με βάση την ομοιότητα συνημίτονου των ενσωματώσεών τους:

$$s(e_i, e_j) = \cos(V(e_i), V(e_j)). \quad (1)$$

Η βα στο χώρο των οντοτήτων. Ενσωματώνει τη σημασιολογία από τις οντότητες και τις επιφανειακές μορφές τους: Οι οντότητες στο κείμενο αναγνωρίζονται, οι διαφορετικές επιφανειακές μορφές μιας οντότητας ευθυγραμμίζονται και η ακριβής αντιστοίχιση γίνεται σε επίπεδο οντότητας. Το ονομάζουμε αυτό

πίνακα σε στοιχεία κατάταξης ερωτήματος-έγγραφου.

Το πρώτο βήμα είναι η μέγιστη συγκέντρωση κατά μήκος της διάστασης του ερωτήματος:

$$\mathcal{S}^{\rightarrow}(d) = \max_{ei \in E \rightarrow q} s(e_i, E \rightarrow d). \quad (2)$$

$E \rightarrow q$ και $E \rightarrow d$ είναι τα bag-of-entities των q και d. $\mathcal{S}^{\rightarrow}(d)$ είναι ένα διάνυσμα διαστάσεων $|E \rightarrow d|$. Η διάσταση j^{th} είναι η μέγιστη ομοιότητα της οντότητας $_{ej\ του}$ εγγράφου με οποιαδήποτε οντότητα του ερωτήματος.

Το δεύτερο βήμα είναι η συγκέντρωση σε δυάδες (ιστόγραμμα) για την καταμέτρηση των αντιστοιχιών σε διαφορετικές εντάσεις [11]:

$$B_k(q, d) = \log \sum_j I(st_k \leq s_{\rightarrow j}(d) < ed_k). \quad (3)$$

$[st_k, ed_k)$ είναι το εύρος για το δοχείο k^{th}. B_k είναι ο αριθμός των οντοτήτων εγγράφων των οποίων η βαθμολογία εμπίπτει σε αυτό το bin.

Το max-pooling αντιστοιχεί κάθε οντότητα εγγράφου στην πλησιέστερη οντότητα του ερωτήματος με τη χρήση ενσωματώσεων, η οποία είναι η ακριβής αντιστοιχία, εάν υπάρχει. Η βαθμολογία της περιγράφει πόσο στενά συνδεδεμένη είναι μια οντότητα εγγράφου με το ερώτημα. Το bin-pooling μετρά τον αριθμό των οντοτήτων εγγράφων με διαφορετική ισχύ σύνδεσης με το ερώτημα. Το bin με εύρος [1, 1] μετρά τις ακριβείς αντιστοιχίες και τα άλλα bin παράγουν soft match sig- nals [11]. Τα δύο βήματα συγκέντρωσης συνοψίζουν μαζί τις αντιστοιχίες οντοτήτων σε στοιχεία κατάταξης ερωτήματος-έγγραφου.

Κατάταξη με σημασιολογικά στοιχεία.

Οι βαθμολογίες bin B χρησιμοποιούνται ως χαρακτηριστικά για την τυπική μάθηση για την κατάταξη των μοντέλων στο ESR:

$$f(q, d|G) = w_{0}f_{S2}(q, d) + W^T B(q, d) \quad (4)$$

όπου $f_{S2}(q, d)$ είναι η βαθμολογία από το σύστημα παραγωγής της S2, w_0 και W είναι οι προς εκμάθηση παράμετροι και $f(q, d|G)$ είναι η τελική βαθμολογία κατάταξης. Με βάση τον τύπο ακμής που εκπαιδεύεται η ενσωμάτωση οντοτήτων, υπάρχουν τέσσερις παραλλαγές του ESR: ESR- Author, ESR-Context, ESR-Desc και ESR-Venue.

Με τις αναπαραστάσεις που βασίζονται σε οντότητες, οι ακριβείς αντιστοιχίες (έξυπνη διατύπωση) επιτρέπουν στο ESR να θεωρεί πολλαπλές λέξεις ως ενιαία μονάδα με τρόπο που να διέπεται από αρχές, και οι ενσωματώσεις γράφων γνώσης επιτρέπουν στο ESR να περιγράφει τη σημασιολογική συγγένεια μέσω μαλακών αντιστοιχιών. Τα σήματα ακριβών αντιστοιχιών και μαλακών αντιστοιχιών αξιοποιούνται από το ενοποιημένο πλαίσιο ενσωμάτωσης, συγκέντρωσης και κατάταξης του ESR.

5. ΠΕΙΡΑΜΑΤΙΚΉ ΜΕΘΟΔΟΛΟΓΊΑ

Η παρούσα ενότητα περιγράφει το σύνολο δεδομένων αναφοράς κατάταξης των
S2 και τις πειραματικές ρυθμίσεις.

5.1 Σημείο αναφοράς κατάταξης

Τα ερωτήματα της συγκριτικής αξιολόγησης προέρχονται από το αρχείο καταγραφής ερωτημάτων του S2 κατά τους πρώτους έξι μήνες του 2016. Υπάρχουν συνολικά 100 ερωτήματα, 20 ομοιόμορφα δειγματοληπτικά από την κύρια κίνηση (100 συχνότερα ερωτήματα), 30 από τη διάμεσο (ερωτήματα που εμφανίζονται περισσότερες από 10 φορές) και 50 σκληρά ερωτήματα από τα 200 ερωτήματα με τις χειρότερες επιδόσεις βάσει του μέσου βάθους κλικ. Τα ερωτήματα συγγραφέα και τόπου διεξαγωγής αγνοούνται χειροκίνητα, καθώς αφορούν περισσότερο την αναγνώριση του ονόματος και όχι την κατάταξη.

Τα υποψήφια έγγραφα προέκυψαν από τη συγκέντρωση διαφόρων παραλλαγών του συστήματος κατάταξης S2. Πρώτον, επισημάναμε αρκετά από τα κορυφαία αποτελέσματα κατάταξης από το S2. Στη συνέχεια, διάφορες παραλλαγές των συστημάτων κατάταξης του S2, με τα ίδια χαρακτηριστικά, αλλά διαφορετικά μοντέλα μάθησης για την κατάταξη, εκπαιδεύονται και δοκιμάζονται σε αυτές τις ετικέτες με τη χρήση διασταυρούμενης επικύρωσης. Τα 10 κορυφαία αποτελέσματα από αυτά τα συστήματα κατάταξης που προέκυψαν από τη διασταυρούμενη επικύρωση προστέθηκαν στη δεξαμενή εγγράφων. Θα μπορούσαν επίσης να επισημανθούν για μια άλλη επανάληψη της εκπαίδευσης. Η διαδικασία εκπαίδευσης-ετικετών επαναλήφθηκε δύο φορές- μετά από αυτό, οι κατατάξεις είχαν συγκλίνει.

Δοκιμάσαμε επίσης τη συγκέντρωση με κλασικά μοντέλα ανάκτησης, όπως το BM25 και το μοντέλο πιθανότητας ερωτήματος, αλλά τα υποψήφια έγγραφά τους ήταν πολύ χειρότερα από το σύστημα παραγωγής. Στόχος μας ήταν να βελτιώσουμε ένα ήδη καλό σύστημα, οπότε επιλέξαμε να χρησιμοποιήσουμε την υψηλότερης ποιότητας δεξαμενή που παρήγαγαν οι παραλλαγές S2. Χρησιμοποιήσαμε τις ίδιες πέντε κατηγορίες συνάφειας που χρησιμοποιούνται από το TREC Web Track. Η κρίση της συνάφειας των ερευνητικών εργασιών σε ακαδημαϊκά ερωτήματα απαιτεί καλή κατανόηση των σχετικών ερευνητικών θεμάτων. Είναι δύσκολο να βρει κανείς εργαζόμενους στο crowd-sourcing με τέτοιο ερευνητικό υπόβαθρο. Έτσι, ζητήσαμε από δύο ερευνητές του Ινστιτούτου Allen να επισημάνουν το ερώτημα-έγγραφο
ζεύγη. Οι διαφορές στις ετικέτες επιλύθηκαν με συζήτηση.

Η κατανομή των ετικετών συνάφειας στο σύνολο δεδομένων μας παρουσιάζεται στον Πίνακα 1. Τα ίδια στατιστικά στοιχεία από το TREC Web Track 2009-2012 παρατίθενται επίσης για λόγους αναφοράς. Οι δικές μας κρίσεις συνάφειας μοιράζονται παρόμοια κατανομή, αν και τα δεδομένα μας είναι πιο καθαρά, για παράδειγμα λόγω έλλειψης spam.

Το σύνολο δεδομένων αναφοράς είναι διαθέσιμο στη διεύθυνση http://boston.lti.cs.cmu.edu/appendices/WWW2016/.

5.2 Πειραματικές ρυθμίσεις

Δεδομένα: Οι επιδόσεις κατάταξης αξιολογούνται στο σύνολο δεδομένων αναφοράς που συζητήθηκε στην ενότητα 5.1. Οι επιδόσεις σύνδεσης οντοτήτων αξιολογούνται στα ίδια ερωτήματα με χειροκίνητη σύνδεση οντοτήτων από τους ίδιους σχολιαστές.

Βασικές γραμμές: Η βασική γραμμή είναι το σύστημα παραγωγής του Semantic Scholar (S2) την 1η Ιουλίου 2016, όπως περιγράφεται στην ενότητα 3. Πρόκειται για μια ισχυρή γραμμή βάσης. Μια εσωτερική αξιολόγηση και μια αξιολόγηση τρίτων δείχνουν ότι η ακρίβειά του είναι τουλάχιστον εξίσου καλή με άλλες ακαδημαϊκές μηχανές αναζήτησης στην αγορά. Περιλαμβάνουμε επίσης τις BM25-F και tf.idf-F για λόγους αναφοράς. Το BM25 και το μοντέλο διανυσματικού χώρου εφαρμόζονται στα πεδία τίτλος, ab- stract και σώμα της εργασίας. Οι παράμετροι τους (βάρη πεδίων) μαθαίνονται χρησιμοποιώντας το ίδιο μοντέλο εκμάθησης για κατάταξη με τη μέθοδό μας στο ίδιο περιβάλλον διασταυρούμενης επικύρωσης.

Μετρικές αξιολόγησης: (αυστηρή αξιολόγηση [5]) και ο μέσος όρος του επιπέδου του ερωτήματος και του επιπέδου της οντότητας (λιτή αξιολόγηση [12]). Η κατάταξη αξιολογείται με το NDCG@20, την κύρια μετρική αξιολόγησης στο TREC Web Track. Ως

Πίνακας 1: Κατανομή των ετικετών συνάφειας στο σύνολο δεδομένων αναφοράς του Semantic Scholar. Ο πίνακας **S2** δείχνει τον αριθμό και το ποσοστό των ζευγών ερωτημάτων-εγγράφων από τα 100 ερωτήματα δοκιμής που έχουν επισημανθεί στο αντίστοιχο επίπεδο συνάφειας. Το **TREC** δείχνει τα στατιστικά στοιχεία των ετικετών συνάφειας από τα 200 ερωτήματα του TREC Web Track 2009-2012.

Επίπεδο συνάφειας	**S2**		**TREC**	
Off-Topic (0)	3080	65.24%	54660	77.45%
Σχετικά (1)	1060	22.45%	10778	15.27%
Σχετικό (2)	317	6.71%	3681	5.22%
Ακριβώς σωστό (3)	213	4.51%	598	0.85%
Πλοήγηση (4)	51	1.08%	858	1.22%

Πίνακας 2: Αποτελέσματα αξιολόγησης σύνδεσης οντοτήτων. Οι οντότητες συνδέονται με CMNS. Το σώμα δείχνει τα αποτελέσματα όταν χρησιμοποιούνται ως στόχοι φράσεις-κλειδιά που εξάγονται με τη βοήθεια του au- tomatically extracted keyphrases. Η Freebase δείχνει τα αποτελέσματα όταν χρησιμοποιούνται οντότητες της Freebase ως στόχοι. Εμφανίζονται τα Precison και Recall από την λιτή αξιολόγηση και την αυστηρή αξιολόγηση.

	Λιτή αξιολόγηση		**Αυστηρή αξιολόγηση**	
	Prec	**Rec**	**Prec**	**Rec**
Corpus	0.5817	0.5625	0.5400	0.5400
Freebase	0.6960	0.6958	0.6800	0.6800

online σύστημα παραγωγής, το S2 ενδιαφέρεται ιδιαίτερα για τις κορυφαίες θέσεις, οπότε αξιολογούνται επίσης οι NDCG@{1, 5, *10}*. Οι στατιστικές σημαντικότητες ελέγχονται με δοκιμή μετατροπής με $p < 0,05$.

Μέθοδοι ESR: Με βάση τον τύπο ακμής που χρησιμοποιείται για την απόκτηση της ενσωμάτωσης οντότητας, υπάρχουν τέσσερις εκδοχές της ESR: ESR-Author, ESR-Context, ESR-Desc και ESR-Venue. Οι εμφωλεύσεις για τις ESR-Author και ESR-Venue εκπαιδεύονται με συγγραφείς και χώρους με περισσότερες από 1 δημοσιεύσεις. Οι ενσωματώσεις περιγραφής και πλαισίου εκπαιδεύονται με οντότητες και όρους με ελάχιστη συχνότητα 5.

Η σύνδεση οντοτήτων γίνεται από το CMNS με όλες τις συνδεδεμένες οντότητες να διατηρούνται για να διασφαλίζεται η ανάκληση [12, 27]. Οι οντότητες του σώματος δεν έχουν πολλαπλές επιφανειακές μορφές, οπότε η CMNS περιορίζεται στην ακριβή αντιστοίχιση. Οι οντότητες της Freebase συνδέονται χρησιμοποιώντας επιφανειακές μορφές που συλλέγονται από το σχολιασμό FACC1 της Google [10].

Οι βαθμολογίες σύνδεσης οντοτήτων κατανέμονται σε πέντε πεδία: [1, 1], [0.75, 1), [0.5, 0.75), [0.25, 0.5), [0, 0.25) με το ακριβές αντιστοιχία με τον πρώτο κάδο [11]. Απορρίπτουμε τα αρνητικά bins, καθώς οι αρνητικές ομοιότητες συνημίτονου μεταξύ οντοτήτων δεν είναι κατατοπιστικές: οι περισσότερες από αυτές δεν σχετίζονται καθόλου.

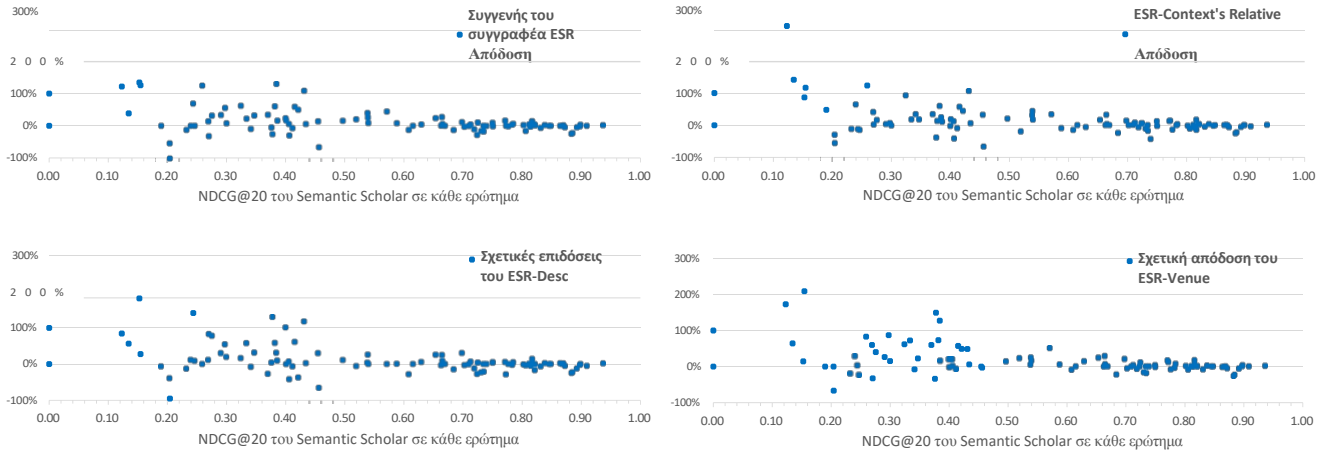
Όλες οι άλλες ρυθμίσεις ακολουθούν τα προηγούμενα πρότυπα. Η διαστασιμότητα του em- bedding είναι 300. Οι πέντε δεξαμενές και τα τρία πεδία της εργασίας (τίτλος, περίληψη και σώμα) δημιουργούν 15 χαρακτηριστικά, τα οποία συνδυάζονται με την αρχική βαθμολογία του S2 χρησιμοποιώντας γραμμικό RankSVM [14]. Όλα τα μοντέλα και οι παραμέτρους των βασικών μοντέλων εκπαιδεύονται και αξιολογούνται χρησιμοποιώντας 10 φορές διασταυρούμενη επικύρωση με 80% train, 10% development και 10% test σε κάθε φορά. Η υπερ-παράμετρος "c" του RankSVM επιλέγεται από {0.0001, 0.0005, 0.001, 0.005, 0.01, 0.05, 0.1, 0.5, *1}* χρησιμοποιώντας το τμήμα ανάπτυξης κάθε πτυχής.

6. ΑΠΟΤΕΛΈΣΜΑΤΑ ΑΞΙΟΛΌΓΗΣΗΣ

Πέντε πειράματα διερεύνησαν τη σύνδεση οντοτήτων και την ακρίβεια κατάταξης εγγράφων, καθώς και τις επιδράσεις τριών στοιχείων του συστήματος (αντιστοίχιση με βάση οντότητες, ενσωμάτωση, συγκέντρωση).

Πίνακας 3: Συνολική ακρίβεια του ESR σε σύγκριση με το Semantic Scholar (S2). Τα ESR-Author, ESR-Context, ESR-Desc και ESR-Venue είναι ESR με ενσωμάτωση οντοτήτων εκπαιδευμένη από τις αντίστοιχες ακμές. Οι σχετικές επιδόσεις σε σύγκριση με το S2 είναι σε ποσοστά. **Win/Tie/Loss** είναι ο αριθμός των ερωτημάτων που μια μέθοδος βελτιώνει, δεν αλλάζει ή βλάπτει, σε σύγκριση με την S2. Τα καλύτερα αποτελέσματα σε κάθε μετρική σημειώνονται με **Bold**. Οι στατιστικά σημαντικές βελτιώσεις ($P>0,05$) σε σχέση με την S2 σημειώνονται με †.

Μέθοδος	NDCG@1		NDCG@5		NDCG@10		NDCG@20		W/T/L
tf.idf-F	0.2020	-59.65%	0.2254	-54.93%	0.2741	-47.57%	0.3299	-39.91%	28/01/71
BM25-F	0.2512	-49.81%	0.2890	-42.20%	0.3150	-39.74%	0.3693	-32.75%	32/01/67
Semantic Scholar	0.5006	-	0.5000	-	0.5228	-	0.5491	-	-/-/-
ESR-συγγραφέας	0.5499†	+9.85%	0.5501†	+10.02%	0.5671†	+8.47%	0.5935†	+8.08%	60/10/30
ESR-Context	0.5519†	+10.25%	0.5417†	+8.35%	0.5636†	+7.80%	0.5918†	+7.77%	58/04/38
ESR-Desc	0.5304	+5.96%	0.5496†	+9.92%	0.5536†	+5.88%	0.5875†	+6.99%	55/11/34
ESR-χώρος διεξαγωγής	**0.5638**†	+12.63%	**0.5700**†	+13.99%	**0.5795**†	+10.83%	**0.6090**†	+10.91%	59/11/30



Σχήμα 3: Η σχετική NDCG@20 του ESR σε σύγκριση με το Semantic Scholar (S2) σε μεμονωμένα ερωτήματα. Κάθε σημείο αντιστοιχεί σε ένα ερώτημα. Η τιμή στον άξονα x είναι το NDCG@20 του S2 σε κάθε ερώτημα. Ο άξονας y δείχνει το σχετικό NDCG@20 του ESR (ποσοστό) σε σύγκριση με το S2.

6.1 Απόδοση σύνδεσης οντοτήτων

Η ακρίβεια σύνδεσης οντοτήτων του CMNS στα ερωτήματά μας παρουσιάζεται στον πίνακα 2. Το σώμα και η ελεύθερη βάση αναφέρονται στη χρήση οντοτήτων από τις εξαγόμενες πληκτροφράσεις στο σώμα ή την ελεύθερη βάση της S2. Η Precison και η Recall αξιολογούνται με τις μετρικές lean evalua- tion (μέσος όρος ερωτήματος και οντότητας) και strict evaluation (μόνο ερωτήματα).

Τα αποτελέσματα του Πίνακα 2 αποκαλύπτουν ένα σαφές χάσμα μεταξύ της ποιότητας των οντοτήτων που εξάγονται αυτόματα και των οντοτήτων που επιμελούνται χειροκίνητα. Οι επιδόσεις σύνδεσης είναι 10-25% καλύτερες με οντότητες ελεύθερης βάσης από ό,τι με οντότητες σώματος σε όλες τις μετρικές αξιολόγησης, γεγονός που καταδεικνύει τις σημαντικές διαφορές στην ποιότητα των συνόλων οντοτήτων τους. Περαιτέρω ανάλυση διαπιστώνει ότι η Freebase παρέχει όχι μόνο ένα μεγαλύτερο σύνολο επιφανειακών μορφών, αλλά και ένα καθαρότερο και μεγαλύτερο σύνολο οντοτήτων εννοιών της επιστήμης της πληροφορικής. Πράγματι, η χειροκίνητη εξέτασή μας διαπίστωσε ότι μόνο οι πιο συχνές αυτόματα εξαγόμενες βασικές φράσεις (περίπου δέκα χιλιάδες) είναι αξιόπιστες. Μετά από αυτό, υπάρχει πολύς θόρυβος. Αυτές οι πιο συχνές φράσεις-κλειδιά περιλαμβάνονται σχεδόν όλες στην Freebase- λίγες πρόσθετες πληροφορίες παρέχονται από τις οντότητες του Σώματος. Η απόλυτη ακρίβεια και η ανάκληση είναι υψηλότερες από τη σύνδεση οντοτήτων με τη Freebase σε ερωτήματα γενικού τομέα (TREC Web Track) [12, 27]. Η χειροκίνητη εξέτασή μας διαπιστώνει ότι ένας πιθανός λόγος είναι η χαμηλότερη ασάφεια στα ακαδημαϊκά ερωτήματα σε σχέση με τα ερωτήματα TREC Web Track. Επίσης, δεδομένου ότι τα ερωτήματά μας προέρχονται από την κεφαλή και τη μέση της διαδικτυακής κίνησης, είναι

κυρίως για δημοφιλή θέματα. Η κάλυψη της Freebase σε αυτά δεν είναι χειρότερη από ό,τι στα ερωτήματα γενικού τομέα. Λόγω της κορυφαίας ακρίβειας σύνδεσης οντοτήτων, στα υπόλοιπα πειράματά μας χρησιμοποιήθηκε μόνο η Freebase.

6.2 Απόδοση κατάταξης

Οι τέσσερις εκδόσεις του ESR διαφέρουν μόνο ως προς τις ακμές που χρησιμοποιούν για να επιτύχουν την ενσωμάτωση οντοτήτων. Οι σχετικές επιδόσεις σε σύγκριση με το σύστημα παραγωγής Semantic Scholar (S2) παρουσιάζονται σε ποσοστά. **Win/Tie/Loss** είναι ο αριθμός των ερωτημάτων που υπερέβησαν, παρέμειναν αμετάβλητα και ζημιώθηκαν από κάθε μέθοδο σε σύγκριση με το S2. Οι στατιστικά σημαντικές βελτιώσεις σε σχέση με το S2 σημειώνονται με *†*.

Το σύστημα παραγωγής S2 ξεπερνά κατά πολύ το BM25-F περιθώριο. Το NDCG@1 σχεδόν διπλασιάζεται. Το αποτέλεσμα αυτό επιβεβαιώνει την ποιότητα του σημερινού συστήματος παραγωγής. Παρόλο που τα μισά ερωτήματα επιλέχθηκαν σκόπιμα για να είναι δύσκολα, σε όλα τα βάθη το S2 επιτυγχάνει απόλυτες βαθμολογίες NDCG άνω του 0,5.

Το ESR παρέχει ένα περαιτέρω άλμα σε σχέση με το σύστημα παραγωγής με
τουλάχιστον 5% σε όλες τις μετρικές αξιολόγησης και με όλους τους τύπους ακμών. Με το Venue, οι βελτιώσεις είναι σταθερά υψηλότερες από 10%. Στις προγενέστερες θέσεις που είναι πιο σημαντικές για την ικανοποίηση των χρηστών, οι επιδόσεις του ESR είναι επίσης ισχυρότερες, με περίπου 2-3% περισσότερες βελτιώσεις στις NDCG@1 και NDCG@5 από ό,τι στη NDCG@20. Οι βελτιώσεις είναι στατιστικά σημαντικές, με μόνη εξαίρεση το ESR-Desc στο

NDCG@1. Πιστεύουμε ότι αυτή η συμπεριφορά οφείλεται στο γεγονός ότι οι τύποι ακμών Author, Context και Venue είναι ειδικοί για τον τομέα, επειδή συλλέγονται από το σώμα κειμένων του S2, ενώ το Desc προέρχεται από την Freebase και δεν δίνεται ιδιαίτερη προσοχή στον τομέα της επιστήμης των υπολογιστών.

Το ESR έχει σχεδιαστεί για να βελτιώνει τα ερωτήματα που είναι δύσκολα για το Semantic Scholar. Για να επαληθεύσουμε ότι το ESR πληροί αυτή την απαίτηση, απεικονίζουμε την απόδοση του ESR σε μεμονωμένα ερωτήματα σε σχέση με την απόδοση του S2 στο Σχήμα 3. Κάθε σημείο του σχήματος διορθώνει
απαντά σε ένα ερώτημα. Η NDCG@20 της S2 εμφανίζεται στον άξονα x. Η σχετική απόδοση του ESR σε σύγκριση με το S2 παρουσιάζεται στον άξονα y.

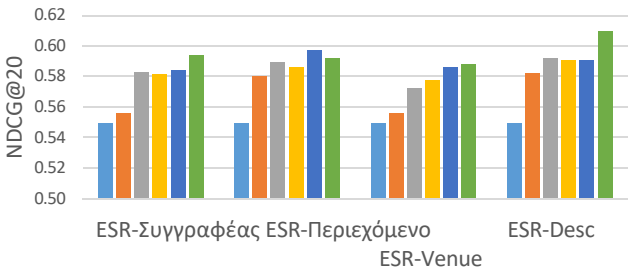
Και στα τέσσερα υποδιαγράμματα, ο κύριος αντίκτυπος του ESR αφορά τα δύσκολα ερωτήματα (αριστερή πλευρά). Στα ερωτήματα στα οποία η S2 έχει ήδη καλή απόδοση, το ESR επιφέρει μόνο μικρές βελτιώσεις: Τα περισσότερα ερωτήματα στη δεξιά πλευρά παραμένουν τα ίδια ή αλλάζουν μόνο λίγο. Στα ερωτήματα στα οποία η κατάταξη με βάση τις λέξεις του S2 αποτυγχάνει, για παράδειγμα, σε εκείνα των οποίων η NDCG $< 0,3$, τα σημασιολογικά στοιχεία από τον γράφο γνώσης βελτιώνουν πολλά από αυτά με μεγάλα περιθώρια. Οι βελτιώσεις είναι επίσης ισχυρές. Περισσότερα από τα μισά ερωτήματα βελτιώνονται με μεγάλα κέρδη. Λιγότερα ερωτήματα πλήττονται και οι απώλειες είναι συνήθως μικρές.

Το πείραμα αυτό αποδεικνύει την ικανότητα του ESR να βελτιώνει ένα πολύ ανταγωνιστικό σύστημα παραγωγής σε απευθείας σύνδεση. Η διαφήμιση της ESR
πλεονεκτήματα ευνοούν επίσης την ικανοποίηση των χρηστών των μηχανών αναζήτησης στο διαδίκτυο: Οι βελτιώσεις είναι εύρωστες με λιγότερα ερωτήματα που έχουν υποστεί σοβαρές ζημιές και, το σημαντικότερο, το ESR διορθώνει τα δύσκολα ερωτήματα που το σύστημα παραγωγής βρίσκει δύσκολα.

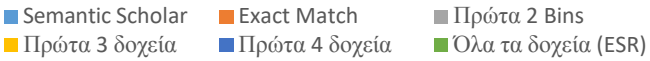
6.3 Αποτελεσματικότητα της αντιστοίχισης βάσει οντοτήτων

Το ESR αντιστοιχίζει το ερώτημα και τα έγγραφα με βάση τις αναπαραστάσεις οντοτήτων τους, χρησιμοποιώντας τη σημασιολογία από το γράφο γνώσης. Η σημασιολογική συμβολή στην κατάταξη του ESR μπορεί να προέρχεται από δύο πλευρές: ακριβής αντιστοίχιση με έξυπνη διατύπωση και ήπια αντιστοίχιση με ενσωμάτωση του γράφου γνώσης. Το τρίτο πείραμα διερεύνησε την αποτελεσματικότητα της αντιστοίχισης του ESR με βάση τις οντότητες, τόσο της ακριβούς αντιστοίχισης όσο και της ήπιας αντιστοίχισης.

Υπενθυμίζεται ότι το ESR χρησιμοποιεί πέντε κάδους για να συνδυάζει και να σταθμίζει τα ταιριάσματα διαφορετικής ισχύος. Σε αυτό το πείραμα χρησιμοποιήθηκε το ίδιο μοντέλο κατάταξης, αλλά διαφοροποιήθηκαν τα χρησιμοποιούμενα bins. Ξεκινήσαμε χρησιμοποιώντας μόνο το πρώτο δοχείο ακριβούς αντιστοιχίας $[1, 1]$- στη συνέχεια προσθέσαμε το δεύτερο δοχείο $[0,75, 1)$, το τρίτο $[0,5, 0,75)$ και το τέταρτο $[0,25, 0,5)$ και αξιολογήσαμε την αποτελεσματικότητα των ακριβών και των μαλακών αντιστοιχιών με διαφορετική ισχύ. Τα αποτελέσματα με διαφορετικούς αριθμούς bins παρουσιάζονται στο Σχήμα 4. Για λόγους συντομίας, παρουσιάζεται μόνο η NDCG@20 (ο άξονας y). Η συμπεριφορά είναι παρόμοια για άλλα βάθη. Τα αποτελέσματα των Semantic Scholar και ESR με όλα τα bins εμφανίζονται επίσης για σύγκριση.



Οι πληροφορίες ακριβούς ταύτισης των οντοτήτων (το πρώτο δοχείο) παρέχουν περίπου 6% κέρδος σε σχέση με το S2, με τα Context και Venue. Τα σήματα αντιστοιχίας ex act με ESR-Author και ESR-Desc είναι αραιά, επειδή ορισμένες οντότητες δεν έχουν ακμές Author ή Desc. Σε αυτή την περίπτωση, οι κατατάξεις τους μειώνονται σε S2 και τα κέρδη τους είναι μικρότερα. Η χειροκίνητη εξέτασή μας διαπίστωσε ότι αυτό το κέρδος
προέρχεται από το φαινόμενο της "έξυπνης διατύπωσης": η περιγραφή μιας οντότητας αντιμετωπίζεται ως μια ολόκληρη μονάδα και διαφορετικές φράσεις που αναφέρονται στην ίδια οντότητα ευθυγραμμίζονται. Για παράδειγμα, οι κατατάξεις ερωτημάτων όπως "natural language interface" και "robust prin- ciple component analysis" βελτιώνονται σημαντικά, ενώ στο S2 τα σήματα κειμενικής ομοιότητάς τους αναμειγνύονται από τους επιμέρους όρους και υποφράσεις τους.



Σχήμα 4: Ακρίβεια ESR με τη χρήση διαφορετικών αριθμών δοχείων αντιστοίχισης. Για κάθε ομάδα, από αριστερά προς τα δεξιά: Πρώτα 2 Bins, Πρώτα 3 Bins, και Πρώτα 4 Bins, τα οποία χρησιμοποιούν μόνο τα πρώτα k bins με τις υψηλότερες βαθμολογίες αντιστοίχισης- το τελευταίο All Bins είναι το αρχικό ESR.

Η πληροφορία για το μαλακό ταίριασμα (μεταγενέστερα bins) συνεισφέρει περίπου άλλο 5% της βελτίωσης. Τα bins μαλακής αντιστοίχισης καταγράφουν πόσες οντότητες εγγράφων σχετίζονται με τις οντότητες του ερωτήματος σε συγκεκριμένες εντάσεις. Διαισθητικά, η μαλακή αντιστοίχιση θα πρέπει να συνεισφέρει για όλα τα ερωτήματα, καθώς η γνώση περισσότερων πληροφοριών για τις οντότητες του εγγράφου θα πρέπει πάντα να βοηθάει. Όμως η εξέτασή μας διαπιστώνει ότι αυτή η πληροφορία είναι πιο αποτελεσματική σε ορισμένα ερωτήματα, για παράδειγμα, "δυναμικός προγραμματισμός τμηματοποίησης", "κατασκευή οντολογίας" και "ουσιαστικές φράσεις". Το μαλακό ταίριασμα βοηθά το ESR να βρει τα έγγραφα των οποίων οι έννοιες (π.χ. ερευνητική περιοχή, θέμα και εργασία.) σχετίζονται σημασιολογικά με τις ανάγκες πληροφόρησης αυτών των ερωτημάτων, ενώ το ταίριασμα με βάση τις λέξεις του S2 αποτυγχάνει σε αυτό.

Το πείραμα αυτό μας βοηθά να κατανοήσουμε γιατί η ρητή σεμαντική στους γράφους γνώσης είναι χρήσιμη για την κατάταξη. Γνωρίζοντας σε ποια οντότητα αναφέρεται μια φράση και αν διαφορετικές φράσεις αφορούν το ίδιο πράγμα, το σήμα της *ακριβούς αντιστοιχίας* γυαλίζει. Γνωρίζοντας τη συγγένεια μεταξύ των οντοτήτων του ερωτήματος και των οντοτήτων του εγγράφου μέσω της ενσωμάτωσής τους, ενσωματώνονται πρόσθετες συνδέσεις *μαλακής αντιστοίχισης* που περιγράφουν τη συγγένεια ερωτήματος- εγγράφου με σημασιολογία.

6.4 Αποτελεσματικότητα της ενσωμάτωσης

Το ESR αποτυπώνει τη σημασιολογική συγγένεια μεταξύ οντοτήτων χρησιμοποιώντας την απόστασή τους στο χώρο ενσωμάτωσης. Ένα πλεονέκτημα της χρήσης των ενσωματώσεων σε σύγκριση με τις ακατέργαστες ακμές του γράφου γνώσης είναι η αποδοτικότητά τους, η οποία είναι αυστηρά περιορισμένη στις διαδικτυακές μηχανές αναζήτησης. Με την ενσωμάτωση των γειτόνων μιας οντότητας σε ένα πυκνό συνεχές διάνυσμα, κατά τη διάρκεια της εκτέλεσης, το ESR αποφεύγει να ασχοληθεί με τη δομή του γράφου του γράφου γνώσης, η οποία είναι αραιή, ποικίλου μήκους και πολύ πιο δαπανηρή στην επεξεργασία της σε σχέση με τα πυκνά διανύσματα σταθερού μήκους.

Ωστόσο, θυσιάζει η ESR την αποτελεσματικότητα για την αποδοτικότητα; Το τέταρτο πείραμα μελέτησε την επίδραση των ενσωματώσεων στην αποτελεσματικότητα του ESR, συγκρίνοντας το με την απόδοση κατάταξης με τη χρήση ακατέργαστων ακμών του γράφου γνώσης. Σε αυτό το πείραμα, σχηματίζεται μια διακριτή διανυσματική αναπαράσταση για κάθε οντότητα για κάθε τύπο ακμής. Κάθε μια από τις διαστάσεις του διανύσματος είναι ένας γείτονας της οντότητας. Το βάρος του είναι η συχνότητα με την οποία συνδέονται μεταξύ τους. Οι ακατέργαστες παραλλαγές του ESR διαμορφώνονται στη συνέχεια με την ενσωμάτωση του γράφου γνώσης που επανατοποθετείται από αυτή τη διακριτή αναπαράσταση οντοτήτων και όλα τα υπόλοιπα παραμένουν ίδια.

Πίνακας 4: Απόδοση των διαφόρων στρατηγικών που χρησιμοποιούν το γράφημα γνώσης στην κατάταξη. Η Raw υπολογίζει άμεσα τις ομοιότητες οντοτήτων στον αρχικό διακριτό χώρο. Η Mean χρησιμοποιεί mean-pooling κατά τη γενίκευση του πίνακα μεταφοράς οντοτήτων σε αποδεικτικά στοιχεία κατάταξης ερωτήματος-έγγραφου. Το Max χρησιμοποιεί max-pooling. Το Mean&Bin αντικαθιστά το max-pooling στο πρώτο στάδιο του ESR με mean-pooling. Οι σχετικές επιδόσεις (ποσοστά), οι στατιστικά σημαντικές διαφορές (†) και οι Win/Tie/Loss συγκρίνονται με την έκδοση ESR που χρησιμοποιεί τον ίδιο τύπο ακμής και ενσωμάτωση- για παράδειγμα, Raw-Author έναντι ESR-Author.

Μέθοδος	NDCG@20		W/T/L
ESR-συγγραφέας	0.5935	-	-/-/-
ESR-Context	0.5918	-	-/-/-
ESR-Desc	0.5875	-	-/-/-
ESR-χώρος διεξαγωγής	**0.6090**	-	-/-/-
Raw-Author	0.5821	-1.91%	45/06/49
Raw-Context	0.5642†	-4.66%	38/06/56
Raw-Desc	0.5788	-1.48%	46/05/49
Raw-Venue	0.5576†	-8.43%	28/07/65
Μέσος όρος-συγγραφέας	0.5685†	-4.22%	33/09/58
Mean-Context	0.5676†	-4.08%	39/06/55
Mean-Desc	0.5660	-3.66%	45/12/43
Μέσος όρος-χώρος διεξαγωγής	0.5599†	-8.07%	32/10/58
Max-Author	0.5842	-1.56%	38/10/52
Max-Context	0.5861	-0.95%	52/07/41
Max-Desc	0.5659†	-3.67%	41/12/47
Max-Venue	0.5763†	-5.38%	32/12/56
Mean&Bin-Author	0.5823	-1.89%	41/06/53
Mean&Bin-Context	0.5808	-1.85%	41/08/51
Mean&Bin-Desc	0.5694	-3.07%	38/14/48
Mean&Bin-Venue	0.5639†	-7.41%	31/10/59

Ο πίνακας 4 παρουσιάζει τα αποτελέσματα αυτών των "ακατέργαστων" μεθόδων. Διαφορετικές εκδόσεις της Raw χρησιμοποιούν διαφορετικές ακμές (Author, Context, Desc και Venue) για την αναπαράσταση οντοτήτων. Οι σχετικές επιδόσεις και το Win/Tie/Loss συγκρίνονται με την αντίστοιχη έκδοση ESR που χρησιμοποιεί ακριβώς τις ίδιες πληροφορίες αλλά με ενσωμάτωση γράφου γνώσης. Το αποτέλεσμα δείχνει ότι το ESR επωφελείται πραγματικά από την ενσωμάτωση του γράφου γνώσης- οι μέθοδοι Raw έχουν σχεδόν πάντα χειρότερες επιδόσεις από την αντίστοιχη έκδοση του ESR. Πιστεύουμε ότι το πλεονέκτημα της ενσωμάτωσης γράφων γνώσης είναι παρόμοιο με την ενσωμάτωση λέξεων [18]: η ενσωμάτωση αποτυπώνει καλύτερα τη σημασιολογία με την παραγοντοποίηση των ακατέργαστων αραιών δεδομένων σε έναν ομαλό χώρο χαμηλών διαστάσεων.

6.5 Αποτελεσματικότητα της συγκέντρωσης

Το ESR εφαρμόζει ένα pooling δύο σταδίων στον πίνακα μετάφρασης οντοτήτων για να αποκτήσει στοιχεία κατάταξης ερωτήματος-έγγραφου. Το πρώτο, max-pooling, χρησιμοποιείται για την αντιστοίχιση κάθε οντότητας εγγράφου με την πλησιέστερη οντότητα του ερωτήματος. Το δεύτερο, bin-pooling, χρησιμοποιείται για να συνοψίσει τα αποτελέσματα αντιστοίχισης κάθε οντότητας εγγράφου σε συχνότητες αντιστοίχισης με διαφορετική ισχύ. Αυτό το πείραμα αξιολογεί την αποτελεσματικότητα της στρατηγικής συγκέντρωσης του ESR.

Συγκρίνουμε τη συγκέντρωση δύο σταδίων του ESR με διάφορες κοινές στρατηγικές συγκέντρωσης: mean-pooling που συνοψίζει τον πίνακα μετα- λειτουρ- γίας σε μία μέση βαθμολογία, max-pooling που κρατάει μόνο την υψηλότερη βαθμολογία στον πίνακα και mean&bin-pooling που είναι η ίδια με την max-pooling και bin-pooling του ESR, αλλά στο πρώτο βήμα οι οντότητες εγγράφων αντιστοιχίζονται με τις

μέσες ομοιότητες με τις οντότητες του ερωτήματος. Εκτός από τη στρατηγική συγκέντρωσης, όλες οι άλλες ρυθμίσεις του ESR διατηρούνται.

Τα αποτελέσματα των διαφόρων στρατηγικών συγκέντρωσης παρουσιάζονται στο δεύτερο μισό του πίνακα 4. Οι σχετικές επιδόσεις και τα Win/Tie/Loss συγκρίνονται με την αντίστοιχη έκδοση του ESR. Τα αποτελέσματα καταδεικνύουν την αποτελεσματικότητα της στρατηγικής συγκέντρωσης δύο σταδίων του ESR: Όλες οι άλλες στρατηγικές συγκέντρωσης είναι χειρότερες. Αφαίρεση ολόκληρου του πίνακα μετάφρασης οντοτήτων
σε μια μέση ή μέγιστη βαθμολογία μπορεί να χάσει πάρα πολλές πληροφορίες. Η ομαδοποίηση μέσων όρων και διαιρέσεων αποδίδει επίσης χειρότερα. Διαισθητικά, θα προτιμούσαμε οντότητες εγγράφων που ταιριάζουν πολύ καλά με μία από τις οντότητες του ερωτήματος, παρά οντότητες που έχουν μέτριες αντιστοιχίες με πολλές οντότητες του ερωτήματος. Επίσης, η πληροφορία για την ακριβή αντιστοίχιση δεν διατηρείται στο mean&bin-pooling όταν υπάρχουν πολλαπλές οντότητες ερωτήματος.

Το αποτέλεσμα αυτό δείχνει ότι η γενίκευση των αποδείξεων σε επίπεδο οντοτήτων στο επίπεδο ερωτήματος-έγγραφου δεν είναι εύκολη υπόθεση. Πρέπει να βρεθεί το σωστό επίπεδο αφαίρεσης για να επιτευχθεί ένα καλό αποτέλεσμα. Υπάρχουν και άλλες στρατηγικές αφαίρεσης που είναι πιο πολύπλοκες και θα μπορούσαν να είναι πιο ισχυρές. Για παράδειγμα, μπορεί κανείς να φανταστεί τη δημιουργία ενός RNN ή CNN πάνω στο μεταφραστικό ma- trix, αλλά αυτό θα απαιτούσε περισσότερες ετικέτες εκπαίδευσης. Πιστεύουμε ότι η συγκέντρωση δύο σταδίων του ESR παρέχει τη σωστή ισορροπία μεταξύ πολυπλοκότητας του μοντέλου και κοκκομετρίας αφαίρεσης, δεδομένου του μεγέθους των δεδομένων εκπαίδευσης που διαθέτουμε.

7. ΣΥΜΠΕΡΆΣΜΑΤΑ ΚΑΙ ΜΕΛΛΟΝΤΙΚΈΣ ΕΡΓΑΣΙΕΣ

Η ανάλυση των αρχείων καταγραφής ερωτημάτων του Semantic Scholar αποκάλυψε ότι ένα μεγάλο ποσοστό των ερωτημάτων κεφαλής περιλαμβάνει ερευνητικές έννοιες και ότι μια σημαντική πηγή σφάλματος ήταν η αδυναμία ακόμη και ενός καλά ρυθμισμένου συστήματος bag-of-words να τα κατατάξει με ακρίβεια. Για την αντιμετώπιση αυτής της πρόκλησης, αναπτύξαμε την Explicit Semantic Ranking (ESR), μια νέα τεχνική που χρησιμοποιεί τις ρητές σημασιολογικές έννοιες από έναν γράφο γνώσης στην ακαδημαϊκή αναζήτηση. Στο ESR, τα ερωτήματα και τα έγγραφα αναπαρίστανται στο χώρο οντοτήτων με τη χρήση των σχολίων τους και η κατάταξη ορίζεται από τη σημασιολογική τους συνάφεια που περιγράφεται από τις συνδέσεις των οντοτήτων τους, σε ένα πλαίσιο ενσωμάτωσης, συγκέντρωσης και κατάταξης.

Πειράματα σε ένα περιβάλλον δοκιμών Semantic Scholar αποδεικνύουν
ότι το ESR βελτιώνει το σύστημα παραγωγής κατά 6% έως 14%. Η πρόσθετη ανάλυση αποκάλυψε την αποτελεσματικότητα της ρητής σημασιολογίας: οι οντότητες και οι επιφανειακές μορφές τους βοηθούν στην αναγνώριση των εννοιών σε ένα ερώτημα και βελτιώνουν το σήμα *ακριβούς* αντιστοίχισης- η δομή του γράφου γνώσης βοηθά στην οικοδόμηση πρόσθετων συνδέσεων μεταξύ του ερωτήματος και των εγγράφων και παρέχει αποτελεσματικά και νέα στοιχεία *μαλακής αντιστοίχισης*. Με το πλαίσιο ενσωμάτωσης, συγκέντρωσης και κατάταξης που αξιοποιεί επιτυχώς αυτή τη σημασιολογία, το ESR παρέχει ισχυρές βελτιώσεις, ειδικά στα ερωτήματα που είναι δύσκολα για τα μοντέλα κατάταξης που βασίζονται σε λέξεις. Ίσως παραδόξως, διαπιστώσαμε ότι η χρήση των enti- ties της Freebase ήταν πιο αποτελεσματική από τις keyphrases που εξάγονται αυτόματα από το corpus της S2. Αν και η Freebase θεωρείται γενικής χρήσης, παρέχει εκπληκτικά καλή κάλυψη των οντοτήτων στον τομέα μας - την επιστήμη των υπολογιστών. Η αξία αυτού του γράφου γνώσης μπορεί να βελτιωθεί περαιτέρω με την προσθήκη σημασιολογίας ειδικού τομέα, όπως οι τόποι και οι συγγραφείς. Το αποτέλεσμα αυτό είναι ενθαρρυντικό, διότι οι καλές βάσεις γνώσης συγκεκριμένου τομέα είναι δύσκολο να δημιουργηθούν από το μηδέν. Δείχνει ότι οντότητες από μια βάση γνώσης γενικού τομέα μπορούν να μια καλή αρχή.

Διαφορετικοί τύποι ακμών στο γράφημα γνώσης αποδίδουν μάλλον διαφορετική σημασιολογία. Στα πειράματά μας, υπάρχει λιγότερο από 15% επικάλυψη μεταξύ των στενών γειτόνων μιας οντότητας σε διαφορετικούς

διαφορετικούς χώρους ενσωμάτωσης. Οι διάφορες παραλλαγές του ESR έχουν επίσης διαφορετικές επιδόσεις σε διαφορετικά ερωτήματα. Η παρούσα εργασία επικεντρώνεται κυρίως στον τρόπο αξιοποίησης κάθε τύπου ακμής ξεχωριστά. Μια σημαντική μελλοντική ερευνητική κατεύθυνση είναι η μελέτη του τρόπου καλύτερης αξιοποίησης της σημασιολογίας του γράφου γνώσης με πιο ενοποιημένο τρόπο, ίσως με τη βοήθεια ετικετών κατάταξης.

Η παρούσα εργασία παρουσιάζει μια νέα μέθοδο χρήσης γραφημάτων γνώσης για τη βελτίωση της κατάταξης της ακαδημαϊκής αναζήτησης. Αν και οι λεπτομέρειες αυτής της εργασίας αφορούν ειδικά το Semantic Scholar, οι τεχνικές και τα διδάγματα που αντλήθηκαν είναι γενικά και μπορούν να εφαρμοστούν σε άλλες μηχανές αναζήτησης πλήρους κειμένου.

8. ΕΥΧΑΡΙΣΤΙΕΣ

Η έρευνα αυτή υποστηρίχθηκε από την επιχορήγηση IIS-1422676 του National Science Foun- dation (NSF) και από δωρεά του Allen Institute for Artificial Intelligence. Οι απόψεις, τα ευρήματα και τα συμπεράσματα που περιέχονται στην παρούσα εργασία είναι των συγγραφέων και δεν αντανακλούν απαραίτητα εκείνες των χορηγών.

9. ΑΝΑΦΟΡΕΣ

[1] A. Arnold και W. W. Cohen. Εξαγωγή πληροφοριών ως πρόβλεψη συνδέσμων: Χρήση επιμελημένων δικτύων παραπομπών για τη βελτίωση της ανίχνευσης γονιδίων. In *International Conference on Wireless Algorithms, Systems, and Applications*, pages 541-550. Springer, 2009.

[2] K. Balog, L. Azzopardi και M. De Rijke. Τυπικά μοντέλα για την εύρεση εμπειρογνωμόνων σε εταιρικά σώματα. In *Proceedings of the 29th annual international ACM SIGIR conference on Research and development in information retrieval (SIGIR 2006)*, pages 43-50. ACM, 2006.

[3] A. Berger και J. Lafferty. Ανάκτηση πληροφοριών ως στατιστική μετάφραση. In *Proceedings of the 22nd Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 1999)*, pages 222-229. ACM, 1999.

[4] C. Caragea, F. A. Bulgarov, A. Godea και S. Das Gollapalli. Εξαγωγή φράσεων-κλειδιών από ερευνητικές εργασίες με βάση τις παραπομπές: Μια εποπτευόμενη προσέγγιση. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1435-1446. Association for Computational Linguistics, 2014.

[5] D. Carmel, M.-W. Chang, E. Gabrilovich, B.-J. P. Hsu, και K. Wang. ERD'14: Πρόκληση αναγνώρισης και αποσαφήνισης οντοτήτων. In *Proceedings of the 37th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2014)*. ACM, 2014.

[6] J. Chen, C. Xiong και J. Callan. Μια εμπειρική μελέτη της εκμάθησης κατάταξης για αναζήτηση οντοτήτων. In *Proceedings of the 39th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval,(SIGIR 2016)*. ACM, 2016. To Appear.

[7] N. Craswell, A. P. de Vries και I. Soboroff. Επισκόπηση του επιχειρηματικού κομματιού trec 2005. In *Proceedings of The 14th Text Retrieval Conference (TREC 2005)*, volume 5, pages 199-205, 2005.

[8] J. Dalton, L. Dietz και J. Allan. Επέκταση χαρακτηριστικών ερωτημάτων οντοτήτων με χρήση συνδέσμων βάσης γνώσης. In *Proceedings of the 37th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2014)*, pages 365-374. ACM, 2014.

[9] L. Dietz, A. Kotov και E. Meij. Αξιοποίηση βάσεων γνώσης στην ανάκτηση πληροφοριών με επίκεντρο το κείμενο. In *Proceedings of the 2016 ACM on International Conference on the Theory of Information Retrieval (ICTIR 2016)*, pages 5-5. ACM, 2016.

[10] E. Gabrilovich, M. Ringgaard και A. Subramanya. FACC1: Freebase annotation of ClueWeb corpora, Version 1 (Ημερομηνία έκδοσης 2013-06-26, Format version 1, Correction επίπεδο 0), Ιούνιος 2013.

[11] J. Guo, Y. Fan, A. Qingyao και W. Croft. Ένα βαθύ μοντέλο αντιστοίχισης συνάφειας για ad-hoc ανάκτηση. In *Proceedings of the 25th ACM International on Conference on Information and Knowledge Management (CIKM 2016)*, page To Appear. ACM, 2016.

[12] F. Hasibi, K. Balog και S. E. Bratsberg. Σύνδεση οντοτήτων σε ερωτήματα: Εργασίες και αξιολόγηση. Στα *πρακτικά του πέμπτου*

ACM International Conference on The Theory of Information Retrieval (ICTIR 2015), σελίδες 171-180. ACM, 2015.

[13] P.-S. Huang, X. He, J. Gao, L. Deng, A. Acero και L. Heck. Εκμάθηση βαθιών δομημένων σημασιολογικών μοντέλων για αναζήτηση στο διαδίκτυο με χρήση δεδομένων κλικ. In *Proceedings of the 22nd ACM international conference on Conference on information & knowledge management (CIKM 2013)*, pages 2333-2338. ACM, 2013.

[14] T. Joachims. Βελτιστοποίηση μηχανών αναζήτησης με χρήση δεδομένων κλικ. In *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD 2002)*, pages 133-142. ACM, 2002.

[15] T.-Y. Liu. Μάθηση κατάταξης για την ανάκτηση πληροφοριών. *Foundations and Trends in Information Retrieval*, 3(3):225-331, 2009.

[16] X. Liu και H. Fang. Latent entity space: μια νέα προσέγγιση ανάκτησης για ερωτήματα που περιέχουν οντότητες. *Information Retrieval Journal*, 18(6):473-503, 2015.

[17] X. Liu, P. Yang και H. Fang. Η οντότητα ήρθε για να σώσει - Αξιοποίηση οντοτήτων για την ελαχιστοποίηση των κινδύνων στην αναζήτηση στο διαδίκτυο. Στα *Πρακτικά του 23ου Συνεδρίου Ανάκτησης Κειμένου, (TREC 2014)*. NIST, 2014.

[18] T. Mikolov, I. Sutskever, K. Chen, G. S. Corrado και J. Dean. Κατανεμημένες αναπαραστάσεις λέξεων και φράσεων και η συνθετικότητά τους. In *Proceedings of the 2tth Advances in Neural Information Processing Systems 2013 (NIPS 2013)*, pages 3111-3119, 2013.

[19] H. Raviv, O. Kurland και D. Carmel. Ανάκτηση εγγράφων με χρήση γλωσσικών μοντέλων βασισμένων σε οντότητες. In *Proceedings of the 39th International ACM SIGIR conference on Research and Development in Information Retrieval (SIGIR 2016)*, pages 65-74. ACM, 2016.

[20] A. Sinha, Z. Shen, Y. Song, H. Ma, D. Eide, B.-j. P. Hsu, και K. Wang. Επισκόπηση της ακαδημαϊκής υπηρεσίας microsoft (MAS) και των εφαρμογών της. Στα *Πρακτικά του 24ου Διεθνούς Συνεδρίου για τον Παγκόσμιο Ιστό (WWW 2015)*, σελίδες 243-246. ACM, 2015.

[21] J. Tang, J. Zhang, L. Yao, J. Li, L. Zhang και Z. Su. Arnetminer: εξαγωγή και εξόρυξη ακαδημαϊκών κοινωνικών δικτύων. In *Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining (KDD 2008)*, pages 990-998. ACM, 2008.

[22] I. Vuli´c και M.-F. Moens. Μονόγλωσσα και διαγλωσσικά μοντέλα ανάκτησης πληροφοριών βασισμένα σε (δίγλωσσες) ενσωματώσεις λέξεων. In *Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2015)*, pages 363-372. ACM, 2015.

[23] A. D. Wade, K. Wang, Y. Sun και A. Gulli. Wsdm cup 2016: Entity ranking challenge. In *Proceedings of the Ninth ACM International Conference on Web Search and Data Mining (WSDM 2016)*, pages 593-594. ACM, 2016.

[24] X. Wei και W. B. Croft. Μοντέλα εγγράφων με βάση το Lda για ad-hoc ανάκτηση. In *Proceedings of the 29th annual international ACM SIGIR conference on Research and development in information retrieval (SIGIR 2006)*, pages 178-185. ACM, 2006.

[25] C. Xiong και J. Callan. EsdRank: Σύνδεση ερωτημάτων και εγγράφων μέσω εξωτερικών ημιδομημένων δεδομένων. In *Proceedings of the 24th ACM International Conference on Information and Knowledge Management (CIKM 2015)*, pages 951-960. ACM, 2015.

[26] C. Xiong και J. Callan. Επέκταση ερωτήσεων με τη Freebase. In *Proceedings of the fifth ACM International Conference on the Theory of Information Retrieval (ICTIR 2015)*, pages 111-120. ACM, 2015.

[27] C. Xiong, J. Callan και T.-Y. Liu. Αναπαράσταση σακούλας με οντότητες για κατάταξη. In *Proceedings of the sixth ACM International Conference on the Theory of Information Retrieval (ICTIR 2016)*, pages 181-184. ACM, 2016.

[28] Y. Xu, G. J. Jones και B. Wang. Ανατροφοδότηση ψευδο-σχετικότητας εξαρτώμενη από το ερώτημα με βάση τη Wikipedia. In *Proceedings of the 32nd Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2009)*, pages 59-66. ACM, 2009.

[29] J. Zhang, J. Tang και J. Li. Εύρεση εμπειρογνωμόνων σε ένα κοινωνικό δίκτυο. In *International Conference on Database Systems for Advanced Applications*, pages 1066-1069. Springer, 2007.