DeepL

Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.



Σημασιολογική αναζήτηση για επιστημονικά έγγραφα

Iana Atanassova, Marc Bertin

Για να παραθέσετε αυτή την έκδοση:

Iana Atanassova, Marc Bertin. Σημασιολογική αναζήτηση για επιστημονικά έγγραφα. Semantic Publishing Challenge co-located with the 11th European Semantic Web Conference ESWC2014, European Se- mantic Web Conference ESWC, May 2014, Anissaras, Greece. hal-01953993

HAL Id: hal-01953993

https://hal.science/hal-01953993

Υποβλήθηκε στις 13 Δεκ 2018

Το HAL είναι ένα διεπιστημονικό αρχείο ανοικτής πρόσβασης για την κατάθεση και τη διάδοση επιστημονικών ερευνητικών εγγράφων, είτε έχουν δημοσιευθεί είτε όχι. Τα έγγραφα μπορεί να προέρχονται από διδακτικά και ερευνητικά ιδρύματα στη Γαλλία ή στο εξωτερικό, ή από δημόσια ή ιδιωτικά ερευνητικά κέντρα.

L'archive ouverte pluridisciplinaire **HAL**, est destinée au dépôt et à la diffusion de documents scientifiques de niveau recherche, publiés ou non, émanant des établissements d'enseignement et de recherche français ou étrangers, des laboratoires publics ou privés.

Σημασιολογική αναζήτηση για επιστημονικές εργασίες

Iana Atanassova και Marc Bertin

CIRST, Πανεπιστήμιο του Κουέβου του Μοντρέ
B.P. 8888, Succ. Centre-ville
H3C 3P8 Μόντρεαλ (Κεμπέκ)
Καναδάς
iana.atanassova@nlp-labs.org, bertin.marc@courrier.uqam.ca

Περίληψη. Η ανάκτηση πληροφοριών σε επιστημονικές δημοσιεύσεις μπορεί να βελτιωθεί μέσω σημασιολογικού σχολιασμού με σκοπό τον εντοπισμό σχετικών φράσεων που περιέχουν συγκεκριμένες σημασιολογικές σχέσεις, όπως η έκφραση μεθόδων, ορισμών, υποθέσεων. Παρουσιάζουμε ένα σύστημα IR για επιστημονικές δημοσιεύσεις το οποίο παρέχει τη δυνατότητα ταξινόμησης των αποτελεσμάτων σύμφωνα με σημασιολογικές όψεις. Οι σημασιολογικές επισημειώσεις λαμβάνονται με τη χρήση μιας μεθόδου βασισμένης σε κανόνες που εντοπίζει συγκεκριμένες γλωσσικές ενδείξεις οργανωμένες σε μια γλωσσική οντολογία. Η προσέγγιση αυτή υλοποιείται με τον Solr Search Server και παρέχει αποτελεσματική αναζήτηση και πλοήγηση σε επιστημονικές εργασίες. Το πρόγραμμα επίδειξης είναι διαθέσιμο στη διεύθυνση http://sempub2014.nlp-labs.org/task3/.

Λέξεις-κλειδιά: Ανάκτηση Πληροφοριών, Faceted Search, Semantic Facets, Solr

1 Εισαγωγή

Σήμερα, με την εμφάνιση της ανοικτής επιστήμης, περισσότερα επιστημονικά άρθρα είναι διαθέσιμα σε πλήρες κείμενο. Ο όγκος των δεδομένων κειμένου που παρέχονται, ευνοεί την ανάπτυξη νέων εργαλείων για την αποτελεσματική εξερεύνηση του περιεχομένου των ερευνητικών άρθρων. Η αξιοποίηση του σημασιολογικού σχολιασμού για την ανάκτηση πληροφοριών αποτελεί αντικείμενο πολλών εργασιών (π.χ. [6]) και η εξαγωγή φράσεων-κλειδιών από επιστημονικά άρθρα (βλ. [9]) είναι ένα στενά συνδεδεμένο θέμα. Στόχος της ανάπτυξης νέων εργαλείων ανάκτησης πληροφοριών είναι η μείωση του πνευματικού φόρτου εργασίας των χρηστών κατά την παραγωγή νοητικών αναπαραστάσεων των εγγράφων προκειμένου να εντοπίσουν πραγματικά σημαντικές πληροφορίες. Η άποψη αυτή εξετάζεται από τους Bertin και Atanassova [2].

Στην παρούσα εργασία περιγράφουμε μια μηχανή σημασιολογικής αναζήτησης που παρέχει έναν νέο τρόπο πρόσβασης σε σχετικές πληροφορίες σε επιστημονικές εργασίες. Για την υλοποίηση του αυτόματου σχολιασμού του συνόλου των σημασιολογικών κατηγοριών στα κείμενα χρησιμοποιούμε την εργασία του [4]. Άλλες εφαρμογές αυτής της προσέγγισης παρουσιάζονται στα [1,3].

2 Μέθοδος

Για τη μελέτη αυτή, επεξεργαστήκαμε άρθρα από επτά επιστημονικά περιοδικά, που δημοσιεύονται από τη Δημόσια Βιβλιοθήκη της Επιστήμης (PLOS) και είναι διαθέσιμα σε ανοικτή πρόσβαση. Τα άρθρα είναι σε μορφή XML, δομημένα με τη χρήση του Journal Article Tag Suite

(JATS)[1], παρέχοντας τα πλήρη μεταδεδομένα και το πλήρες κείμενο των άρθρων. Οι ενότητες και οι παράγραφοι του κειμένου αναπαρίστανται ως ξεχωριστά στοιχεία. Επεξεργαστήκαμε το σύνολο των ερευνητικών άρθρων αυτών των περιοδικών μέχρι τον Σεπτέμβριο/Οκτώβριο του 2012. Ο πίνακας 1 δείχνει τον αριθμό των άρθρων και των προτάσεων που επεξεργάστηκαν για κάθε περιοδικό.

Περιοδικό	Αριθμός άρθρων	Αριθμός προτάσεων
PLoS Biology	2,965	426,522
PLoS Computational Biology	2,107	518,289
PLoS Genetics	2,560	566,323
PLoS Medicine	2,228	218,459
PLoS Παραμελημένες τροπικές ασθένειες	1,366	217,861
PLoS Pathogens	2,354	514,751
PLoS ONE	33,782	6,080,566
Σύνολο	47,362	8,542,771

Πίνακας 1. Σύνολο δεδομένων

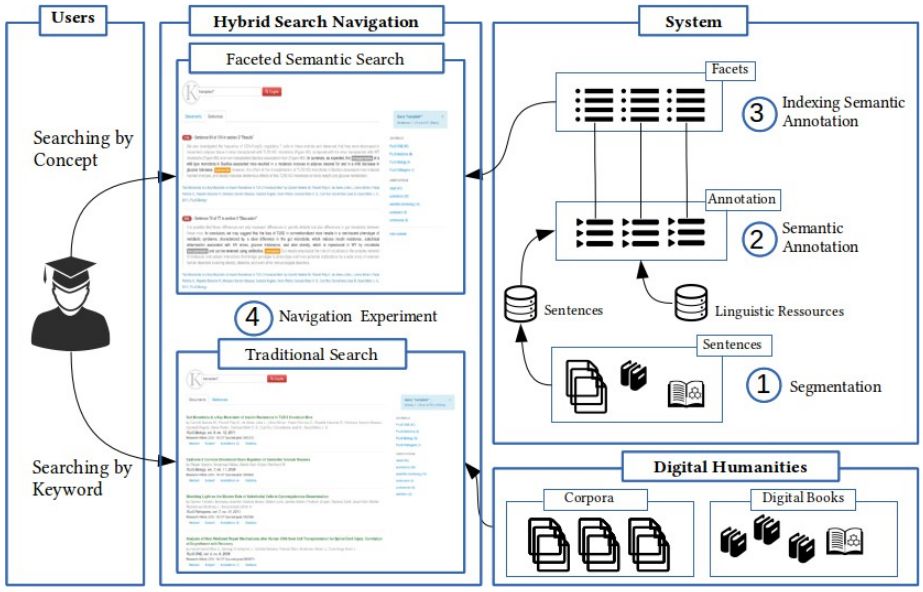
Θεωρούμε τις προτάσεις ως τη βασική μονάδα στην επεξεργασία μας. Στόχος μας είναι να παρέχουμε σημασιολογικό σχολιασμό ορισμένων προτάσεων του σώματος, που αντιστοιχούν σε συγκεκριμένες ανάγκες του χρήστη σε ένα πλαίσιο ανάκτησης πληροφοριών. Οι σχολιασμένες προτάσεις μπορούν στη συνέχεια να χρησιμοποιηθούν για την υλοποίηση λειτουργιών σημασιολογικής αναζήτησης σε συνδυασμό με την κλασική ανάκτηση πληροφοριών με λέξεις-κλειδιά. Η αναζήτηση με όψεις επιτρέπει στο χρήστη να απεικονίσει πολλαπλές κατηγορίες και να ταξινομήσει τις αναφορές σύμφωνα με αυτές τις κατηγορίες. Στο Σχήμα 1 παρουσιάζονται τα βήματα επεξεργασίας που θα περιγραφούν παρακάτω. Η διεπαφή είναι διαθέσιμη στη διεύθυνση http://sempub2014.nlp-labs.org/task3/.

Εξαγωγή μεταδεδομένων. Από τα έγγραφα XML εξάγονται πεδία μεταδεδομένων, όπως τίτλοι, συγγραφείς, περίληψη, περιοδικό και θέμα. Επιπλέον, εξάγουμε όλα τα βιβλιογραφικά δεδομένα, δηλαδή τον κατάλογο των παραπομπών στη βιβλιογραφία, και εντοπίζουμε τα τμήματα κειμένου στα οποία αυτές οι παραπομπές αναφέρονται στο κείμενο. Έτσι, είμαστε σε θέση να παρέχουμε στη διεπαφή χρήστη μετρητές για τον αριθμό των αναφορών και των παραπομπών στο κείμενο για κάθε άρθρο, καθώς και δείκτες στις παραπομπές κάθε αναφοράς.

Τμηματοποίηση. Τμηματοποιούμε όλες τις παραγράφους του συνόλου δεδομένων σε προτάσεις. Η διαδικασία τμηματοποίησης, που βασίζεται στην ανάλυση των σημείων στίξης, έχει ήδη συζητηθεί σε αρκετές δημοσιεύσεις και τα λεπτομερή αποτελέσματα της τμηματοποίησης αυτού του συνόλου δεδομένων έχουν δοθεί στους Bertin et al. [5].

Σημασιολογικός σχολιασμός. Οι γλωσσικοί μας πόροι βασίζονται στη μέθοδο Contextual Exploration (CE) που περιγράφεται στο Descles [7]. Η μέθοδος αυτή πραγματοποιεί την

[1] Το παρόν πρότυπο αποτελεί εφαρμογή του NISO Z39.96-2012 και το JATS αποτελεί συνέχεια του NLM Archiving and Interchange DTD: http://jats.nlm.nih.gov.



Σχήμα 1. Faceting & σημασιολογικός σχολιασμός

αυτόματος σημασιολογικός σχολιασμός τμημάτων κειμένου για μια δεδομένη εργασία σχολιασμού, όπως ο εντοπισμός και η ταξινόμηση παραπομπών, η εξαγωγή τμημάτων για περίληψη και ο εντοπισμός ειδικών σημασιολογικών κατηγοριών, όπως ορισμοί, υποθέσεις κ.λπ. Η μέθοδος CE είναι μια διαδικασία λήψης αποφάσεων, η οποία παρουσιάζεται με τη μορφή ενός συνόλου κανόνων και γλωσσικών ενδείξεων που ενεργοποιούν την εφαρμογή των κανόνων.

Έχουμε σχολιάσει τις προτάσεις του σώματός μας με ένα σύνολο κατηγοριών που αντιστοιχούν σε κοινές σημασιολογικές σχέσεις που εκφράζονται σε επιστημονικά άρθρα:

αποτέλεσμα: προτάσεις που εκφράζουν ένα αποτέλεσμα που προέκυψε από την εργασία ή από τις αναφερόμενες εργασίες.
summarize: προτάσεις που συνοψίζουν μια μέθοδο, μια εργασία κ.λπ. που συνήθως βρίσκονται στις ενότητες αποτελεσμάτων και συζήτησης.
secienti c παρακολούθηση: προτάσεις που εκφράζουν γεγονότα και εικασίες που είναι σημαντικές για την παρακολούθηση της καινοτομίας και των νέων αποτελεσμάτων.
de nition: προτάσεις που εκφράζουν ορισμούς που δίνονται από την εργασία ή από αναφερόμενες εργασίες.
συμπέρασμα: προτάσεις που εκφράζουν το συμπέρασμα μιας εργασίας.
controverse: προτάσεις που εκφράζουν αντιθέσεις, διαφορετικές απόψεις κ.λπ.
συμφωνία : προτάσεις που εκφράζουν συμφωνία στις μεθόδους, τα αποτελέσματα κ.λπ. μιας εργασίας και των αναφερόμενων εργασιών.
γνώμη: προτάσεις που εκφράζουν τις απόψεις των συγγραφέων μιας εργασίας.

Ο Πίνακας 2 παρουσιάζει τον αριθμό των άρθρων που περιέχουν σχολιασμούς και τον αριθμό των σχολιασμένων προτάσεων. Δεν έχουμε αξιολογήσει τους σχολιασμούς για αυτό το

Περιοδικό	Άρθρα με σχόλια	Σχολιασμένες προτάσεις
PLoS Biology	1,157	1,654
PLoS Computational Biology	1,440	2,782
PLoS Genetics	1,644	2,428
PLoS Medicine	635	778
PLoS Παραμελημένες τροπικές ασθένειες	590	752
PLoS Pathogens	1,459	2,408
PLoS ONE	18,419	26,855
Σύνολο	25,344	37,657

Πίνακας 2. Στατιστικά στοιχεία σχολιασμού

σύνολο δεδομένων. Προηγούμενες εργασίες [3,4] παρείχαν αξιολογήσεις της μεθόδου σχολιασμού που λειτούργησε σε άλλα σύνολα δεδομένων και έλαβαν μάλλον υψηλές τιμές ακρίβειας. Οι σχολιασμοί μπορούν να μετατραπούν σε διασυνδεδεμένα δεδομένα με χρήση μηχανικά αναγνώσιμου RDF για διαλειτουργικότητα με άλλα εργαλεία. Μετά την αξιολόγηση, θα είμαστε σε θέση να παρέχουμε ένα σχολιασμένο σώμα δεδομένων που μπορεί να χρησιμοποιηθεί για την ανάπτυξη άλλων προσεγγίσεων, για παράδειγμα με τη χρήση χώρων ονομάτων και οντολογιών όπως οι SPAR και DoCO [8].

Ευρετηρίαση σημασιολογικών σχολίων. Υλοποιήσαμε μια μηχανή σημασιολογικής αναζήτησης χρησιμοποιώντας τον Apache Solr Search Server[2]. Ο Solr παρέχει REST-like APIs που διευκολύνουν την εργασία με XML les. Στην υλοποίησή μας τα έγγραφα XML με σχόλια ευρετηριάστηκαν χρησιμοποιώντας λαβές εισαγωγής XSLT. Ο Solr χρησιμοποιεί τη βιβλιοθήκη αναζήτησης Lucene Java για ευρετηρίαση και αναζήτηση πλήρους κειμένου.

Έχουμε ευρετηριάσει τόσο τα άρθρα όσο και τις προτάσεις ως δύο διαφορετικούς τύπους εγγράφων που συνδέονται στο ευρετήριο του Solr. Αυτό μας επιτρέπει να υλοποιήσουμε αναζήτηση τόσο σε επίπεδο άρθρου όσο και σε επίπεδο πρότασης. Όλες οι σχολιασμένες προτάσεις ευρετηριάστηκαν μαζί με τις κατηγορίες σχολιασμού τους και με το άμεσο περιεχόμενό τους (προηγούμενη και επόμενη πρόταση).

Σημασιολογική αναζήτηση. Η διεπαφή αναζήτησης παρέχει αναζήτηση σε δύο επίπεδα: έγγραφα και προτάσεις. Σε κάθε επίπεδο, οι σημασιολογικοί σχολιασμοί είναι ορατοί και μπορούν να χρησιμοποιηθούν ως όψεις για την ταξινόμηση των αποτελεσμάτων. Ο αρχικός κατάλογος αποτελεσμάτων λαμβάνεται με αναζήτηση με λέξεις-κλειδιά. Η κλασική σύνταξη ερωτημάτων (χρήση των *, AND, OR, κ.λπ.) υποστηρίζεται από τον αναλυτή ερωτημάτων του Solr.

Σε επίπεδο εγγράφου, ο χρήστης έχει πρόσβαση στον κατάλογο των σχετικών εγγράφων. Κάθε έγγραφο παρουσιάζεται με τα μεταδεδομένα του. Δίνονται δύο νέοι τύποι πληροφοριών σε σύγκριση με τις κλασικές μηχανές αναζήτησης: τα σχόλια στην εργασία και ορισμένα στατιστικά στοιχεία σχετικά με το άρθρο (αριθμός αναφορών και παραπομπών στο κείμενο, κ.λπ.).

Σε επίπεδο προτάσεων, τα αποτελέσματα της αναζήτησης δίνονται ως κατάλογος προτάσεων στα συμφραζόμενά τους, μαζί με τις επισημάνσεις. Μια πρόταση θεωρείται σχετική εάν περιέχει τις λέξεις-κλειδιά και είναι σχολιασμένη με μία από τις σημασιολογικές κατηγορίες. Για κάθε πρόταση, έχουμε παράσχει ορισμένες πρόσθετες πληροφορίες για τη θέση της

[2] https://lucene.apache.org/solr/

στην εργασία (ο πρώτος αριθμός που εμφανίζεται με κόκκινη κουκκίδα), η θέση του στην ενότητα και οι βιβλιογραφικές πληροφορίες της εργασίας.

3 Συμπέρασμα και περαιτέρω ανάπτυξη

Η επίδειξή μας παρουσιάζει μια πρώτη εφαρμογή σημασιολογικών όψεων σε επίπεδο συναισθημάτων. Αυτή η προσέγγιση παρέχει έναν νέο τρόπο πρόσβασης σε σχετικές πληροφορίες και πλοήγησης σε επιστημονικές εργασίες. Περαιτέρω βελτιώσεις μπορούν να γίνουν στην επεξεργασία διαχωρισμού και σχολιασμού. Αυτή η ηλεκτρονική έκδοση είναι ένα πρώιμο πρωτότυπο και στόχος μας είναι να αναπτύξουμε και άλλες σημασιολογικές κατηγορίες και όψεις που σχετίζονται με επιστημονικά άρθρα.

Ευχαριστίες

Θέλουμε να ευχαριστήσουμε το Observatoire des Sciences et des Technologies (OST)[3], Μόντρεαλ, Καναδάς, για τη συλλογή και την παροχή του συνόλου δεδομένων PLOS.

Αναφορές

1. Bertin, M.: Κατηγοριοποιήσεις και σχολιασμοί των αναφορών στην αξιολόγηση της έρευνας. In: Proceedings of the 21th International Florida Arti cial Intelligence Research Society Conference. pp. 456 46 (2008)
2. Bertin, M., Atanassova, I.: Semantic Enrichment of Scienti c Publications and Meta-δεδομένα : Ανάλυση παραπομπών μέσω της ανάλυσης πλαισίου και της γνωστικής ανάλυσης. In: Proceed- ings of the 1st International Workshop on Mining Scienti c Publications, in con- junction with Joint Conference on Digital Libraries JCDL-2012. ACM/IEEE (2012)
3. Bertin, M., Atanassova, I., Descl s, J.P.: Αυτόματη ανάλυση της κρίσης των συγγραφέων σε επιστημονικά άρθρα βάσει σημασιολογικού σχολιασμού. In: International Florida Arti cial Intelligence), Research Society Conference, Sanibel Island, Florida. pp. 19 21 (2009).
4. Bertin, M., Atanassova, I., Descl s, J.P.: Εξαγωγή των ορισμών του συγγραφέα χρησιμοποιώντας
   Ευρετηριασμένο αναγνωριστικό αναφοράς. In: Proceedings of the 1st Workshop on De nition Extraction , in conjunction with RANLP 2009. pp. 61 67. Association for Compu- tational Linguistics (2009).
5. Bertin, M., Atanassova, I., Lariviere, V., Gingras, Y.: Η κατανομή των αναφορών σε επιστημονικά έγγραφα: μια ανάλυση της δομής IMRaD. In: 14th International Society of Scientometrics and Informetrics Conference. pp. 591 603. Διεθνής Εταιρεία Πληροφορικής και Επιστημονικής (2013).
6. Buscaldi, D., Zargayouna, H.: Yasemir: Ακόμα μια σημασιολογική ανάκτηση πληροφοριών σύστημα. Στο: Proceedings of the sixth international workshop on Exploiting semantic annotations in information retrieval. pp. 13 16. ACM (2013).
7. Descl s, J.P.: Για την επεξεργασία της διερεύνησης του πλαισίου για τον λόγο και την αυτόματη ανα-
   των κειμένων. In: 281 284 (2006).
8. Shotton, D., Peroni, S.: DoCO, the document components ontology (2011)
9. You, W., Fontaine, D., Barth s, J.P.: A automatic keyphrase extraction system for scienti c documents. Knowledge and information systems 34(3), 691 724 (2013).

[3] http://www.ost.uqam.ca/