DeepL

Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

Δημοσιεύθηκε online 12 Ιουνίου *2012Nucleic Acids Research, 2012, Vol. 40, Web Server issue W585-W591*
doi:10.1093/nar/gks563

GeneView: μια ολοκληρωμένη μηχανή σημασιολογικής αναζήτησης για το PubMed

Philippe Thomas, Johannes Starlinger, Alexander Vowinkel, Sebastian Arzt και Ulf Leser*

Knowledge Management in Bioinformatics, Institute for Computer Science, Humboldt-Universita¨ t zu Berlin, Unter den Linden 6, 10099 Berlin, Germany

Παραλήφθηκε στις 28 Φεβρουαρίου 2012, αναθεωρημένο στις 6 Μαΐου 2012, αποδεκτό στις 19 Μαΐου 2012.

ΠΕΡΙΛΗΨΗ

Τα ερευνητικά αποτελέσματα δημοσιεύονται κυρίως στην επιστημονική βιβλιογραφία και οι προσπάθειες επιμέλειας δεν μπορούν να συμβαδίσουν με την ταχεία αύξηση της δημοσιευμένης βιβλιογραφίας. Η πληθώρα της γνώσης παραμένει κρυμμένη σε μεγάλα αποθετήρια κειμένων όπως το MEDLINE. Κατά συνέπεια, οι επιστήμονες της επιστήμης της ζωής πρέπει να ξοδεύουν μεγάλο χρονικό διάστημα για την αναζήτηση συγκεκριμένων πληροφοριών. Η τεράστια ασάφεια μεταξύ των περισσότερων ονομάτων βιοϊατρικών αντικειμένων, όπως γονίδια, χημικές ουσίες και ασθένειες, παράγει συχνά πολύ μεγάλα και μη συγκεκριμένα αποτελέσματα αναζήτησης. Παρουσιάζουμε το GeneView, μια σημασιολογική μηχανή αναζήτησης για βιοϊατρική γνώση. Το GeneView βασίζεται σε μια πλήρως σχολιασμένη έκδοση των περιλήψεων του PubMed και των ανοικτά διαθέσιμων πλήρων κειμένων του PubMed Central. Αυτή η ημιδομημένη αναπαράσταση των βιοϊατρικών κειμένων επιτρέπει μια σειρά από χαρακτηριστικά που επεκτείνουν τις κλασικές μηχανές αναζήτησης. Για παράδειγμα, οι χρήστες μπορούν να αναζητούν οντότητες χρησιμοποιώντας μοναδικά αναγνωριστικά βάσης δεδομένων ή να κατατάσσουν τα έγγραφα με βάση τον αριθμό των συγκεκριμένων αναφορών που περιέχουν. Ο σχολιασμός πραγματοποιείται από ένα πλήθος σύγχρονων εργαλείων εξόρυξης κειμένου για την αναγνώριση αναφορών από 10 κατηγορίες οντοτήτων και για τον εντοπισμό αλληλεπιδράσεων πρωτεΐνης-πρωτεΐνης. Το GeneView περιέχει επί του παρόντος σχολιασμούς για >194 εκατομμύρια οντότητες από 10 κατηγορίες για ~21 εκατομμύρια αναφορές με 271 000 σώματα πλήρους κειμένου. Το GeneView μπορεί να αναζητηθεί στη διεύθυνση http://bc3.informatik.hu-berlin.de/.

ΕΙΣΑΓΩΓΗ

Η επιστημονική βιβλιογραφία είναι το κύριο μέσο για την κοινοποίηση νέων ερευνητικών αποτελεσμάτων. Ωστόσο, ο όγκος των συσσωρευμένων κειμένων έχει φθάσει σε σημείο όπου η αναζήτηση συγκεκριμένων πληροφοριών καθίσταται δυσχερής. Εκτός από τον τεράστιο αριθμό των διαθέσιμων κειμένων, η υψηλή

η ασάφεια μεταξύ των περισσότερων ονομάτων βιοϊατρικών αντικειμένων, όπως γονίδια, χημικές ουσίες και ασθένειες, παράγει συχνά πολύ μεγάλα και μη συγκεκριμένα αποτελέσματα αναζήτησης. Αυτό τεκμηριώνεται από το γεγονός ότι πάνω από το ένα τρίτο όλων των αναζητήσεων στο PubMed καταλήγει σε >100 αναφορές (1). Επιπλέον, οι βιοϊατρικές δημοσιεύσεις δύσκολα ακολουθούν συμβάσεις ονοματοδοσίας για οντότητες και παραμένουν προσκολλημένες στα αγαπημένα ονόματα των συγγραφέων τους (2). Οι λέξεις-κλειδιά που αποδίδονται χειροκίνητα, όπως οι όροι MeSH, ανακουφίζουν μόνο εν μέρει το πρόβλημα, καθώς οι εν λόγω ετικέτες είναι πασίγνωστα ελλιπείς και αντιπροσωπεύουν μάλλον χονδροειδείς έννοιες. Για να αντιμετωπιστούν αυτά τα ζητήματα και να διευκολυνθεί η αναζήτηση συγκεκριμένων οντοτήτων σε αποθετήρια βιοϊατρικού κειμένου, απαιτούνται εργαλεία που εξάγουν σημασιολογική γνώση από τη βιοϊατρική βιβλιογραφία. Σε αυτό το άρθρο, παρουσιάζουμε το GeneView, μια διαδικτυακή εφαρμογή που παρέχει πρόσβαση σε μια πλήρως σχολιασμένη έκδοση ~21 εκατομμυρίων περιλήψεων του PubMed και ~271 000 ανοιχτά διαθέσιμων πλήρων κειμένων του PubMed Central. Χρησιμοποιεί ένα πλήθος από σύγχρονα εργαλεία εξόρυξης κειμένου βελτιστοποιημένα για την αναγνώριση αναφορών από 10 διαφορετικές κατηγορίες οντοτήτων και για τον αυτόματο εντοπισμό αλληλεπιδράσεων πρωτεΐνης-πρωτεΐνης (PPI). Μεταξύ άλλων οντοτήτων, το GeneView περιέχει επί του παρόντος 32,8 εκατομμύρια γονίδια, 73,3 εκατομμύρια χημικές ουσίες, 914 000 μονοπυρηνικούς πολυμορφισμούς SNP και 3,9 εκατομμύρια PPIs. Εκτός από την ευρεία κάλυψη οντοτήτων, το GeneView προσφέρει επίσης μια σειρά από μοναδικά χαρακτηριστικά για την αναζήτηση άρθρων. Για παράδειγμα, οι χρήστες μπορούν να κατατάσσουν τα αποτελέσματα των ερωτημάτων με βάση το περιεχόμενο των άρθρων σε σχέση με έναν εξατομικευμένο κατάλογο γονιδίων ή με βάση τον αριθμό των γονιδίων ή των SNP που περιέχουν.

Σχετικές εργασίες

Υπάρχουν διάφορα διαδικτυακά εργαλεία που υποστηρίζουν την ανάκτηση βιοϊατρικών πληροφοριών με τη χρήση εξόρυξης κειμένου. Συζητάμε τα εργαλεία που μοιάζουν περισσότερο με το GeneView και παραπέμπουμε στις αναφορές (3,4) για εξαιρετικές ανασκοπήσεις αυτού του τομέα. iHop
(5) παρέχει πρόσβαση σε ένα υποσύνολο προτάσεων της PubMed που περιέχουν τουλάχιστον δύο πρωτεΐνες σε συνδυασμό με λέξεις-κλειδιά που αφορούν συγκεκριμένες δράσεις. Οντότητες εκτός από τις πρωτεΐνες δεν λαμβάνονται υπόψη. Το AliBaba (6) συγκεντρώνει τις εξαγόμενες

*Σε ποιον πρέπει να απευθύνεται η αλληλογραφία. Τηλ: +49 30 20933902- Φαξ: +49 30 20935484- Ηλεκτρονικό ταχυδρομείο: leser@informatik.hu-berlin.de.

© Ο(οι) συγγραφέας(ες) 2012. Εκδόθηκε από το Oxford University Press.
Αυτό είναι ένα άρθρο ανοικτής πρόσβασης που διανέμεται υπό τους όρους της άδειας Creative Commons Attribution Non-Commercial License (http://creativecommons.org/licenses/ by-nc/3.0), η οποία επιτρέπει την απεριόριστη μη εμπορική χρήση, διανομή και αναπαραγωγή σε οποιοδήποτε μέσο, υπό την προϋπόθεση ότι το πρωτότυπο έργο αναφέρεται κατάλληλα.

Κατέβηκε από το https://academic.oup.com/nar/article/40/W1/W585/1751822 από τον χρήστη του Πανεπιστημίου Αιγαίου στις 08 Νοεμβρίου 2023

γνώση σε όλα τα αποτελέσματα ενός ερωτήματος PubMed και τα απεικονίζει ως γράφημα, ενώ το GeneView επικεντρώνεται στα μεμονωμένα έγγραφα. Το EbiMed (7) ανακτά συνυπάρχουσες οντότητες για ένα συγκεκριμένο ερώτημα και τις κατατάσσει με βάση τη συχνότητα. Όπως το AliBaba και σε αντίθεση με το GeneView, παρέχει έτσι συγκεντρωτικά αποτελέσματα- επιπλέον, το GeneView χρησιμοποιεί μια εξελιγμένη τεχνική μηχανικής μάθησης για να ανιχνεύσει σχέσεις αντί για συν-συχνότητες. Το UKPMC (8) επεκτείνει τη λειτουργικότητα του PubMed Central με τη χρήση του Whatizit (9) για την αναγνώριση και την επισήμανση οντοτήτων σε περιλήψεις. Το σύστημα δεν επισημαίνει οντότητες σε πλήρη κείμενα ούτε παρέχει λειτουργικότητα για αναζήτηση με αναγνωριστικά βάσης δεδομένων αντί για (ενδεχομένως διφορούμενα) ονόματα οντοτήτων. Τέλος, το GoPubMed (10) αναγνωρίζει γονίδια, όρους γονιδιακής οντολογίας και MeSH και παρουσιάζει αποτελέσματα αναζήτησης χρησιμοποιώντας τη δομή πίσω από αυτά τα λεξιλόγια. Αντίθετα, το GeneView αναγνωρίζει ένα ευρύτερο σύνολο τύπων οντοτήτων, αλλά όχι όρους γονιδιακής οντολογίας, παρέχει δυνατότητες αναζήτησης χρησιμοποιώντας μοναδικά αναγνωριστικά βάσεων δεδομένων και βρίσκει επίσης σχέσεις μεταξύ πρωτεϊνών σε κείμενα. Σημειώστε ότι το GeneView, σε αντίθεση με όλα τα συστήματα (εκτός από το UKPMC), περιλαμβάνει το πλήρες ανοικτό σώμα πλήρους κειμένου PMC, επιπλέον όλων των περιλήψεων Medline. Το GeneView προσφέρει όλες τις επισημειώσεις ως λήψεις για να υποστηρίξει την ανάπτυξη νέων εφαρμογών, απαλλάσσοντας τους προγραμματιστές αλγορίθμων ανάλυσης δεδομένων από την ανάγκη να ασχοληθούν με ένα πλήθος πακέτων εξόρυξης κειμένου.

ΠΕΡΙΓΡΑΦΉ ΤΟΥ ΣΥΣΤΉΜΑΤΟΣ

Το GeneView περιέχει όλα τα άρθρα από το PubMed και το υποσύνολο ανοικτής πρόσβασης του PubMed Central. Για τον σημασιολογικό εμπλουτισμό αυτών των άρθρων και την παροχή βολικής πρόσβασης του χρήστη, το GeneView χρησιμοποιεί διάφορα διαλειτουργικά στοιχεία: (i) μονάδες αναγνώρισης ονομαστικών οντοτήτων και εξαγωγής PPI,
(ii) ένα ανεστραμμένο ευρετήριο για αποτελεσματική αναζήτηση- (iii) έναν προσαρμόσιμο αλγόριθμο κατάταξης που λαμβάνει υπόψη τις εξαγόμενες οντοκεντρικές πληροφορίες και (iv) ένα διαδικτυακό front end για την υποβολή ερωτημάτων και την οπτικοποίηση.

Αναγνώριση ονομαστικών οντοτήτων

Για την αναγνώριση ονομαστικών οντοτήτων, χρησιμοποιούμε ένα πλήθος εργαλείων τελευταίας τεχνολογίας.

Γονίδια
Για την αναγνώριση των ονομάτων γονιδίων και την κανονικοποίηση, χρησιμοποιούμε το GNAT (11). Το GNAT βασίζεται σε προσαρμοσμένα λεξικά και τυχαία πεδία υπό συνθήκη (CRFs) και κανονικοποιεί τις αναφορές γονιδίων σε Entrez Gene IDs. Το σύστημα κατατάχθηκε μεταξύ των πρώτων σε διάφορες κριτικές αξιολογήσεις (12,13) και επιτυγχάνει, σύμφωνα με τις αξιολογήσεις αυτές, ακρίβεια 82% και ανάκληση 82% για περιλήψεις και τιμές ακρίβειας/ανάκλησης 54/47% για άρθρα πλήρους κειμένου. Ωστόσο, οι αξιολογήσεις αυτές πραγματοποιήθηκαν σε επίπεδο εγγράφου, επομένως οι επιδόσεις του GNAT σε επίπεδο αναφοράς, όπως εμφανίζονται στο GeneView, ενδέχεται να είναι διαφορετικές. Χρησιμοποιώντας τοπικά προφίλ συμφραζομένων και ευρετικές λειτουργίες, το GNAT προσπαθεί να βρει το πιο πιθανό Entrez Gene ID για ένα αναγνωρισμένο γονίδιο. Σε αβέβαιες περιπτώσεις, το GNAT συσχετίζει τις αναφορές γονιδίων με περισσότερα από ένα αναγνωριστικά. Λόγω των διαφορετικών προφίλ περιβάλλοντος, μια αναφορά γονιδίου μπορεί να σχολιαστεί σε μια πρόταση, αλλά

Κατέβηκε από το https://academic.oup.com/nar/article/40/W1/W585/1751822 από τον χρήστη του Πανεπιστημίου Αιγαίου στις 08 Νοεμβρίου 2023

έχασε σε ένα άλλο. Συνεπώς, οι σημειώσεις διαδίδονται σε προηγούμενα παραλειπόμενα tokens, συμπεριλαμβανομένων των αναφορών συντομογραφιών και μακρών μορφών.

Πολυμορφισμοί ενός νουκλεοτιδίου

Τα φυσικά και τεχνητά SNPs ανιχνεύονται με τη χρήση μιας βελτιωμένης έκδοσης του MutationFinder (14). Αυτή η έκδοση επιτυγχάνει ακρίβεια και ανάκληση 97,5% και 80,7%, αντίστοιχα, στο αρχικό σύνολο δοκιμών 508 περιλήψεων. Στη συνέχεια, κανονικοποιούμε τις αναφορές SNP σε αναγνωριστικά dbSNP. Η διαδικασία κανονικοποίησής μας επιτυγχάνει ακρίβεια 93,0% και ανάκληση 51,0% σε ένα σώμα 296 εγγράφων (15). Οι αναφορές αναγνωριστικών dbSNP αναγνωρίζονται με τη χρήση κανονικών εκφράσεων, επιτυγχάνοντας ακρίβεια 98,2% σε ένα σύνολο 100 τυχαία επιλεγμένων εγγράφων.

Είδος

Τα είδη ταυτοποιούνται και κανονικοποιούνται με την ταξινομία NCBI χρησιμοποιώντας το LINNAEUS, το οποίο επιτυγχάνει ακρίβεια 97% και ανάκληση 94% σε ένα σώμα δοκιμών 100 εγγράφων πλήρους κειμένου (16).

Χημικές ουσίες

Αναγνωρίζουμε χημικές ενώσεις χρησιμοποιώντας το ChemSpot (17), μια υβριδική προσέγγιση που χρησιμοποιεί CRF για την ανίχνευση χημικών ονομάτων που μοιάζουν με τα IUPAC και ένα προσαρμοσμένο λεξικό για άλλες χημικές ουσίες, συμπεριλαμβανομένων τετριμμένων ονομάτων, συντομογραφιών και μοριακών τύπων. Το ChemSpot επιτυγχάνει ακρίβεια 68% και ανάκληση 69,5% στο σώμα κειμένων SCAI (18).

Τροποποιήσεις ιστόνης

Οι τροποποιήσεις των ιστονών αναγνωρίζονται χρησιμοποιώντας ένα σύνολο 134 κανονικών εκφράσεων και κανονικοποιούνται σύμφωνα με την ονοματολογία των τροποποιήσεων των ιστονών του Brno. Η προσέγγιση αυτή επιτυγχάνει προ-κρίση 94,4% και ανάκληση 88,7% σε σώμα αξιολόγησης 1 000 εγγράφων (19).

Άλλες κατονομαζόμενες οντότητες

Τέλος, οι αναφορές κυτταρικών τύπων, ασθενειών, φαρμάκων, ενζύμων και ιστών εξάγονται χρησιμοποιώντας λεξικά που παρέχονται από το AliBaba (6). Κυρίως λόγω της έλλειψης κατάλληλων σωμάτων κειμένων, δεν είναι δυνατόν να παρασχεθούν λογικές μετρικές ποιότητας για αυτές τις κατηγορίες οντοτήτων.

Λαμβάνοντας υπόψη το μικρό μέγεθος των διαθέσιμων σωμάτων, οι αναφερόμενες τιμές αξιολόγησης πρέπει να θεωρηθούν ως πρόχειρες εκτιμήσεις. Οι επικαλυπτόμενες επισημάνσεις, π.χ. αμινοξέα μέσα σε αναφορές μεταλλάξεων, δεν διαχωρίζονται. Αντ' αυτού, παρέχονται σύνδεσμοι για όλες αυτές τις περιπτώσεις. Αυτό ισχύει επίσης για αναγνωρισμένα ονόματα γονιδίων όπου το GNAT δεν ήταν σε θέση να διακρίνει μεταξύ πολλών Entrez Gene ID. Το GeneView χρησιμοποιεί μια προσέγγιση μηχανικής μάθησης που βασίζεται σε μηχανές διανυσμάτων υποστήριξης για την εξαγωγή σχέσεων μεταξύ αναγνωρισμένων πρωτεϊνών (20). Το τελικό μοντέλο εκπαιδεύεται στο σύνολο πέντε σωμάτων που έχουν σχολιαστεί με PPIs (21). Η μέθοδος πέτυχε πολύ καλά αποτελέσματα σε μια συνολική αξιολόγηση εννέα προσεγγίσεων μηχανικής μάθησης για την εξαγωγή PPI (22). Ανάλογα με το σώμα αξιολόγησης, οι βαθμολογίες F_1 από 54,5% έως 74,5% είναι παρατηρήθηκε.

Η διαδικτυακή διεπαφή παρουσιάζει επί του παρόντος αποτελέσματα για γονίδια, SNPs, χημικές ουσίες, τροποποιήσεις ιστονών, ονόματα φαρμάκων και

PPIs. Αυτοί και πρόσθετοι τύποι οντοτήτων παρέχονται ως ξεχωριστή λήψη. Το αποθετήριο εγγράφων του GeneView ενημερώνεται σε τακτική βάση 3 μηνών και οι σχολιασμοί ανανεώνονται όταν δημοσιεύονται σημαντικές εκδόσεις των εργαλείων NER.

Ευρετηρίαση

Όλες οι περιλήψεις PubMed και τα ελεύθερα διαθέσιμα πλήρη κείμενα PMC λαμβάνονται ως αρχεία XML, αναλύονται και εισάγονται στο Lucene. Το Lucene εξυπηρετεί το GeneView ως σύστημα αποθήκευσης κειμένου, επεξεργασίας ερωτημάτων και μηχανής κατάταξης. Για κάθε άρθρο, αναλύουμε πρόσθετες πληροφορίες, όπως ονόματα συγγραφέων, συνεργασίες, περιοδικό, όρους MeSH και ημερομηνία δημοσίευσης. Οι ενότητες των άρθρων πλήρους κειμένου (π.χ. τίτλος, μέθοδοι, αποτέλεσμα και λεζάντα εικόνας/πίνακα) αναγνωρίζονται από ένα λεξικό που περιέχει κοινώς χρησιμοποιούμενα ονόματα ενοτήτων. Αυτό επιτρέπει στους χρήστες να περιορίζουν τα ερωτήματα σε ορισμένα τμήματα ενός άρθρου. Η αναγνώριση ονομαστικών οντοτήτων και η εξαγωγή σχέσεων εφαρμόζονται σε όλα τα κείμενα και αποθηκεύονται σε σχεσιακή βάση δεδομένων για να επιτρέπουν τη δομημένη ανάκτηση και τη συγκέντρωση.

Κατάταξη

Το εύρος των ευρετηριασμένων πληροφοριών επιτρέπει την παροχή διαφόρων προηγμένων μεθόδων για την κατάταξη των αποτελεσμάτων αναζήτησης. Αυτές περιλαμβάνουν την κατάταξη με βάση τη συνάφεια ως προς το ερώτημα του χρήστη, την ημερομηνία δημοσίευσης ή τον αριθμό των οντοτήτων ενός συγκεκριμένου τύπου (γονίδια και SNPs) που περιέχουν τα άρθρα. Η κατάταξη με βάση τη συνάφεια βασίζεται στη συχνότητα των όρων στα άρθρα, στην αντίστοιχη επιλεκτικότητα/σημασία των συγκεκριμένων όρων του ερωτήματος και στο μέσο μήκος του τμήματος. Έτσι, τα σύντομα τμήματα όπως ο "τίτλος" ή η "περίληψη" θεωρούνται πιο σημαντικά από τα μεγαλύτερα τμήματα όπως οι "μέθοδοι". Χρησιμοποιούμε ενίσχυση ανά τμήμα για τις αναζητήσεις γονιδίων, με την υψηλότερη βαθμολογία συνάφειας να αποδίδεται στις αναφορές γονιδίων στον "τίτλο", την "περίληψη" ή το "αποτέλεσμα" και τη χαμηλότερη σε εκείνες που αναφέρονται στις "μεθόδους" ή την "εισαγωγή". Τα αποτελέσματα των ερωτημάτων μπορούν επίσης να ταξινομηθούν με βάση μια λίστα γονιδίων που ορίζει ο χρήστης (βλ. τρίτη περίπτωση χρήσης παρακάτω).

Διασύνδεση

Το GeneView είναι προσβάσιμο μέσω ενός διαισθητικού διαδικτυακού περιβάλλοντος εργασίας. Το κεντρικό σημείο πρόσβασης είναι μια φόρμα αναζήτησης που υποστηρίζει διάφορους τύπους ερωτημάτων. Αυτά τα ερωτήματα μπορούν να αξιοποιήσουν πλήρως τα συλλεχθέντα υποκείμενα δεδομένα και τις προηγμένες επιλογές κατάταξης. Η εκτέλεση μιας αναζήτησης επιστρέφει έναν κατάλογο των αντίστοιχων άρθρων. Από προεπιλογή, τα άρθρα αυτά κατατάσσονται με βάση την ημερομηνία δημοσίευσης. Οι επιλογές κατάταξης που περιγράφηκαν προηγουμένως, π.χ. κατάταξη με βάση τη συνάφεια ή τον αριθμό των οντοτήτων, είναι διαθέσιμες για επιλογή από τον χρήστη. Επιπλέον, ο χρήστης μπορεί να μειώσει τον αριθμό των ανακτηθέντων άρθρων με την αναζήτηση αναφορών γονιδίων, μεταλλάξεων ή χημικών ενώσεων. Το αποτέλεσμα ενός ερωτήματος για δύο γονίδια (*UBE2I* και *BRCA1)* εμφανίζεται στην Εικόνα 1.

Η απεικόνιση ενός άρθρου που επιλέχθηκε από τα αποτελέσματα της αναζήτησης παρουσιάζεται στην Εικόνα 2. Η προβολή χωρίζεται σε δύο πλαίσια. Στο κύριο, δεξιό πάνελ εμφανίζεται το άρθρο, συμπεριλαμβανομένων των συγγραφέων και του περιοδικού. Ένα κλικ με το ποντίκι ενεργοποιεί ένα ερώτημα για δημοσιεύσεις από τον επιλεγμένο συγγραφέα ή το επιλεγμένο περιοδικό. Η σήμανση οντοτήτων παρέχεται απευθείας στο κείμενο και οι πρόσθετες πληροφορίες σχετικά με τις οντότητες εμφανίζονται σε ένα αναδυόμενο παράθυρο

Κατέβηκε από το https://academic.oup.com/nar/article/40/W1/W585/1751822 από τον χρήστη του Πανεπιστημίου Αιγαίου στις 08 Νοεμβρίου 2023

με κλικ του ποντικιού. Αυτό περιλαμβάνει συνδέσμους προς συγκεκριμένες βάσεις δεδομένων για οντότητες (π.χ. UniProt, DrugBank ή IntAct) ή πρόσθετες πληροφορίες όπως το επίσημο όνομα του γονιδίου. Η σήμανση παρέχει επίσης τη δυνατότητα αναζήτησης άρθρων που συζητούν την επιλεγμένη οντότητα με ένα κλικ. Για τα ονόματα γονιδίων, αυτό περιλαμβάνει τη δυνατότητα αναζήτησης ειδικά για εκείνα τα άρθρα στα οποία ο δυαδικός ταξινομητής εντόπισε μια PPI για την επιλεγμένη οντότητα. Η αντίστοιχη πρόταση παρέχεται κατόπιν αιτήματος του χρήστη.

Το αριστερό πλαίσιο δείχνει μια επισκόπηση όλων των οντοτήτων που βρέθηκαν στο άρθρο ταξινομημένες με βάση τη συνολική συχνότητα. Από προεπιλογή, επισημαίνονται όλες οι οντότητες, αλλά οι χρήστες μπορούν επίσης να περιορίσουν τον χρωματισμό σε ορισμένους τύπους οντοτήτων. Για τα ονόματα γονιδίων, η επισήμανση μπορεί επίσης να περιοριστεί ανά είδος. Οι μάρτυρες που έχουν σχολιαστεί από περισσότερα από ένα εργαλεία επισημαίνονται με ένα ενδιάμεσο χρώμα και ένα κλικ του ποντικιού παρέχει όλες τις διαθέσιμες πληροφορίες.

ΑΠΟΤΕΛΈΣΜΑΤΑ ΚΑΙ ΣΥΖΉΤΗΣΗ

Το GeneView περιέχει επί του παρόντος 20 962 294 περιλήψεις μαζί με 271 808 σώματα πλήρους κειμένου. Όλα τα άρθρα σχολιάζονται αυτόματα με 10 εργαλεία αναγνώρισης ονομαστικών οντοτήτων. Από τον Ιανουάριο του 2012, το αποθετήριο περιέχει >194 εκατομμύρια οντότητες (για λεπτομερή επισκόπηση, βλ. Πίνακα 1). Από τις 15 197 637 ταυτόχρονες αναφορές πρωτεϊνών, 3 921 267 (25,8%) ταξινομούνται ως PPI. Η διαθεσιμότητα των πλήρων κειμένων απευθείας στο GeneView παρέχει μια πρόσθετη πηγή πληροφοριών. Για παράδειγμα, >21 400 από ~172 000 άρθρα περιέχουν SNPs μόνο στο πλήρες κείμενο. Ομοίως, ο συνολικός αριθμός των SNPs μειώνεται από 914 543 σε 523 398 (57,2%) μετά την αγνόηση των αναφορών πλήρους κειμένου. Αυτοί οι αριθμοί υπογραμμίζουν την πολύ καλύτερη κάλυψη των άρθρων πλήρους κειμένου.

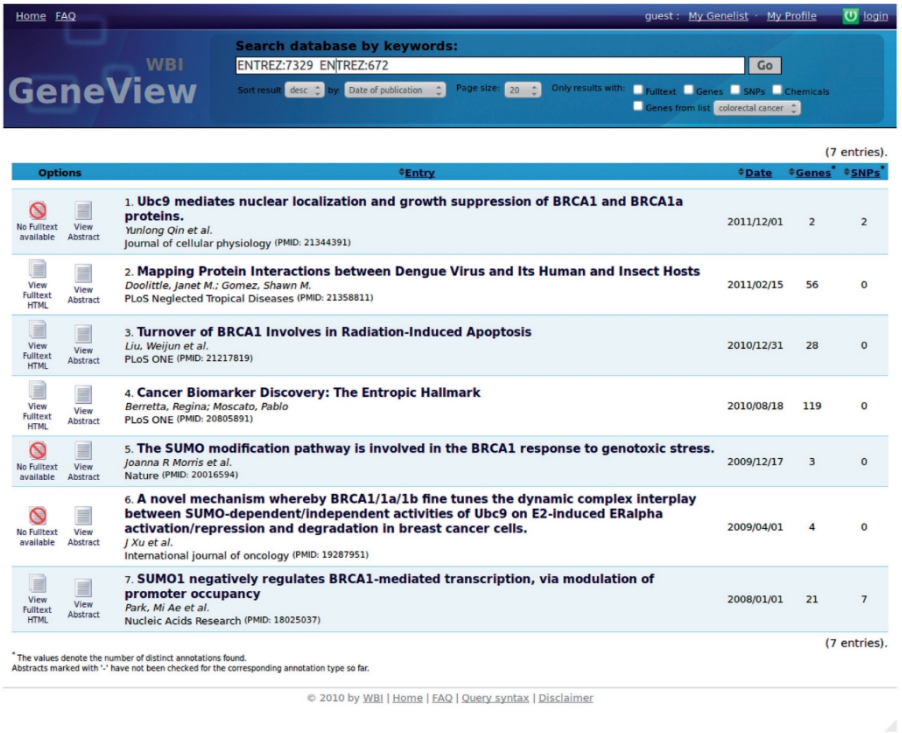
Λειτουργικότητα και χρήση

Η λειτουργικότητα του GeneView περιγράφεται από τις ακόλουθες τέσσερις περιπτώσεις χρήσης.

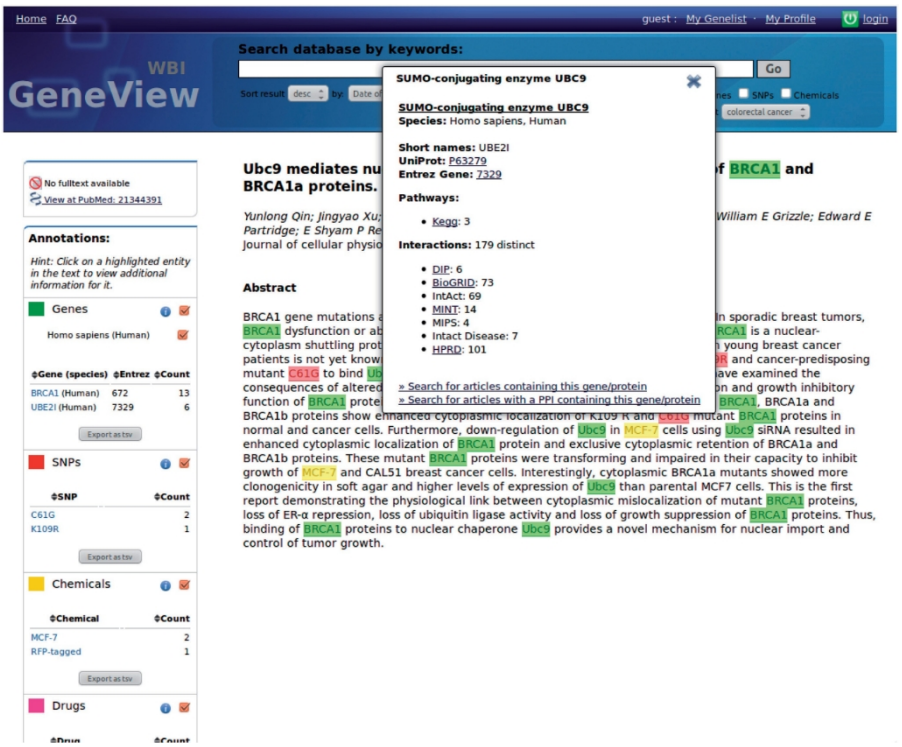
Αναζήτηση ανά οντότητα

Η ασάφεια των ονομάτων οντοτήτων είναι ένα καλά μελετημένο πρόβλημα για διάφορους τύπους οντοτήτων. Για παράδειγμα, το ακρωνύμιο "PAP" αναφέρεται σε περισσότερα από οκτώ διαφορετικά ανθρώπινα γονίδια αλλά και σε έννοιες όπως "πίεση της πνευμονικής αρτηρίας". Αντίστροφα, μια ενιαία οντότητα μπορεί να αναφέρεται με πολλά διαφορετικά ονόματα. Με τη χρήση της αναγνώρισης και της κανονικοποίησης ονομαστικών οντοτήτων, το GeneView μειώνει σημαντικά τον αντίκτυπο τέτοιων προβλημάτων και διευκολύνει την εύρεση σχετικών άρθρων. Το GeneView επιτρέπει επίσης την αναζήτηση άρθρων με τη χρήση μοναδικών αναγνωριστικών όπως Entrez Gene για γονίδια, dbSNP για SNPs, ChemIDPlus για χημικές ουσίες, Brno abbre- viations για τροποποιήσεις ιστονών και DrugBank ή PharmGKB για φάρμακα.

Το πλεονέκτημα των δυνατοτήτων κανονικοποίησης οντοτήτων του GeneView γίνεται εμφανές κατά την αναζήτηση άρθρων που περιγράφουν, ας πούμε, ένα συγκεκριμένο SNP. Ας υποθέσουμε ότι ένας ερευνητής αναζητά το σχετιζόμενο με τη σχιζοφρένεια SNP Val158Met που βρίσκεται στο γονίδιο COMT. Μια άμεση αναζήτηση για αυτό το όνομα οδηγεί σε 448 επιτυχίες στο PubMed, αλλά αγνοεί τον μεγάλο αριθμό λεκτικών παραλλαγών (π.χ. V158M, Val158!Met, Val(158)Met και Val158/Met). Λεξιλογικά



Σχήμα 1. Αποτελέσματα αναζήτησης για άρθρα που αναφέρουν τα γονίδια *UBE2I* (GeneID 7329) και *BRCA1* (GeneID 672).



Σχήμα 2. Οπτικοποίηση ενός επιλεγμένου άρθρου (PMID 21344391). Για μια επιλεγμένη οντότητα μπορούν να παρέχονται πρόσθετες πληροφορίες, όπως το πλήρες όνομα του γονιδίου και σύνδεσμοι προς εξωτερικές βάσεις δεδομένων.

Κατέβηκε από το https://academic.oup.com/nar/article/40/W1/W585/1751822 από τον χρήστη του Πανεπιστημίου Αιγαίου στις 08 Νοεμβρίου 2023

Πίνακας 1. Επισκόπηση όλων των οντοτήτων στο αποθετήριο GeneView

Τύπος οντότητας	Άρθρα	Οντότητες	Μοναδικό	Κανονικοποιημένο
Χημική ουσία	9 851 347	73 354 240	59 232	ChemIDPlus
Είδος	8 815 334	40 992 161	110 880	Ταξινόμηση NCBI
Φάρμακο	6 023 081	44 595 216	3 052	DrugBank/PharmGKB
Gene	2 855 898	32 861 120	81 229	Γονίδιο Entrez
Ένζυμο	561 152	825 889	2 519	Kegg
Ασθένεια	272 240	679 364	9 681	MeSH
SNP	171 597	914 543	18 942	dbSNP
Κυτταρικός τύπος	36 851	82 285	585	MeSH
Ιστός	8 164	9 488	132	MeSH
Histone Mod.	5 938	62 370	316	Ονοματολογία του Μπρνο

Άρθρα: αριθμός παραπομπών με τουλάχιστον μία οντότητα που βρέθηκε- οντότητες: συνολικός αριθμός αναγνωρισμένων αναφορών- μοναδικές: αριθμός διακριτών οντοτήτων- κανονικοποιημένες: οι αναφορές αναγνωριστικού είναι κανονικοποιημένες ως προς.

οι παραλλαγές αναγνωρίζονται και ενοποιούνται στο GeneView, αποδίδοντας 575 άρθρα για την αναζήτηση V158M. Παρόλα αυτά, μια τέτοια αναζήτηση παραμελεί τον μεγάλο αριθμό δυνατοτήτων περιγραφής SNP (π.χ. Val108Leu, 472G>A και 322G>C) και το γεγονός ότι η V158M είναι γνωστό ότι υπάρχει για σχεδόν 20 διαφορετικά ανθρώπινα γονίδια. Μόνο μια αναζήτηση με τη χρήση του μοναδικού αναγνωριστικού dbSNP rs4680 αντιμετωπίζει αυτά τα προβλήματα: μια αναζήτηση για το rs4680 επιστρέφει 672 άρθρα. Σε σύγκριση, το ίδιο το dbSNP καλύπτει αναφορές σε μόλις 165 άρθρα της PubMed για αυτό το SNP.

Το αποτέλεσμα μιας τέτοιας αναζήτησης στο GeneView μπορεί να συνδυαστεί με όλες τις επιλογές φιλτραρίσματος και κατάταξης που περιγράφηκαν προηγουμένως. Επίσης, τα ερωτήματα που αφορούν συγκεκριμένες οντότητες μπορούν να συνδυαστούν με κάθε είδους αναζήτηση με βάση λέξεις-κλειδιά ή άλλη αναζήτηση που αφορά συγκεκριμένες οντότητες. Αυτό επιτρέπει στο χρήστη να διαμορφώνει σύνθετα ερωτήματα, για παράδειγμα, να αναζητά ένα συγκεκριμένο SNP που σχετίζεται με ένα γονίδιο. Μια τέτοια αναζήτηση μπορεί να είναι χρήσιμη όταν το SNP που ενδιαφέρει δεν περιέχεται στο dbSNP ή το αναγνωριστικό είναι άγνωστο. Για παράδειγμα, το GeneView επιστρέφει 531 άρθρα κατά την αναζήτηση του SNP V158M σε συνδυασμό με το γονίδιο COMT. Μια βασική επισκόπηση των συνυπάρχοντων οντοτήτων παρουσιάζεται στον πίνακα 2.

Προηγμένη αναζήτηση με βάση λέξεις-κλειδιά

Επαναλαμβάνοντας το αρχικό μας παράδειγμα, ένας ερευνητής μπορεί να ενδιαφέρεται για μια επισκόπηση των SNPs που σχετίζονται με τη σχιζοφρένεια. Μια αναζήτηση για "σχιζοφρένεια" οδηγεί σε >63 000 άρθρα. Η χρήση του GeneView για τον περιορισμό της αναζήτησης σε άρθρα που αναφέρουν τουλάχιστον ένα SNP μειώνει αυτό το αποτέλεσμα σε ~1 700 άρθρα. Η κατάταξη με βάση τον αριθμό των SNPs επιτρέπει στο χρήστη να βρει τα άρθρα που συζητούν μεγάλο αριθμό διαφορετικών

Πίνακας 2. Αριθμός συνυπαρχουσών εννοιών που περιέχονται στο

GeneView Οντότητα 1	Συνύπαρξη	Οντότητα 2
Gene	Χημική ουσία	48 278 038
Gene	Φάρμακο	20 099 049

Οι πολλαπλές αναφορές της ίδιας οντότητας υπολογίζονται μόνο μία φορά.

Κατέβηκε από το https://academic.oup.com/nar/article/40/W1/W585/1751822 από τον χρήστη του Πανεπιστημίου Αιγαίου στις 08 Νοεμβρίου 2023

SNPs σε συνδυασμό με τη σχιζοφρένεια. Παρόμοια ερωτήματα μπορούν επίσης να εκτελεστούν για άλλους τύπους οντοτήτων ενδιαφέροντος. Εκτός από τις κανονικές αναζητήσεις όρων και φράσεων που είναι γνωστές από άλλες μηχανές αναζήτησης, η ενσωμάτωση πληροφοριών που σχετίζονται με το πλαίσιο επιτρέπει την αναζήτηση σε συγκεκριμένες ενότητες. Για παράδειγμα, είναι δυνατή η αναζήτηση ερωτημάτων όπως "εύρεση όλων των άρθρων στα οποία η "λεζάντα" περιέχει το γονίδιο *EGFR* σε συνδυασμό με τη φράση western blot".

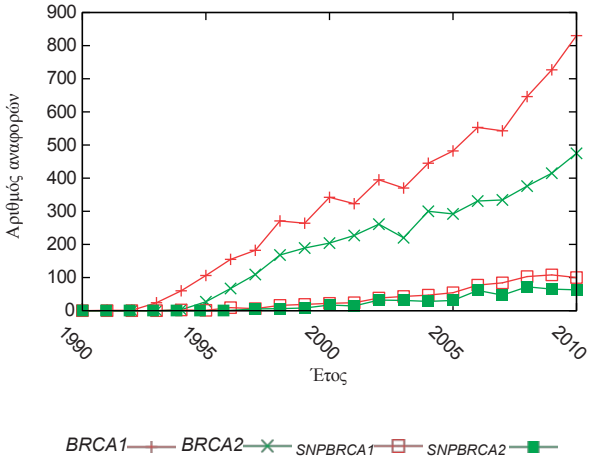
Κατάλογος γονιδίων

Οι ερευνητές έχουν συχνά έναν ειδικό κατάλογο γονιδίων για τα οποία ενδιαφέρονται. Το GeneView παρέχει στους χρήστες τη δυνατότητα να διατηρούν έναν εξατομικευμένο κατάλογο σχετικών γονιδίων και επιτρέπει τον περιορισμό των αποτελεσμάτων των ερωτημάτων σε άρθρα που περιέχουν τουλάχιστον ένα από αυτά τα γονίδια ενδιαφέροντος. Τα άρθρα που ταιριάζουν μπορούν να βαθμολογηθούν και να καταταγούν σύμφωνα με αυτά τα γονίδια ενδιαφέροντος. Η βαθμολόγηση τροποποιεί την προεπιλεγμένη στρατηγική κατάταξης ενσωματώνοντας την ενότητα στην οποία εμφανίζονται τα γονίδια.

Επιδεικνύουμε τη χρησιμότητα αυτής της δυνατότητας με το ακόλουθο παράδειγμα: Το GeneView επιστρέφει 62 798 άρθρα που ταιριάζουν με τον όρο "σχιζοφρένεια". Προσθέσαμε και τα 26 γονίδια από το OMIM που σχετίζονται με τη νόσο σχιζοφρένεια στην προσωπική μας λίστα γονιδίων. Η χρήση αυτής της λίστας γονιδίων που ορίζει ο χρήστης ως φίλτρο επιτρέπει τη μείωση του αποτελέσματος του ερωτήματος σε 1 269 άρθρα που περιέχουν τη λέξη-κλειδί και τουλάχιστον ένα γονίδιο ενδιαφέροντος. Η αλλαγή της κατάταξης σε "συνάφεια" τραβάει τα άρθρα που συζητούν την επίδραση αρκετών από αυτά τα γονίδια στη σχιζοφρένεια στην κορυφή της λίστας αποτελεσμάτων.

Βιοκαλλιέργεια

Μια συνεχής πρόκληση είναι η ολοκλήρωση της λειτουργικής αναγγελίας των γονιδίων. Οι Baumgartner *κ.ά.* (23) εκτιμούν ότι η διαδικασία σχολιασμού όλων των ανθρώπινων γονιδίων με τουλάχιστον μία ετικέτα "Gene Reference Into Function" δεν θα έχει ολοκληρωθεί πριν από το 2020, εκτός εάν η τεχνολογική πρόοδος μπορέσει να βελτιώσει σημαντικά τη διαδικασία σχολιασμού. Η επαύξηση των άρθρων με αυτόματα παραγόμενες ανα- σημάνσεις μπορεί να μειώσει σημαντικά τον χρόνο που απαιτείται για την ανάγνωση και, εάν είναι απαραίτητο, για την επιμέλεια ενός άρθρου (24). Με το πλήθος των σχολιασμένων οντοτήτων, το GeneView είναι απόλυτα κατάλληλο για την υποστήριξη της χειροκίνητης επιμέλειας μεγάλων βιοϊατρικών βάσεων δεδομένων με την επιλεκτική αναζήτηση και επαύξηση βιο- ιατρικών άρθρων. Το GeneView μπορεί επίσης να χρησιμοποιηθεί από τους ερευνητές για την εύρεση PPI για την επαύξηση των υφιστάμενων δικτύων PPI.



Σχήμα 3. Αριθμός αναφορών στις οποίες εμφανίζονται τα γονίδια *BRCA1* ή *BRCA2* για τα τελευταία 20 χρόνια. Ομοίως, παρουσιάζουμε την εξέλιξη των άρθρων με SNPs που συν-αναφέρονται με το *BRCA1* ή *BRCA2*.

Λήψη

Όλες οι επισημάνσεις είναι επίσης διαθέσιμες ως δομημένα φορτία . Αυτό επιτρέπει αναλύσεις μεγάλης κλίμακας, όπως την εκ νέου τριετία των συνυπάρχοντων όρων, την ενσωμάτωση των αποτελεσμάτων εξόρυξης κειμένου σε άλλα εργαλεία ή τη δυνατότητα ανάλυσης της μακροπρόθεσμης εξέλιξης των βιοϊατρικών εννοιών. Αυτό παρουσιάζεται ενδεικτικά για τα γονίδια *BRCA1* και *BRCA2* σε συνδυασμό με τουλάχιστον ένα SNP στην Εικόνα 3.

ΣΥΜΠΕΡΑΣΜΑ

Η παρακολούθηση των τελευταίων ερευνητικών αποτελεσμάτων γίνεται όλο και πιο δύσκολη για τους ερευνητές της βιοϊατρικής . Παρουσιάζουμε το GeneView, ένα γρήγορο και ισχυρό εργαλείο για την πλοήγηση στη βιοϊατρική βιβλιογραφία. Τα σημαντικότερα χαρακτηριστικά του GeneView περιλαμβάνουν τη δυνατότητα αναζήτησης άρθρων που περιγράφουν μια συγκεκριμένη βιολογική οντότητα, ευέλικτη κατάταξη των αποτελεσμάτων ανάλογα με τις ανάγκες των χρηστών με τη χρήση βελτιστοποιημένων αλγορίθμων κατάταξης και μια διαισθητική οπτικοποίηση των σημασιολογικά σχολιασμένων κειμένων. Οι αναζητήσεις πραγματοποιούνται ταυτόχρονα σε περιλήψεις και πλήρη κείμενα. Όλες οι σχολιασμένες οντότητες είναι διαδραστικές: ένα κλικ με το ποντίκι παρέχει πρόσθετες πληροφορίες, όπως συνδέσμους σε εξωτερικές βάσεις δεδομένων αναφοράς ή πληροφορίες για διαδρομές και αλληλεπιδράσεις, και επιτρέπει την αναζήτηση πρόσθετων άρθρων για τη συγκεκριμένη οντότητα απευθείας στο GeneView.

Το GeneView παρέχει επί του παρόντος την πιο ολοκληρωμένη
σημασιολογική μηχανή αναζήτησης για τις βιοεπιστήμες. Το GeneView μπορεί να μειώσει σημαντικά την απαραίτητη προσπάθεια για την αναζήτηση, ανάγνωση, κατανόηση και σχολιασμό βιοϊατρικών άρθρων στη διεύθυνση .

ΕΥΧΑΡΙΣΤΊΕΣ

[GRK 1651/1]. Χρηματοδότηση για χρέωση ανοικτής πρόσβασης: Γερμανικό Συμβούλιο Έρευνας.

Δήλωση σύγκρουσης συμφερόντων. Δεν έχει δηλωθεί κανένα.

ΑΝΑΦΟΡΕΣ

1. Dogan,R.I., Murray,G.C., Névéol,A. και Lu,Z. (2009) Κατανόηση της συμπεριφοράς αναζήτησης των χρηστών του PubMed μέσω της ανάλυσης των αρχείων καταγραφής. *Βάση δεδομένων*, 2009, bap018.
2. Tamames,J. και Valencia,A. (2006) Η επιτυχία (ή όχι) της ονοματολογίας HUGO. *Genome Biol.*, 7, 402.
3. Lu,Z. (2011) PubMed και πέρα από αυτό: μια έρευνα διαδικτυακών εργαλείων για

Ευχαριστούμε τους κριτές για την προσεκτική ανάγνωση του και τα χρήσιμα σχόλιά τους.

ΧΡΗΜΑΤΟΔΟΤΗΣΗ

Γερμανικό Ομοσπονδιακό Υπουργείο Παιδείας και Έρευνας [0315417B] και Γερμανικό Ίδρυμα Ερευνών

Κατέβηκε από το https://academic.oup.com/nar/article/40/W1/W585/1751822 από τον χρήστη του Πανεπιστημίου Αιγαίου στις 08 Νοεμβρίου 2023

baq036.
4. Rodriguez-Esteban,R. (2009) Biomedical text mining and its applications. *PLoS Comput Biol.*, 5, e1000597.
5. Fernández,J.M., Hoffmann,R. και Valencia,A. (2007) iHOP web services. *Nucleic Acids Res.*, 35, W21-W26.
6. Plake,C., Schiemann,T., Pankalla,M., Hakenberg,J. and Leser,U. (2006) AliBaba: PubMed as a graph. *Bioinformatics*, 22, 2444-2445.
7. Rebholz-Schuhmann,D., Kirsch,H., Arregui,M., Gaudan,S., Riethoven,M. και Stoehr,P. (2007) EBIMed-text crunching to gather facts for proteins from Medline. *Bioinformatics*, 23, e237-e244.
8. McEntyre,J.R., Ananiadou,S., Andrews,S., Black,W.J., Boulderstone,R., Buttery,P., Chaplin,D., Chevuru,S., Cobley,N., Coleman,L.-A. *et al*. (2011) UKPMC: μια πηγή πλήρους κειμένου άρθρων για τις επιστήμες της ζωής. *Nucleic Acids Res.*, 39, D58-D65.
9. Rebholz-Schuhmann,D., Arregui,M., Gaudan,S., Kirsch,H. και Jimeno,A. (2008) Επεξεργασία κειμένου μέσω υπηρεσιών ιστού: κλήση του Whatizit. *Bioinformatics*, 24, 296-298.
10. Doms,A. and Schroeder,M. (2005) GoPubMed: εξερεύνηση του PubMed με τη γονιδιακή οντολογία. *Nucleic Acids Res.*, 33, W783-W786.
11. Hakenberg,J., Gerner,M., Haeussler,M., Solt,I., Plake,C., Schroeder,M., Gonzalez,G., Nenadic,G. and Bergman,C.M. (2011) The GNAT library for local and remote gene mention normalization. *Bioinformatics*, 27, 2769-2771.
12. Morgan,A.A., Lu,Z., Wang,X., Cohen,A.M., Fluck,J., Ruch,P., Divoli,A., Fundel,K., Leaman,R., Hakenberg,J. *et al*. (2008) Overview of BioCreative II gene normalization. *Genome Biol.*, 9, S3.
13. Lu,Z., Kao,H.-Y., Wei,C.-H., Huang,M., Liu,J., Kuo,C.-J., Hsu,C.-N., Tsai,R.T.-H., Dai,H.-J., Okazaki,N. *et al*. (2011) The gene normalization task in BioCreative III. *BMC Bioinformatics*, 12(Suppl 8), S2.
14. Caporaso,J.G., Baumgartner,W.A., Randolph,D.A., Cohen,K.B. και Hunter,L. (2007) MutationFinder: ένα σύστημα υψηλής απόδοσης για την εξαγωγή αναφορών σημειακών μεταλλάξεων από κείμενο. *Bioinformatics*, 23, 1862-1865.
15. Thomas,P., Klinger,R., Furlong,L., Hofmann-Apitius,M. και Friedrich,C. (2011) Challenges in the association of human single nucleotide polymorphism mentions with unique database identifiers. *BMC Bioinformatics*, 12(Suppl 4), S4.
16. Gerner,M., Nenadic,G. and Bergman,C.M. (2010) LINNAEUS: ένα σύστημα αναγνώρισης ονομάτων ειδών για τη βιοϊατρική βιβλιογραφία. *BMC Bioinformatics*, 11, 85.
17. Rocktäschel,T., Weidlich,M. and Leser,U. (2012) ChemSpot: ένα υβριδικό σύστημα για την αναγνώριση ονομαστικών οντοτήτων χημικών ουσιών. *Bioinformatics.*, 28, 1633-1640.
18. Kolářik,C., Klinger,R., Friedrich,C.M., Hofmann-Apitius,M. and Fluck,J. (2008) Chemical names: terminological resources and corpora annotation. *Workshop on Building and evaluating resources for biomedical text mining*. Marrakech, Μαρόκο, σσ. 51-58.
19. Kolářik,C., Klinger,R. and Hofmann-Apitius,M. (2009) Προσδιορισμός τροποποιήσεων ιστονών σε βιοϊατρικά κείμενα για την υποστήριξη της επιγονιδιωματικής έρευνας. *BMC Bioinformatics*, 10(Suppl 1), S28.
20. Giuliano,C., Lavelli,A. και Romano,L. (2006) Exploiting shallow linguistic information for relation extraction from biomedical literature. *Πρακτικά του 11ου συνεδρίου του Ευρωπαϊκού*

Κεφάλαιο της Ένωσης για την Υπολογιστική Γλωσσολογία (EACL 2006). Τρέντο, Ιταλία, σσ. 401-408.
21. Pyysalo,S., Airola,A., Heimonen,J., Björne,J., Ginter,F. και Salakoski,T. (2008) Συγκριτική ανάλυση πέντε σωμάτων αλληλεπιδράσεων πρωτεΐνης-πρωτεΐνης . *BMC Bioinformatics*, 9(Suppl 3), S6.
22. Tikk,D., Thomas,P., Palaga,P., Hakenberg,J. and Leser,U. (2010) A comprehensive benchmark of kernel methods to extract protein protein interactions from literature. *PLoS Comput. Biol.*, 6, e1000837.
23. Baumgartner,W.A., Cohen,K.B., Fox,L.M., Acquaah-Mensah,G. και Hunter,L. (2007) Η χειροκίνητη επιμέλεια δεν αρκεί για τον σχολιασμό των γονιδιωματικών βάσεων δεδομένων. *Bioinformatics*, 23, i41-i48.
24. Arighi,C., Roberts,P., Agarwal,S., Bhattacharya,S., Cesareni,G., Chatr-aryamontri,A., Clematide,S., Gaudet,P., Giglio,M., Harrow,I. *et al*. (2011) BioCreative III interactive task: an overview. *BMC Bioinformatics*, 12(Suppl 8), S4.

Κατέβηκε από το https://academic.oup.com/nar/article/40/W1/W585/1751822 από τον χρήστη του Πανεπιστημίου Αιγαίου στις 08 Νοεμβρίου 2023