DeepL
Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

Κεφάλαιο 7
Σημασιολογική αναζήτηση με το GoPubMed

Andreas Doms και Michael Schroeder

Τεχνικό Πανεπιστήμιο της Δρέσδης, Γερμανία
adoms@biotec.tu-dresden.de
http://biotec.tu-dresden.de

Περίληψη. Η αναζήτηση σχετικών πληροφοριών στον παγκόσμιο ιστό είναι μια κύρια απασχόληση των ερευνητών στις μέρες μας. Οι κλασικές μηχανές αναζήτησης με βάση λέξεις-κλειδιά έχουν όρια. Το ασυνεπές λεξιλόγιο που χρησιμοποιούν οι συγγραφείς δεν αντιμετωπίζεται. Δεν μπορούν να βρεθούν σχετικές πληροφορίες που είναι κατανεμημένες σε πολλά έγγραφα. Η επισκόπηση μιας ολόκληρης συλλογής εγγράφων δεν μπορεί να δοθεί με τη βοήθεια καταταγμένων λιστών. Δεν είναι δυνατή η απάντηση ερωτήσεων που απαιτούν σημασιολογική αποσαφήνιση της χρησιμοποιούμενης ορολογίας. Οι τάσεις της βιβλιογραφίας δεν μπορούν να ακολουθηθούν εάν το λεξιλόγιο εξελίσσεται με την πάροδο του χρόνου.

Το GoPubMed είναι μια σημασιολογική μηχανή αναζήτησης που χρησιμοποιεί τη γνώση των οντολογιών για την ευρετηρίαση της βιοϊατρικής βιβλιογραφίας. Σε αυτό το κεφάλαιο συζητάμε πώς η σημασιολογική αναζήτηση μπορεί να συμβάλει στην υπέρβαση των ορίων των κλασικών παραδειγμάτων αναζήτησης.

Λέξεις-κλειδιά: Βιβλιογραφικές τάσεις: Μηχανές αναζήτησης, οντολογίες, βιοεπιστήμες, απάντηση ερωτήσεων, γνώση εμπειρογνωμόνων, βιβλιογραφικές τάσεις.

7.1 Αναζήτηση βιοϊατρικής βιβλιογραφίας

Ένας σημαντικός στόχος στη μετα-γονιδιωματική εποχή είναι η διερεύνηση της τάξης και της λογικής των γενετικών προγραμμάτων (11). Οι εξελίξεις στην τεχνολογία αλληλούχισης κατέστησαν διαθέσιμα τα γονιδιώματα πολλών οργανισμών. Τα πειράματα υψηλής απόδοσης δημιουργούν μάζες δεδομένων που μπορούν να αξιοποιηθούν για νέες γνώσεις σχετικά με τα βιολογικά προγράμματα.

Παρά το γεγονός ότι όλο και περισσότερες βιοϊατρικές γνώσεις αποθηκεύονται σε δομημένες βάσεις δεδομένων (58), συμπεριλαμβανομένων των ακολουθιών γονιδιώματος, των μοριακών δομών, των βιο- λογικών μονοπατιών, των αλληλεπιδράσεων πρωτεϊνών και των συστοιχιών γονιδιακής έκφρασης, το μεγαλύτερο μέρος των διαθέσιμων βιοϊατρικών γνώσεων εξακολουθεί να είναι προσβάσιμο μόνο μέσω μη δομημένου κειμένου στις επιστημονικές δημοσιεύσεις.

Η βιοϊατρική βιβλιογραφία αναπτύσσεται με τρομερούς ρυθμούς και το

PubMed περιλαμβάνει ήδη πάνω από 18.000.000 περιλήψεις. Η εύρεση σχετικής βιβλιογραφίας είναι ένα σημαντικό και δύσκολο πρόβλημα με έως και 5.000 νέες αναφορές στο PubMed κάθε μέρα. Η βιοϊατρική επεξεργασία κειμένων αποσκοπεί στη διαχείριση αυτής της έκρηξης πληροφοριών (7).

Πρόσφατα έχει αφιερωθεί πολλή έρευνα στην ανάλυση της βιοϊατρικής βιβλιογραφίας. Το ενδιαφέρον αυτό προκλήθηκε από την αύξηση της βιβλιογραφίας, αλλά και από τη διαθεσιμότητα περιλήψεων, πλήρων εγγράφων και βιβλιομετρικών δεδομένων. Οι ερευνητές έχουν ενδιαφερθεί συγκεκριμένα για την αυτόματη εξαγωγή πληροφοριών από ελεύθερο κείμενο, όπως ονόματα πρωτεϊνών (22- 60- 31), όροι οντολογίας (55- 8- 16) και

F. Bry και J. Maluszynski (επιμ.): LNCS 5500, σ. 309-342, 2009.
Oc Springer-Verlag Berlin Heidelberg 2009

πρωτεϊνικές αλληλεπιδράσεις (57, 21, 32). Οι τεχνικές αυτές εφαρμόζονται στη συνέχεια για να βοηθήσουν ή ακόμη και να αυτοματοποιήσουν τον σχολιασμό των αναπαραστάσεων των πρωτεϊνών στις βάσεις δεδομένων.

Οι οντολογίες χρησιμοποιούνται όλο και περισσότερο για την αποτύπωση της βιολογικής γνώσης. Ο (26) ορίζει μια οντολογία ως ρητή προδιαγραφή μιας εννοιολόγησης. Στο (38) οι συγγραφείς δίνουν παραδείγματα βιολογικών οντολογιών και γνώσης που βασίζεται σε οντολογίες. Ένα εξέχον παράδειγμα οντολογίας είναι η γονιδιακή οντολογία (GO) (24), η οποία παρέχει ένα ιεραρχικό λεξιλόγιο για τη λειτουργία, τις διεργασίες και τις κυτταρικές θέσεις. Η GO χρησιμοποιείται για τον σχολιασμό πρωτεϊνών σε βιολογικές βάσεις δεδομένων, όπως η βάση δεδομένων ακολουθιών UniProt
(3) και την τράπεζα δεδομένων πρωτεϊνικών δομών PDB (6).

7.1.1 Όρια της κλασικής αναζήτησης

Η εύρεση σχετικής βιβλιογραφίας είναι ένα σημαντικό και δύσκολο πρόβλημα. Ο όγκος της βιβλιογραφίας που διατίθεται σήμερα στο διαδίκτυο είναι τεράστιος. Η Ingenta (www.ingenta.com), ένα ηλεκτρονικό ευρετήριο 17.000 περιοδικών, διαθέτει 7 εκατομμύρια άρθρα που χρονολογούνται από το 1988. Το Infotrieve (www.infotrieve.com) ευρετηριάζει πάνω από 20.000 περιοδικά με 15 εκατομμύρια αναφορές. Το CiteSeer (www.citeseer.com), μια ψηφιακή βιβλιοθήκη, καλύπτει πάνω από ένα εκατομμύριο άρθρα και 22 εκατομμύρια παραπομπές. Άλλα σημαντικά παραδείγματα μηχανών αναζήτησης βιβλιογραφίας είναι οι Google Scholar, Scopus, Scirus και Forschungsportal.Net. Βάσεις δεδομένων
για την επιστημονική βιβλιογραφία αυξάνονται με εκπληκτικό ρυθμό. Η PubMed, μια βάση δεδομένων βιοϊατρικής βιβλιογραφίας, αυξήθηκε κατά 754.003 αναφερόμενα έγγραφα τον τελευταίο χρόνο και καλύπτει πλέον περισσότερα από 18 εκατομμύρια περιλήψεις επιστημονικής βιβλιογραφίας, αν και περίπου τα μισά από αυτά είναι ανακλήσεις και διορθώσεις (55). Με 871 εκατομμύρια αναζητήσεις στην PubMed το 2007 είναι σαφές ότι οι ερευνητές ξοδεύουν σημαντικό χρόνο για την αναζήτηση της επιστημονικής βιβλιογραφίας.

Μεγάλες ποσότητες γνώσεων και πληροφοριών είναι διαθέσιμες στους ερευνητές μέσω εκατομμυρίων εγγράφων. Αλλά χωρίς αποτελεσματικούς τρόπους πρόσβασης πολλά από αυτά θα παραμείνουν απαρατήρητα από τους αναγνώστες λόγω των συντριπτικών ποσοτήτων κειμένου. Οι κλασικές μηχανές αναζήτησης έχουν τους ακόλουθους περιορισμούς:

- Οι κλασικές μηχανές αναζήτησης δεν παρέχουν αποτελέσματα αναζήτησης που κατανέμονται σε πολλαπλά έγγραφα. Οι απαντήσεις είναι ένας ταξινομημένος κατάλογος μεμονωμένων εγγράφων που αναπαρίσταται ως απόσπασμα κειμένου και διεύθυνση URL.
- Το αποτέλεσμα της αναζήτησης είναι μια λίστα επιτυχιών με κατάταξη. Το κόστος για τον χρήστη, ο χρόνος που δαπανάται για την εύρεση σχετικών εγγράφων, αθροίζεται γρήγορα αν οι λέξεις-κλειδιά είναι σχετικές με πολλά θέματα. Για να αυξήσει την $^{\text{ακρίβεια1}}$ ο χρήστης πρέπει να βελτιώσει επαναληπτικά το ερώτημά του, γεγονός που συνήθως μειώνει ταυτόχρονα την $^{\text{ανάκληση2}}$.
- Τα αποτελέσματα που περιλαμβάνουν πολλά σχετικά έγγραφα αντιπροσωπεύονται ελάχιστα από μερικά έγγραφα στην αρχή ενός καταλόγου επιτυχιών.

– Οι κλασικές μηχανές αναζήτησης δεν γνωρίζουν τα συνώνυμα και τις σχεσιακές πληροφορίες της κοινής ορολογίας. Ορισμένες μηχανές στοχεύουν στην παραγωγή υψηλότερης ανάκλησης με την επέκταση του ερωτήματος με συνώνυμα, η τεχνική αυτή συνήθως μειώνει την ακρίβεια των συστημάτων.
– Οι μεταπληροφορίες που χαρακτηρίζουν ολόκληρη τη συλλογή των σχετικών εγγράφων δεν αποτελούν μέρος της απόκρισης μιας κλασικής μηχανής αναζήτησης.

---

[1] Η ακρίβεια μετρά την ικανότητα ενός αλγορίθμου να ανακτά μόνο σχετικές οντότητες.

[2] Η ανάκληση μετρά την ικανότητα ενός αλγορίθμου να εξάγει όλες τις σχετικές οντότητες.

Πίνακας 1. Κατηγοριοποίηση των μηχανών αναζήτησης βιοϊατρικής

Ανάκτηση πληροφοριών		Ανάκτηση Γνώσης	
Βελτιωμένη Επεξεργασία Αποτελεσμάτων		Επεξεργασία Ερωτήσεων	
	Ενσωμάτωση εργαλείων	Σημασιολογική επεξεργασία	
askMedline	BioIE	HubMed	EBIMed
PubMedInteract	ReleMed	PubFocus	GOAnnotator
Γλωσσολόγος PICO	PubMed PubReMiner	Harvester	Info-PubMed
BabelMeSH	ClusterMed		XploreMed
PubFinder	BioMetaCluster		iHop
CiteXplore			ExpertMapper
			Textpresso
			AliBaba
			Chilibot
			PubGene
			MedStory
			GoPubMed

Στην ενότητα που ακολουθεί παρουσιάζονται οι διαδικτυακά διαθέσιμες μηχανές αναζήτησης βιοϊατρικών δεδομένων, οι οποίες παρέχουν λειτουργίες πέραν των κλασικών μηχανών αναζήτησης.

7.1.2 Μηχανές αναζήτησης βιοϊατρικής

Με την ταχεία ανάπτυξη της βιοϊατρικής βιβλιογραφίας αυξήθηκε ο αριθμός των εξειδικευμένων μηχανών αναζήτησης που είναι προσαρμοσμένες στις ανάγκες των ιατρών και των βιολόγων. Το 1997, η κυβέρνηση των ΗΠΑ αποφάσισε να καταστήσει το MEDLINE, τον κατάλογο παραπομπών της Εθνικής Βιβλιοθήκης Ιατρικής, δημόσια προσβάσιμο μέσω του Παγκόσμιου Ιστού. Το 2001, εισήχθη μια νέα διεύθυνση URL www.pubmed.gov. Από τότε έχει γίνει η πιο δημοφιλής βάση δεδομένων βιβλιογραφίας στο διαδίκτυο. Με την εισαγωγή των Entrez Programming Utilities και τη διαθεσιμότητα των παραπομπών σε μορφή XML από το 2000, ο αριθμός των εναλλακτικών διεπαφών του PubMed αυξήθηκε γρήγορα. Βιοϊατρική
οι μηχανές αναζήτησης μπορούν να ταξινομηθούν ανάλογα με την εστίασή τους στην υποστήριξη της ανάκτησης πληροφοριών και στην υποστήριξη της ανάκτησης γνώσεων (36). Ωστόσο, δεν είναι πάντοτε δυνατός ο σαφής διαχωρισμός. Ο Πίνακας 1 δείχνει πώς κατηγοριοποιούνται οι μηχανές αναζήτησης βιοϊατρικής που εξετάζονται στην παρούσα ενότητα.

Μηχανές αναζήτησης που εστιάζουν στην Ανάκτηση Πληροφοριών. Ανάκτηση πληροφοριών είναι η διαδικασία αναζήτησης εγγράφων ή πληροφοριών σε έγγραφα που εκτελείται από έναν ανθρώπινο χρήστη ή έναν αυτοματοποιημένο πράκτορα. Ένα σύστημα που υποστηρίζει ένα ερώτημα ανθρώπινου χρήστη αποσκοπεί στην αύξηση της αναλογίας μεταξύ σχετικών και μη σχετικών εγγράφων κατά την υποβολή ενός ερωτήματος, π.χ. μηχανές αναζήτησης στο διαδίκτυο. Το έργο ενός αυτόματου συστήματος είναι η διόγκωση των φιλτραρισμένων πληροφοριών για τη μείωση του αριθμού των εγγράφων που απαιτούν περαιτέρω επεξεργασία, π.χ. προσαρμόσιμες υπηρεσίες τροφοδοσίας RSS.

Βελτιωμένη αναζήτηση. Το PubMed επεκτείνει τα ερωτήματα των χρηστών χρησιμοποιώντας επικεφαλίδες MeSH[3] και πρόσθετα λεξιλόγια όπως φάρμακα ή χημικές ουσίες. Εάν ένα ερώτημα περιέχει ένα τέτοιο

[3]Ο θησαυρός Medical Subject Headings (MeSH) είναι ένα ελεγχόμενο λεξιλόγιο που περιλαμβάνει βιοϊατρικά θέματα και θέματα που σχετίζονται με την υγεία.

το ερώτημα επεκτείνεται με την επιλογή να συμπεριληφθούν και άρθρα που έχουν σχολιαστεί χειροκίνητα με τον όρο αυτό. Στη διεπαφή PubMed το διευρυμένο αυτό ερώτημα μπορεί να επανεξεταστεί από τον χρήστη. Μπορούν επίσης να κληθούν τα E-Utilities για τον υπολογισμό αυτής της επέκτασης. Αυτή η επέκταση του ερωτήματος βοηθά στην ανάκτηση σχετικών άρθρων που διαφορετικά θα είχαν χαθεί.

Ορισμένα εργαλεία αποσκοπούν στη βελτίωση της αναζήτησης στο PubMed με την υποστήριξη του χρήστη κατά τη διατύπωση του ερωτήματος. Τα χαρακτηριστικά φτάνουν από τη γλωσσική μετάφραση πάνω σε γραφήματα-ικούς στόχους έως την προεπεξεργασία πλήρων αγγλικών ερωτήσεων:

Ο βασισμένος σε κείμενο ιστότοπος askMEDLINE (19) δέχεται ως είσοδο μια ερώτηση σε φυσική γλώσσα. Το σύστημα αφαιρεί τις άσχετες λέξεις και οι εναπομείνασες λέξεις ελέγχονται ως προς τη σχέση τους με τις επικεφαλίδες MeSH μέσω ερωτημάτων στο PubMed. Οι όροι που ταξινομούνται ως "άλλες επιλέξιμες καταχωρίσεις" εξαλείφονται επίσης εάν τα εναπομείναντα αποτελέσματα αναζήτησης είναι λίγα. Το αποτέλεσμα είναι πάντα ένας κατάλογος με τίτλους παραπομπών και συνδέσμους προς την περίληψη και το πλήρες κείμενο.

Το PubMedInteract (42) είναι μια διαδικτυακή διασύνδεση με το PubMed και παρουσιάζει ολισθαίνουσες μπάρες για τον καθορισμό των ορίων και των παραμέτρων αναζήτησης στο PubMed. Μια επιλογή "Preview Count" υπολογίζει τον αριθμό των άρθρων που αναμένονται με τις τρέχουσες ρυθμίσεις.

Το PICO Linguist (18) προσφέρει στους μη αγγλόφωνους ιατρούς τη δυνατότητα να δημιουργήσουν ένα δομημένο κλινικό ερώτημα με ιατρικούς όρους που μπορεί να είναι δύσκολο να εκφραστούν στα αγγλικά, χρησιμοποιώντας το πλαίσιο PICO. Ο χρήστης μπορεί να προσδιορίσει το πρόβλημα του ασθενούς, τη θεραπεία και τις εναλλακτικές θεραπείες και το αποτέλεσμα στη δική του γλώσσα. Πρωταρχικές πηγές λεξιλογίων για τη μετάφραση είναι οι UMLS, MeSH, WHO EMRO και UMLF. Η UMLS είναι ένα έργο που συνδυάζει διάφορες ορολογίες όπως η ICD-10 (Διεθνής Ταξινόμηση των Ασθενειών), η MeSH (40), η SNOMED (45), η LOINC (20), η Gene Ontology (4) και η OMIM (29) σε μία πηγή. Ο Μεταθησαυρός περιέχει έννοιες, ονόματα εννοιών και άλλα χαρακτηριστικά από περισσότερες από 100 τε-μνολογίες, ταξινομήσεις και θησαυρούς- ορισμένες από αυτές σε πολλαπλές εκδόσεις.

Ο δικτυακός τόπος BabelMeSH (18) αντιστοιχίζει τους όρους αναζήτησης σε ένα πολύγλωσσο MeSH σε 12 διαφορετικές γλώσσες. Μόνο οι όροι που παρατίθενται στο πολύγλωσσο λεξιλόγιο μπορούν να χρησιμοποιηθούν για την αναζήτηση.

Η υπηρεσία PubFinder (25) αποσκοπεί στην αυτόματη εξαγωγή περιλήψεων Pubmed που αφορούν ένα συγκεκριμένο επιστημονικό θ έ μ α . Ο χρήστης εισάγει ένα αντιπροσωπευτικό σύνολο αναγνωριστικών PubMed. Με βάση τις περιλήψεις, υπολογίζεται ένας κατάλογος λέξεων διάκρισης, ο οποίος χρησιμοποιείται για την κατάταξη των περιλήψεων Pubmed ως προς την πιθανότητα να ανήκουν στο θέμα που έχει ορίσει ο χρήστης. Οι πρώτες 100 λέξεις που παρουσιάζουν τη μεγαλύτερη διαφορά εμφάνισης μεταξύ της συνολικής συχνότητας μιας λέξης στο PubMed σε ένα λεξικό αναφοράς και της συχνότητας μιας λέξης στις επιλεγμένες περιλήψεις αποτελούν τον κατάλογο των

διακριτικών λέξεων. Ένα σύνολο περιλήψεων που ασχολείται με την εξόρυξη βιβλιογραφίας περιέχει, για παράδειγμα, αυτές τις λέξεις: abstracts, medline, information, articles, names, precision, database, recall, protein, literature, databases, references, system, automatically, interactions, set, mining, scientific, automated, motivation και άλλες.

Το CiteXplore ευρετηριάζει έγγραφα από πηγές όπως το Medline, το European Patent Office, το Chinese Biological Abstracts και το Citeseer χρησιμοποιώντας το πλήρες κείμενο Lucene in- dex. Προσφέρονται προηγμένες αναζητήσεις, όπως αναζήτηση με μπαλαντέρ σε επιλεγμένα χαρακτηριστικά. Μια άλλη επιλογή είναι η επέκταση με συνώνυμα. Οι πληροφορίες που συλλέγονται από άλλες

εφαρμογές, όπως οι InterPro, SwissProt/Trembl και Alternative Splicing. Η εξωτερική υπηρεσία εξόρυξης κειμένου WhatIsIt χρησιμοποιείται για την ανάδειξη των πρωτεϊνών, των γονιδίων και των αλληλεπιδράσεων πρωτεΐνης-πρωτεΐνης. Οι αναφορές μπορούν να εξαχθούν σε μορφή EndNote, RIS και Bibtex.

Επεξεργασία αποτελεσμάτων. Ορισμένα συστήματα επεξεργάζονται περαιτέρω τα αποτελέσματα αναζήτησης για να διευκολύνουν την περιήγηση σε μεγάλο αριθμό εγγράφων ή να συνδέουν με περαιτέρω σχετικές παραπομπές με βάση το περιεχόμενο του αποτελέσματος αναζήτησης. Παραδείγματα είναι η επισήμανση στοιχείων, η επανακατάταξη εγγράφων και η οργάνωση πληροφοριών. Η επισήμανση αποδεικτικών στοιχείων τονίζει οπτικά τα αποσπάσματα κειμένου στα έγγραφα της πηγής. Για παράδειγμα, υπογραμμίζεται η λέξη σε μια πρόταση που δηλώνει μια σχέση δύο οντοτήτων. Οι αναγνώστες υποστηρίζονται κατά τη σάρωση σχετικών αποσπασμάτων κειμένου. Τα έγγραφα μπορούν να ταξινομηθούν σύμφωνα με επιλεγμένα κριτήρια, όπως η ημερομηνία, ο τύπος της παραπομπής, η χρήση του λεξιλογίου ή η φήμη. Οι υπερσύνδεσμοι προς έγγραφα που δεν περιλαμβάνονται στο αρχικό αποτέλεσμα της αναζήτησης, για παράδειγμα έγγραφα στα οποία γίνεται παραπομπή ή έγγραφα με παρόμοιο περιεχόμενο, υποστηρίζουν τους ερευνητές στην εύρεση όλου του σχετικού υλικού. Οργάνωση πληροφοριών είναι η διαδικασία οργάνωσης των πληροφοριών έτσι ώστε να καταστούν χρήσιμες. Για παράδειγμα, οι πίνακες ή τα γραφήματα δικτύου υποστηρίζουν την κατανόηση.

Το BioIE είναι ένα σύστημα βασισμένο σε κανόνες που εξάγει πληροφοριακές προτάσεις από έγγραφα του MED- LINE ή από κείμενα που έχουν μεταφορτωθεί. Οι πληροφοριακές προτάσεις αναφέρονται σε δομές, λειτουργίες, ασθένειες και θεραπευτικές ενώσεις, εντοπισμούς ή οικογενειακές σχέσεις βιολογικών οντοτήτων, ιδίως πρωτεϊνών. Η επιλεγμένη βάση κειμένων μπορεί να απεικονιστεί σε μορφή πίνακα ως πίνακες συχνοτήτων λέξεων, όρων MeSH και φράσεων λέξεων. Τα πρότυπα κειμένου χρησιμοποιούνται για τον εντοπισμό πληροφοριακών προτάσεων ενός επιλεγμένου τύπου, π.χ. λειτουργικές περιγραφές. Οι προτάσεις μπορούν να φιλτραριστούν περαιτέρω για τη συνύπαρξη με πρόσθετες λέξεις-κλειδιά.

Το ReleMed (54) επεκτείνει αυτόματα το ερώτημα ενός χρήστη χρησιμοποιώντας το UMLS και το MeSH. Τα ονόματα των πρωτεϊνών και των γονιδίων επεκτείνονται επίσης. Επίσης, παράγονται λεξιλογικές παραλλαγές των λέξεων. Ο χρήστης έχει τη δυνατότητα να αναιρέσει αυτές τις επεκτάσεις επιλεκτικά. Οι αντιστοιχίες σε ξεχωριστές προτάσεις επισημαίνονται. Το ReleMed χρησιμοποιεί τη σχεσιακή βάση δεδομένων MySql για την υλοποίηση ενός ευρετηρίου πλήρους κειμένου σε μεμονωμένες προτάσεις. Οι επικεφαλίδες MeSH που σχετίζονται με τις περιλήψεις συνενώνονται και αντιμετωπίζονται ως πρόσθετη πρόταση. Η συνάφεια ενός άρθρου ορίζεται σε οκτώ επίπεδα ανάλογα με τη συνύπαρξη όλων των λέξεων-κλειδιών σε μία ή περισσότερες προτάσεις.

Το PubMed PubReMiner (37) εμφανίζει τα περιοδικά του χρήστη στα οποία αναφέρονται περισσότερο οι λέξεις-κλειδιά του. Εμφανίζει τους συγγραφείς που δημοσιεύουν τα περισσότερα άρθρα που αναφέρουν τις λέξεις-κλειδιά. Δείχνει τις λέξεις που χρησιμοποιήθηκαν περισσότερο στον τίτλο και την περίληψη των

άρθρων. Τα ερωτήματα μπορούν να βελτιωθούν με βάση χαρακτηριστικά εγγράφων, όπως διεύθυνση, ουσίες, επικεφαλίδες MeSH, έτος δημοσίευσης, συγγραφέας και άλλα. Το Vivisimo εφαρμόζει μεθόδους ομαδοποίησης στο ClusterMed και στο BioMetaCluster (56).

Στο ClusterMed τα αποτελέσματα της PubMed ομαδοποιούνται με διάφορους τρόπους. Οι διαχωρισμοί των εγγράφων υπολογίζονται με βάση τις συμβολοσειρές (1) στον τίτλο, την περίληψη και τις επικεφαλίδες ιατρικών θεμάτων, (2) μόνο στον τίτλο, την περίληψη, (3) μόνο στις MeSH, (4) μόνο στο όνομα του συγγραφέα, (5) μόνο στην ιδιότητα του συγγραφέα και (6) μόνο στην ημερομηνία δημοσίευσης. Το Vivisimo χρησιμοποιεί λέξεις που βρίσκονται στα χαρακτηριστικά αυτού του εγγράφου για την επισήμανση συστάδων. Οι συστάδες ταξινομούνται με βάση τον αριθμό των εγγράφων που περιέχονται σε αυτές. Η ιεραρχία των συστάδων υπολογίζεται

χρησιμοποιώντας στατιστική επεξεργασία γλώσσας. Για το ερώτημα *rab5* το ClusterMed επέστρεψε αρκετές συστάδες όπως Vacuoles, Phagosomes, Rabaptin-5, Rab5a και άλλες. Οι ετικέτες υπολογίζονται με βάση τα στατιστικά στοιχεία εμφάνισης λέξεων στις περιλήψεις των άρθρων που επανεξετάστηκαν. Η συστάδα "Rabaptin-5" περιέχει υπο-συστάδες όπως "Ubiquitin", "GAT domain", "Vesicular transport", "Nucleotide exchange", "Dimerization Of Rabaptin-5", "Endocytic membrane fusion", "Correlated, Tis- sue", "FRET microscopy", "Cleaved in apoptotic" και άλλες ετικέτες.

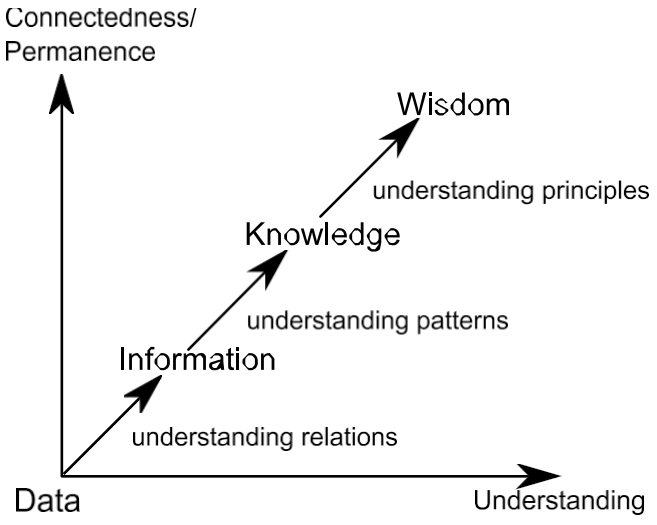
Το ClusterMed παρέχει τη δυνατότητα υπολογισμού των συστάδων μόνο στις επικεφαλίδες MeSH. Εφαρμόζονται οι ίδιες τεχνικές συσταδοποίησης με βάση τις συμβολοσειρές, αλλά με χρήση μόνο λέξεων από το MeSH. Ένα αποτέλεσμα συσταδοποίησης για το ερώτημα *rab5* εμφανίζει συστάδες με ετικέτες με επικεφαλίδες MeSH όπως "Guanine Nucleotide Exchange Factors", "Virology" και "Pathology" αλλά και συνυφασμένες ετικέτες όπως "Analysis, Liver", "Chromatog- raphy, Affinity, Cattle", "Phagosomes, Microbiology" οι οποίες δεν αντιστοιχούν σε μία μόνο επικεφαλίδα ή υπο-επικεφαλίδα MeSH αλλά σε συνδυασμό αυτών. Μια συστάδα δεν περιλαμβάνει απαραίτητα υπο-συστάδες που αντικατοπτρίζονται από μια σχέση στο UMLS. Στα παραδείγματα η συστάδα "Guanine Nucleotide Exchange Factors" περιλαμβάνει ετικέτες κυτταρικών συστατικών, ασθενειών, πεπτιδίων, πρωτεϊνών και αλγορίθμων. Ο αλγόριθμος συσταδοποίησης τα ομαδοποίησε με βάση τη στατιστική συνύπαρξη στο σύνολο των αποτελεσμάτων. Δεν χρησιμοποιούνται πληροφορίες σχετικά με τις σχέσεις μεταξύ των επικεφαλίδων.

Ένα άλλο χαρακτηριστικό του ClusterMed είναι η ομαδοποίηση κατά συγγραφείς. Εδώ, ομαδοποιούνται οι συμβολοσειρές του επωνύμου συν τα αρχικά. Οι υπο-συστάδες περιέχουν συν-συγγραφείς. Οι συστάδες μπορεί να περιέχουν αναφορές PubMed διαφορετικών συγγραφέων με το ίδιο επώνυμο και τα ίδια αρχικά.

Το BioMetaCluster είναι μια μηχανή μετα-αναζήτησης που βασίζεται στην αρχιτεκτονική ομαδοποίησης Vivisimo. Αναζητά 22 διαδικτυακούς πόρους σχετικούς με τον βιοϊατρικό τομέα χρησιμοποιώντας ομαδοποίηση των αποτελεσμάτων αναζήτησης με βάση τις συμβολοσειρές.

Μηχανές αναζήτησης που εστιάζουν στην ανάκτηση γνώσης. Στο (59) οι συγγραφείς συγκρίνουν τα συστήματα ανάκτησης γνώσης και ορίζουν ως καθήκον τους την εύρεση γνώσης από πληροφορίες και την οργάνωσή της σε δομές που μπορούν να χρησιμοποιηθούν από τον άνθρωπο. Ακολουθώντας την (1), το περιεχόμενο του ανθρώπινου νου μπορεί να ταξινομηθεί σε δεδομένα, πληροφορίες, γνώση, κατανόηση και σοφία. (1) Τα δεδομένα απλώς υπάρχουν και δεν έχουν καμία σημασία πέρα από την ύπαρξή τους. Τα σύμβολα, όπως οι ακατέργαστοι αριθμοί, είναι δεδομένα. (2) Οι πληροφορίες είναι δεδομένα στα οποία έχει δοθεί νόημα μέσω σχεσιακής σύνδεσης. Προσθέτει πλαίσιο. Αυτό το νόημα δεν χρειάζεται να είναι χρήσιμο. Μια σχεσιακή βάση δεδομένων περιέχει δομημένα σχεσιακά δεδομένα. (3) Γνώση είναι η κατάλληλη συλλογή πληροφοριών, έτσι ώστε η πρόθεσή της να είναι χρήσιμη. Τα προγράμματα υπολογιστών που μοντελοποιούν ή προσομοιώνουν κάποια διαδικασία εφαρμόζουν γνώση. (4) Η κατανόηση είναι μια παρεμβολική και προβολική διαδικασία. Με την κατανόηση μπορεί κανείς να συνθέσει νέες γνώσεις ή τουλάχιστον πληροφορίες. (5) υποστηρίζουν ότι ορισμένα συστήματα τεχνητής νοημοσύνης μπορούν να

παράγουν νέα γνώση και επομένως είναι "κατανοητά". (5) Η σοφία είναι μια εξωστρεφής και μη ντετερμινιστική, μη πιθανολογική διαδικασία. Διαβάστε το δοκίμιο από το (53) για μια ενδιαφέρουσα φιλοσοφική συζήτηση. (5) Προτείνετε μια ερμηνεία των εννοιών όπως φαίνεται στο σχήμα 1. Η μετάβαση από τα δεδομένα στην πληροφορία, στη γνώση και, τέλος, στη σοφία επιτυγχάνεται με την κατανόηση. Ορισμένα συστήματα εστιάζουν στην ενσωμάτωση εξωτερικών προγραμμάτων για την επίτευξη αυτών των μεταβάσεων.



Σχήμα 1. Το διάγραμμα δείχνει τις μεταβάσεις από τα δεδομένα στην πληροφορία, στη γνώση και, τέλος, στη σοφία. Η κατανόηση δεν είναι ένα ξεχωριστό επίπεδο από μόνη της, είναι απαραίτητη για τη μετάβαση από κάθε στάδιο στο επόμενο. Το σχήμα υιοθετήθηκε από το (5). (1) επισημαίνει ότι οι πληροφορίες γερνούν γρήγορα, η γνώση έχει μεγαλύτερη χρονική διάρκεια, μόνο η σοφία είναι μόνιμη.

Ενσωμάτωση εργαλείων. Οι βιοϊατρικές μηχανές αναζήτησης που επεξεργάζονται τα αποτελέσματα αναζήτησης εξωτερικά καλούν μεθόδους API ή υπηρεσίες ιστού για την ανάλυση μεμονωμένων παραπομπών ή παρτίδων παραπομπών. Αυτά τα χαρακτηριστικά επηρεάζονται από τις ιδέες του Σημασιολογικού Ιστού. Ορισμένες υπηρεσίες επιτρέπουν διάφορες μορφές ανταλλαγής δεδομένων, όπως RDF, XML, BibTex, RIS, Endnote και απλό κείμενο.

Η HubMed (17) προσφέρει μια σειρά εξωτερικών εργαλείων για την επεξεργασία των αποτελεσμάτων της PubMed. Η αναζήτηση συμπεριφέρεται ακριβώς όπως η αρχική στο PubMed, εάν κάποιος επιλέξει να χρησιμοποιήσει την επιλογή ταξινόμηση κατά ημερομηνία. Μια εναλλακτική λύση είναι η επιλογή sort by relevance (ταξινόμηση κατά συνάφεια). Εδώ, χρησιμοποιείται ένα ευρετήριο Apache Lucene, αλλά δεν αναπτύσσονται οι επικεφαλίδες MeSH, όπως γίνεται μέσω της αναζήτησης στο PubMed. Η επιλογή sort by relevance φαίνεται να ευνοεί τις παραπομπές που περιέχουν όλες τις λέξεις-κλειδιά του ερωτήματος. Ορισμένα εσωτερικά εργαλεία βοηθούν στη διαχείριση των παραπομπών. Ένα πρόχειρο αποθηκεύει ένα σύνολο παραπομπών για μετέπειτα επαναχρησιμοποίηση. Η λειτουργία ιστορικού επιτρέπει την ανάκτηση προηγούμενων αναζητήσεων. Οι παραπομπές μπορούν να επισημανθούν με αυθαίρετες λέξεις-κλειδιά για μεταγενέστερο φιλτράρισμα για αυτές. Επιπλέον, μπορούν να χρησιμοποιηθούν ετικέτες άλλων χ ρ η σ τ ώ ν .

Η αναζήτηση μπορεί να περιοριστεί ή να διευρυνθεί με τις πιο στενά συνδεδεμένες λέξεις. Η συγγένεια υπολογίζεται χρησιμοποιώντας μια κατάταξη tf-idf (35) των λέξεων των πρώτων 500 παραπομπών. Μια άλλη επιλογή για τον χειρισμό του αρχικού ερωτήματος είναι η λειτουργία

ομαδοποίησης του HubMed. Ο αλγόριθμος Lingo (39) χρησιμοποιείται για την ομαδοποίηση των 200 πρώτων παραπομπών του αρχικού ερωτήματος. Οι συστάδες συνδέονται με τις πρώτες 20 αναφορές κάθε συστάδας.

Ένα εξωτερικό βοηθητικό πρόγραμμα που καλείται από το HubMed είναι το ELink utility του Entrez. Για ορισμένα άρθρα, γενικά αν ένα άρθρο αναφέρεται στην ανακάλυψη ή την αλληλούχιση ενός γονιδίου

ή πρωτεΐνη, οι σύνδεσμοι μεταξύ των βάσεων δεδομένων παρουσιάζονται από την HubMed. Ένα άλλο εργαλείο που χρησιμοποιείται είναι η διαδικτυακή υπηρεσία Whatizit (51), η οποία αναγνωρίζει όρους όπως ονόματα πρωτεϊνών και βιολογικές διεργασίες, συνδέοντάς τους με υπηρεσίες όπως η UniProt και η Gene Ontology. Οι παραπομπές στο πρόχειρο μπορούν να απεικονιστούν με την εφαρμογή Touch- Graph Java [applet4]. Το HubMed επικεντρώνεται στη βελτίωση της αναζήτησης αλλά και στην ενσωμάτωση εργαλείων και συνεπώς στην υποστήριξη της ανάκτησης γνώσης.

Το PubFocus (48) είναι ένα εργαλείο βιβλιομετρικών στατιστικών που ενσωματώνει εξωτερικά δεδομένα και υπηρεσίες ιστού για την επεξεργασία των αναζητήσεων στο PubMed και την παροχή καταταγμένων καταλόγων με εξέχοντες συγγραφείς, πόλεις και περιοδικά. Η κατάταξη των παραπομπών βασίζεται σε παράγοντες επίδρασης περιοδικών, όγκο προωθητικών παραπομπών, δυναμική παραπομπών και επίπεδο συνεισφοράς των συγγραφέων. Το PubFocus χρησιμοποιεί τους μη δωρεάν συντελεστές αντίκτυπου των Journal Citation Reports που δημοσιεύονται από την Thomson Scientific. Οι πληροφορίες για τις προωθητικές αναφορές βασίζονται στο PubMed Central και το Google Scholar. Η ανάκτηση δεδομένων εκτελείται online με την ανάλυση της εξόδου HTML του εξωτερικού ιστότοπου. Οι συγγραφείς ορίζουν διάφορους δείκτες, όπως ο δείκτης παραπομπών σε σχέση με την ηλικία, ο συνδυασμένος συντελεστής αντίκτυπου, ο αθροιστικός συντελεστής αντίκτυπου και η κατάταξη του συγγραφέα. Οι όροι του θησαυρού NCI και της βάσης δεδομένων MGD mammalian gene ontology που εμφανίζονται στους τίτλους και/ή στις περιλήψεις των παραπομπών εξάγονται χρησιμοποιώντας μια αναζήτηση πλήρους κειμένου MySQL. Τ α στατιστικά στοιχεία για τους όρους αυτούς ενσωματώνονται επίσης στη διεπαφή ιστού και χρησιμεύουν για την περαιτέρω βελτίωση του αρχικού ερωτήματος.

Το Harvester ανιχνεύει και διασυνδέει τους ακόλουθους διαδικτυακούς πόρους: H-Inv, HomoloGene, Hwiki-Forum, iHOP, IPI, MapView, Mi- tocheck, OMIM, PolyMeta, PSORT II, SMART, SOSUI, SOURCE, STRING, Unigene, UniprotKB, Wikipedia. Το Harvester διασυνδέει δημόσιες βιοπληροφορικές βάσεις δεδομένων και διακομιστές πρόβλεψης για να παρέχει γρήγορη πρόσβαση σε συγκεκριμένες πρωτεϊνικές βιο- μορφικές πληροφορίες.

Σημασιολογική επεξεργασία. Οι μηχανές βιοϊατρικής αναζήτησης χρησιμοποιούν διάφορες τεχνικές για να ξεπεράσουν το σημασιολογικό κενό μεταξύ του κειμένου και του νοήματός του. Μια ισχυρή υπόθεση που διατυπώνεται από ορισμένα εργαλεία είναι ότι η ταυτόχρονη εμφάνιση βιολογικών οντοτήτων σε μια πρόταση υποδηλώνει ενδεχομένως μια παρατήρηση ή μια υπόθεση αλληλεπίδρασης in vivo. Οι βιολογικές οντότητες έχουν εξαιρετικά διφορούμενη ορολογία. Οι τεχνικές αποσαφήνισης στοχεύουν στην επίλυση αυτού του προβλήματος. Ορισμένα εργαλεία κάνουν χρήση των σχέσεων των εννοιών σε ταξινομίες ή οντολογίες και χρησιμοποιούν τεχνικές συλλογισμού. Εάν τα ευρήματα μπορούν να επιβεβαιώσουν ότι είναι σημαντικά, οι πληροφορίες αυτές συγκεντρώνονται και μπορούν να θεωρηθούν ως γνώση και να χρησιμοποιηθούν για την απάντηση ερωτήσεων. Μια μορφή διαλόγου μπορεί να καθοδηγήσει την ανάκτηση γνώσης κατευθύνοντας το είδος της γνώσης που ζητείται. Τέλος, ορισμένα εργαλεία πειραματίζονται με τη δημιουργία υποθέσεων, τη χρησιμοποιούμενη γνώση και κάποια στατιστικά σήματα για να παρουσιάσουν

δυνητικά νέα γνώση η οποία πρέπει να επιβεβαιωθεί.

Με το EBIMed (52) εντοπίζετε συσχετίσεις μεταξύ πρωτεϊνικών/γονιδιακών κυτταρικών συστατικών, βιολογικών διεργασιών, μοριακών λειτουργιών, φαρμάκων και ειδών. Τα αποτελέσματα παρουσιάζονται σε μορφή πίνακα. Παρατίθενται προτάσεις που υποστηρίζουν τις συσχετίσεις. Η μορφή πίνακα για την παρουσίαση πολλών σχέσεων μεταξύ βιολογικών οντοτήτων

[4] sourceforge.net/projects/touchgraph

ταξινομημένες με βάση τη συχνότητά τους, είναι ένας τρόπος να παρέχεται στο χρήστη μια γρήγορη επισκόπηση. Μια τέτοια συσσωρευμένη μορφή πληροφοριών μπορεί να υποστηρίξει τη βιβλιογραφική αναζήτηση για ασκοινωνίες, επειδή ο χρήστης διαβάζει κυρίως σχετικές προτάσεις. Οι συγγραφείς υποστηρίζουν ότι το EBIMed είναι συμπληρωματικό του PubMed με την έννοια ότι τα μεγάλα σύνολα αποτελεσμάτων στο PubMed είναι κουραστικά για να διαβαστούν, ενώ οι πίνακες του EBIMed αναμένεται να βοηθήσουν περισσότερο για μεγαλύτερα σύνολα παραπομπών.

Ο GOAnnotator στοχεύει στην υποστήριξη των επιμελητών βάσεων δεδομένων. Το καθήκον τους είναι να επιβεβαιώνουν την αυτόματη επιμέλεια βάσεων δεδομένων συνδέοντας τις παρατηρήσεις με πειραματικά αποτελέσματα που περιγράφονται σε δημοσιεύσεις με κριτές. Το εργαλείο παρέχει τεκμήρια κειμένου για γονιδιακά προϊόντα που έχουν ήδη μη επιμεληθεί τους αυτόματα παραγόμενους σχολιασμούς και συνδέει τους μη επιμεληθέντες σχολιασμούς με κείμενα που εξάγονται από τη βιβλιογραφία υποστηρίζοντας έτσι τους επιμελητές GO στην επιλογή των σωστών όρων. Ο GOAnnotator αξιοποιεί την ιεραρχική δομή του GO και μπορεί επίσης να προτείνει εναλλακτικές, δηλαδή πιο ακριβείς σχολιασμούς. Η ακρίβεια του συστήματος είναι υψηλή λόγω της εστιασμένης αναζήτησης με τις προηγουμένως σχολιασμένες παρόμοιες έννοιες.

Το Info-PubMed παρέχει πληροφορίες από το Medline σχετικά με τις αλληλεπιδράσεις πρωτεΐνης-πρωτεΐνης. Δεδομένου του ονόματος ενός γονιδίου ή μιας πρωτεΐνης, εμφανίζει έναν κατάλογο με τα ονόματα άλλων γονιδίων/πρωτεϊνών που συναντώνται σε προτάσεις από το Medline, μαζί με τη συχνότητα της συνύπαρξης. Χρησιμοποιούνται τεχνικές εξαγωγής πληροφοριών για τον εντοπισμό ενός συνόλου προτάσεων που υποδεικνύουν σαφώς αλληλεπιδράσεις. Η διεπαφή χρήστη επιτρέπει τη συλλογή δηλώσεων με drag&drop και την οπτικοποίησή τους με τη χρήση εξωτερικού εργαλείου.

Το XplorMed (46) επιτρέπει στο χρήστη να εξερευνήσει ένα σύνολο περιλήψεων της Medline. Προσφέρονται τρία σημεία αναζήτησης: Medline, ένα σύνολο εγγράφων PMIDs ή μέσω μιας εγγραφής σε βάση δεδομένων με συσχετίσεις με τη Medline. Στη συνέχεια, το σύστημα ταξινομεί τις περιλήψεις με βάση την κορυφαία ιεραρχία των όρων MeSH που συνδέονται με κάθε καταχώρηση MEDLINE. Μπορούν να επιλεγούν μία ή περισσότερες κατηγορίες ανώτατου επιπέδου της MeSH. Τα συσχετιζόμενα άρθρα αναλύονται τώρα για λέξεις που σχετίζονται σημαντικά με άλλες σε αυτό το υποσύνολο άρθρων. Μια κύρια συνεισφορά του XplorMed είναι η λειτουργικότητα για τη διερεύνηση του λεξιλογίου που χρησιμοποιείται σε ένα σύνολο άρθρων. Μπορεί να οπτικοποιηθεί το πλαίσιο των εξέχουσων λέξεων από τις περιλήψεις. Πρόκειται για έναν κατάλογο άλλων λέξεων στα κείμενα που εμφανίζονται συχνά μαζί με αυτές τις λέξεις. Με βάση αυτή την ανάλυση, μπορούν να επιλεγούν αλυσίδες λέξεων, ένα διατεταγμένο σύνολο λέξεων όπου η 2η εξαρτάται από την 1η, η 3η εξαρτάται από τη 2η κ.ο.κ. Η επιλεγμένη αλυσίδα λέξεων μπορεί να χρησιμοποιηθεί για την επανακατάταξη των αρχικών παραπομπών Medline. Όσο περισσότερες αλυσιδωτές λέξεις εμφανίζονται σε μια περίληψη τόσο υψηλότερα κατατάσσεται. Οι συγγραφείς ισχυρίζονται ότι το XplorMed μπορεί να χρησιμοποιηθεί για σύνολα άρθρων για τα οποία ο χρήστης δεν γνωρίζει αρχικά τι να περιμένει. Αποκαλύπτεται εξέχον λεξιλόγιο, το οποίο χρησιμοποιείται αργότερα για την επανακατάταξη.

Το Information Hyperlinked over Proteins (33) είναι ένας δικτυακός τόπος που προσφέρει πλοήγηση μέσω υπερσυνδέσμων σε περιλήψεις του PubMed μέσω αναφορών γονιδίων/πρωτεϊνών σε προτάσεις. Κατά την αναζήτηση ο χρήστης λαμβάνει έναν κατάλογο προτάσεων που περιέχουν ταυτόχρονες αναφορές γονιδίων/πρωτεϊνών. Υποτίθεται ότι υπάρχει αλληλεπίδραση των ταυτόχρονων οντοτήτων και επισημαίνεται ο προβλεπόμενος τύπος της αλληλεπίδρασης. Σε περίπτωση ύπαρξης μεγάλης κλίμακας πειραματικών αποδείξεων μιας αλληλεπίδρασης, αυτό υποδεικνύεται επίσης με σύνδεσμο προς τα πειραματικά αποτελέσματα. Η αποσαφήνιση των ονομάτων γονιδίων/πρωτεϊνών είναι ένα δύσκολο έργο (60).

Το iHop επιτρέπει στους χρήστες να επαληθεύουν τα ευρήματά του, επισημαίνοντας τα ονόματα των οντοτήτων στις αρχικές προτάσεις. Έτσι, η έρευνα θα είναι σε θέση να επιβεβαιώσει τα ευρήματα. Υποδεικνύονται τρία επίπεδα εμπιστοσύνης του αλγορίθμου. Ο χρήστης μπορεί να δημιουργήσει γονιδιακές τροποποιήσεις επισυνάπτοντας αλληλεπιδράσεις γονιδίων/πρωτεϊνών σε μια γραφική αναπαράσταση. Ενώ το iHop είναι ένα εργαλείο ανάκτησης πληροφοριών, καθώς εμφανίζει προτάσεις της PubMed για αναφορές γονιδίων/πρωτεϊνών, επιπλέον αποσαφηνίζει τέτοιες οντότητες. Αυτό επιτρέπει μια σημασιολογική σύνδεση μεταξύ των προτάσεων και μέσω συνώνυμων ετικετών της ίδιας οντότητας. Επιπλέον, αυτό μπορεί να χρησιμοποιηθεί για τη δημιουργία δικτύων αλληλεπίδρασης χειροκίνητα ή αυτόματα. Αυτό είναι μια πιθανή πηγή νέων γνώσεων σε δεδομένα που έχουν ήδη δημοσιευθεί και ενδεχομένως υποστηρίζουν νέες υποθέσεις. Ως εκ τούτου, το iHop αναγνωρίζεται και ως εργαλείο ανάκτησης γνώσης.

Για μια επιλογή 105 θεμάτων, ο Expert Mapper υπολόγισε τους εξέχοντες συγγραφείς από τις αναφορές στο Medline των ετών 1997 έως 2006, ομαδοποιημένους σε γεωγραφικές περιοχές. Η κύρια συνεισφορά του Expert Mapper είναι η συσσώρευση πληροφοριών για την υπαγωγή ενός συγγραφέα, έτσι ώστε να είναι δυνατή μια λογική χειροκίνητη πρόβλεψη για την ταυτότητα ενός ατόμου.

Η Textpresso (41) είναι μια μηχανή αναζήτησης βασισμένη σε οντολογία, η οποία είναι κατασκευασμένη από επιστημονική βιβλιογραφία για το C. elegans και επιλεγμένους άλλους τομείς. Τα κείμενα ευρετηριάζονται με βιολογικές έννοιες και σχέσεις. Οι ετικέτες εμπίπτουν σε 33 κατηγορίες που αποτελούν την οντολογία Textpresso. Σε ένα δεύτερο επίπεδο η Textpresso διατηρεί περίπου 14.500 κανονικές εκφράσεις που αντιπροσωπεύουν γνωστές διατυπώσεις σχέσεων μιας γονικής κατηγορίας με άλλες οντότητες. Μια επιλογή άρθρων πλήρους κειμένου επιλεγμένων ειδών ευρετηριάζεται. Ο χρήστης μπορεί να ανακτήσει προτάσεις που αναφέρουν λέξεις-κλειδιά και έννοιες. Επί του παρόντος, ο κατάλογος περιλαμβάνει 101 έννοιες, ορισμένες από τις οποίες είναι γνωστές από τη Gene Ontol- ogy. Για κάθε κατηγορία η Textpresso διατηρεί έναν κατάλογο κανονικών εκφράσεων που χρησιμοποιούνται για την ευρετηρίαση των κειμένων. Η Textpresso μπορεί να ανακτήσει περιλήψεις που αναφέρουν ένα στάδιο ζωής στο C. elegans και ένα τμήμα του κυττάρου. Η ευρετηρίαση ενός άρθρου με μια έννοια απόγονο συνεπάγεται την ευρετηρίαση και με τις έννοιες πρόγονο. Κάθε έννοια στην οντολογία έχει τον δικό της αλγόριθμο ταυτοποίησης. Η Textpresso παρέχει δεκάδες χιλιάδες ευρετηριασμένα άρθρα που περιέχουν περισσότερα από 222.000 γεγονότα.

Το AliBaba (47) απεικονίζει το PubMed ως γράφημα. Αναλύει τις περιλήψεις του PubMed για βιολογικά αντικείμενα και τις σχέσεις τους, όπως αναφέρονται στα κείμενα. Το Ali Baba οπτικοποιεί το δίκτυο που προκύπτει σε γραφική μορφή, παρουσιάζοντας έτσι μια γρήγορη επισκόπηση όλων των πληροφοριών που περιέχονται στις περιλήψεις. Εντοπίζονται ποικίλες σχέσεις μεταξύ πρωτεϊνών, (υπο)κυτταρικών θέσεων, γονιδίων, φαρμάκων, ιστών, ασθενειών και άλλων. Οι σχέσεις που εξάγονται έχουν μια τιμή εμπιστοσύνης η οποία μπορεί να χρησιμοποιηθεί για το φιλτράρισμα λιγότερο πιθανών σωστών συσχετίσεων. Η διαδραστική γραφική αναπαράσταση επιτρέπει την ανθρώπινη ερμηνεία δεδομένων υψηλής διάστασης.

Ο Chilibot (13) αναζητά τις περιλήψεις του PubMed για συγκεκριμένες

σχέσεις μεταξύ πρωτεϊνών, γονιδίων ή λέξεων-κλειδιών. Ο χρήστης εισάγει έναν κατάλογο δύο ή περισσότερων γονιδίων ή άλλων λέξεων-κλειδιών. Το PubMed αναζητά αναφορές που αναφέρουν αυτές τις οντότητες ή ένα συνώνυμο σε μία πρόταση. Οι προτάσεις που προκύπτουν κατηγοριοποιούνται αργότερα σε έξι τύπους: (1) Αλληλεπιδραστική σχέση (διεγερτική), (2) Αλληλεπιδραστική σχέση (ανασταλτική),
(3) Διαδραστική σχέση (τόσο διεγερτική όσο και ανασταλτική), (4) Διαδραστική σχέση (ουδέτερη), (5) Μη διαδραστική (δηλαδή παράλληλη) σχέση και

(6) Μόνο αφηρημένη συνύπαρξη. Στη συνέχεια, οι σχέσεις απεικονίζονται σε ένα δισδιάστατο γράφημα με χρωματιστούς κόμβους και ακμές. Οι κόμβοι δηλώνουν τη βιολογική οντότητα ή τις λέξεις-κλειδιά και οι ακμές δηλώνουν τον παρατηρούμενο τύπο σχέσης και τον αριθμό της. Ο γράφος είναι υπερσυνδεδεμένος με το αρχικό σύνολο προτάσεων από το οποίο προέκυψαν οι σχέσεις. Ο χρήστης μπορεί να επιβεβαιώσει κάθε σχέση και να αφαιρέσει ψευδείς ακμές από το γράφημα. Ένα άλλο χαρακτηριστικό του Chilibot είναι η δημιουργία νέων υποθέσεων. Δύο κόμβοι που δεν συνδέονται άμεσα μεταξύ τους μπορούν να αναζητηθούν για τον σύνδεσμο που λείπει. Σχεδιάζεται ένας γράφος πιθανών έμμεσων αλληλεπιδράσεων. Η υπόθεση δημιουργείται με βάση τις κοινές συνδέσεις με άλλες οντότητες, οι οποίες κατασκευάζονται με βάση τη συσχέτιση, μια αρχή που χρησιμοποιήθηκε προηγουμένως σε μελέτες γονιδιακής λειτουργίας (50). Το PubGene (34) είναι παρόμοιο με το Chilibot, βασιζόμενο σε μη κατευθυνόμενες αλληλεπιδράσεις. Τα διαδικτυακά εργαλεία PubGene επιτρέπουν στους χρήστες να αναλύουν δεδομένα γονιδιακής έκφρασης με πληροφορίες βιβλιογραφικού δικτύου, να περιηγούνται σε βιβλιογραφικούς γείτονες ενός συγκεκριμένου γονιδίου, να αναζητούν βιβλιογραφικά άρθρα για ένα σύνολο γονιδίων, να αναζητούν όρους οντολογίας που σχετίζονται με ένα συγκεκριμένο γονίδιο, να αναζητούν όρους MeSH που βρέθηκαν με ένα σύνολο γονιδίων και αναζήτηση επίσημης ονοματολογίας.

Το Medstory[5] ομαδοποιεί τα στοιχεία των αποτελεσμάτων σε κατηγορίες. Οι κατηγορίες δείχνουν στους χρήστες πώς κατανέμονται τα αποτελέσματα. Κάθε κατηγορία προτείνει περαιτέρω θέματα. Η επιλογή των επιμέρους θεμάτων δίνει την επιλογή να ξεκινήσει μια νέα αναζήτηση με ένα περιορισμένο ερώτημα. Αναφέρονται οι κύριοι ερευνητές στην περιοχή. Το Medstory επικεντρώνεται στον μη ιατρικό εμπειρογνώμονα.

Περίληψη της σύγκρισης. Ο πίνακας 2 συνοψίζει τα χαρακτηριστικά όλων των συγκρινόμενων μηχανών αναζήτησης. Τα χαρακτηριστικά επιλέχθηκαν προκειμένου να αναδειχθούν οι διαφορετικές προσεγγίσεις των εργαλείων: (1) PubMed query expansion/refinement: επεκτείνει τις επικεφαλίδες MeSH και πρόσθετα λεξιλόγια όπως φάρμακα ή χημικά, μεταδεδομένα παραπομπών, (2) επεκτείνει τα ονόματα γονιδίων/πρωτεϊνών με συνώνυμα,
(3) προσφορά περιορισμού/επέκτασης με έννοιες οντολογίας, (4) γλωσσική μετάφραση των όρων, (5) διαχείριση πλήρων ερωτημάτων φυσικής γλώσσας, (6) υποβολή ερωτημάτων με άλλα έγγραφα/διασταυρωμένες παραπομπές σε βάσεις δεδομένων, (7) εναλλακτικό πλήρες κείμενο in- dex (Lucene/MySQL), (8) τελειοποίηση με βάση μεταδεδομένα που προκύπτουν από το αρχικό σύνολο αποτελεσμάτων, (9) μετα-αναζήτηση σε ξεχωριστές βάσεις δεδομένων, (10) τελειοποίηση με βάση λέξεις-κλειδιά που προκύπτουν από το αρχικό σύνολο αποτελεσμάτων, (11) παράκαμψη της κανονικής επέκτασης ερωτημάτων PubMed/ειδικών ερωτημάτων PubMed, (12) ειδικές οντότητες (γονίδια/πρωτεΐνες), (14) αναζήτηση στην UMLS, (15) αναζήτηση στην MeSH, (16) αναζήτηση στη γονιδιακή οντολογία, (17) περιήγηση εντός της ιεραρχίας της ταξινομίας/οντολογίας, (18) περιήγηση εντός εντοπισμένων εμφανίσεων κειμένου, (19) ιστορικό ερωτημάτων, (20) μόνιμος λογαριασμός χρήστη, (21) Ses- sion clipboard, (23) σύνδεσμοι στον τίτλο, (24) σύνδεσμοι στην περίληψη, (25) παρέχει εξωτερικούς συνδέσμους, (26) εμφανίζει PMID, (27) εμφανίζει πρόταση αποδεικτικών στοιχείων, (28) εμφανίζει snip- pets κειμένου, (29) καλεί εξωτερικές διαδικτυακές υπηρεσίες, (31) επισημαίνονται

λέξεις-κλειδιά από το ερώτημα,
(32) επισημανθείσες βιοϊατρικές οντότητες/σχέσεις, (33) επισημανθείσες οντολογικές συμπτώσεις που εντοπίστηκαν, (34) επισημανθείσα λεξιλογία (ετικέτες συστάδων/σημαντικές λέξεις),
(36) Επανακατάταξη με βάση τη σύμπτωση των λέξεων-κλειδιών, (37) Επανακατάταξη με βάση τη σύμπτωση των αναγνωρισμένων οντοτήτων, (38) Επανακατάταξη με βάση εξωτερικές αναφορές σε βάσεις δεδομένων ή προ-υπολογισμένα στατιστικά στοιχεία, (39) Γλωσσική δομή (π.χ. συμπερασματικές προτάσεις), (41) Ομοιότητα Cosin με βάση, (42) με βάση τη συν-συγγραφή, (43)

[5] medstory.com

Πίνακας 2. Σύγκριση μηχανών αναζήτησης βιοϊατρικής. Τα κύρια χαρακτηριστικά των εργαλείων σημειώνονται με έντονη γραφή.

	Ανάκτηση πληροφοριών									**Ανάκτηση γνώσης**									
	Ερώτηση στο				**Επεξεργασία αποτελεσμάτων**					**Εργαλείο Intgr.**			**Σημασιολογική επεξεργασία**						
Μηχανές αναζήτησης βιοϊατρικής	Μεταχηματισμός ερωτήματος	Εξερεύνηση των επιλεγμένων	Σύνδεση με το πρωτότυπο result	Σύνδεση με άλλα σχετικά έγγραφα	Αποδεικτικά στοιχεία που υποστηρίζουν	Επανακατάταξη	Σύνδεση με άλλα σχετικά έγγραφα	Πληροφορίες οργάνωση	Ειδικά χαρακτηριστικά	Ενιαία πειραματική επεξεργασία	Επεξεργασία partidas	Εξαγωγή partidas	Αναγνώριση οντοτήτων	Συνάνεση/ Σχέσεις	Αποσαφήνιση	Υποκατανάλωση/ Συλλογισμ	Περίληψη	Απάντηση ερώτησης	Διάλογος χρήστη	Υποθέσεις γενιά
PubMed	1	14, 15, 16	**20**, 21	23, 24, 25			41													
askMedline	5	15		23, 25			41													
PubMed Αλληλεπίδραση	1			23, 24, 25			41		50											
Γλωσσολόγος PICO	**4**			23, 24, 25			41													
BabelMesh	**4**			23, 24, 25			41		51											
Pubfinder	**6**		20	23, 24, 25			**41**													
ReleMed	7			23, 25	31	**36**														
PubMed PubReMiner	**8**			26				**47**												
ClusterMed	1			23, 24, 25	34	36		**44**												
BioMetaCluster	**9**			28	34			**44**												
PubFocus	1			23, 24		**38**	42	**47**			60									
HubMed	7, 10		21	23, 24, 25, **29**	32, 33	36	**41**	**48**	52	57	59	63, 64, 65	67, 68, 69							
BioIE	1			26, 27	31			**47**						72						
CiteXplore	2, **7**		19	23, 24, 25, 26	32, 33		43			57		64, 65	67, 68	72	74					
iHOP	2, 7	**18**	20	25, 26, 27	**32**	**37, 38**		46			60		67	72			83, 84			
Info-PubMed	12		20	26, 27	**32**			46, 47, 48	55				67	72					90	
EBIMed				24, 25, 26, 27				47		57			67, 68	72			83			
GoPubMed	1, 2, 3, 8	15, 16, **17**	19, 21	23, 24, 25	31, **33**	36, 37	41	**45**				62, 63, 64, 65	67, 68, 69	71, 72	74, **76**		81, 82		89	
AliBaba	1	18		25, 26, 27	32			**46**, 49			58		67	72	**75**	**78**			90	
XplorMed	6			23, 25	34	**36**		**44**			58			72						
GOAnnotator	12			23, 26		**38**		47			58, 60		**68**	72		78				
Textpresso		17		23, 24, 25	34	36	41		53			62, 65	67, **68**	72						
Chilibot	11		20	27	31, 32	39		46, 49	54				67	**72**			**84**		90	**92**

μέσω του ονόματος του συγγραφέα, (44) ιεραρχική ταξινόμηση με βάση μετρικές απόστασης,
(45) ιεραρχική ταξινόμηση με χρήση ταξινομιών/οντολογιών, (46) 2D γράφος εννοιών, (47) στατιστικές σε μορφή πίνακα, (48) κλήση εξωτερικής υπηρεσίας, (50) γραφικές διαφάνειες, (51) επικοινωνία μέσω ηλεκτρονικού ταχυδρομείου, (52) κοινωνική σήμανση, (53) ειδική γλώσσα ερωτημάτων,
(54) επεξεργασία κατά δέσμες, (55) γραφικό περιβάλλον drag&drop, (57) εξωτερικό εργαλείο σήμανσης, (58) εισαγωγή βιβλιογραφικών αναφορών από επιμελήσεις εξωτερικών βάσεων δεδομένων, (59) οπτικοποίηση με χρήση εξωτερικού εργαλείου, (60) χρήση εξωτερικών πειραματικών μεταδεδομένων

μεγάλης κλίμακας,

(62) XML, (63) RDF, (64) BibTex, (65) Endnote (RIS), (67) βιοϊατρικά στοιχεία (π.χ. γονίδια/πρωτεΐνες), (68) ορολογία ταξινομίας/οντολογίας, (69) ορολογία Wikipedia, (71) εντός περιλήψεων, (72) εντός προτάσεων, (74) αποσαφήνιση για βιο-εντολές, (75) αποσαφήνιση για ορολογία ταξινομίας/οντολογίας, (76) αποσαφήνιση για συγγραφείς, (78) is-a γενίκευση, (80) σημαντικές συμβολοσειρές, (81) σημαντικές έννοιες ταξινομίας/οντολογίας, (82) προφίλ εμπειρογνωμόνων, (83) σημαντικές βιο-οντότητες, (84) σύνοψη κειμένου, (87) ρητή απάντηση ερωτήσεων, (89) κατηγορίες ερωτήσεων, (90) γραφική αλληλεπίδραση, (92) ρητή παραγωγή υποθέσεων.

Ο πίνακας 2 δείχνει ότι οι περισσότερες βιοϊατρικές μηχανές αναζήτησης παρέχουν ήδη εκτεταμένη λειτουργικότητα για την Ανάκτηση Πληροφοριών, ενώ μόνο οι μισές από αυτές παρέχουν κάποια υποστήριξη για την Ανάκτηση Γνώσης. Οι βιοεπιστήμες είναι πρώτοι που υιοθετούν τις σημασιολογικές τεχνολογίες. Ορισμένες βιοϊατρικές μηχανές αναζήτησης προσφέρουν λειτουργικότητα για τη σημασιολογική επεξεργασία των αποτελεσμάτων προκειμένου να παρέχουν πιο συμπυκνωμένα ή πιο συναφή αποτελέσματα στο χρήστη. Η αναγνώριση οντοτήτων και η ανάλυση συνεμφάνισης υποστηρίζονται ευρύτερα. Το υπόβαθρο γνώσης των οντολογιών δεν χρησιμοποιείται ακόμη ευρέως.

7.1.3 Το παράδειγμα αναζήτησης με βάση την οντολογία

Η βάση μιας σημασιολογικής μηχανής αναζήτησης είναι η υποκείμενη ειδική εμπειρογνωμοσύνη. Η γνώση αυτή αποτυπώνεται σε μία ή περισσότερες οντολογίες. Σε αντίθεση με την κλασική αναζήτηση με λέξεις-κλειδιά, τα αποτελέσματα δεν παρουσιάζονται ως μακρύς ταξινομημένος κατάλογος εγγράφων αλλά ως ιεραρχικό ευρετήριο. Οι έννοιες που ορίζονται στις οντολογίες προσδιορίζονται στο κείμενο κάθε εγγράφου. Αυτή η φάση αντιστοίχισης είναι σαφώς η πιο κρίσιμη για την ποιότητα των αποτελεσμάτων. Απαιτούνται αποτελεσματικοί αλγόριθμοι αναγνώρισης εννοιών για να αντιμετωπίσουν τη διαφορετική μορφολογία και σύνταξη των ετικετών των εννοιών. Ένα άλλο σημαντικό ζήτημα είναι η αποσαφήνιση του νοήματος λέξης, καθώς οι ετικέτες εννοιών μπορεί να έχουν διαφορετικό νόημα σε διαφορετικά περιβάλλοντα (2).

Μετά την αντιστοίχιση των εγγράφων με τις έννοιες που αναφέρονται στο κείμενο υπολογίζεται ένα hi- erachical index, το οποίο ονομάζεται επαγόμενη οντολογία (induced ontology). Η ιδέα είναι να υπολογιστεί ένας γράφος ο οποίος συνδέει όλες τις έννοιες που βρίσκονται στα σχόλια των ανακτηθέντων εγγράφων με την πιο γενική έννοια που έχει οριστεί, τη ρίζα της οντολογίας. Στην επαγόμενη οντολογία περιλαμβάνονται όλες οι έννοιες της γνώσης υποβάθρου που αποτελούν μέρος μιας διαδρομής από μια σχολιασμένη έννοια μέχρι τη ρίζα. Ο γράφος περιέχει πολλαπλές περιπτώσεις εννοιών που έχουν περισσότερες από μία γονικές έννοιες. Το σύνολο των εννοιών Θ που αντιπροσωπεύεται από την επαγόμενη οντολογία μπορεί να οριστεί ως εξής:

$$\Theta = \bigcup_{1..d} \bigcup_{1..a(i)} \bigcup^{t} \bigcup \text{πρόγονοι}(O, \text{έννοια}(i, t)) \quad (1)$$

όπου d είναι ο αριθμός των εγγράφων ενός συνόλου αποτελεσμάτων και $a(i)$ είναι ο αριθμός των σχολίων σε ένα έγγραφο. Η συνάρτηση *concept* επιστρέφει την έννοια της οντολογίας που σχετίζεται με ένα σχολιασμό εγγράφου και η συνάρτηση *ancestors* επιστρέφει το σύνολο των εννοιών που σχετίζονται μεταβατικά με τη δεδομένη έννοια στην οντολογία O.

Ο ακυκλικός γράφος που προκύπτει λειτουργεί ως "πίνακας περιεχομένων" για τα αποτελέσματα της αναζήτησης. Ο χρήστης μπορεί να εξερευνήσει το γράφημα. Σε οποιοδήποτε επίπεδο μπορεί να επιλεγεί μια έννοια. Τα έγγραφα που σχετίζονται με αυτόν τον κόμβο είναι μόνο εκείνα που αναφέρουν την έννοια ή μια απόγονη έννοια ή ένα συνώνυμο. Στην Εικόνα 2 παρουσιάζεται ένα παράδειγμα μιας επαγόμενης οντολογίας για ένα ερώτημα στο PubMed με χρήση της MeSH και της γονιδιακής οντολογίας ως γνώσης υποβάθρου.

Εκτός από το κλασικό παράδειγμα αναζήτησης με βάση λέξεις-κλειδιά και το παράδειγμα αναζήτησης με βάση οντολογίες, υπάρχει και το παράδειγμα που βασίζεται στην επεξεργασία φυσικής γλώσσας. Μια μηχανή αναζήτησης NLP τελευταίας τεχνολογίας που δημιουργήθηκε πρόσφατα είναι η Powerset[6]. Χρησιμοποιεί τη γνώση υποβάθρου της Wikipedia για να απαντήσει σε ερωτήσεις πλήρους πρότασης. Το Powerset αναλύει το σώμα εγγράφων χρησιμοποιώντας τεχνικές επεξεργασίας φυσικής γλώσσας. Ο χρήστης εισάγει μια πλήρη ερώτηση και το σύστημα απαντά με έναν κατάλογο πιθανών απαντήσεων με τη μορφή αποσπασμάτων κειμένου από τη Wikipedia. Η γνώση υποβάθρου που χρησιμοποιείται είναι αποθηκευμένη σε κείμενο φυσικής γλώσσας και όχι σε δομημένες οντολογίες. Ο χρήστης πρέπει να είναι σε θέση να διατυπώσει μια ερώτηση που περιέχει αρκετές πληροφορίες ώστε το σύστημα να βρει σχετικές απαντήσεις και το σύστημα πρέπει να είναι σε θέση να αναλύσει σωστά την πρόταση. Συχνά είναι δύσκολο για τον χρήστη να διατυπώσει μια ακριβή ερώτηση και συχνά είναι ακόμη πιο δύσκολο για τον αναλυτή να κατανοήσει μια σύνθετη ερώτηση.

Στο Σχήμα 3 παρουσιάζονται τα παραδείγματα που βασίζονται σε λέξεις-κλειδιά και σε φυσική γλώσσα σε σχέση με το παράδειγμα που βασίζεται στην οντολογία. Οι απαντήσεις των αναζητήσεων που βασίζονται σε λέξεις-κλειδιά και NLP είναι συνήθως μεμονωμένα έγγραφα, ενώ οι αναζητήσεις που βασίζονται στην οντολογία προσφέρουν ένα περίγραμμα όλων των σχετικών εγγράφων. Οι αναζητήσεις με βάση το NLP και την οντολογία χρησιμοποιούν σημασιολογικές τεχνολογίες για τη δόμηση του κειμένου, ενώ η αναζήτηση με βάση τις λέξεις-κλειδιά βασίζεται σε n-grams χαρακτήρων. Οι αναζητήσεις βάσει λέξεων-κλειδιών και οντολογίας λαμβάνουν ως είσοδο φράσεις λέξεων, ενώ η αναζήτηση βάσει NLP λαμβάνει ως είσοδο πλήρεις ερωτήσεις.

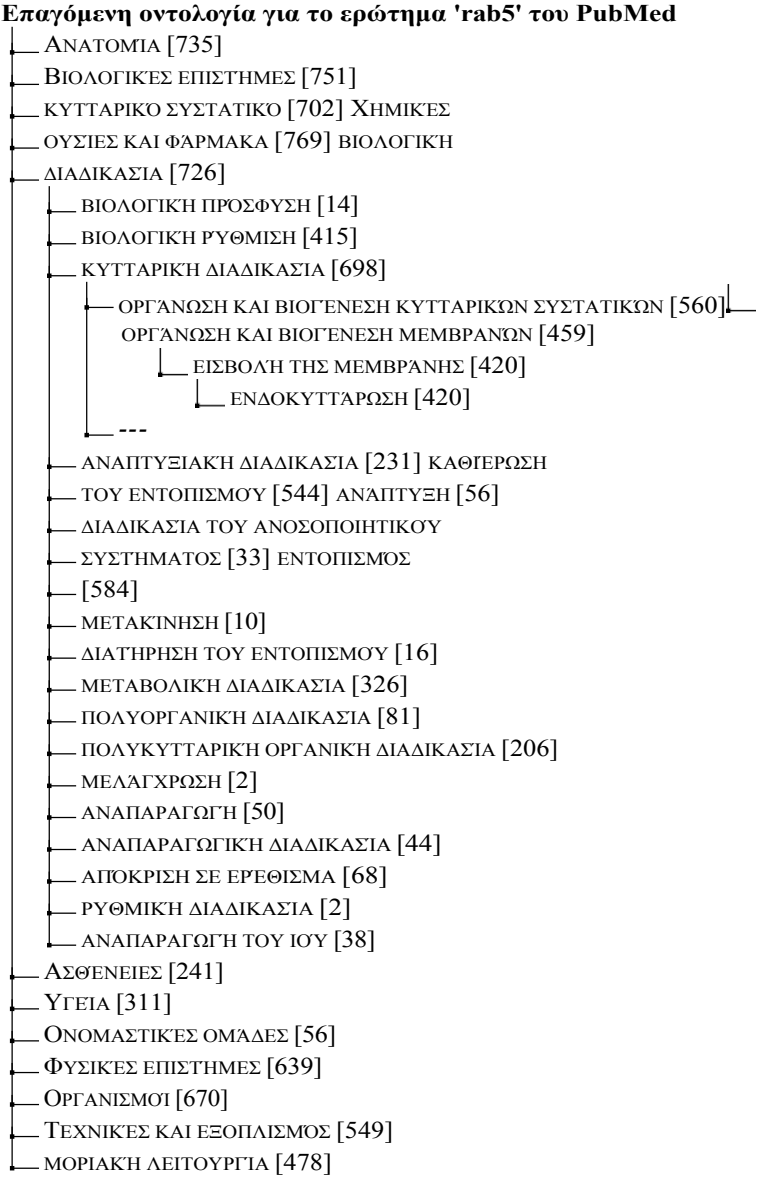
7.2 Απάντηση σε βιοϊατρικές ερωτήσεις

Όταν οι χρήστες κάνουν αναζήτηση έχουν ερωτήσεις στο μυαλό τους. Η απάντηση σε ερωτήσεις σε έναν τομέα απαιτεί τη γνώση της ορολογίας του εν λόγω τομέα. Οι κλασικές προσεγγίσεις αναζήτησης δεν κάνουν χρήση της γνώσης υποβάθρου κατά την αναζήτηση. Αυτή η ενότητα περιγράφει την προσέγγιση του GoPubMed για τη χρήση οντολογικής γνώσης υποβάθρου κατά την εξόρυξη ενός σώματος βιβλιογραφίας για την απάντηση βιοϊατρικών ερωτήσεων. Αποδεικνύεται ότι η γνώση υποβάθρου μπορεί να χρησιμοποιηθεί για την εύρεση πιο σχετικών εγγράφων και για την οργάνωση των αποτελεσμάτων ώστε να εστιάζεται σε σημαντικές πτυχές. Μια πτυχή είναι ένα σύνολο παρόμοιων δηλώσεων, π.χ. ένα σύνολο προτάσεων που περιγράφουν τη σχέση μεταξύ μιας ασθένειας και ενός φαρμάκου. Ο στόχος είναι να απαντηθούν βιοϊατρικά ερωτήματα με την ελάχιστη δυνατή αλληλεπίδραση του χρήστη.

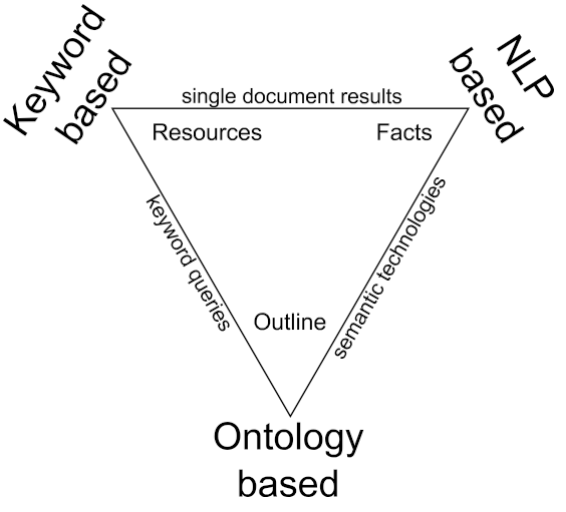
Ο στόχος των συστημάτων ανάκτησης πληροφοριών είναι η μεγιστοποίηση της ακρίβειας των αποτελεσμάτων, ελαχιστοποιώντας τον αριθμό των άσχετων εγγράφων που παρουσιάζονται στον χρήστη, και η μεγιστοποίηση της ανάκλησης, ελαχιστοποιώντας τον αριθμό των σχετικών εγγράφων που χάθηκαν.

Μετά την ανάκτηση των σχετικών εγγράφων, ο χρήστης ενδιαφέρεται να συλλέξει συγκεκριμένες πληροφορίες από τα έγγραφα. Τελικά ο χρήστης θέλει να απαντήσει σε μια ερώτηση

[6] powerset.com



Σχήμα 2. Αυτό το σχήμα δείχνει την επαγόμενη οντολογία για το αποτέλεσμα του PubMed στο ερώτημα *"rab5"*. Οι κατηγορίες κορυφαίου επιπέδου MeSH και GO είναι αλφαβητικά ταξινομημένες. Ο κλάδος GO CELLULAR PROCESS επεκτείνεται στην έννοια ENDOCYTOSIS, το θέμα pro- cess πιο εντατικά για την πρωτεΐνη. Η επαγόμενη οντολογία δείχνει 16 άλλες βιολογικές διεργασίες που σχετίζονται με την πρωτεΐνη rab5. Οι αριθμοί δηλώνουν την ποσότητα των συνδεδεμένων εγγράφων.



Σχήμα 3. Τρία παραδείγματα αναζήτησης. Η αναζήτηση με βάση λέξεις-κλειδιά και η αναζήτηση με βάση οντολογία δέχονται ως είσοδο ερωτήματα με λέξεις-κλειδιά, ενώ η αναζήτηση με βάση NLP δέχεται ως είσοδο πλήρεις προτάσεις ερωτήσεων. Η αναζήτηση με βάση το NLP και τις λέξεις-κλειδιά επιστρέφει μεμονωμένα έγγραφα ως αποτελέσματα, ενώ η αναζήτηση με βάση την οντολογία επιστρέφει ένα γράφημα που μπορεί να χρησιμοποιηθεί ως περίγραμμα των αποτελεσμάτων αναζήτησης. Η αναζήτηση με βάση την οντολογία και το NLP χρησιμοποιεί σημασιολογικές τεχνολογίες για να αντιστοιχίσει έγγραφα ή τμήματα εγγράφων σε τυπικά καθορισμένη γνώση υποβάθρου. Η αναζήτηση με βάση λέξεις-κλειδιά επιστρέφει καταλόγους πόρων, π.χ. καταλόγους διευθύνσεων URL. Η αναζήτηση με βάση το NLP επιστρέφει γεγονότα ως απαντήσεις σε ερωτήσεις, π.χ. την απόσταση μεταξύ δύο πόλεων. Η αναζήτηση με βάση την οντολογία επιστρέφει ένα περίγραμμα σε ένα δυνητικά πολύ μεγάλο σύνολο αποτελεσμάτων. Το περίγραμμα οργανώνει τα έγγραφα που προκύπτουν ιεραρχικά σύμφωνα με τα αναγνωρισμένα θέματα.

και έτσι να αποκτήσουν γνώση. Η ιδέα είναι η οργάνωση των αποτελεσμάτων αναζήτησης με τη χρήση της δομημένης γνώσης υποβάθρου των οντολογιών, έτσι ώστε η πρόθεσή της να είναι χρήσιμη .

7.2.1 Χαρακτηρισμός των τύπων ερωτήσεων

Ο χρήστης μπορεί να περιμένει απαντήσεις μόνο σε ερωτήσεις που καλύπτονται από αποσπάσματα κειμένου από τα έγγραφα ή από τις καθορισμένες έννοιες της γνώσης υποβάθρου. Θεωρείται ότι η γνώση υποβάθρου και το σώμα εγγράφων αφορούν τον ίδιο τομέα. Οι απαντήσεις σε ερωτήσεις που είναι σύντομα αποσπάσματα κειμένου από περιλήψεις βιβλιογραφίας ονομάζονται απαντήσεις παραπομπών, οι απαντήσεις που μπορούν να δοθούν με τη μορφή συλλογής εννοιών οντολογίας και των ορισμών τους ονομάζονται απαντήσεις γλωσσαρίου. Η ιδέα και στις δύο περιπτώσεις είναι η συλλογιστική πάνω στις σχέσεις που αποτυπώνονται στη γνώση υποβάθρου για να απαντηθούν οι ερωτήσεις.

Απαντήσεις για την παραπομπή. Για παράδειγμα, ο χρήστης θέλει να μάθει πώς λειτουργεί η ασπιρίνη. Είναι δυνατόν να απαντηθεί αυτή η ερώτηση παρέχοντας

μία ή περισσότερες δηλώσεις, εάν το σώμα κειμένων περιέχει έγγραφα που αναφέρουν το φάρμακο και μια επαρκή έννοια της

τη γνώση υποβάθρου σε εγγύτητα. Ο χρήστης δεν χρειάζεται να γνωρίζει αυτή την έννοια ούτε τα συνώνυμά της. Το σημείο εισόδου για την απάντηση της ερώτησης θα είναι οι κατηγορίες της γνώσης υποβάθρου. Κάθε επίπεδο της ιεραρχικά δομημένης γνώσης περιλαμβάνει πιθανές απαντήσεις. Όσο πιο εξοικειωμένος είναι ο χρήστης με τον τομέα τόσο βαθύτερα μπορεί να επιλέξει ένα σημείο εισόδου.

Ένα πιθανό σενάριο για την απάντηση της ερώτησης είναι το εξής: ο χρήστης στέλνει στο σύστημα τη λέξη-κλειδί *"ασπιρίνη"*. Το σύστημα εμφανίζει έναν πίνακα περιεχομένου που περιλαμβάνει αναγνωρισμένες έννοιες στα έγγραφα που ανακτήθηκαν. Ο χρήστης επιλέγει μια κατάλληλη έννοια μεταξύ των εμφανιζόμενων κατηγοριών στον πίνακα περιεχομένου. Μια κατάλληλη έννοια για να απαντηθεί το παραπάνω ερώτημα είναι η ΒΙΟΛΟΓΙΚΉ ΔΙΑΔΙΚΑΣΊΑ, μια μάλλον γενική έννοια στον τομέα της βιοϊατρικής. Οι χρήστες που είναι εξοικειωμένοι με τον βιοϊατρικό τομέα μπορούν να επιλέξουν μια πιο συγκεκριμένη έννοια, όπως η ΡΥΘΜΙΣΗ ΤΗΣ ΚΥΤΤΑΡΙΚΉΣ ΜΕΤΑΒΟΛΙΚΉΣ ΔΙΑΔΙΚΑΣΊΑΣ. Το σύστημα εμφανίζει τώρα επισημασμένα αποσπάσματα κειμένου που αναφέρουν τη λέξη-κλειδί και τις επιλεγμένες έννοιες και τους απογόνους τους. Τα πιθανά αποτελέσματα για την παραπάνω ερώτηση είναι τα εξής:

> *Η ασπιρίνη ασκεί τις μοναδικές φαρμακολογικές της επιδράσεις με τη μη αναστρέψιμη ακετυλίωση ενός υπολείμματος σερίνης στην περιοχή της κυκλοοξυγενάσης των προσταγλανδιν-Η(2)-συντάξεων (PGHSs) (PMID: 18242581).*
>
> *Η ασπιρίνη που χορηγεί ΝΟ αναστέλλει την ενεργοποίηση του NF-kappaB σε ανθρώπινες καρκινικές κυτταρικές σειρές και σε ποντίκια Min. (PMID: 18174252)*

Στο πρώτο πέρασμα αναφέρεται η ΚΥΚΛΟΟΞΥΓΕΝΆΣΗ (ΜΟΝΟΠΆΤΙ), μια βιολογική διεργασία. Στο δεύτερο πέρασμα αναφέρεται η ΕΝΕΡΓΟΠΟΊΗΣΗ ΤΟΥ NF-KAPPAB, μια ρυθμιστική διαδικασία στο κύτταρο. Η ασπιρίνη έχει διάφορες επιδράσεις στις βιολογικές διαδικασίες ενός οργανισμού. Και οι δύο απαντήσεις αντιπροσωπεύουν σωστές και χρήσιμες απαντήσεις για διαφορετικά ακροατήρια ανάλογα με το υπόβαθρό τους.

Glossary Answers. Ένας χρήστης ενδιαφέρεται να μάθει ποιες ασθένειες σχετίζονται με έναν γνωστό ιό. Σε αυτό το σενάριο, τα έγγραφα με αναφορές οποιασδήποτε ασθένειας κοντά στον ιό είναι σχετικά. Η απάντηση στην ερώτηση θα ήταν ένας κατάλογος ασθενειών που συνδέεται με τα αποσπάσματα κειμένου που δηλώνουν τη σχέση με τον ιό. Η απάντηση θα μπορούσε να είναι ένας ταξινομημένος κατάλογος ασθενειών ταξινομημένος με βάση τη συχνότητα συνύπαρξης στη βιβλιογραφία.

Για το ερώτημα *"HIV"* ένα σύστημα μπορεί να εντοπίσει το ακόλουθο απόσπασμα σε μια δημοσίευση:

> *Επιπολασμός ορών ηπατίτιδας Β, C και ιών δέλτα σε ασθενείς με HIV-1 από τη Σενεγάλη κατά την έναρξη της HAART (αναδρομική μελέτη). (PMID: 18551596)*

Η ΗΠΑΤΙΤΙΔΑ είναι μια ασθένεια που ορίζεται στην ορολογία MeSH. Η MeSH

ορίζει 6527 απογόνους της έννοιας ΑΣΘΈΝΕΙΑ. Η παραπομπή δείχνει μια στενή σχέση μεταξύ της λοίμωξης HIV και αυτής της νόσου.

Στην ενότητα που ακολουθεί περιγράφονται αλγόριθμοι που αναπτύχθηκαν για την εύρεση απαντήσεων σε βιοϊατρικά ερωτήματα με βάση ένα σημασιολογικά σχολιασμένο σώμα βιβλιογραφίας με χρήση οντολογικής γνώσης υποβάθρου.

Βιβλιομετρικές απαντήσεις. Ένας άλλος τύπος ερωτήσεων αφορά την εκδοτική συμπεριφορά σε ένα επιλεγμένο ερευνητικό πεδίο. Τα ερωτήματα κατά πόσον ένα θέμα αποτελεί ενεργό πεδίο αναζήτησης και ποιοι συγγραφείς είναι οι πιο εξέχοντες σε ένα πεδίο μπορούν να απαντηθούν μόνο με ολόκληρο το σώμα της βιβλιογραφίας. Το πρόβλημα είναι ότι δεν υπάρχει κοινό λεξιλόγιο που να χρησιμοποιείται από τους ερευνητές. Η ορολογία που χρησιμοποιείται διαφέρει ανάλογα με το χρόνο και τις γεωγραφικές τοποθεσίες. Στην ενότητα 7.3 παρουσιάζεται πώς η αναζήτηση βάσει οντολογίας μπορεί να απαντήσει σε βιβλιομετρικά ερωτήματα.

7.2.2 Χρήση γνώσεων ιστορικού για την απάντηση σε ερωτήσεις

Το TREC Genomics Track 2006 (30) είναι μια ετήσια δραστηριότητα της κοινότητας της ανάκτησης πληροφοριών με στόχο την αξιολόγηση συστημάτων και χρηστών. Για την αξιολόγηση των μηχανών αναζήτησης βιοϊατρικής αναπτύχθηκε μια νέα ενιαία εργασία που επικεντρώθηκε στην ανάκτηση αποσπασμάτων (από μέρος έως πρόταση έως παράγραφο σε μήκος) με σύνδεση με το αρχικό έγγραφο. Τα θέματα εκφράζονται ως ερωτήσεις και τα συστήματα μετρήθηκαν ως προς το πόσο καλά ανακτούν σχετικές πληροφορίες σε επίπεδο αποσπάσματος, πτυχής και εγγράφου. Τα συμμετέχοντα συστήματα επέστρεψαν αποσπάσματα που συνδέονταν με τα έγγραφα της πηγής. Οι κριτές βαθμολόγησαν τα επιστρεφόμενα αποσπάσματα και τα ομαδοποίησαν ανά πτυχή.

Οι ακόλουθες ερωτήσεις του TREC Genomics Track 2006 απαντήθηκαν με τη χρήση του GoPubMed. Υπήρχαν τρεις τύποι ερωτημάτων: (1) ερωτήσεις για το ρόλο ενός γονιδίου ή μιας πρωτεΐνης σε μια ασθένεια, (2) τη διασύνδεση βιολογικών οντοτήτων και
(3) η βιολογική λειτουργία μιας οντότητας.

Για τον πρώτο τύπο ερωτήσεων, οι λέξεις-κλειδιά του ερωτήματος ήταν το όνομα της πρωτεΐνης ή τα συνώνυμα, εφόσον παρέχονται από τον αλγόριθμο που περιγράφεται στο (28), ο οποίος υλοποιείται στο GoPubMed. Στη συνέχεια, κάνοντας κλικ στην επαγόμενη οντολογία στην αντίστοιχη ασθένεια σαρώνονται τα συνδεδεμένα έγγραφα που κατατάσσονται σύμφωνα με την πτυχή. Μόνο τα σωστά τεκμήρια στην πρώτη σελίδα των απαντήσεων λήφθηκαν υπόψη.

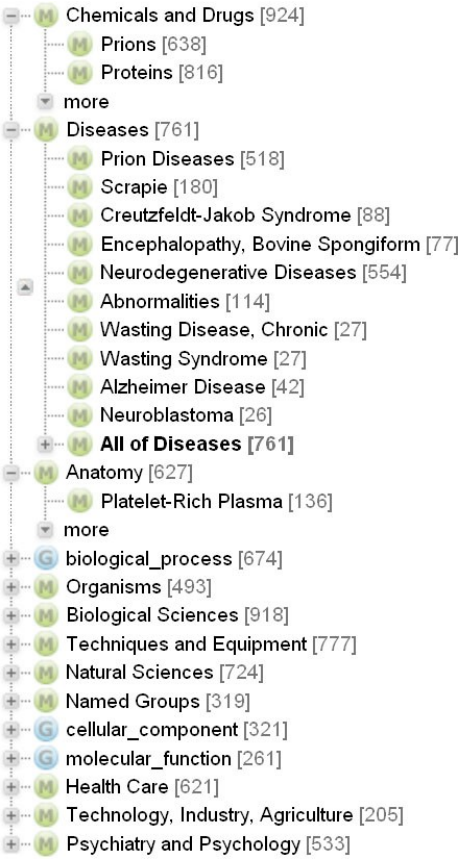
Για τον δεύτερο τύπο ερωτήσεων, οι δύο οντότητες και τα συνώνυμά τους εισήχθησαν ως λέξεις-κλειδιά και οι απαντήσεις από τις κορυφαίες κατηγορίες λήφθηκαν υπόψη. Οι κορυφαίες κατηγορίες υπολογίστηκαν με κατάταξη "tf-idf".

Για τον τρίτο τύπο ερωτήσεων, η βιολογική οντότητα εισήχθη ως συμβολοσειρά ερωτήματος και η αντίστοιχη βιολογική λειτουργία επιλέχθηκε στην οντολογία. Και πάλι λήφθηκαν υπόψη μόνο οι απαντήσεις που δόθηκαν στην πρώτη σελίδα. Οι ερωτήσεις TREC όλων των ετών είναι αριθμημένες. Οι ερωτήσεις του έτους 2006 αρχίζουν με 160 και τελειώνουν με 187.

Ρόλοι των γονιδίων και των πρωτεϊνών στις ασθένειες: Ποιος είναι ο ρόλος της PrnP στη νόσο των τρελών αγελάδων; (TREC #160). "*Από το 2004, έχουν αναφερθεί σημαντικές συσχετίσεις μεταξύ της ευαισθησίας στη σπογγώδη εγκεφαλοπάθεια των βοοειδών (ΣΕΒ) στα βοοειδή και των συχνοτήτων πολυμορφισμών εισαγωγής/διαγραφής (ins/del- indel) εντός του*

γονιδίου της πρωτεΐνης πρίον των βοοειδών (PRNP). PMID: 18399944"

Το GoPubMed παρουσιάζει αυτή την απάντηση μετά από αναζήτηση για *"PrnP"* ακολουθούμενη από δύο διαισθητικά κλικ: (1) Η PrnP είναι μια πρωτεΐνη, οπότε χρησιμοποιούμε την επέκταση του ονόματος της πρωτεΐνης κάνοντας κλικ στην επιλογή: *"Expand your query with synonyms for PrnP"*. (2) Ο κλάδος των ασθενειών του MeSH παραθέτει την επίσημη ονομασία μεταξύ των κορυφαίων εννοιών, ENCEPHALOPA- THY, BOVINE SPONGIFORM. Στην εικόνα 4 παρουσιάζεται η επαγόμενη οντολογία για το ερώτημα

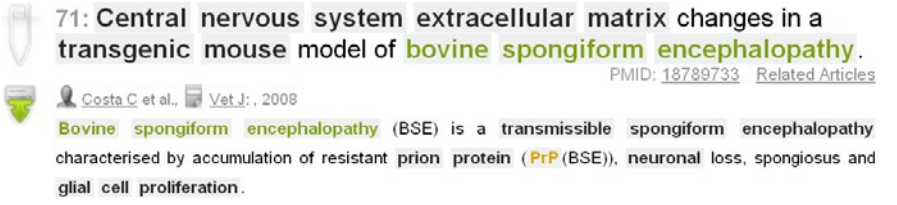


Σχήμα 4. Αυτό το στιγμιότυπο οθόνης δείχνει την επαγόμενη οντολογία για το ερώτημα *"PrnP"* στο GoP- ubMed. Επιλέγεται η "ENCEPHALOPATHY, BOVINE SPONGIFORM", η επίσημη ονομασία για τη "νόσο των τρελών αγελάδων". Συνδέεται με 77 δημοσιεύσεις στο PubMed. Επιπλέον, το SCRAPIE, το ΣΥΝΔΡΟΜΟ CREUTZFELDT-JAKOB και άλλες ασθένειες παρατίθενται στον κλάδο των ασθενειών του MeSH.

"PrnP". Η ασθένεια ENCEPHALOPATHY, BOVINE SPONGIFORM, ή αλλιώς Mad Cow Disease, συνδέσεις με 77 δημοσιεύσεις που αναφέρουν την ασθένεια και την PrnP. Η εικόνα 5 δείχνει πώς το GoPubMed απεικονίζει τα έγγραφα στη λειτουργία snippet, εμφανίζοντας μια πρόταση που αναφέρει τη λέξη-κλειδί και τον επιλεγμένο όρο ή έναν απόγονο.

Το μέτρο σύγκρισης TREC απαριθμεί 32 απαντήσεις που αναφέρουν μια μετάλλαξη στην PrnP που παίζει ρόλο στη νόσο των τρελών αγελάδων. Αυτό δείχνει ότι η σημαντική πτυχή, οι μεταλλαγμένες παραλλαγές του PrnP σχετίζονται με τη νόσο των τρελών αγελάδων, μπορεί να βρεθεί με μια απλή αναζήτηση στο GoPubMed. Τρεις διαισθητικές αλληλεπιδράσεις του χρήστη. Η επαγόμενη οντολογία κατέχει απαντήσεις για πολλές ακόμη πτυχές που σχετίζονται με το θέμα. Για παράδειγμα, συνδέει 91 δημοσιεύσεις με μια συναφή ασθένεια στον άνθρωπο ΤΟ ΣΥΝΔΡΟΜΟ CREUTZFELDT-JAKOB και ΤΟ

SCRAPIE μια θανατηφόρα ασθένεια του νευρικού συστήματος στα αιγοπρόβατα, 185 συνδέσεις.



Σχήμα 5. Αυτό το στιγμιότυπο οθόνης δείχνει το πρώτο απόσπασμα κειμένου που βλέπει ο χρήστης όταν κάνει κλικ στο ENCEPHALOPATHY, BOVINE SPONGIFORM. Η λέξη-κλειδί *"PrP"* είναι συνώνυμο του *"PrnP"* και επισημαίνεται με κίτρινο χρώμα. Το συνώνυμο της νόσου, BOVINE SPONGIFORM EN- CEPHALOPATHY, επισημαίνεται με πράσινο χρώμα. Το απόσπασμα κατατάσσεται στην υψηλότερη θέση επειδή πρόκειται για πρόσφατη δημοσίευση καθώς και επειδή η λέξη-κλειδί και η έννοια αναφέρονται στην ίδια πρόταση.

Αυτό δείχνει ένα σημαντικό πλεονέκτημα της αναζήτησης με βάση την οντολογία: την αναζήτηση με βάση την τύχη και την επισκόπηση. Η γνώση υποβάθρου παρέχει μια περίληψη του συνολικού περιεχομένου των αποτελεσμάτων αναζήτησης.

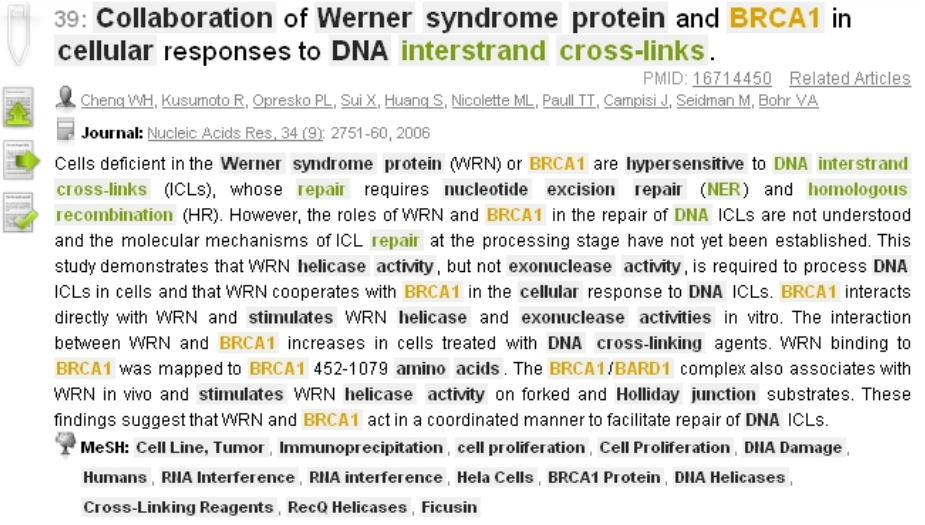
Η αλληλεπίδραση των βιολογικών οντοτήτων: Πώς ρυθμίζει η BARD1 τη δραστηριότητα της BRCA1; (TREC #168). " *Το BARD1 ρυθμίζει τη διαμεσολαβούμενη από το BRCA1 τρανσακτιβισμό των υποκινητών p21(WAF1/CIP1) και Gadd45. (PMID: 18243530)*"

Το GoPubMed παρουσιάζει τον τίτλο αυτής της δημοσίευσης ως απάντηση μετά από αναζήτηση για *"BRCA1 AND BARD1"* και ένα κλικ στην επιλογή *"Expand your query with synonyms for BRCA1, BARD1"*. Το τρίτο απόσπασμα κειμένου αναφέρει σαφώς τη διασύνδεση των δύο πρωτεϊνών. Το GoPubMed εμφανίζει εξ ορισμού όχι ολόκληρη την περίληψη. Επιλέγεται μία πρόταση ως απόσπασμα κειμένου που αναφέρει λέξεις-κλειδιά και έννοιες. Σε αυτό το παράδειγμα δεν επιλέχθηκε καμία έννοια, αλλά οι δύο λέξεις-κλειδιά αναφέρονται στα αποσπάσματα κειμένου.

Το GoPubMed ταξινομεί τα 132 άρθρα χρησιμοποιώντας την MeSH και τη γονιδιακή οντολογία. Ο κλάδος GO BIOLOGICAL PROCESS απαριθμεί σημαντικές έννοιες όπως REGU- LATION OF PROGRESSION THROUGH CELL CYCLE με 67 τεκμήρια όπως: "*Ο καταστολέας όγκων BRCA1 υπάρχει ως ετεροδιμερές σύμπλοκο με το BARD1 και το σύμπλοκο αυτό θεωρείται ότι μεσολαβεί για πολλές από τις λειτουργίες που αποδίδονται στο BRCA1, συμπεριλαμβανομένου του ρόλου του στην καταστολή των όγκων.*". Είναι ενδιαφέρον ότι το απόσπασμα κατατάχθηκε ψηλά επειδή η ΚΑΤΑΣΤΟΛΉ ΌΓΚΩΝ είναι συνώνυμο της γονιδιακής οντολογίας της ΡΎΘΜΙΣΗΣ ΤΗΣ ΠΡΟΌΔΟΥ ΜΈΣΩ ΤΟΥ ΚΥΤΤΑΡΙΚΟΎ ΚΎΚΛΟΥ.

Μια άλλη σημαντική πτυχή αντιπροσωπεύεται από τη δεύτερη βιολογική διαδικασία ΕΠΙΔΙΌΡΘΩΣΗΣ του DNA. Κάνοντας κλικ σε αυτήν, εμφανίζονται τα στοιχεία: "Τα *κύτταρα με ανεπάρκεια της πρωτεΐνης του συνδρόμου Werner (WRN) ή της BRCA1 είναι υπερευαίσθητα σε διασταυρούμενους δεσμούς μεταξύ των αλυσίδων του DNA (ICLs), η επιδιόρθωση των οποίων απαιτεί επιδιόρθωση με νουκλεοτιδική εκτομή (NER) και ομόλογο ανασυνδυασμό (HR). PMID:* 16714450". Η περίληψη, που παρουσιάζεται στην εικόνα 6, κατατάχθηκε σε υψηλή θέση επειδή αναφέρει τις λέξεις-κλειδιά και την έννοια INTERSTRAND CROSSLINK REPAIR (ΕΠΙΔΙΌΡΘΩΣΗ ΔΙΑΚΛΆΔΩΣΗΣ ΔΙΑΚΛΆΔΩΣΗΣ), η οποία

εντοπίστηκε από τον αλγόριθμο Concept Recog- nition. Η έννοια είναι συνώνυμο της ΕΠΙΔΙΌΡΘΩΣΗΣ ΝΟΥΚΛΕΟΤΙΔΊΩΝ-ΑΠΟΚΟΠΤΗΣ, η οποία είναι απόγονος της ΕΠΙΔΙΌΡΘΩΣΗΣ του DNA. Για την πτυχή "επιδιόρθωση του DNA" υπάρχουν άλλα 52 τεκμήρια που παρατίθενται στην επαγόμενη οντολογία.



Σχήμα 6. Μια πλήρης περίληψη που εμφανίζεται στην προβολή εγγράφων του GoPubMed για το ερώτημα *"BRCA1 AND BARD1"*. Η περίληψη εμφανίζεται κατά την επιλογή της έννοιας DNA re- PAIR. Σημειώστε ότι η επιδιόρθωση του DNA δεν αναφέρεται κυριολεκτικά στο κείμενο. Αντ' αυτού, ο αλγόριθμος αναγνώρισης εννοιών (Con- cept Recognition) εντόπισε την ΕΠΙΔΙΌΡΘΩΣΗ ΔΙΑΣΤΑΥΡΟΎΜΕΝΩΝ ΑΛΥΣΙΔΩΝ ως συνώνυμο της ΕΠΙΔΙΌΡΘΩΣΗΣ ΝΟΥΚΛΕΟΤΙΔΊΩΝ-ΑΠΟΚΟΠΤΗΣ, η οποία είναι απόγονος της ΕΠΙΔΙΌΡΘΩΣΗΣ του DNA.

Βιολογική λειτουργία των οντοτήτων: Πώς επηρεάζουν οι αλληλεπιδράσεις Bop-Pes την κυτταρική ανάπτυξη; (TREC #177). "*Το πυρηνικό σύμπλεγμα PeBoW, αποτελούμενο από τα Pes1, Bop1 και WDR12, είναι απαραίτητο για τον κυτταρικό πολλαπλασιασμό και την επεξεργασία του ri- bosomal RNA στα κύτταρα των θηλαστικών. (PMID: 16738141)*".

Το GoPubMed παρουσιάζει αυτό το απόσπασμα κατά την αναζήτηση για *"Bop AND Pes"* ακολουθούμενη από κλικ στην επιλογή *"Expand your query with synonyms for Bop, Pes"* και φιλτράρισμα για τον τίτλο MeSH CELL GROWTH PROCESSES. Η λειτουργία προηγμένης αναζήτησης στο GoPubMed επιτρέπει το φιλτράρισμα με κλάδους εννοιών. Η προηγμένη αναζήτηση *Bop AND Pes +*mesh#"Cell Growth Processes"* διατηρεί μόνο έγγραφα που αναφέρουν την κυτταρική ανάπτυξη. Το παραπάνω απόσπασμα εμφανίζεται στη θέση 1 από τα έξι έγγραφα όταν χρησιμοποιείται αυτό το ερώτημα προηγμένης αναζήτησης και αναπτύσσονται τα ονόματα των πρωτεϊνών.

Το χρυσό πρότυπο TREC παραθέτει αποσπάσματα του πλήρους κειμένου των εγγράφων του PubMed Central ως έγκυρες απαντήσεις στις ερωτήσεις. Για την ερώτηση #177 το πρότυπο παραθέτει 7 αποσπάσματα που έγιναν δεκτά από τους επιμελητές ως απάντηση στην ερώτηση. Για παράδειγμα, το απόσπασμα: "*Είναι ενδιαφέρον ότι ένα πιθανό ομόλογο σύμπλοκο του Pes1-Bop1-WDR12 στη ζύμη (Nop7p-Erb1p-Ytm1p) εμπλέκεται στον έλεγχο της βιογένεσης των ριβοσωμάτων και της εισόδου στη φάση S. Συμπερασματικά, η ακεραιότητα του συμπλόκου PeBoW απαιτείται για τη βιογένεση των ριβοσωμάτων και τον κυτταρικό πολλαπλασιασμό στα κύτταρα των θηλαστικών. (PMID: 16043514)*" έγινε δεκτή ως απάντηση στην ερώτηση αριθ. 177.

Όλες οι ερωτήσεις του TREC 2006 Genomics Track μπορούσαν να απαντηθούν με το GoP- ubMed. Είναι σημαντικό να σημειωθεί ότι οι απαντήσεις του GoPubMed βασίζονται στην

περιλήψεις και όχι στα πλήρη κείμενα, όπως χρησιμοποιείται από τους συμμετέχοντες στο TREC. Ο πίνακας 3 παρουσιάζει τη σύνοψη των αποτελεσμάτων αυτής της αξιολόγησης. Η στήλη Advanced Query δείχνει τη σύνταξη του ερωτήματος που υποβλήθηκε στο σύστημα για κάθε ερώτημα. Περιέχει τις λέξεις-κλειδιά της ερώτησης καθώς και τον κλάδο εννοιών που είναι σχετικός με την απάντηση της ερώτησης. Η στήλη "Ex" δηλώνει αν χρησιμοποιήθηκε ή όχι η επέκταση ονόματος πρωτεΐνης/γονιδίου. Η στήλη "As- pect" περιέχει την έννοια στην οποία βρέθηκε η απάντηση. Το IS δίνει τον αριθμό των εγγράφων που χρησιμοποιήθηκαν για την επαγωγή της οντολογίας. RS είναι ο αριθμός των εγγράφων που συνδέονται με την πτυχή. Pos είναι η θέση στον κατάλογο αποσπασμάτων που βρέθηκε η απάντηση. UI είναι ο αριθμός των αλληλεπιδράσεων του χρήστη που απαιτούνται για την εύρεση της ερώτησης.

Παρά το γεγονός ότι η αξιολόγηση αυτή πραγματοποιήθηκε μόνο με τα περιληπτικά κείμενα, σε αντίθεση με τα πλήρη κείμενα που χρησιμοποιήθηκαν κατά την αξιολόγηση TREC, το GoPubMed είναι σε θέση να απαντήσει σε όλες τις ερωτήσεις με ελάχιστες απαιτούμενες αλληλεπιδράσεις του χρήστη. Τα προηγμένα ερωτήματα που χρησιμοποιήθηκαν σε αυτό το πείραμα μπορούν εύκολα να αντικατασταθούν από μια απλή αναζήτηση με λέξεις-κλειδιά συν ένα κλικ στην έννοια στην οντολογία. Στις περισσότερες περιπτώσεις οι έννοιες που επιλέγονται εδώ είναι κορυφαίες κατηγορίες των ερωτημάτων. Στις άλλες περιπτώσεις μια αναζήτηση στη γνώση υποβάθρου με την επιλογή *"Εύρεση σχετικών κατηγοριών ..."* εντοπίζει γρήγορα τις κατάλληλες έννοιες.

Ο αριθμός των επίσημων απαντήσεων TREC ανά ερώτηση κυμαίνεται μεταξύ 0 και 593 αποσπασμάτων. Οι απαντήσεις καλύπτουν ως επί το πλείστον όχι μόνο μία πτυχή του θέματος. Για παράδειγμα, μια απάντηση TREC στην ερώτηση με αριθμό 160 σχετίζεται με τις μεταλλάξεις: "*Nineteen mutations of the PrP gene are associated with inherited human prion disease... (PMID: Pmid: 7642588 Span: 19641-86)*" μια άλλη πτυχή, η παθογένεια στα βοοειδή και τα πρόβατα, καλύπτεται από τη σωστή απάντηση: "η *σπογγώδης εγκεφαλοπάθεια των βοοειδών στα βοοειδή και η τρομώδης νόσος στα πρόβατα είναι μέλη μιας οικογένειας λοιμωδών νευροεκφυλιστικών ασθενειών των θηλαστικών που είναι γνωστές ως δια- φορετικές σπογγώδεις εγκεφαλοπάθειες. Κατά τη διάρκεια της παθογένειας της νόσου, μια ανθεκτική στην πρωτεάση μορφή της πρωτεΐνης πρίον (PrP) συσσωρεύεται στον εγκέφαλο και σε άλλους ιστούς των μολυσμένων ζώων... Pmid: 7852415 Span: 4349-483*".

Στο GoPubMed το φάσμα των σχετικών απαντήσεων στις ερωτήσεις αντικατοπτρίζεται στην επαγόμενη οντολογία. Ο χρήστης μπορεί να εξερευνήσει τις πτυχές με πλοήγηση στην επαγόμενη ιεραρχία. Οι κορυφαίες κατηγορίες βοηθούν στον εντοπισμό σημαντικών πτυχών χωρίς την ανάγκη εμβάθυνσης στην ιεραρχία.

7.3 Αποκαλυπτικές τάσεις στη βιβλιογραφία

Πρόσφατα, πολλές έρευνες αφιερώθηκαν στην ανάλυση της βιοϊατρικής βιβλιογραφίας. Το ενδιαφέρον αυτό προκλήθηκε από την αύξηση της βιβλιογραφίας, αλλά και από τη διαθεσιμότητα περιλήψεων, πλήρων

εγγράφων και βιβλιομετρικών δεδομένων. Οι ερευνητές έχουν ενδιαφερθεί ιδιαίτερα για την αυτόματη εξαγωγή πληροφοριών από ελεύθερο κείμενο, όπως ονόματα πρωτεϊνών (22- 60- 31), όροι οντολογίας (55- 8- 16) και πρωτεϊνικές αλληλεπιδράσεις (57, 21, 32).

Όλες οι παραπάνω εφαρμογές εξόρυξης κειμένου βασίζονται στη βιβλιογραφία, η οποία αυξάνεται συνολικά. Αλλά με μια πιο προσεκτική ματιά αποδεικνύεται ότι ορισμένοι ερευνητικοί τομείς συρρικνώνονται, ενώ άλλοι απογειώνονται. Οι βιβλιομετρικές αναλύσεις έχουν ως στόχο να ρίξουν φως σε αυτές τις εξελίξεις και να εντοπίσουν τις αναδυόμενες τάσεις. Τέτοιες αναλύσεις χρονολογούνται από τη δεκαετία του 60.

Πίνακας 3. QN: Αριθμός ερώτησης, Ex: Expand Protein/Gene names, IS: Μέγεθος δείγματος, RS: Μέγεθος αποτελέσματος, Pos: Θέση, UI: Αλληλεπιδράσεις χρήστη

QN	Ερωτήσεις για προχωρημένους	Ex	Όψη	IS	RS	Θέση	UI
160	PrnP	ναι	mesh#"Encephalopathy, Bovine Spongiform"	1000	77	1	1
161	IDE	όχι	mesh#"Alzheimer Disease"	1000	57	1	1
162	MMS2	όχι	go#"επιδιόρθωση DNA"	1000	1	5	1
163	APC +*mesh#"Νεοπλάσματα παχέος εντέρου"	όχι	Νεοπλάσματα του παχέος εντέρου [210]	1000	208	7	1
164	Nur77 +*mesh#"Parkinson Disease"	όχι	mesh#"Parkinson Disease"	1000	6	1	1
165	CTSD ΚΑΙ ApoE +*μέσο+"Νόσος Alzheimer"	ναι	mesh#"Alzheimer Disease"	1000	18	3	2
166	TGF-beta1 +*mesh#"Cerebral Amyloid Angiopathy"	όχι	mesh#"Αγγειοπάθεια του εγκεφαλικού αμυλοειδούς"	5000	3	1	1
167	Νουκλεοσιδική διφωσφορική κινάση +*mesh#"Neoplasms"	ναι	"Μετάσταση νεοπλάσματος"	1000	148	1	3
168	BARD1 ΚΑΙ BRCA1 +*go#"βιολογική διαδικασία"	ναι	go#"ρύθμιση της εξέλιξης του κυτταρικού κύκλου"	1000	67	1	3
169	APC +*mesh#Actins	όχι	mesh#Actins	1000	19	2	5
170	COP2 ΚΑΙ CFTR +*go#"πρωτεΐνη συνδεδεμένη με τον καταβολική διαδικασία"	ER ναι	διαδικασία καταβολισμού των πρωτεϊνών που σχετίζονται με το go#ER	1000	3	2	3
171	Nurr-77 +*mesh#"T-λεμφοκύτταρα"	ναι	mesh#T-λεμφοκύτταρα	1000	100	2	2
172	p53 +*go#απόπτωση	όχι	go#"επαγωγή της απόπτωσης"	1000	409	1	1
173	νικοτινικός υποδοχέας άλφα7	όχι	go#"μεταβολική διαδικασία αιθανόλης"	1000	1	1	2
174	BRCA1 +*go#"ubiquitin binding"	όχι	mesh#Νεοπλάσματα	1000	2	1	3
175	L1 AND L2 AND HPV11 +*go#"ικό καψίδιο"	όχι	go#"ικό καψίδιο"	1000	2	2	2
176	Sec61 +*mesh#"Κυστική ίνωση Transmembrane Con-Ρυθμιστής ροής"	όχι	mesh#"Κυστική ίνωση"	1000	6	1	2
177	Bop AND Pes +*mesh#"Διαδικασίες κυτταρικής ανάπτυξης"	ναι	mesh#"Διαδικασίες κυτταρικής ανάπτυξης"	1000	6	1	3
178	IGF +*mesh#Δέρμα +*mesh#"Υποδοχείς, ινσουλίνη"	όχι	go#"ρύθμιση της μετανάστευσης των κερατινοκυττάρων"	1000	2	1	1
179	HNF4 +*mesh#"Παράγοντες μεταγραφής COUP"	ναι	mesh#"Καρκίνωμα, ηπατοκυτταρικό"	1000	9	1	2
180	Ret ΚΑΙ GDNF	ναι	mesh#"Ηπατοκύτταρα"	1000	3	1	3
181	huntingtin +*mesh#Μετάλλαξη	όχι	go#αυτόσωμα	1000	48	1	2
182	ηχητικός σκαντζόχοιρος +*mesh#Mutation	όχι	mesh#"Holoprosencephaly"	1000	17	1	1
183	NM23 +*mesh#Mutation	όχι	mesh#"Genes, Tumor Suppressor"	1000	78	1	1
184	Pes +*go#"κυτταρική ανάπτυξη" +*mesh#Μετάλλαξη	ναι	mesh#"Διαδικασίες κυτταρικής ανάπτυξης"	1000	4	1	

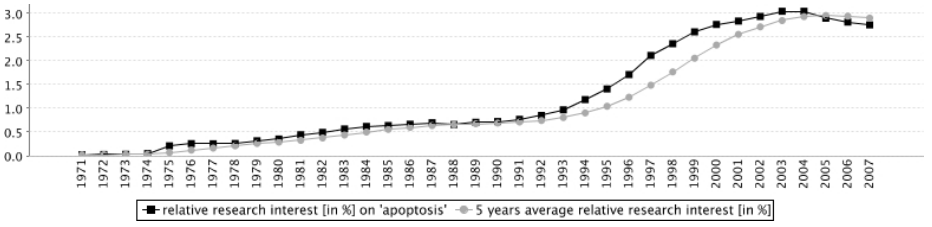
185 υποδοχέας υποκρετίνης 2 +*mesh#Μετάλλαξη	ναι	mesh#Ναρκοληψία	1000	15	3	3
186 Presenilin-1 +*mesh#Μετάλλαξη	ναι	mesh#"Alzheimer Disease"	1000	466	1	3
187 FHM1 +*mesh#Μετάλλαξη	όχι	mesh#Hippocampus	1000	2	1	1

(49) και συνήθως επικεντρώνονται σε ερευνητικά θέματα (23), σε συγκεκριμένα περιοδικά (9) ή στους ίδιους τους ερευνητές (43, 44, 49, 27, 12, 10). (23) διερευνούν π.χ. την έρευνα σχετικά με τον προγραμματισμένο κυτταρικό θάνατο. Παρά το γεγονός ότι ο προγραμματισμένος κυτταρικός θάνατος περιγράφηκε πριν από 25 χρόνια, χρειάστηκαν περίπου 15 χρόνια μέχρι να εμφανιστούν περιοδικά όπως το "Cell Death and Differ- entiation" και να απογειωθεί ο αριθμός των δημοσιεύσεων στον τομέα αυτό γενικά. Ως παράδειγμα ανάλυσης ενός συγκεκριμένου περιοδικού, ο Boyack ανέλυσε την εμφάνιση και την εξέλιξη των θεμάτων που καλύπτει το PNAS (9). Ένας πολύ ενεργός τ ο μ έ α ς έρευνας αποσκοπεί στην κατανόηση της κοινωνικής διαδικασίας της δημοσίευσης μέσω της διερεύνησης των δικτύων συν-συγγραφέων και συν-παραπομπών (43- 44- 49- 27- 12- 10). Τέτοιες αναλύσεις al- low one να εντοπίσουν συγγραφείς σε έναν οργανισμό, οι οποίοι εργάζονται διεπιστημονικά και συνδέουν διαφορετικά ασύνδετα δίκτυα συν-συγγραφέων (44), να ζωντανέψουν τις αναφορές βασικών δημοσιεύσεων με την πάροδο του χρόνου (12), την εξέλιξη των δικτύων συγγραφέων και δημοσιεύσεων (10) και να κατανοήσουν πώς σχηματίζονται ομάδες (27). Όλες αυτές οι αναλύσεις είναι χρήσιμες για να δούμε την έρευνα από τη σκοπιά των πτηνών. Η παρούσα ενότητα συνδέει τέτοιες αναλύσεις με τη μηχανή αναζήτησης βιβλιογραφίας με βάση την οντολογία GoPubMed για να υποστηρίξει την ανακάλυψη τάσεων σε θέματα που ενδιαφέρουν τους μοριακούς βιολόγους.

Το GoPubMed εξάγει όρους GO από όλες τις 18.000.000 περιλήψεις της PubMed και επιτρέπει στους χρήστες να εξερευνήσουν τα αποτελέσματα της αναζήτησής τους με τη γονιδιακή οντολογία. Η συσχέτιση των εννοιών GO με τις περιλήψεις του GoPubMed αποτελεί πολύτιμο πόρο για την κατανόηση του τρόπου με τον οποίο αναπτύσσεται ένα ερευνητικό θέμα - που αντιπροσωπεύεται από μια έννοια GO -. Δείχνει πόσα άρθρα δημοσιεύτηκαν με την πάροδο του χρόνου, ποιοι συγγραφείς είναι πιο παραγωγικοί για το θέμα, ποια περιοδικά καλύπτουν καλύτερα το θέμα και ποιες χώρες δημοσιεύουν περισσότερο για το θέμα. Η χρήση μιας οντολογίας για αυτές τις αναλύσεις είναι πολύ σημαντική, καθώς περιλαμβάνει συνώνυμα και υποέννοιες. Ως π α ρ ά δ ε ι γ μ α , οι (23) επισημαίνουν ότι κατά τις δεκαετίες του 60 και του 70 οι ερευνητές στις ΗΠΑ χρησιμοποιούσαν τον "προγραμματισμένο κυτταρικό θάνατο", ενώ οι Ευρωπαίοι συνάδελφοί τους χρησιμοποιούσαν την "απόπτωση". Στην παρούσα ανάλυση, αυτές αντιμετωπίζονται ως ισοδύναμες με τη βοήθεια της υποκείμενης οντολογίας. Επίσης, είναι σημαντικό να ληφθούν υπόψη οι υποέννοιες, καθώς ορισμένες εργασίες μπορεί να αναφέρουν τις GTPάσες γενικά, ενώ άλλες αναφέρονται σε συγκεκριμένες GTPάσες όπως Ran, Rac, Rho κ.λπ. Και πάλι, η χρήση της οντολογίας εξασφαλίζει ότι μια ανάλυση των GTPases θα περιλαμβάνει όλες τις συγκεκριμένες GTPases. Εκτός από τα ερευνητικά θέματα, αναλύθηκαν οι συγγραφείς και οι τόποι. Τα αποτελέσματα δείχνουν την εκδοτική τους δραστηριότητα σε βάθος χρόνου και τα θέματα που καλύπτουν. Τέλος, αναλύθηκε ολόκληρη η βιοϊατρική βιβλιογραφία για τον εντοπισμό των περιοδικών, τα οποία αναφέρουν τις περισσότερες έννοιες GO. Υποθέτοντας ότι ο GO αποτυπώνει τις βασικές γνώσεις ενός μοριακού βιολόγου, αυτά είναι τα πιο σημαντικά περιοδικά για τον μοριακό βιολόγο. Το πείραμα διαρθρώθηκε ως εξής: π ρ α γ μ α τ ο π ο ι ή θ η κ ε βιβλιομετρική ανάλυση με επίκεντρο τα "σημαντικά θέματα" που διερευνούν την απόπτωση και το ενδοσώμα. Δεύτερον, μια έρευνα των "σημαντικών τόπων" δείχνει πώς μπορούν να ταξινομηθούν οι οργανισμοί

και οι τόποι, και η ανάλυση των "σημαντικών περιοδικών" συνοψίζει τα κύρια θέματα που καλύπτει ένα περιοδικό. Τέλος, εξετάστηκε ολόκληρη η γονιδιακή οντολογία αναλύθηκαν τα 20 πιο σημαντικά περιοδικά για έναν μοριακό βιολόγο.

Είναι σημαντικό να αναφερθεί ότι κάθε προσπάθεια ποσοτικής ανάλυσης της βιβλιογραφίας, όσο εξελιγμένη και αν είναι, πρέπει να ερμηνεύεται με τεκμηριωμένη κρίση. Οι απόλυτες συχνότητες παραπομπών μπορεί να παρερμηνευθούν. Δεν είναι στις προθέσεις μας να κρίνουμε τη σημασία της συμβολής μεμονωμένων επιστημόνων ή ιδρυμάτων.



Εικ. 7. Περιλήψεις της PubMed ανά έτος που αναφέρουν ΤΗΝ ΑΠΌΠΤΩΣΗ (συμπεριλαμβανομένων των συνωνύμων και των εξειδικεύσεων του όρου)

7.3.1 Σημαντικό θέμα: .

Το 1997, οι Garfield και Melino ανέλυσαν την επιστημονική βιβλιογραφία σχετικά με τον προγραμματισμένο κυτταρικό θάνατο (απόπτωση) (23), χρησιμοποιώντας το Science Citation Index του ISI. Χρησιμοποιώντας τ η ν ημερομηνία δημοσίευσης, τη συχνότητα, τις παραπομπές και τις συν-παραπομπές των εργασιών, ανέλυσαν την ανάπτυξη του τομέα, τις πιο δραστήριες χώρες, τα κυριότερα περιοδικά και τους βασικούς συγγραφείς. Διαπίστωσαν ότι υπήρξε σημαντική αύξηση του αντίκτυπου των άρθρων σχετικά με τον προγραμματισμένο κυτταρικό θάνατο μετά το 1990 και ότι ήταν ένα από τα πιο καυτά θέματα το 1997. Ορισμένες από τις χώρες που συγκαταλέγονται μεταξύ των πιο ενεργών είναι οι ΗΠΑ, το Ηνωμένο Βασίλειο, η Γερμανία, η Αυστραλία και η Γαλλία. Τα περιοδικά που δημοσιεύουν πιο ενεργά για την απόπτωση είναι τα Immunology, Blood, FASEB Journal Cancer Research, Biological Chemistry, PNAS και Oncogene. Οι συγγραφείς με τις περισσότερες αναφορές είναι οι AH Wyllie, SJ Korsmeyer και GT Williams καθώς και αργότερα στις θέσεις 17 και 22 οι JC Reed και PH Krammer. Τέτοιες πληροφορίες είναι πολύτιμες για να αποκτήσετε γρήγορα μια γενική εικόνα ενός νέου τομέα.

Αν και ο συγγραφέας δήλωσε σε μεταγενέστερο προσάρτημα ότι έκανε ένα λάθος και έτσι οι Strasser και Vaux δεν αναφέρθηκαν αν και έπρεπε να είναι στη 2η θέση και 3. Επίσης, άλλα ερευνητικά πεδία όπως το νιτρικό οξείδιο και το p53 αναφέρονται ως παρόμοια ενεργά ερευνητικά πεδία αυτή τη στιγμή.

Οι βιβλιομετρικές αναλύσεις, όπως οι παραπάνω, είναι πολύτιμες αλλά δύσκολα εκπονήσιμες. Ειδικά στην αρχή, οι αναδυόμενες τάσεις μπορεί να είναι γνωστές με διαφορετικά ονόματα. Όπως επισημαίνουν οι Garfield και Melino, αρχικά ο όρος απόπτωση χρησιμοποιήθηκε συχνότερα στην Ευρώπη, ενώ στις ΗΠΑ επινοήθηκε το ίδιο θέμα προγραμματισμένος κυτταρικός θάνατος. Εκτός από τα συνώνυμα, τέτοιες αναλύσεις θα πρέπει να λαμβάνουν υπόψη εργασίες, οι οποίες δεν αναφέρουν την απόπτωση ρητά αλλά εμμέσως.

Ως παράδειγμα, αναφέρατε έγγραφα που αναφέρουν ΤΗΝ ΑΠΕΛΕΥΘΈΡΩΣΗ ΚΥΤΟΧΡΏΜΑΤΟΣ C ΑΠΌ ΤΑ ΜΙΤΟΧΌΝΔΡΙΑ ή την ΕΝΕΡΓΟΠΟΊΗΣΗ της ΚΑΣΠΆΣΗΣ. Δεδομένου ότι η απελευθέρωση του κυτοχρώματος c από τον μεσομεμβρανικό χώρο των μιτοχονδρίων στο κυτταρόλυμα οδηγεί στην ενεργοποίηση της κασπάσης και αποτελεί πρώιμο βήμα της απόπτωσης. Ως εκ τούτου, οι εργασίες που αναφέρουν αυτούς τους όρους θα πρέπει επίσης να θεωρηθούν ότι καλύπτουν την απόπτωση.

Αυτά τα δύο προβλήματα - η χρήση συνωνύμων και η συμπερίληψη των εξειδικεύσεων των όρων - μπορούν να αντιμετωπιστούν με μια οντολογία. Η γονιδιακή οντολογία ορίζει π.χ. τα συνώνυμα ΑΠΌΠΤΩΣΗ και ΠΡΟΓΡΑΜΜΑΤΙΣΜΈΝΟΣ ΚΥΤΤΑΡΙΚΌΣ ΘΆΝΑΤΟΣ ΤΎΠΟΥ Ι. Επιπλέον, ορίζει ότι η ΕΝΕΡΓΟΠΟΊΗΣΗ ΤΗΣ ΚΑΣΠΆΣΗΣ αποτελεί μέρος του ΑΠΟΠΤΩΤΙΚΟΎ ΠΡΟΓΡΆΜΜΑΤΟΣ, το οποίο αποτελεί μέρος της ΑΠΌΠΤΩΣΗΣ.

Δεδομένου ότι το GoPubMed ευρετηριάζει όλες τις περιλήψεις της PubMed με την GeneOntology, οι αναλύσεις μας περιλαμβάνουν την εξέταση των συνωνύμων και των εξειδικεύσεων. Για την απόπτωση βρίσκουμε πολύ παρόμοια αποτελέσματα με αυτά των Garfield και Melino. Η εκθετική αύξηση των δημοσιεύσεων μετά το 1990 φαίνεται στο σχήμα 7. Το σχήμα δείχνει επίσης ότι η τάση αυτή συνεχίστηκε μετά το 1997, όταν δημοσιεύθηκε η ανάλυση των Garfield και Melino. Ενώ οι Garfield και Melino ισχυρίζονται ότι Η ΑΠΌΠΤΩΣΗ είναι ένα καυτό θέμα, μπορούμε να ποσοτικοποιήσουμε αυτόν τον ισχυρισμό σε κάποιο βαθμό.

Λαμβάνοντας υπόψη τον αριθμό των δημοσιεύσεων μεταξύ 1991 και 1997, η απόπτωση κατατάσσεται στη θέση 16 σε σύγκριση με άλλες έννοιες GO στο ίδιο επίπεδο με την απόπτωση ή βαθύτερα στην ιεραρχία GO. Η ανάλυση των χωρών επιβεβαιώνει επίσης το εύρημα των Garfield και Melino, αν και η υψηλή θέση της Αυστραλίας το 1997 έχει μειωθεί. Όλα τα σχετικά περιοδικά που εντοπίστηκαν από τους Garfield και Melino επιβεβαιώνονται από την ανάλυσή μας. Τα έξι περιοδικά τους κατατάσσονται στην πρώτη 5άδα και στη θέση 8 (Blood). Η ανάλυση αποκαλύπτει επιπλέον τα περιοδικά Biochemical and Biophysical Research Communications και Nucleic Acids Research στις θέσεις 6 και 7 ως ιδιαίτερα σημαντικά για την απόπτωση.

Η κατάταξη για τους πιο ενεργά εκδότες συγγραφείς είναι διαφορετική σε αυτή την ανάλυση από τα αποτελέσματα των Garfield και Melino. Αυτό οφείλεται στο γεγονός ότι, σε αντίθεση με αυτούς, για την κατάταξη των συγγραφέων μπορούσε να χρησιμοποιηθεί μόνο ο αριθμός των εργασιών που αναφέρουν την απόπτωση και όχι οι αναφορές και ο αντίκτυπος των εργασιών. Ωστόσο, οι δύο συγγραφείς με την υψηλότερη κατάταξη Reed και Krammer κατατάσσονται επίσης πολύ ψηλά στα αποτελέσματα. Αυτό δείχνει ότι η εξέταση των αναφορών των άρθρων δίνει γενικά μια σημαντικά διαφορετική κατάταξη από την απλή χρήση της συχνότητας αναφοράς όρων. Για να βελτιωθεί αυτό θα χρειάζονταν πληροφορίες σχετικά με τις αναφορές για κάθε περίληψη.

Μπορεί κανείς να συμπεράνει ότι αυτή η προσέγγιση ευρετηρίασης της χρήσης των εννοιών GO σε περιλήψεις βιβλιογραφίας οδηγεί σε πολύ παρόμοια αποτελέσματα σε σύγκριση με την προσέγγιση των Garfield και Melino. Οι κύριες διαφορές είναι οι εξής: (1) ότι αυτή η προσέγγιση είναι πλήρως αυτοματοποιημένη και πάντα ενημερωμένη, ενώ τα αποτελέσματά τους χρονολογούνται από το 1997,
(2) λαμβάνονται υπόψη τα συνώνυμα και οι εξειδικεύσεις, (3) και κυρίως αυτή η ανάλυση είναι διαθέσιμη στο διαδίκτυο για οποιαδήποτε από τις 24.000 έννοιες GO.

7.3.2 Σημαντικό θέμα: Ενδοσώματος

Ας εξετάσουμε ένα άλλο παράδειγμα εκτός από την απόπτωση, δηλαδή το κυτταρικό σύνθετο ΕΝΔΟΣΩΜΑ του GO, το οποίο περιλαμβάνει υποόρους όπως το πρώιμο και το όψιμο ενδοσώμα. Όπως φαίνεται στο κάτω μέρος της Εικόνας 8, μπορεί κανείς να δει ότι η έρευνα σε αυτούς τους τομείς αυξάνεται σταθερά με υπεργραμμικό τρόπο. Είναι σαφές ότι η έρευνα που σχετίζεται με το ενδόσωμα είναι ένα καυτό θέμα αυτή τη στιγμή. Όπως είναι αναμενόμενο η βιβλιογραφία κυριαρχείται από χώρες της Βόρειας Αμερικής, της Ευρώπης και της Ιαπωνίας. Ωστόσο, ένα μικρό μέρος αποδίδεται στη Σιγκαπούρη, το οποίο

είναι σημαντικό λόγω του μικρού μεγέθους της. Στον πίνακα 8 παρουσιάζονται τα κυριότερα περιοδικά και οι συγγραφείς.

7.3.3 Σημαντικό μέρος: Δρέσδη

Οι βιβλιομετρικές αναλύσεις μπορούν επίσης να εφαρμοστούν για να αποκτήσουν μια γενική εικόνα των οργανισμών και των χώρων. Η αξιολόγηση των θεμάτων που καλύπτουν οι δημοσιεύσεις των οποίων ο τίτλος αναφέρει τη Δρέσδη αποκαλύπτει π .χ. ότι η βιοϊατρική έρευνα στη Δρέσδη επικεντρώνεται

Πίνακας 4. Στατιστικά στοιχεία για ΤΟ ΕΝΔΟΣΩΜΑ (άρθρο = αριθμός άρθρων που περιέχουν ΤΟ ΕΝΔΟΣΩΜΑ). Επάνω αριστερά: Τα πιο παραγωγικά περιοδικά. Επάνω δεξιά: Πιο παραγωγικοί συγγραφείς.

Περιοδικό	Art.	Συγγραφέας	Art.
Βιολογική χημεία	777	P D Stahl	59
Κυτταρική βιολογία	420	H J Geuze	52
Επιστήμη των κυττάρων	261	T Berg	44
Μοριακή βιολογία του κυττάρου	250	J Gruenberg	44
Ιολογία	180	I Mellman	44
PNAS	178	B I Posner	41
Ανοσολογία	152	J J Bergeron	40
Bioch. et biophy. acta	144	K Sandvig	36
European j. of cell bio.	134	M Zerial	36
Βιοχημικό περιοδικό	131	G Griffiths	35
Κυκλοφορία	114	B van Deurs	35
Περιοδικό EMBO	113	R G Parton	35
American j. of physiology	104	A S Verkman	31
Bioch. & biophy.res.comm.	90	H Stenmark	29
Έρευνα κυττάρων και ιστών	90	S R Pfeffer	29
Άλλα περιοδικά	6389		

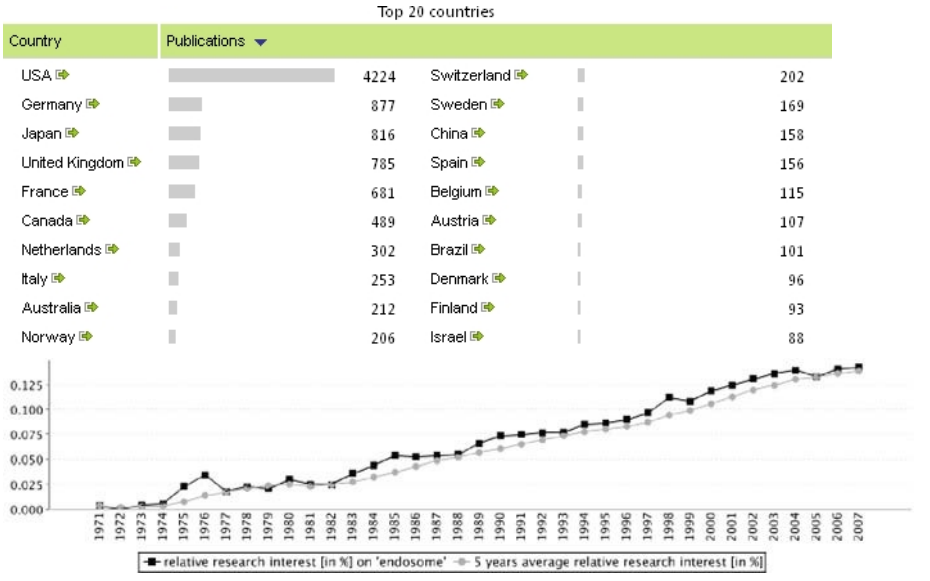
για τα ακόλουθα θέματα: *Πυρετός, γαστριδίωση, γαλουχία, κυτταροκίνηση, κυτταροκίνηση, ενδοσώμα, αυτοσώμα, αγγειοδιαστολή, ενυδάτωση, φωσφορυλίωση, επούλωση πληγών, δενδρίτης, λιπιδική σχεδία, παρεμβολή RNA, κυτταροσκελετός, αγγειογένεση, κυτταρική μετανάστευση, φλεγμονώδης απόκριση, επιδιόρθωση αναντιστοιχιών, κενό, κολλαγόνο τύπου I, ίμπρινόλυση, έκκριση ινσουλίνης, σύνδεση υποδοχέα αγγειακού ενδοθηλιακού αυξητικού παράγοντα, φαγοκυττάρωση, κυτταρική αναπνοή, σύμπλεγμα πόρων, χρωματίνη.*

Αυτό δίνει μια άμεση εντύπωση και τα επιμέρους θέματα μπορούν να εντοπιστούν σε ερευνητές και ομάδες. Π.χ. η παρέμβαση RNA είναι ένα καυτό θέμα στη Δρέσδη με μια εγκατάσταση υψηλής απόδοσης RNAi screening, η οποία έχει οδηγήσει σε πολυάριθμες δημοσιεύσεις, συμπεριλαμβανομένων άρθρων υψηλού προφίλ στο Nature.

7.3.4 Σημαντικό περιοδικό: Ποιοι είναι οι 10 πιο συχνά χρησιμοποιούμενοι όροι GO στα Nature, Cell και Science;

Παρόμοια με την ανάλυση (9) που πραγματοποιήθηκε για το PNAS, μπορούμε να αναλύσουμε και άλλα περιοδικά. Για παράδειγμα, εξετάσαμε τους 10 πιο συχνά αναφερόμενους όρους στα περιοδικά Nature, Cell και Science. Ορισμένοι όροι εμφανίζονται συχνά σε όλα τα μεγάλα περιοδικά, όπως *το εξωγόνο, η απόπτωση, η μεταλλαξιγένεση, η κυτταροκίνηση, η δραστηριότητα του αντιπομπού, η αντιγραφή του DNA και η συναρμολόγηση των φάγων*. Ορισμένοι όροι αναφέρονται συχνότερα σε ένα από τα περιοδικά σε σύγκριση με άλλα. Π.χ. διαπιστώθηκε ότι το Cell απαριθμεί συχνότερα άρθρα σχετικά με την *έναρξη της μεταγραφής, το ενδοπλασματικό δίκτυο, το νουκλεόσωμα, την πρωτεϊνική στόχευση, την πρωτεϊνική-ER στόχευση και τη ρύθμιση του κυτταρικού κύκλου,* γεγονός που αντικατοπτρίζει πολύ καλά την εστίασή του στη μοριακή κυτταρική

βιολογία. Το Science (Weekly) βρέθηκε να απαριθμεί περιλήψεις που περιέχουν *ενεργοποίηση Τ-κυττάρων, μεταφορά νουκλεϊκών οξέων, ρύθμιση του δυναμικού δράσης, μεταφορά διοξειδίου του άνθρακα*



Σχήμα 8. Στιγμιότυπο των στατιστικών στοιχείων του GoPubMed για την έννοια ENDOSOME. Επάνω: Οι πιο παραγωγικές χώρες. Κάτω: Άρθρα για το ενδοσωμάτιο με την πάροδο του χρόνου.

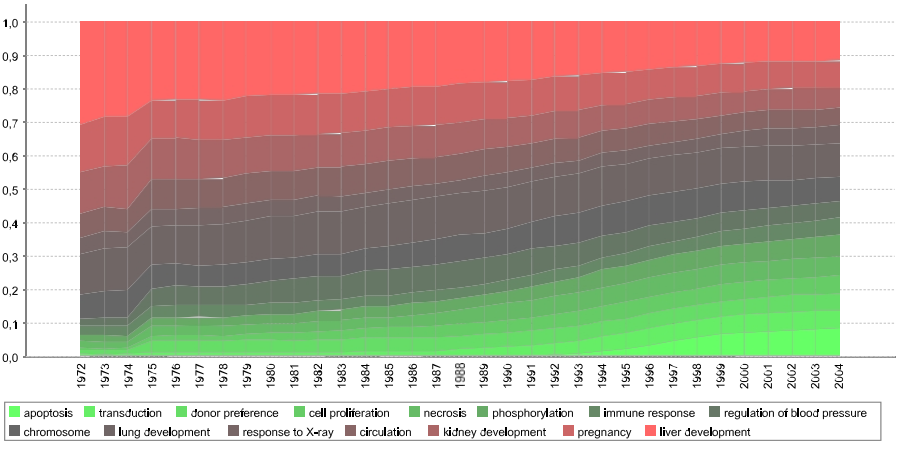
και απόκριση στο διοξείδιο του άνθρακα περισσότερο από άλλα περιοδικά και Nature *μεταφορά νουκλεϊκών οξέων, μυοσίνη, ρύθμιση του δυναμικού δράσης και παραγωγή δυναμικού δράσης* .

7.3.5 20 περιοδικά για τον μοριακό βιολόγο

Η βάση δεδομένων PubMed είναι η κύρια πηγή για περιλήψεις βιβλιογραφίας στον τομέα της βιοϊατρικής και καλύπτει χιλιάδες περιοδικά, που χρονολογούνται από τη δεκαετία του '60, με εκατομμύρια συγγραφείς και αρκετά εκατομμύρια περιλήψεις. Από την άλλη πλευρά, η GeneOntology είναι ένα μεγάλο λεξιλόγιο με πάνω από 24.000 όρους που καλύπτει πολλές πτυχές που ενδιαφέρουν έναν μοριακό βιολόγο. Υποθέτοντας ότι το GO αντικατοπτρίζει τα θέματα που ενδιαφέρουν έναν μοριακό βιολόγο, επιθυμούμε να αναλύσουμε πόσο μεγάλο μέρος της βιβλιογραφίας της PubMed μπορεί να είναι πραγματικά ενδιαφέρον, ποιοι όροι GO αναφέρονται συχνότερα και ποια περιοδικά είναι τα πιο σχετικά.

Πόσα άρθρα αναφέρουν όρους GO; Η PubMed αναπτύσσεται με τρομερούς ρυθμούς και μόνο το 2004 καταχωρήθηκαν 598278 νέες περιλήψεις. Πόσα από αυτά όμως αφορούν έναν μοριακό βιολόγο, καθώς υπάρχουν και πολύ γενικά άρθρα όπως "Σχετική αποτελεσματικότητα των προτεινόμενων φαρμάκων κατά της ασθένειας της κίνησης του διαστημικού λεωφορείου", "Σημείο-αντίθεση: πρέπει οι γιατροί να δέχονται δώρα από τους ασθενείς τους; Όχι: Τα δώρα υποβαθμίζουν την πραγματική αξία της φροντίδας", "Το γιατί και το γιατί της ενδυνάμωσης: το κλειδί για την ικανοποίηση από την εργασία και την επαγγελματική ανέλιξη". παρ' όλα αυτά, η ανάλυσή μας δείχνει ότι σχεδόν τα μισά (47,9%) από όλα τα άρθρα στην αγγλική γλώσσα αναφέρουν τουλάχιστον

έναν όρο GO. Το ποσοστό αυτό είναι αρκετά υψηλό, καθώς π.χ. το Nature, το οποίο



Εικ. 9. Εξέλιξη των θεμάτων για τις έννοιες GO με τις περισσότερες αναφορές από το 1972. Ο κατάλογος των εννοιών GO είναι ταξινομημένος με βάση το ερευνητικό ενδιαφέρον με την πάροδο του χρόνου. Θέματα όπως η απόπτωση, η μεταβίβαση, η προτίμηση του δότη, ο κυτταρικός πολλαπλασιασμός και η νέκρωση παρουσιάζουν αυξανόμενο ερευνητικό ενδιαφέρον, ενώ η ανάπτυξη του ήπατος, η εγκυμοσύνη και η ανάπτυξη των νεφρών παρουσιάζουν σχετικά μειωμένο ρυθμό αναφορών στις περιλήψεις της PubMed.

είναι σίγουρα το αποδεκτό περιοδικό για κάθε μοριακό βιολόγο, έχει μόνο στο 38,5% των άρθρων του τουλάχιστον έναν όρο GO.

Ποιοι είναι οι 10 πιο συχνά χρησιμοποιούμενοι όροι GO ανά έτος; Επιλέχθηκε επίπεδο εξειδίκευσης μεγαλύτερο του 5 στη γονιδιακή οντολογία για να συγκριθούν τα ερευνητικά θέματα σε δύο έτη 1972 και 2004. Αυτό σημαίνει ότι αγνοήθηκαν οι όροι της οντολογίας υψηλού επιπέδου. Οι έννοιες GO που αναφέρονταν συχνά στις περιλήψεις και στα δύο έτη ήταν: ΑΝΆΠΤΥΞΗ ΝΕΦΡΏΝ, ΑΝΆΠΤΥΞΗ ΠΝΕΥΜΌΝΩΝ, ΑΠΌΚΡΙΣΗ ΣΕ ΑΚΤΊΝΕΣ X, ΑΠΌΚΡΙΣΗ ΣΕ ΙΟΎΣ και ΦΩΣΦΟΡΥΛΊΩΣΗ. Τα άρθρα από το 1972 ανέφεραν επιπλέον συχνότερα τις ακόλουθες έννοιες GO: ΜΙΚΡΟΣΩΜΑ, ΚΥΤΤΑΡΙΚΉ ΑΝΑΠΝΟΉ, ΣΥΝΑΡΜΟΛΌΓΗΣΗ ΦΆΓΩΝ, ΔΡΑΣΤΗΡΙΌΤΗΤΑ ΑΝΤΙΦΟΡΈΑ, ΑΝΆΠΤΥΞΗ ΤΟΥ ΚΕΝΤΡΙΚΟΎ ΝΕΥΡΙΚΟΎ ΣΥΣΤΉΜΑΤΟΣ, ΑΝΤΙΓΡΑΦΉ του DNA, ΔΡΑΣΤΗΡΙΌΤΗΤΑ ΑΛΚΑΛΙΚΉΣ ΦΩΣΦΑΤΆΣΗΣ, ΜΕΤΑΦΟΡΆ ΝΟΥΚΛΕΪΚΩΝ ΟΞΈΩΝ, ΡΥΘΜΙΣΗ ΤΗΣ ΙΣΟΡΡΟΠΊΑΣ, ΔΡΑΣΤΗΡΙΌΤΗΤΑ ΡΕΝΊΝΗΣ, ΛΥΣΟΣΩΜΑ, ΣΙΕΛΟΓΌΝΟΣ ΑΔΈΝΑΣ (de-ΤΕΡΜΑΤΙΣΜΌΣ/ΜΟΡΦΟΓΈΝΕΣΗ) και ΩΟΡΡΗΞΊΑ.

Στο Αντίθετα στο αυτό το το το ακόλουθο νέα θέματα ήταν θέματα της έρευνας το 2004: ΑΠΌΠΤΩΣΗ, ΠΡΟΤΙΜΗΣΗ ΔΩΡΗΤΏΝ, ΕΝΔΟΘΗΛΙΑΚΆ ΚΥΤΤΑΡΑ (ακτίνες). ΕΝΕΡΓΟΠΟΊΗΣΗ/ΜΟΡΦΟΓΈΝΕΣΗ), ΠΡΟΔΙΑΓΡΑΦΉ ΤΟΥ ΕΞΩΓΕΝ αγγειογόνο-ΙΣΗΜΕΡΙΝΟΎ, ΈΣ, ESIS, ΟΠΤΙΚΉ ΑΝΤΊΛΗΨΗ, ΦΛΕΓΜΟΝΏΔΗΣ ΑΠΌΚΡΙΣΗ, ΒΙΟΣΥΝΘΕΣΗ ΙΝΤΕΡΦΕΡΌΝΗΣ-ΓΆΜΜΑ, ΑΠΌΚΡΙΣΗ ΣΕ ΔΡΑΣΤΙΚΆ ΕΊΔΗ ΟΞΥΓΌΝΟΥ.

Στο σχήμα 9 παρουσιάζεται η εξέλιξη των πιο συχνά χρησιμοποιούμενων εννοιών GO με την πάροδο του χρόνου. Μπορεί κανείς να δει σαφώς ότι θέματα όπως η απόπτωση, η μεταγωγή, η προ- δοχή του δότη, ο κυτταρικός

πολλαπλασιασμός και η νέκρωση παρουσιάζουν αυξανόμενο ερευνητικό ενδιαφέρον, ενώ η ανάπτυξη του ήπατος, η εγκυμοσύνη και η ανάπτυξη των νεφρών παρουσιάζουν σχετικά μειωμένο ρυθμό αναφορών στις περιλήψεις της PubMed.

Πίνακας 5. 20 περιοδικά για τον μοριακό βιολόγο

Pos.	Εφημερίδα
1.	Βιολογική χημεία
2.	PNAS
3.	Biochimica et biophysica acta
4.	Ανοσολογία
5.	Ανακοινώσεις βιοχημικής και βιοφυσικής έρευνας
6.	Αμερικανικό περιοδικό φυσιολογίας
7.	Βιοχημεία
8.	Βιοχημικό περιοδικό
9.	Έρευνα εγκεφάλου
10.	Έρευνα για τον καρκίνο
11.	Ιολογία
12.	Επιστολές FEBS
13.	Βακτηριολογία
14.	Αίμα
15.	Ενδοκρινολογία
16.	Κυτταρική βιολογία
17.	Ευρωπαϊκό περιοδικό βιοχημείας / FEBS
18.	Μόλυνση και ανοσία
19.	Μοριακή και κυτταρική βιολογία
20.	Φύση

Ποια 20 περιοδικά αναφέρουν τους περισσότερους όρους GO; Τέλος, ας στραφούμε στα "20 περιοδικά για τον μοριακό βιολόγο", τα οποία εμφανίζονται εν μέρει στον πίνακα 5. Biological chemistry, PNAS, Biochimica et biophysica acta, Immunology, Biochemical and biophysical research communications, American journal of physiology, Biochemistry, Biochemical journal, Brain research, Cancer research, Virology, FEBS letters, Bacteriology, Blood, Endocrinology, Cell biology , Eu- ropean journal of biochemistry, FEBS, Infection and immunity, Molecular and cellular biology και Nature. Άλλα περιοδικά όπως το Science κατατάσσονται στη θέση 32, το EMBO στη θέση 26, το Cell στη θέση 52. Είναι ενδιαφέρον ότι πολλά περιοδικά βιοχημείας κατατάσσονται στις πρώτες θέσεις.

Αυτό δείχνει την υψηλή συνάφεια της επιλογής των περιοδικών. Στην ηλεκτρονική έκδοση ο χρήστης μπορεί να περιηγηθεί σε όλες τις περιλήψεις ενός επιλεγμένου περιοδικού που αναφέρουν έναν προηγουμένως επιλεγμένο όρο GO μέσω του GO.

7.4 Συμπέρασμα

Το GoPubMed αναπτύχθηκε σε πλήρη εφαρμογή στο πλαίσιο του έργου REWERSE. Η διαδικτυακή μηχανή αναζήτησης βρίσκεται σε απευθείας σύνδεση στη διεύθυνση `www.gopubmed.org` από το 2004 και εξυπηρετεί χιλιάδες χρήστες καθημερινά.

Οι συνεισφορές που πραγματοποιήθηκαν κατά τη διάρκεια του έργου REWERSE περιλαμβάνουν μια πλήρη έρευνα σχετικά με τις σύγχρονες μηχανές αναζήτησης βιοϊατρικής. Τα συστήματα κατηγοριοποιήθηκαν ανάλογα με τα χαρακτηριστικά τους που υποστηρίζουν την πληροφορία και τη γνώση

Ανάκτηση. Ένα συμπέρασμα είναι ότι ορισμένα συστήματα επεξεργάζονται σημασιολογικά τα έγγραφα, αλλά κανένα σύστημα δεν χρησιμοποιεί οντολογίες για την οργάνωση των αποτελεσμάτων αναζήτησης.

Μια άλλη συνεισφορά είναι μια έρευνα σε 15 ελεύθερα διαθέσιμα σώματα σχολιασμού. Δεν υπάρχει κανένα σώμα που να μπορεί να εφαρμοστεί άμεσα για την αξιολόγηση αλγορίθμων αναγνώρισης εννοιών για όρους της γονιδιακής οντολογίας. Το σύνολο δεδομένων BioCreAtIvE είναι η καλύτερη πηγή για χειροκίνητα επιβεβαιωμένες σημειώσεις γονιδιακής οντολογίας σε πλήρη κείμενα. Ωστόσο, είναι προκατειλημμένο προς τον σχολιασμό επιλεγμένων πρωτεϊνών.

Στο πλαίσιο των αποτελεσμάτων του REWERSE αναπτύχθηκε ένας νέος αγωγός αναγνώρισης εννοιών(15), ο οποίος βελτίωσε την απόδοση που αναφέρθηκε προηγουμένως (14) κατά 25,7%, επιτυγχάνοντας 79,9% ακρίβεια και 72,7% ανάκληση. Για την πρόσβαση στην ποιότητα του αγωγού και τη διευκόλυνση της περαιτέρω εκπαίδευσης για διφορούμενες ετικέτες οντολογίας σχεδιάστηκε ένα εργαλείο επεξεργασίας. Με αυτά τα εργαλεία δημιουργήθηκε ένα νέο σημείο αναφοράς που αποτελείται από 689 περιλήψεις PubMed και 18.356 επιμελήσεις, προσωπικά επιμελημένες από τους αρχικούς au- thors των άρθρων PubMed.

(15) συνοψίζει επίσης την πρώτη, βασισμένη στην οντολογία, μεγάλης κλίμακας, διαθέσιμη στο διαδίκτυο, επικαιροποιημένη βιβλιομετρική ανάλυση για θέματα μοριακής βιολογίας που αντιπροσωπεύονται από έννοιες της γονιδιακής οντολογίας αξιολογείται. Αποδεικνύεται ότι η μέθοδος συνάδει με τις υπάρχουσες, αλλά συχνά ξεπερασμένες, αναλύσεις.

Οι μέθοδοι που αναπτύχθηκαν κατά τη διάρκεια του έργου REWERSE δεν περιορίζονται στον βιοϊατρικό τομέα. Επί του παρόντος διερευνάται πώς μπορούν να δημιουργηθούν νέες οντολογίες με την επέκταση των διαθέσιμων οντολογιών τομέα ή από το μηδέν. Ο σχεδιασμός οντολογιών είναι μια εργασία εντάσεως εργασίας. Μεγάλο ενδιαφέρον παρουσιάζει ο τρόπος με τον οποίο τα διαθέσιμα σώματα βιβλιογραφίας μπορούν να χρησιμοποιηθούν για τη δημιουργία προτάσεων για ετικέτες εννοιών οντολογίας, συνώνυμα, συντομογραφίες, ορισμούς κειμένου και σχέσεις μεταξύ εννοιών.

Οι επαγόμενες οντολογίες αποτελούν πλούσια πηγή πληροφοριών. Ωστόσο, οι μέθοδοι αναγνώρισης εννοιών δεν μπορούν να είναι τέλειες. Ακόμη και οι ανθρώπινοι ειδικοί διαφωνούν σ ε μεγάλο αριθμό αναφορών εννοιών σε κείμενα φυσικής γλώσσας. Ως εκ τούτου, η επαγόμενη οντολογία θα φέρει πάντα άσχετες πληροφορίες και θα λείπουν κάποιες σχετικές πληροφορίες που κρύβονται στα κείμενα. Η επαναλαμβανόμενη δηλωμένη γνώση αντιπροσωπεύεται καλά στην επαγόμενη οντολογία. Έχει μεγάλο ενδιαφέρον ο τρόπος εντοπισμού υποεκπροσωπούμενης ή νέας γνώσης σε συλλογές εγγράφων. Η δυσκολία εδώ είναι να διακρίνουμε αυτή τη γνώση από το θόρυβο με τη μορφή άσχετων επισημάνσεων.

Αναφορές

[1] Ackoff, R.L.: Από τα δεδομένα στη σοφία. Journal of Applies Systems Analysis 16, 3-9 (1989).

[2] Andreopoulos, B., Alexopoulou, D., Schroeder, M.: Word sense disambiguation

in biomedical ontologies with term co-occurrence analysis and document clustering. Internation Journal of Data Mining and Bioinformatics (2008) (Ειδικό τεύχος για την εξόρυξη κειμένου και την ανάκτηση πληροφοριών).

[3] Apweiler, R., Bairoch, A., Wu, C., Barker, W., Boeckmann, B., Ferro, S., Gasteiger, E., Huang, H., Lopez, R., Magrane, M., Martin, M., Natale, D., ODono- van, C., Redaschi, N., Yeh, L.: UniProt: the universal protein knowledgebase. Nucleic Acids Res. 32(D), D115-D119 (2004).

[4] Ashburner, M., Ball, C.A., Blake, J.A., Botstein, D., Butler, H., Cherry, J.M., Davis, A.P., Dolinski, K., Dwight, S.S., Eppig, J.T., Harris, M.A., Hill, D.P., Issel- Tarver, L., Kasarskis, A., Lewis, S., Matese, J.C., Richardson, J.E., Ringwald, M., Rubin, G.M., Sherlock, G.: Gene ontology: tool for the unification of biology. Η κοινοπραξία γονιδιακής οντολογίας. Nat. Genet. 25(1), 25-29 (2000)

[5] Bellinger, G., Castro, D., Mills, A.: Data, Information, Knowledge, and Wisdom (2004), http://www.systems-thinking.org/dikw/dikw.htm.

[6] Berman, H.M., Westbrook, J., Feng, Z., Gilliland, G., Bhat, T.N., Weissig, H., Shindyalov, I.N., Bourne, P.E.: The protein data bank. Nucleic Acids Res. 28(1), 235-242 (2000).

[7] Blaschke, C., Hirschman, L., Valencia, A.: Εξαγωγή πληροφοριών στη μοριακή βιολογία. Briefings in Bioinformatics 3, 154-165 (2002).

[8] Blaschke, C., Leon, E.A., Krallinger, M., Valencia, A.: Αξιολόγηση της βιοδημιουργικής αξιολόγησης της εργασίας 2. BMC Bioinformatics 6(suppl. 1) (2005).

[9] Boyack, K.: Χαρτογράφηση τομέων γνώσης: PNAS. PNAS 101(1), 5192-5199 (2004).

[10] B¨orner, K., Mary, J., Goldstone, R.: The simultaneous evolution of author and paper networks. PNAS 101(1), 5266-5273 (2004).

[11] Brown, P.O., Botstein, D.: Exploring the new world of the genome with dna microarrays. Nat. Genet. 21(suppl. 1), 33-37 (1999).

[12] Chen, C.: Chen: Αναζητώντας πνευματικά σημεία καμπής: Προοδευτική οπτικοποίηση του τομέα της γνώσης. PNAS 101(1), 5303-5318 (2004)

[13] Chen, H., Sharp, B.M.: Πλούσιο σε περιεχόμενο βιολογικό δίκτυο που κατασκευάζεται με εξόρυξη περιλήψεων PubMed. BMC Bioinformatics 5(1) (Οκτώβριος 2004).

[14] Doms, A.: Χρήση αλγορίθμων ευθυγράμμισης ακολουθιών για την εξαγωγή όρων γονιδιακής οντολογίας σε περιλήψεις βιοϊατρικής βιβλιογραφίας. Διπλωματική εργασία, TU Δρέσδης (2004)

[15] Doms, A.: GoPubMed: αναζήτηση βιβλιογραφίας με βάση την οντολογία για τις επιστήμες της ζωής. Διδακτορική διατριβή, Τεχνικό Πανεπιστήμιο της Δρέσδης (2009).

[16] Doms, A., Schroeder, M.: GoPubMed: εξερεύνηση του PubMed με τη γονιδιακή οντολογία. Nucl. Acids Res. 33, W783-W786 (2005)

[17] Eaton, A.D.: Hubmed: μια διαδικτυακή διεπαφή αναζήτησης βιοϊατρικής βιβλιογραφίας. Nucleic Acids Res. 34(Web Server issue) (Ιούλιος 2006).

[18] Fontelo, P., Liu, F., Leon, S., Anne, A., Ackerman, M.: PICO linguist and BabelMeSH: Development and partial evaluation of evidence-based multilanguage search tools for medline/pubmed. Stud. Health Technol. Inform. 129, 817-821 (2007)

[19] Fontelo, P., Liu, F., Ackerman, M.: Askmedline: ένα εργαλείο ερωτημάτων ελεύθερου κειμένου, φυσικής γλώσσας για το medline/pubmed. BMC Med. Inform. Decis. Mak. 5(1) (Μάρτιος 2005)

[20] Forrey, A.W., McDonald, C.J., DeMoor, G., Huff, S.M., Leavelle, D., Leland, D., Fiers, T., Charles, L., Griffin, B., Stalling, F., Tullis, A., Hutchins, K., Baenziger, J.: Logical observation identifier names and codes (loinc) database: a public use set of codes and names for electronic reporting of clinical laboratory test results. Clin. Chem. 42(1), 81-90 (1996)

[21] Friedman, C., Kra, P., Yu, H., Krauthammer, M., Rzhetsky, A.: GENIES: ένα σύστημα επεξεργασίας φυσικής γλώσσας για την εξαγωγή μοριακών μονοπατιών από άρθρα περιοδικών. In: Proceedings of the International Conference on Intelligent Systems for Molecular Biology, σ. 574-582 (2001).

[22] Fukuda, K., Tamura, A., Tsunoda, T., Takagi, T.: Toward information extraction:

identifying protein names from biological papers. In: Pac. Symp. Biocomput., σ. 707-718 (1998).

[23] Garfield, E., Melino, G.: Η ανάπτυξη του πεδίου του κυτταρικού θανάτου: μια ανάλυση από το δείκτη επιστημονικών παραπομπών isi. Κυτταρικός θάνατος και διαφοροποίηση 4, 352-361 (1997).
[24] Κοινοπραξία γονιδιακής οντολογίας: Η βάση δεδομένων και η πηγή πληροφορικής της Γονιδιακής Οντολογίας (GO). Nucleic Acids Res. 1(32), D258-D261 (2004).
[25] Goetz, T., von der Lieth, C.W.: Pubfinder: ένα εργαλείο για τη βελτίωση του ρυθμού ανάκτησης σχετικών περιλήψεων pubmed. Nucleic Acids Res. 33(Web Server issue) (Ιούλιος 2005).
[26] Gruber, T.R.: Μια μεταφραστική προσέγγιση για φορητές προδιαγραφές οντολογιών. Knowl. Acquis. 5(2), 199-220 (1993)
[27] Guimer, R., Uzzi, B., Spiro, J., Amaral, L.: Οι μηχανισμοί συγκρότησης ομάδων καθορίζουν τη δομή του δικτύου συνεργασίας και την απόδοση της ομάδας. Science 308(5722), 697- 702 (2005)
[28] Hakenberg, J., Plake, C., Royer, L., Strobelt, H., Leser, U., Schroeder, M.: Gene mention normalization and interaction extraction with context models and sentence motifs. Genome Biology 9(suppl. 2) (2008).
[29] Hamosh, A., Scott, A.F., Amberger, J., Bocchini, C., Valle, D., McKusick, V.A.: Online mendelian inheritance in man (omim), a knowledgebase of human genes and genetic disorders. Nucleic Acids Res. 30(1), 52-55 (2002).
[30] Hersh, W., Cohen, A.M., Roberts, P., Rekapalli, H.K.: Overview of the TREC 2006 question answering track. In: (TREC 2006) Πρακτικά (2006).
[31] Hirschman, L., Colosimo, M., Morgan, A., Yeh, A.: Επισκόπηση της εργασίας 1β του BioCreAtIvE: κανονικοποιημένες λίστες γονιδίων. BMC Bioinformatics 6(1), S11 (2005).
[32] Hoffmann, R., Valencia, A.: Ένα δίκτυο γονιδίων για την πλοήγηση στη βιβλιογραφία. Nature Genetics 36, 664 (2004)
[33] Hoffmann, R., Valencia, A.: Ένα δίκτυο γονιδίων για την πλοήγηση στη βιβλιογραφία. Nat. Genet. 36(7) (2004)
[34] Jenssen, T.K., Laegreid, A., Komorowski, J., Hovig, E.: Ένα βιβλιογραφικό δίκτυο ανθρώπινων γονιδίων για ανάλυση γονιδιακής έκφρασης υψηλής απόδοσης. Nat. Genet. 28(1), 21-28 (2001)
[35] Joachims, T.: Πιθανολογική ανάλυση του αλγορίθμου rocchio με tfidf για κατηγοριοποίηση κειμένων. In: Fisher, D.H. (ed.) Proceedings of ICML 1997, 14th Interna- tional Conference on Machine Learning, Nashville, US, pp. 143-151. Morgan Kauf- mann Publishers, San Francisco (1997).
[36] Kaenel, I.d., Iriarte, P.: Εναλλακτικές διεπαφές για αναζητήσεις στο PubMed. In: Βιβλιοθήκες Υγείας (2006).
[37] Koster, J.: PubMed Pubreminer: ένα εργαλείο για τη δημιουργία ερωτημάτων PubMed και την εξόρυξη βιβλιογραφίας (2007)
[38] Lambrix, P., Tan, H., Jakoniene, V., Str¨omb¨ack, L.: Biological Ontologies, σσ. 85-99. Springer, Heidelberg (2007)
[39] Law, S., Jerzy, O., Dawid, S.: Lingo: (2004)
[40] Lowe, H.J., Barnett, G.O.: (mesh) για την εκτέλεση βιβλιογραφικών αναζητήσεων. JAMA 271(14), 1103-1108 (1994).
[41] Mu¨ller, H.M., Kenny, E.E., Sternberg, P.W.: Textpresso: An ontology-based information retrieval and extraction system for biological literature. PLoS Biol- ogy 2(11) (2003).
[42] Muin, M., Fontelo, P.: PubMed interact: βελτιωμένη διεπαφή για αναζητήσεις Medline/PubMed. BMC Medical Informatics and Decision Making 6, 36+ (2006).

[43] Newman, M.: Η δομή των δικτύων επιστημονικής συνεργασίας. PNAS 98(2), 404- 409 (2001).
[44] Newman, M.: Δίκτυα συν-συγγραφής και πρότυπα επιστημονικής συνεργασίας. PNAS 101(1), 5200-5205 (2004)
[45] Patrick, J., Wang, Y., Budd, P.: Ένα αυτοματοποιημένο σύστημα για τη μετατροπή κλινικών σημειώσεων σε κλινική ορολογία snomed. In: ACSW 2007: Proceedings of the fifth Australasian symposium on ACSW frontiers, Darlinghurst, Australia, pp. 219-
226. Australian Computer Society, Inc., Αυστραλία (2007)
[46] Perez-Iratxeta, C., Perez, A., Bork, P., Andrade, M.: Ενημέρωση για το XplorMed: Ένας διακομιστής ιστού για την εξερεύνηση της επιστημονικής βιβλιογραφίας. Nucleic Acids Res. 31(13), 3866-3868 (2003).
[47] Plake, C., Schiemann, T., Pankalla, M., Hakenberg, J., Leser, U.: ALIBABA: PubMed ως γράφημα. Βιοπληροφορική 22(19), 2444 (2006).
[48] Plikus, M.V., Zhang, Z., Chuong, C.M.: Pubfocus: Σημασιολογική ανάλυση παραπομπών medline/pubmed μέσω ενσωμάτωσης ελεγχόμενων βιοϊατρικών λεξικών και αλγορίθμου κατάταξης. BMC Bioinformatics 7, 424 (2006).
[49] Price, D.: Δίκτυα επιστημονικών εργασιών. Science 30(149), 510-515 (1965)
[50] Quackenbush, J.: Γονιδιωματική. μικροσυστοιχίες - ενοχή από συσχέτιση. Science 302(5643), 240-241 (2003)
[51] Rebholz-Schuhmann, D., Arregui, M., Gaudan, S., Kirsch, H., Jimeno, A.: Text processing through web services: calling whatizit. Βιοπληροφορική 24(2), 296-298 (2008).
[52] Rebholz-Schuhmann, D., Kirsch, H., Arregui, M., Gaudan, S., Riethoven, M., Stoehr, P.: EBIMed-text crunching to gather facts for proteins from medline. Bioinformatics 23(2), e237-e244 (2007).
[53] Sharma, N.: The origin of the data information knowledge wisdom hierarchy (Φεβρουάριος 2008) (αδημοσίευτο)
[54] Siadaty, M.S., Shu, J., Knaus, W.A.: Relemed: για τη βάση δεδομένων βιοϊατρικών άρθρων medline. BMC Medical Informatics and Decision Making 7, 1+ (2007).
[55] Smith, T., Cleary, J.: Αυτόματη σύνδεση των περιλήψεων της medline με τη γονιδιολογία. In: Bio-Ontologies Meeting, Brisbane, Αυστραλία (2003).
[56] Taylor, D.P.: Taylor: An integrated biomedical knowledge extraction and analysis plat- form: using federated search and document clustering technology. Methods Mol. Biol. 356, 293-300 (2006).
[57] Thomas, J., Milward, D., Ouzounis, C., Pulman, S., Carroll, M.: Automatic extraction of protein interactions from scientific abstracts. In: Proc. of the Pacific Symp. on Biocomputing, σ. 538-549 (2002).
[58] Tyers, M., Mann, M.: Mann: From genomics to proteomics. Nature (London) 422, 193- 197 (2003)
[59] Yao, Y., Zeng, Y., Zhong, N., Huang, X.: Αναζήτηση γνώσης (KR). In: IEEE/WIC/ACM International Conference on Web Intelligence (2007).
[60] Yeh, A., Morgan, A., Colosimo, M., Hirschman, L.: BioCreAtIvE task 1a: αξιολόγηση εύρεσης αναφορών γονιδίων. BMC Bioinformatics 6(1), S2 (2005).