ΕΙΣΑΓΩΓΉ

Από το 1996 υπολογίζεται ότι έχουν δημοσιευθεί πάνω από 64 εκατομμύρια επιστημονικά άρθρα. Μόνο το 2022 έχουν δημοσιοποιηθεί 5.14 εκατομμύρια άρθρα συμπεριλαμβανομένων σύντομων ερευνών, ανασκοπήσεων και πρακτικών συνεδρίων [1] . Ερευνητές, φοιτητές και επαγγελματίες που δραστηριοποιούνται σε επιστημονικούς τομείς δεν είναι απαραίτητο ότι γνωρίζουν όλη την ορολογία του ερευνητικού πεδίου. […]. Ο τεράστιος αυτός όγκος δεδομένων απαιτεί την ανάπτυξη εξελιγμένων μηχανών αναζήτησης που ανακτούν την πληροφορία με σημασιολογικό χαρακτήρα [what??]. Ο στόχος ανάπτυξης σημασιολογικής μηχανής αναζήτησης άρθρων μπορεί να αυξήσει την ακρίβεια των πληροφοριών που εξάγονται και παράλληλα να μειώσει σημαντικά τον χρόνο αναζήτησης και εργασίας της επιστημονικής έρευνας. Η αναζήτηση μπορεί να αφορά σε διαφορετικό κομμάτι ενός άρθρου και η Πληροφορία να βρίσκεται σε οποιοδήποτε σημείο.

Ένα επιστημονικό άρθρο μπορεί να αποτελείται από επικεφαλίδες, παραγράφους, σχήματα, πίνακες και γραφήματα, μαθηματικές εξισώσεις και αλγορίθμους και βιβλιογραφία. Οι επικεφαλίδες περιέχουν τον τίτλο του άρθρου, τους συγγραφείς, το επιστημονικό συνέδριο ή και περιοδικού στο οποίο δημοσιεύεται, τις ιδιότητες των προαναφερόμενων, την περίληψη, την λίστα των περιεχομένων και των σελίδων. Οι παράγραφοι αποτελούν το κυρίως κείμενο με την ολοκληρωμένη ανάλυση του θέματος. Τα σχήματα παρουσιάζουν τα δεδομένα σε συνάρτηση μιας ορισμένης παραμέτρου, οι πίνακες βοηθούν στην παρουσίαση δομημένων δεδομένων, οι μαθηματικές εξισώσεις παρουσιάζουν την μαθηματική έκφραση του προβλήματος πάνω στο θέμα, οι αλγόριθμοι (συχνά σε μορφή ψευδοκώδικα) παρουσιάζουν έναν τρόπο επίλυσης ενος υπολογιστικού προβλήματος. Τέλος, η βιβλιογραφία περιέχει όλες τις πηγές, τις αναφορές και τις σημειώσεις του βασικού κειμένου. Επομένως, όλα τα παραπάνω μέρη πρέπει να

Στην παρούσα διπλωματική εργασία, προτείνουμε την ανάπτυξη ενός έξυπνου αποθετηρίου για την σημασιολογική περιγραφή και αναζήτηση επιστημονικών άρθρων στο διαδίκτυο.

RELATED WORK

Οι ειδικοί όροι στο τομέα του Σημασιολογικού Ιστού παίζουν κρίσιμο ρόλο στην κατανόηση και στην ανάπτυξη προηγμένων εφαρμογών στα πληροφοριακά συστήματα.

Η Σημασιολογική Αναζήτηση είναι μέρος της ευρύτερης έννοιας του Σημασιολογικού Ιστού (Semantic Web). Ο σημασιολογικός ιστός είναι η επέκταση του Παγκόσμιου Ιστού (World Wide Web) και ορίστηκε από τον Οργανισμό του Παγκόσμιου Ιστού (W3C) με στόχο να μην διαδίδεται απλώς η Πληροφορία αλλά να αντιλαμβάνεται και να διαδίδεται το νόημα του “περιεχομένου”. Η Σημασιολογική Αναζήτηση δίνει την δυνατότητα να πραγματοποιούνται αναζητήσεις με βάση το νόημα των δεδομένων και όχι με την απλή αλληλουχία των λέξεων (keyword search).

Το μοντέλο δεδομένων του Σημασιολογικού Ιστού είναι το RDF (Resource Description Framework - Πλαίσιο Περιγραφής Πόρων) και προσφέρει μια ευέλικτη και αφηρημένη δομή στην απεικόνιση των δεδομένων. Το RDF έχει την μορφή τριπτύχου. Ένα τριπτυχο αποτελείται από Υποκείμενο –Προκείμενο – Αντικείμενο και κάθε πτυχή έχει ένα μοναδικό αναγνωριστικό (URI). Πιο συγκεκριμένα, το υποκείμενο είναι το αναγνωριστικο του πόρου για το οποίο έχουμε κάνει την δήλωση, το προκείμενο είναι ο χαρακτηρισμός ή η ιδιότητα του υποκειμένου και το αντικείμενο είναι η τιμή της ιδιότητας. Για παράδειγμα, έχουμε την πολύ απλή πρόταση "Ο Τσαρλς μένει στην Νέα Υόρκη". Το υποκείμενο της πρότασης θα είναι το URI του Τσαρλς, το προκείμενο θα είναι ο χαρακτηρισμός το URI του "μένει" και το αντικείμενο ως η τιμή του χαρακτηρισμού είναι το URI της "Νέας Υόρκης"

Η σύνδεση πολλών RDF μεταξύ τους δημιουργεί την απεικόνιση του όρου των Συνδεδεμένων Δεδομένων (Linked Data) και διευκολύνουν την δημιουργία ενός ψηφιακού γράφου. Με αυτό δίνεται η δυνατότητα να αναζητηθεί εύκολα η πρόσβαση στην Πληροφορία που μπορεί ακόμα να βρίσκεται χωρισμένη και σε διαφορετικές πηγές.

Ως μοντέλο δεδομένων, το RDF είναι αφηρημένο. Η δημοφιλέστερη τυποποιημένη αναπαράσταση των τριπτύχων RDF γίνεται με την XML. Η σύνταξη με την XML καθιστά εύκολη την κατανόηση της δομής των δεδομένων όχι μόνο από υπολογιστικά μηνύματα αλλα και από άνθρωπο. [εδώ ίσως χρειάζεται κάποιο παράδειγμα]. Ωστόσο, οι δηλώσεις των μεταβλητών στα τρίπτυχα των RDF δεν μπορούν να είναι αυθαίρετες. Χρειάζεται να υπάρχουν συγκεκριμένοι κανόνες λεξιλογίου για την πραγματική αναπαράσταση της Πληροφορίας.

Οι οντολογίες και η γλώσσα οντολογίας ιστου OWL αποτελούν κεντρικά στοιχεία στην αρχιτεκτονική και την λειτουργία του σημασιολογικού ιστου, επιτρέποντας στην κατανόηση και επεξεργασία δεδομένων από τον υπολογιστή[...]

Υπάρχουν 3 τύποι οντολογιών και χωρίζονται με βάση τον βαθμό της εννοιολογικής προσέγγισης. Οι τύποι αυτοί είναι η Οντολογία Ανωτάτου Επιπέδου (Top-level Ontology), Οντολογία Τομέα (Domain Ontology) και Οντολογία Εφαρμογής (Application Ontology) [2]. Κάθε τύπος οντολογίας έχει διαφορετικό εύρος Πληροφορίας. Η Οντολογία Ανωτάτου Επιπέδου απεικονίζει πολύ γενικές έννοιες που είναι ανεξάρτητες από κάποιο τομέα. Η συγκεκριμένη οντολογία έχει εφαρμογή σε όλους τους τομείς και το λεξιλόγιο περιέχει κυρίως χρονικές και χωρικές έννοιες. Έπειτα, η Οντολογία Τομέα αναπαριστά δεδομένα σε έναν συγκεκριμένο τομέα και περιέχει λεξιλόγια σχετικα με τις έννοιες και τις σχέσεις τους. Αυτός ο τύπος οντολογίας σχεδιάζεται να ταιριάζει οχι μονο στις ανάγκες της εκάστοτε κοινότητας που δραστηριοποιειται στον συγκεκριμένο τομέα, αλλά περιέχει και εννοιολογικές δομές που μπορούν να διαδοθούν σε διαφορετικές κοινότητες. Αυτο συνεπάγεται οι προγραμματιστές να μην χρειάζεται να αναπτύξουν νέες οντολογιες απο το μηδέν αλλά να χρησιμοποιούν όρους αναφορικά από ήδη υπάρχοντες οντολογίες με ορισμένες τροποποιήσεις. Τέλος,η Οντολογία Εφαρμογών αναφέρεται σε κομμάτια γνώσης που εξαρτώνται τόσο από έναν συγκεκριμένο τομέα όσο και από μια εργασία. Ως εκ τούτου, σχετίζεται με τις μεθόδους επίλυσης προβλημάτων και παρέχει μια ελάχιστη δομή ορολογλιών για να ταιριάζει στις ανάγκες ενός συγκεκριμένου τομέα και μιας κοινότητας, η οποία την

καθιστούν πολύ συγκεκριμένη. Ως εκ τούτου, δεν μπορεί να μοιραστεί ή να χρησιμοποιηθεί από άλλη κοινότητα.

Οι Οντολογίες είναι δομημένες συλλογές εννοιών και κλάσεων που καθορίζουν την σημασία και των τρόπο ερμηνείας των δεδομένων. Ορίζουν επιπλέον χαρακτηριστικά και ιδιότητες των κλάσεων και καθιερώνει τις σχέσεις μεταξύ των εννοιών. Η σημασία της Πληροφορίας που παράγεται την καθιστά κατανοητή για τον υπολογιστή. Κάθε επιστημονικός τομέας έχει την δική του Οντολογία, όπως για παράδειγμα η Ιατρική και η Μηχανολογία. Οι οντολογίες αποτελούν το θεμέλιο του Σημασιολογικού Ιστου και επιτρέπουν στις εφαρμογές να κατανοούν και να ανταλλάσουν δεδομένα με περισσότερο αποδοτικους αλγορίθμους.

Η OWL είναι γλώσσα οντολογίας ιστου του W3C είναι η γλώσσα που δημιουργεί και αναπαριστά τις Οντολογίες. Επιτρέπει την δημιουργία λεπτομεριακών στοιχείων RDF. Μέσω της OWL μπορούν να οριστούν πολύπλοκες σχέσεις μεταξύ πόρων, να οριστούν κλάσεις και υποκλάσεις να κατηγοριοποιηθούν σε αυτές, να εφαρμοστούν περιορισμοί, όπως περιορισμοί στις τιμές των ιδιοτήτων, και να οριστούν κανόνες για την κατανόηση και την επεξεργασία δεδομένων.Η OWL βοηθά έτσι στην ανάπτυξη εξειδικευμένων, πλήρως αυτοματοποιημένων συστημάτων που μπορούν να κατανοούν και να διαχειρίζονται δεδομένα με πολύπλοκες σχέσεις και σημασιολογία. [W3C]

Η γλώσσα SPARQL είναι γλώσσα ερωτημάτων (queries) που χρησιμοποιείται για την ανάκτηση της πληροφορίας απο τα αποθηκευμένα σύνολα δεδομένων RDF. Είναι ειδικά σχεδιασμένη γλώσσα για να επεξεργάζεται σημασιολογικά δεδομένα. Η SPARQL υποστηρίζει πολλές ευέλικτες δυνατότητες για την ανάκτηση της πληροφορίας, με την αναζήτηση των RDF να γίνεται με συγκεκριμένα κριτήρια όπως περιορισμούς (WHERE), ταξινόμηση (ORDER BY), κατηγοριοποιηση (GROUP BY). [W3C]

Η βασική δομή ενός SPARQL περιέχει 2 όρους, την SELECT και την WHERE. Ο όρος Select με επιλεγμένη μια ή πολλές μεταβλητές αφορά στο ποια είναι η πληροφορία που χρειάζεται να αναζητηθεί και να ανατεθεί σε αυτήν ή αυτές μεταβλητη και ο όρος Where αφορά στον περιορισμό που χρειάζεται να αναζητηθεί η πληροφορία. Επιπλέον, για τον καλύτερο περιορισμό στην ανάκτηση της πληροφορίας μπορουν να χρησιμοποιηθούν επιπλέον οι όροι Filter, LIMIT, OFFSET, ORDER BY και να προστεθούν στο τέλος της βασικής δομης ενός SPARQL query. Άλλοι όροι που μπορούν να χρησιμοποιηθούν συνδυαστικά με την SELECT είναι οι COUNT και SUM που ανακτουν πληροφορίες σχετικά με τον αριθμό και το άθροισμα των αποτελεσμάτων αντίστοιχα.

ΠΗΓΕΣ

[1] https://wordsrated.com/number-of-academic-papers-published-per-year/

[2] Awny Sayed, Amal Al MuqrishiIBRI-CASONTO: Ontology-based semantic search engine, Egyptian Informatics Journal, 2017